CS2 AI COACHING SYSTEM

Ultimate CS2 Coach

Parte 2 — Servizi, Analisi e Database

Coaching Services, Knowledge & Retrieval, Analysis Engines, Database Schema, Training Pipeline

Autore: Renan Augusto Macena

Marzo 2026

5. Sottosistema 3 — Servizi di Coaching

https://github.com/renanaugustomacena-ux/Counter-Strike-coach-AI **cartella nella repo:** `backend/services/` **File:** `coaching_service.py`, `ollama_writer.py`, `analysis_orchestrator.py`

Questo sottosistema è il **centro decisionale**: prende tutto ciò che le reti neurali e i sistemi di conoscenza hanno prodotto e lo sintetizza in veri e propri consigli di coaching per il giocatore.

> **Analogia:** Se il nucleo della rete neurale (Sezione 3) è il cervello e il coach RAP (Sezione 4) è il medico specialista, allora il sottosistema dei Servizi di Coaching è la **receptionist e la reception** dell'ospedale. Prende i referti del medico, le note dell'infermiere e i risultati di laboratorio e li trasforma in un rapporto chiaro per il paziente. Ha anche un piano di riserva per ogni scenario: se lo specialista non è disponibile, ti indirizza a un medico di base; se il medico di base è assente, ti consegna un opuscolo; e se tutto il resto fallisce, almeno ti fornisce i tuoi parametri vitali di base. Il paziente (giocatore) se ne va SEMPRE con qualcosa di utile, mai a mani vuote.

-CoachingService (`coaching_service.py`)

Il **motore di sintesi centrale** che implementa una **catena di fallback di coaching a 4 livelli** con degradazione graduale:

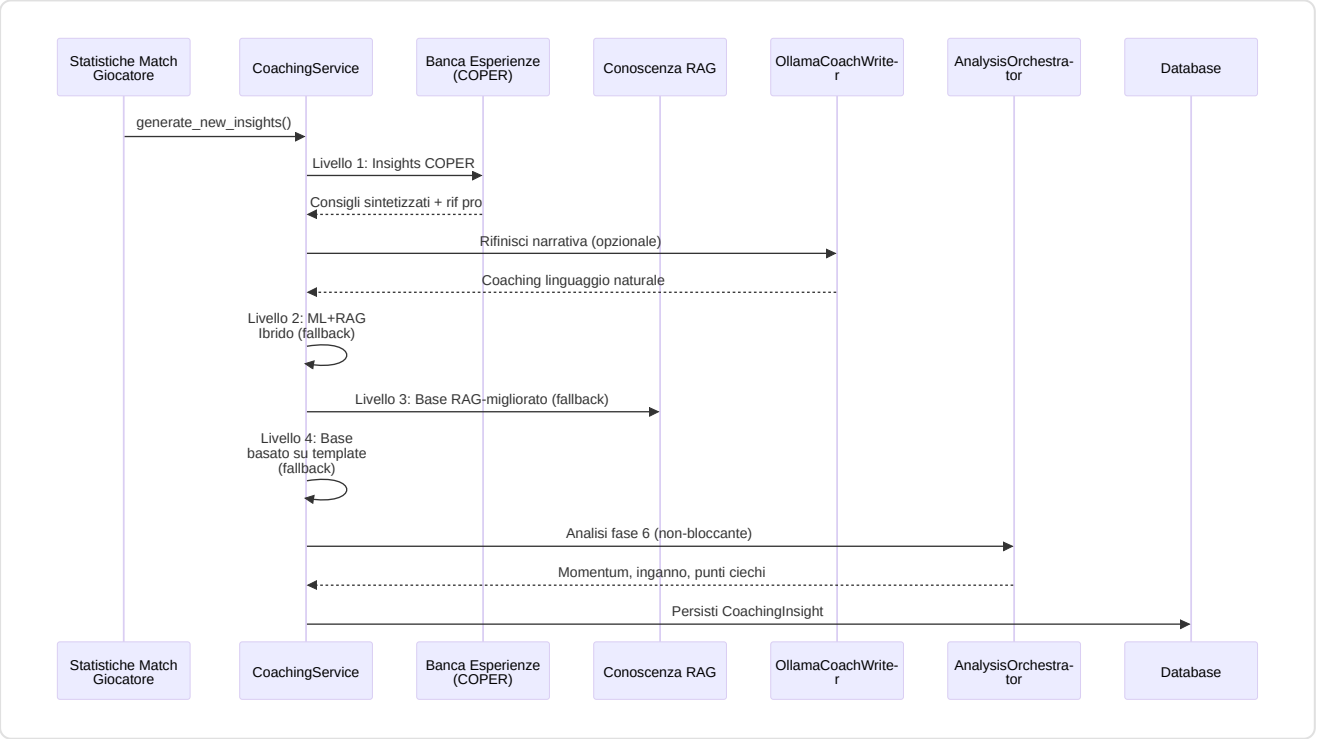

Spiegazione Diagramma: Segui le frecce dall'alto verso il basso: questo è il "processo di pensiero" dell'allenatore in ordine: (1) Arrivano i dati della partita. (2) L'allenatore chiede prima all'Experience Bank: "Abbiamo già visto questa situazione? Cosa ha funzionato?". (3) Se la risposta sembra troppo robotica, la invia facoltativamente a Ollama (un programmatore di intelligenza artificiale locale) per renderla più naturale. (4) Se l'Experience Bank non dispone di dati sufficienti, ricorre alla modalità ibrida (previsioni ML + conoscenza RAG combinate). (5) Se anche i modelli ML non sono disponibili, ricorre solo a RAG (cercando suggerimenti pertinenti). (6) Se anche RAG fallisce, utilizza semplici modelli statistici ("Il tuo rapporto K/D è 0,8, sotto la media"). (7) Nel frattempo, in background, 7 motori di analisi eseguono indagini speciali attraverso 5 pipeline (momentum, inganno, entropia, strategia+punti ciechi, distanza ingaggio). (8) Tutto viene salvato nel database per riferimento futuro.

Catena di fallback a 4 livelli:

Livello	Metodo	Fiducia	Quando utilizzato
1.**COPER**	`_generate_coper_insights()`	Massima	Predefinita — sintesi basata sull'esperienza
2.**Ibrido**	`_generate_hybrid_insights()`	Alta	Se COPER non ha esperienza sufficiente
3.**RAG Base**	`_enhance_with_rag()`	Media	Se i modelli ML non sono disponibili
4.**Template**	Modello statistico di base	Bassa	Ultima risorsa — restituisce sempre*qualcosa*

Analogia: Il fallback a 4 livelli è come **ordinare del cibo al ristorante**. Il Livello 1 (COPER) è la specialità dello chef: il piatto migliore e più personalizzato, creato in base all'esperienza. Il Livello 2 (Ibrido) è il menu standard: ottimo cibo, ma non così personalizzato. Il Livello 3 (RAG Base) è il menu per bambini: più semplice, ma comunque nutriente. Il Livello 4 (Modello) è pane e acqua: base, ma non uscirai mai affamato. La garanzia principale è: **il giocatore riceve sempre consigli di allenamento**, qualunque cosa accada. Il sistema non ti dice mai "Mi dispiace, non ho niente per te".

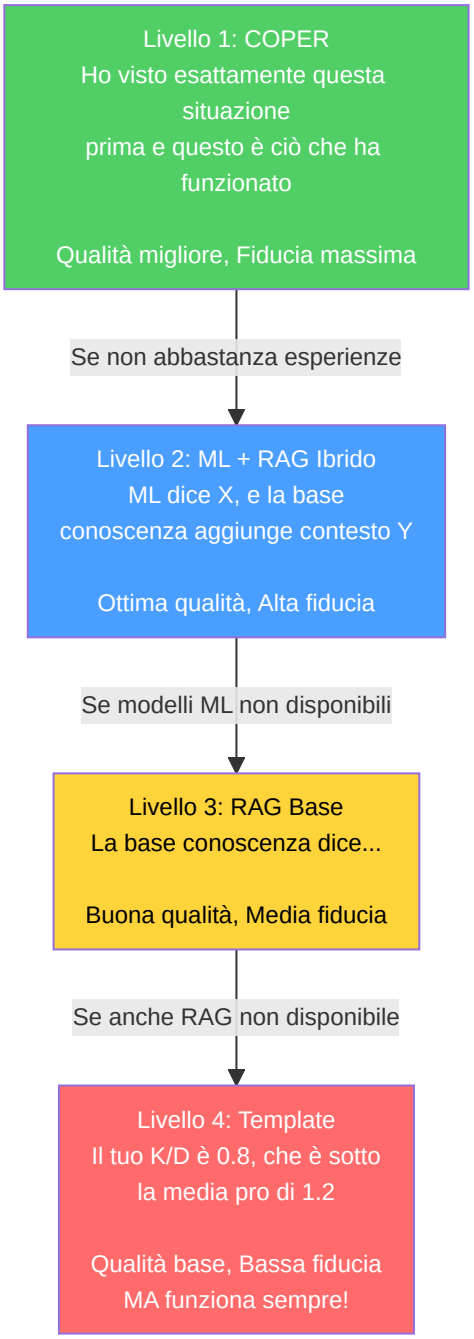

Progettazione chiave: Non restituisce mai zero insight. L'analisi di Fase 6 è non bloccante (incapsulata in try-catch, registrata in modo non fatale).

> **Correzione G-08 (Coaching Fallback):** In precedenza, il metodo `_generate_coper_insights()` non riceveva i parametri `deviations` e `rounds_played` dal chiamante, causando un fallback silenzioso ai template di base. Dopo la rimediazione, `generate_new_insights()` ora passa esplicitamente entrambi i parametri (`deviations=deviations, rounds_played=rounds_played`) al handler COPER, garantendo che il Livello 1 COPER possa generare insight contestuali basati sulle deviazioni statistiche reali del giocatore rispetto alla baseline pro. Senza questa correzione, il sistema avrebbe sempre degradato al Livello 4 (template) anche quando i dati COPER erano disponibili.

Arricchimento della baseline temporale (Proposta 11): Il servizio di coaching ora integra confronti pro ponderati nel tempo tramite due nuovi metodi:

- `_get_temporal_baseline(map_name)` — recupera una baseline pro ponderata in base a `TemporalBaselineDecay` (emivita = 90 giorni) invece di medie statiche
- `_baseline_context_note(deviations, map_name)` — genera una descrizione in linguaggio naturale ("In base ai dati pro recenti ponderati in base alla recenza, il tuo ADR è inferiore del 12% rispetto alla meta media attuale su de_mirage") per l'arricchimento COPER

Questo garantisce che gli insight di coaching riflettano la **meta media attuale** anziché medie storiche obsolete. Se i dati temporali non sono sufficienti (< 10 schede statistiche), il servizio ricorre alla funzione legacy `get_pro_baseline()` in modo trasparente.

> **Analogia:** In precedenza, l'allenatore ti confrontava con un'**istantanea** di statistiche professionali di mesi fa. Ora utilizza una **media in tempo reale e aggiornata** in cui le prestazioni professionali recenti contano più di quelle vecchie, come una valutazione su una curva in cui i punteggi dei test della settimana scorsa contano più di quelli dell'anno scorso. Se la media della classe in "ADR" è aumentata questo mese, lo vedrai immediatamente riflesso nei tuoi consigli di allenamento.

Inferenza della fase del round (`_infer_round_phase`): Valore dell'attrezzatura → classificazione della fase del round:

Valore dell'attrezzatura	Fase del round
< $1.500	`pistol`
$1.500 – $2.999	`eco`
$ 3.000 – $ 3.999	`force`
≥ $ 4.000	`full_buy`

Classificazione dell'intervallo di salute (`_health_to_range`): Utilizzato per l'hashing del contesto COPER: `"full"` (≥80), `"damaged"` (40–79), `"critical"` (<40).

-OllamaCoachWriter (`ollama_writer.py`)

Trasforma le informazioni di coaching strutturate in linguaggio naturale tramite LLM locale (Ollama).

- **Singleton** tramite factory `get_ollama_writer()`
- **Funzionalità contrassegnata:** impostazione `USE_OLLAMA_COACHING` (predefinita: False)
- **Degradazione graduale:** restituisce il testo originale se Ollama non è disponibile
- **Prompt di sistema:** tono da esperto di coaching CS2, <100 parole, fattibile, incoraggiante

> **Analogia:** OllamaCoachWriter è come un **traduttore** che prende statistiche aride e le trasforma in consigli motivanti. Senza di esso, l'allenatore potrebbe dire: "deviazione media: -0,07, punteggio z: -1,4, categoria: meccanica". Con questo, l'allenatore dice: "La tua percentuale di tiri alla testa è leggermente inferiore alla media dei professionisti. Prova a concentrarti sul posizionamento del mirino: tienilo all'altezza della testa in curva". Esegue un modello di intelligenza artificiale locale (Ollama) sul tuo computer: non serve internet, né dati vengono inviati al cloud. Se Ollama non è installato, il sistema utilizza semplicemente il testo originale: nessun crash, nessun errore, solo una formulazione leggermente meno curata.

-AnalysisOrchestrator (`analysis_orchestrator.py`)

Sintetizza l'analisi avanzata di Fase 6 istanziando 7 motori e orchestrando 5 pipeline di analisi:

Input: Dati di tick della partita, eventi, statistiche dei giocatori **Output:** `MatchAnalysis` con oggetti `RoundAnalysis` per round contenenti:

- `momentum_score` (tilt/striscia vincente)
- `deception_score` (sofisticatezza tattica)
- `utility_entropy` (misurazione dell'efficacia)
- `blind_spots` (lacune strategiche)
- `strategy_rec` (raccomandazione dell'albero di gioco)
- `engagement_range` (analisi distanza di ingaggio)

Motori istanziati: `belief_estimator`, `deception_analyzer`, `momentum_tracker`, `entropy_analyzer`, `game_tree`, `blind_spot_detector`, `engagement_analyzer` (7 motori). Il `belief_estimator` è istanziato ma attualmente non invocato direttamente come pipeline separata.

Analogia: AnalysisOrchestrator è come una **squadra di 7 detective specializzati**, ognuno dei quali indaga su un aspetto diverso del tuo gameplay. *Detective Momentum* verifica se sei in una fase di successo o in difficoltà. *Detective Deception* verifica se sei prevedibile o subdolo. *Detective Entropy* verifica se la tua utilità (granate) è efficace. *Detective Blind Spots* verifica se continui a commettere lo stesso errore. *Detective Strategy* verifica se stai prendendo le decisioni giuste. *Detective Death Probability* verifica quanto sono rischiose le tue posizioni. *Detective Engagement Range* verifica a quali distanze combatti meglio. Tutti questi controlli funzionano in background (non bloccanti), quindi anche se un detective fallisce, gli altri segnalano comunque le loro scoperte.

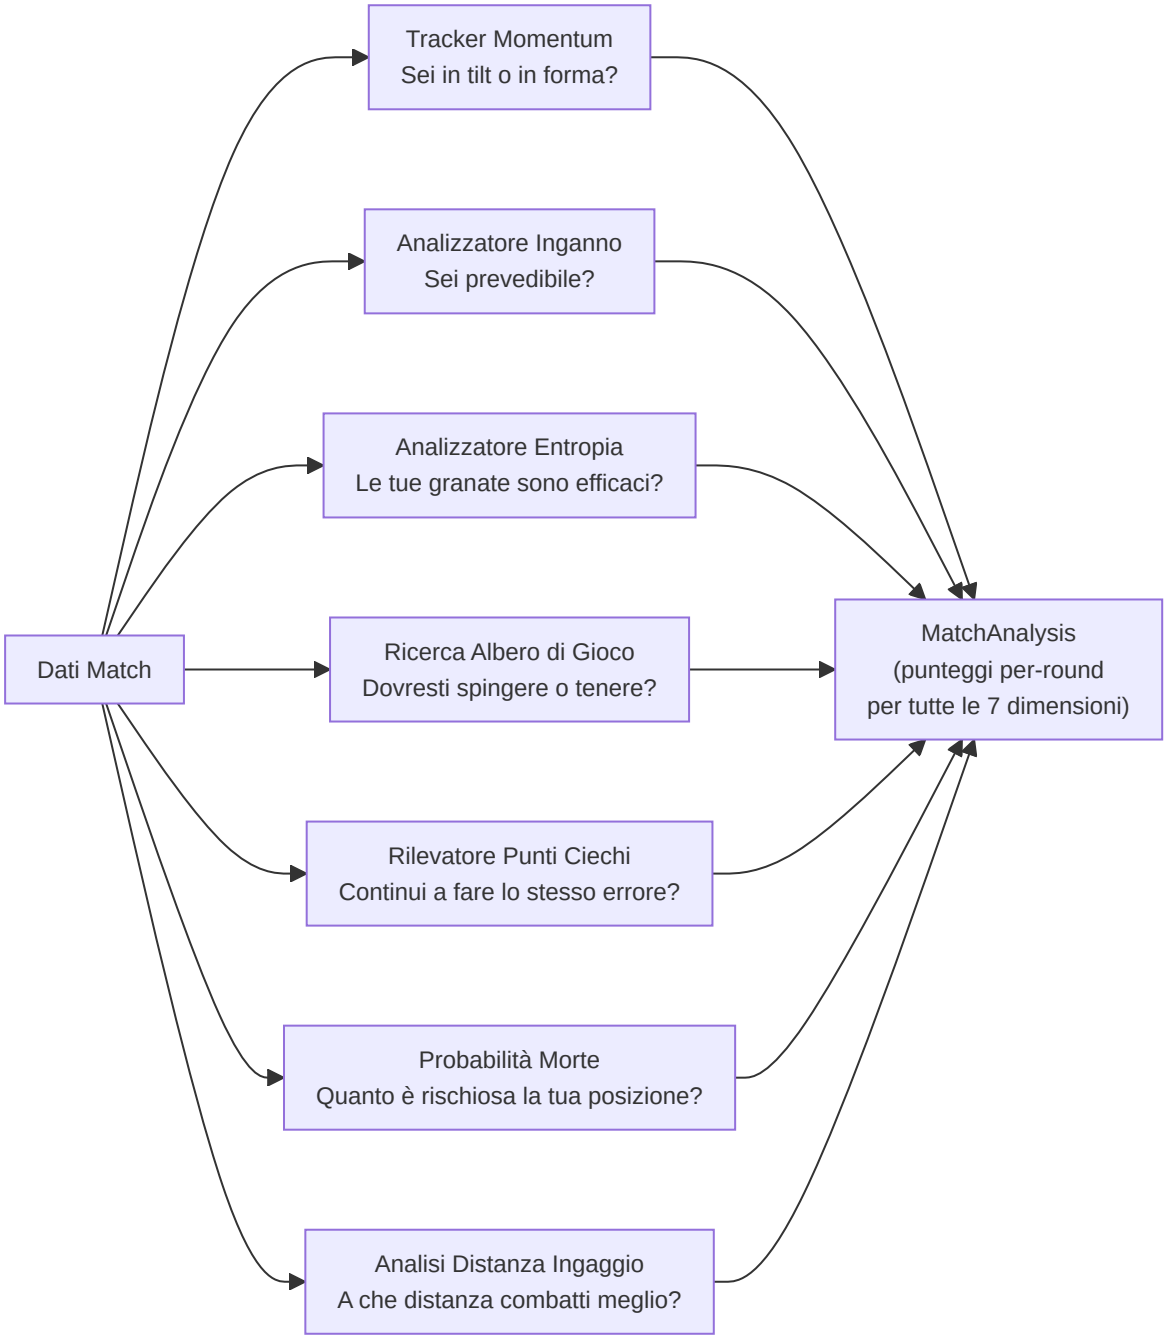

-Servizi Aggiuntivi (Non documentati in precedenza)

Oltre ai tre servizi principali (CoachingService, OllamaCoachWriter, AnalysisOrchestrator), la directory `backend/services/` contiene **7 servizi aggiuntivi** che completano l'ecosistema di coaching:

> **Analogia:** Se CoachingService è il **direttore dell'ospedale**, i servizi aggiuntivi sono i **reparti specializzati**: c'è il reparto di dialogo (coaching interattivo), il reparto lezioni (formazione strutturata), il laboratorio linguistico (LLM), il reparto imaging (visualizzazioni), l'anagrafe (profili), il reparto analisi (coordinamento) e il sistema di telemetria (monitoraggio remoto).

CoachingDialogueEngine (`coaching_dialogue.py`, 373 righe)

Motore di dialogo multi-turno con augmentazione RAG e Experience Bank. Evolve il single-shot OllamaCoachWriter in una **sessione interattiva** dove i giocatori possono fare domande follow-up sulle loro prestazioni.

Componente	Dettaglio
Classificazione intent	Keyword-based: 4 categorie (positioning, utility, economy, aim) + general fallback
Contesto sliding window	`MAX_CONTEXT_TURNS = 6` (12 messaggi: 6 user + 6 assistant)
Retrieval augmentation	RAG top-3 + Experience Bank top-3, iniettati nel messaggio utente
Fallback offline	Template-based con RAG-only quando Ollama non è disponibile
Singleton	`get_dialogue_engine()` — factory module-level

Pipeline di risposta:

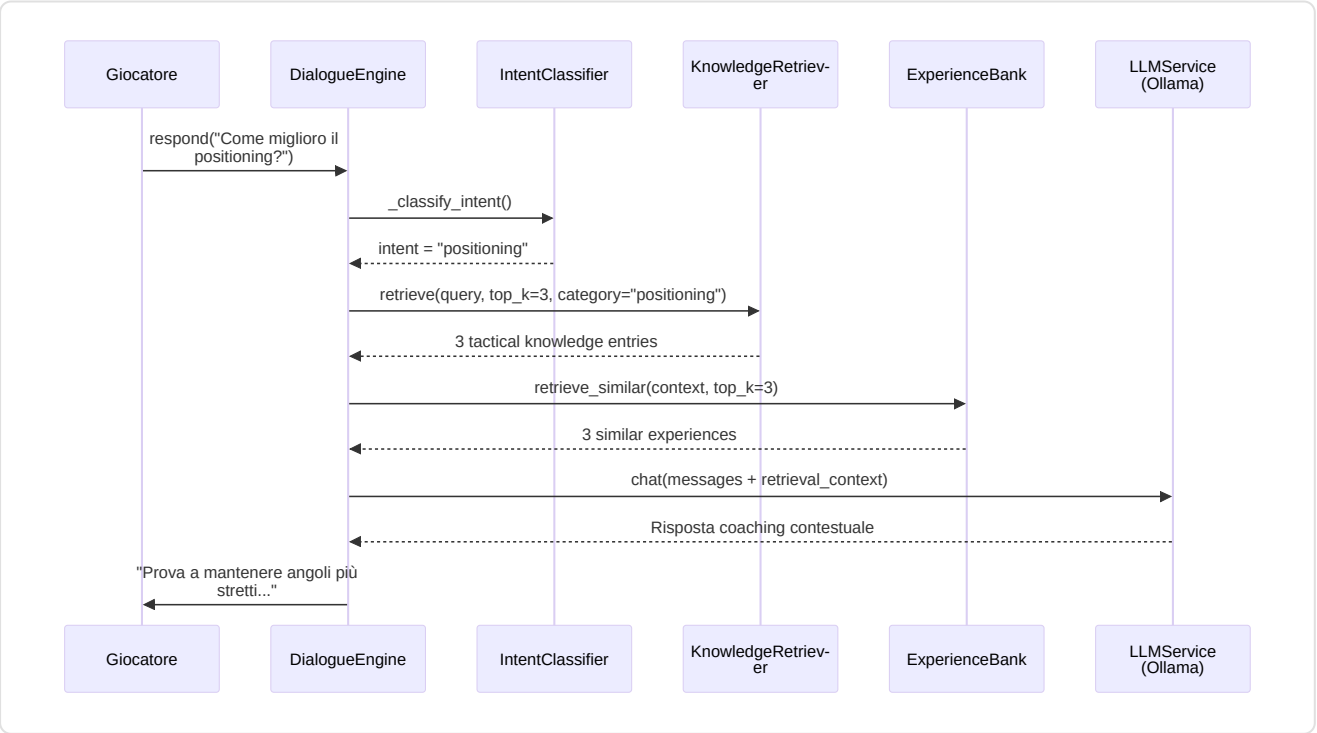

Gestione sessione: `start_session(player_name, demo_name)` → carica contesto dal DB (ultimi 5 insight, area focus primaria) → genera messaggio di apertura via LLM → `respond(user_message)` per turni successivi → `clear_session()` per reset.

Sicurezza dello storico (F5-06): Il messaggio utente viene aggiunto alla cronologia solo *dopo* aver ottenuto una risposta valida dal LLM, evitando stati inconsistenti in caso di eccezione.

LessonGenerator (`lesson_generator.py`, 382 righe)

Generatore di lezioni educative strutturate a partire dall'analisi delle demo:

Soglia	Costante	Valore	Uso
ADR forte	`_ADR_STRONG_THRESHOLD`	75.0	Identifica punti di forza
ADR debole	`_ADR_WEAK_THRESHOLD`	60.0	Identifica aree di miglioramento
HS% forte	`_HS_STRONG_THRESHOLD`	0.40	Precisione sopra la media
HS% debole	`_HS_WEAK_THRESHOLD`	0.35	Precisione sotto la media
Rating sopra media	`_RATING_ABOVE_AVG`	1.0	Prestazione positiva
KAST forte	`_KAST_STRONG_THRESHOLD`	0.70	Contributo costante
Rapporto morti	`_DEATH_RATIO_WARNING`	1.5×	deaths > kills × 1.5 = warning

Struttura lezione generata:

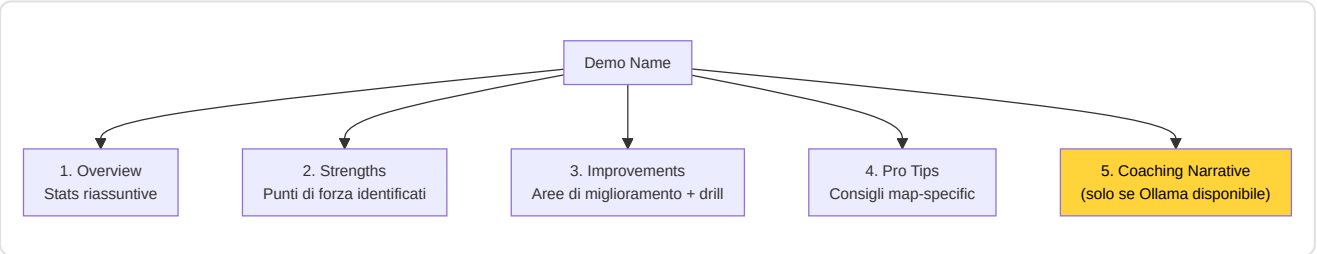

Pro Tips map-specific: Database interno con consigli per mirage, inferno, dust2, ancient, nuke. Fallback a consigli generali per mappe non coperte.

LLMService (`llm_service.py`, 253 righe)

Servizio di integrazione Ollama per inferenza LLM locale:

Parametro	Valore	Descrizione
`OLLAMA_URL`	`http://localhost:11434`	Endpoint Ollama (env: `OLLAMA_URL`)
`DEFAULT_MODEL`	`llama3.2:3b`	Modello piccolo e veloce (env: `OLLAMA_MODEL`)
`_AVAILABILITY_TTL`	60s	Cache di disponibilità
`temperature`	0.7	Creatività delle risposte
`top_p`	0.9	Nucleus sampling
`num_predict`	500	Limite lunghezza risposta

API supportate:

Metodo	Endpoint Ollama	Uso
`generate(prompt)`	`/api/generate`	Generazione single-shot
`chat(messages)`	`/api/chat`	Conversazione multi-turno
`generate_lesson(insights)`	`/api/generate`	Lezioni da insight RAP
`explain_round_decision(round_data)`	`/api/generate`	Spiegazione round singolo
`generate_pro_tip(context)`	`/api/generate`	Tip contestuale

Auto-discovery modello: Se il modello configurato non è disponibile, utilizza automaticamente il primo modello installato. Singleton via `get_llm_service()`.

VisualizationService (`visualization_service.py`, 119 righe)

Genera grafici radar Matplotlib per confronto User vs Pro:

- `generate_performance_radar(user_stats, pro_stats, output_path)` → file PNG con radar overlay
- `plot_comparison_v2(p1_name, p2_name, p1_stats, p2_stats)` → `io.BytesIO` buffer PNG
- Feature confrontate: avg_kills, avg_adr, avg_hs, avg_kast, accuracy
- Rendering wrappato in try/except (F5-19) per gestire stats vuote o backend matplotlib assente

ProfileService (`profile_service.py`, 127 righe)

Orchestratore di sincronizzazione profili esterni:

- `fetch_steam_stats(steam_id)` → nickname, avatar, playtime CS2 (ore)
- `fetch_faceit_stats(nickname)` → faceit_elo, faceit_level, faceit_id
- `sync_all_external_data(steam_id, faceit_name)` → upsert su `PlayerProfile` in DB
- Chiavi API caricate da environment/keyring (F5-22), mai hardcoded

AnalysisService (`analysis_service.py`, 92 righe)

Servizio di coordinamento analisi con drift detection:

- `analyze_latest_performance(player_name)` → ultime stats dal DB
- `get_pro_comparison(player_name, pro_name)` → confronto side-by-side
- `check_for_drift(player_name)` → `detect_feature_drift()` sulle ultime 100 partite

TelemetryClient (`telemetry_client.py`, 60 righe)

Client async per invio metriche a server centrale:

- Protocollo: `httpx.Client` → `POST /api/ingest/telemetry`
- URL configurabile: `CS2_TELEMETRY_URL` (default: `http://127.0.0.1:8000`)
- Fallback graceful se httpx non installato (feature opzionale)
- **Anti-fabrication compliant:** nessun dato sintetico nel self-test

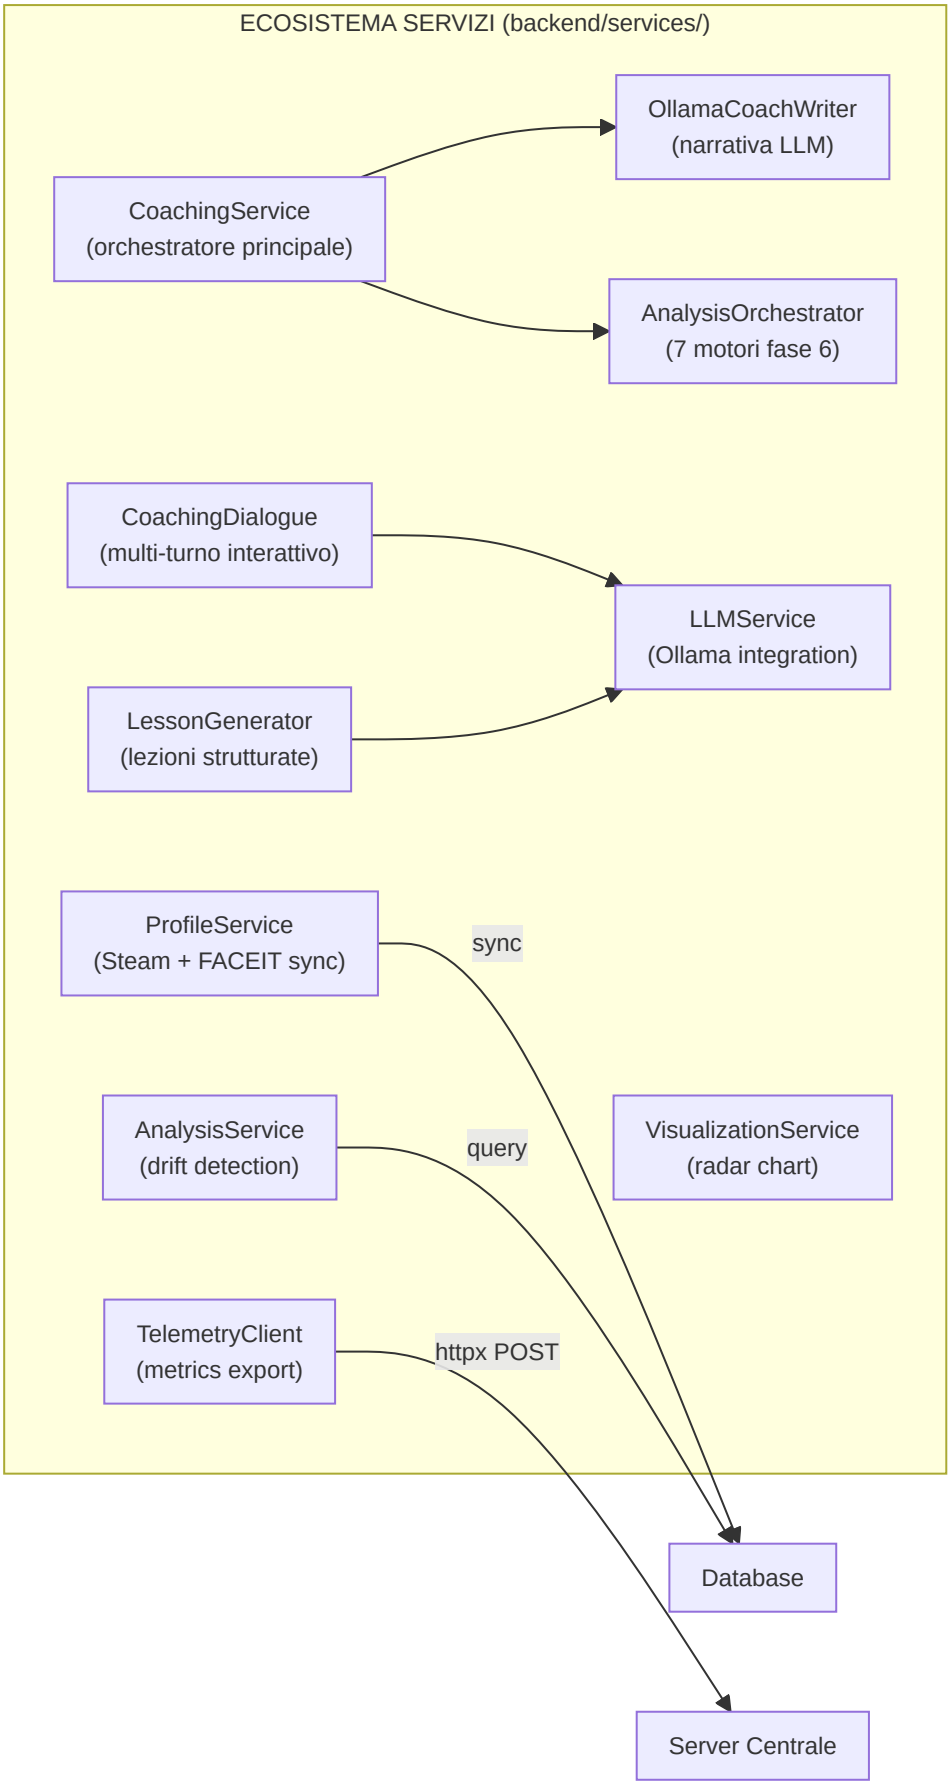
ECOSISTEMA SERVIZI (backend/services/)
OllamaCoachWriter
(narrativa LLM)
CoachingService
(orchestratore principale)
AnalysisOrchestrator
(7 motori fase 6)
CoachingDialogue
(multi-turno interattivo)
LLMService
(Ollama integration)
LessonGenerator
(lezioni strutturate)
ProfileService
(Steam + FACEIT sync)
sync
AnalysisService
(drift detection)
query
VisualizationService
(radar chart)
TelemetryClient
(metrics export)
httpx POST
Database
Server Centrale

5B. Sottosistema 3B — Motori di Coaching

Cartella nella repo: `backend/coaching/` **File:** 7 moduli, ~1.100 righe totali

Questo sottosistema contiene i **motori decisionali di coaching** che trasformano deviazioni statistiche grezze in consigli prioritizzati e contestualizzati. A differenza dei Servizi (Sezione 5) che orchestrano e presentano, i Motori di Coaching contengono la **logica di ragionamento** dell'allenatore.

> **Analogia:** Se i Servizi di Coaching (Sezione 5) sono la **reception dell'ospedale**, i Motori di Coaching sono i **medici specialisti nei loro studi**. Il `CorrectionEngine` è il medico di base che pesa i sintomi e decide quali 3 sono i più urgenti. Il `HybridCoachingEngine` è il primario che sintetizza ML e conoscenza enciclopedica per formulare diagnosi complete.
> L' `ExplanationGenerator` è lo specialista che traduce il gergo medico in parole comprensibili al paziente. Il `ProBridge` è il consulente che porta i referti di altri ospedali (dati HLTV) e li rende compatibili con il sistema locale. Il `LongitudinalEngine` è l'epidemiologo che studia i trend nel tempo.

-HybridCoachingEngine (`hybrid_engine.py`, 643 righe)

Il **cuore decisionale** del coaching: sintetizza predizioni ML con conoscenza RAG per generare insight unificati e deduplicati.

Pipeline a 5 stadi:

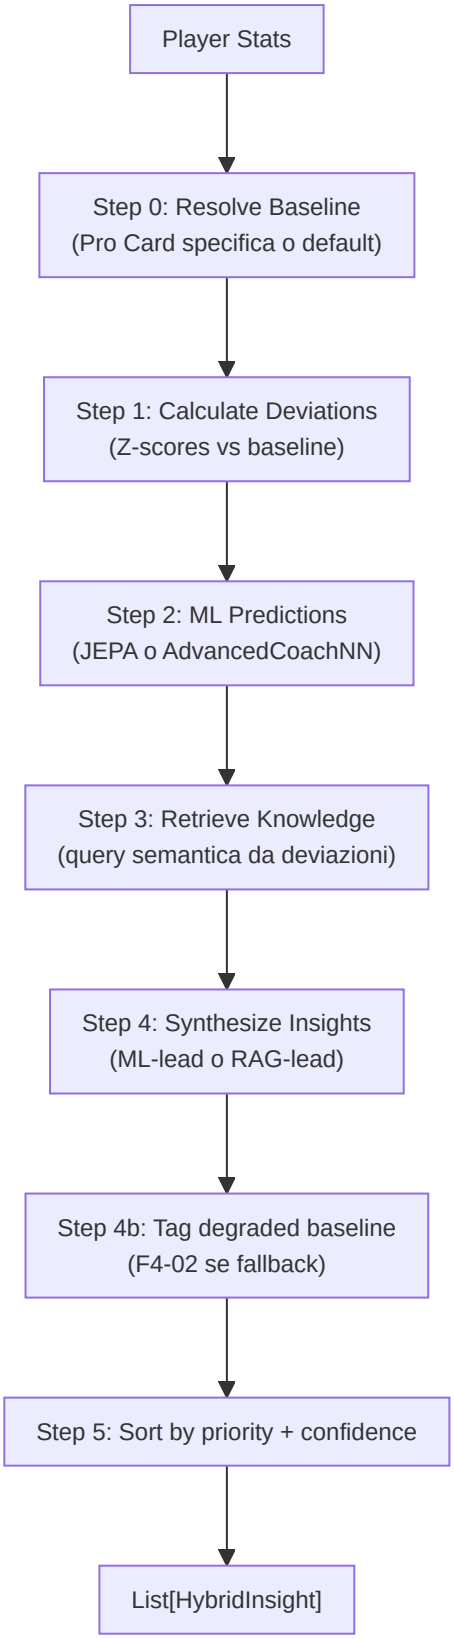

Classi e dataclass:

Tipo	Nome	Descrizione
`Enum`	`InsightPriority`	CRITICAL (|Z|>2.5, conf>0.8), HIGH (|Z|>2.0, conf>0.6), MEDIUM (|Z|>1.0, conf>0.4), LOW
`dataclass`	`HybridInsight`	title, message, priority, confidence, feature, ml_z_score, knowledge_refs, pro_examples, tick_range, demo_name

Formula di confidenza:

```
base_confidence = |z_score|/3.0 × 0.6 + knowledge_effectiveness × 0.4
confidence = base_confidence × MetaDriftEngine.get_meta_confidence_adjustment()
```

Dove `knowledge_effectiveness = min(1.0, mean(usage_count) / 100)`.

Strategia di sintesi:

Condizione	Strategia
|Z| > 2 (alta confidenza ML)	Lead con ML, supporto con RAG
|Z| < 1 (bassa confidenza ML)	Lead con RAG
1 ≤ |Z| ≤ 2	Approccio bilanciato
Nessuna deviazione significativa	Insight knowledge-only (priorità LOW)

TASK 2.7.1 — Reference Clip: Ogni `HybridInsight` può includere `tick_range: (start, end)` e `demo_name` per permettere alla UI di saltare direttamente all'evidenza nel file demo.

Fallback baseline (F4-02): Se `get_pro_baseline()` fallisce, usa valori statici hardcoded e marca tutti gli insight con `baseline_quality=degraded` nel messaggio.

-CorrectionEngine (`correction_engine.py`, 65 righe)

Genera le **top-3 correzioni pesate** da deviazioni Z-score:

Costante	Valore	Uso
`CONFIDENCE_ROUNDS_CEILING`	300	Scaling confidenza: `min(1.0, rounds / 300)`

Pesi di importanza (DEFAULT_IMPORTANCE):

Feature	Peso
`avg_kast`	1.5
`avg_adr`	1.5
`accuracy`	1.4
`impact_rounds`	1.3
`avg_hs`	1.2
`econ_rating`	1.1
`positional_aggression_score`	1.0

Pipeline: `deviations` → applica confidence scaling × rounds_played → opzionale `apply_nn_refinement()` → sort per `|weighted_z| × importance` → restituisci top 3.

Override utente: I pesi sono sovrascrivibili via `get_setting("COACH_WEIGHT_OVERRIDES")`.

-ExplanationGenerator (`explainability.py`, 95 righe)

Traduce segnali latenti RL in **narrative comprensibili** organizzate per i 5 assi di competenza (`SkillAxes`):

Asse	Template Negativo	Template Azione
MECHANICS	"Your {feature} is {delta}% below professional standards..."	"Focus on crosshair height when clearing corners..."
POSITIONING	"Positioning at {location} was suboptimal..."	"Try holding a tighter angle at {location}..."
UTILITY	"Utility timing with {weapon} was suboptimal..."	"Wait for a clear sound cue before deploying..."
TIMING	"Engagement timing is lagging behind..."	"Coordinate with teammates to trade-frag..."
DECISION	"Decision efficiency is {delta}% lower..."	"In clutch scenarios, prioritize the round objective..."

Principio "Silence is a Valid Action":

Soglia	Costante	Valore	Comportamento
Silenzio	`SILENCE_THRESHOLD`	0.2	|delta| < 0.2 → nessun feedback (silenzio)
Severità alta	`SEVERITY_HIGH_BOUNDARY`	1.5	|delta| > 1.5 → "High"
Severità media	`SEVERITY_MEDIUM_BOUNDARY`	0.8	|delta| > 0.8 → "Medium"

Filtro di complessità: Per `skill_level < 3` (principianti), le narrative negative sono semplificate alla sola azione suggerita, evitando sovraccarico cognitivo.

-NNRefinement (`nn_refinement.py`, 31 righe)

Applica aggiustamenti di peso dalla rete neurale alle correzioni pre-calcolate:

```
refined_z = weighted_z × (1 + nn_adjustments["{feature}_weight"])
```

Modulo leggero che scala le correzioni dal `CorrectionEngine` usando pesi appresi dal modello ML, permettendo al sistema neurale di influenzare la prioritizzazione dei consigli.

-ProBridge (`pro_bridge.py`, 115 righe)

Layer di traduzione che assimila Player Card HLTV nel modello cognitivo del coach:

Classe	Responsabilità
`PlayerCardAssimilator`	Converte `ProPlayerStatCard` → baseline coach-compatible
`get_pro_baseline_for_coach()`	Factory function diretta

Costante chiave: `ESTIMATED_ROUNDS_PER_MATCH = 24.0` — utilizzata per convertire KPR/DPR in avg_kills/avg_deaths.

Mappatura metriche:

Metrica HLTV	Metrica Coach	Trasformazione
`card.kpr`	`avg_kills`	`kpr × 24`
`card.dpr`	`avg_deaths`	`dpr × 24`
`card.adr`	`avg_adr`	diretto
`card.kast`	`avg_kast`	diretto
`card.impact`	`impact_rounds`	diretto
`card.rating_2_0`	`rating`	diretto
`detailed_stats.headshot_pct`	`avg_hs`	diretto (default 0.45)
`detailed_stats.total_opening_kills`	`entry_rate`	`/100` (euristica)
`detailed_stats.utility_damage_per_round`	`utility_damage`	diretto (default 45.0)

Classificazione archetipo: `get_player_archetype()` → Star Fragger (impact>1.3), Support Anchor (kast>0.75), Sniper Specialist (AWP kills>40%), All-Rounder (default).

-PlayerTokenResolver (`token_resolver.py`, 108 righe)

Risolve **token statici** (Card) per il confronto dinamico:

- `get_player_token(player_name)` → token dict con identity, core_metrics, tactical_baselines, granular_data, metadata

- `compare_performance_to_token(match_stats, token)` → `Correction Delta` con deltas per rating, adr, kast, accuracy_vs_hs e flag `is_underperforming` (rating < 85% del pro)

Struttura Token:

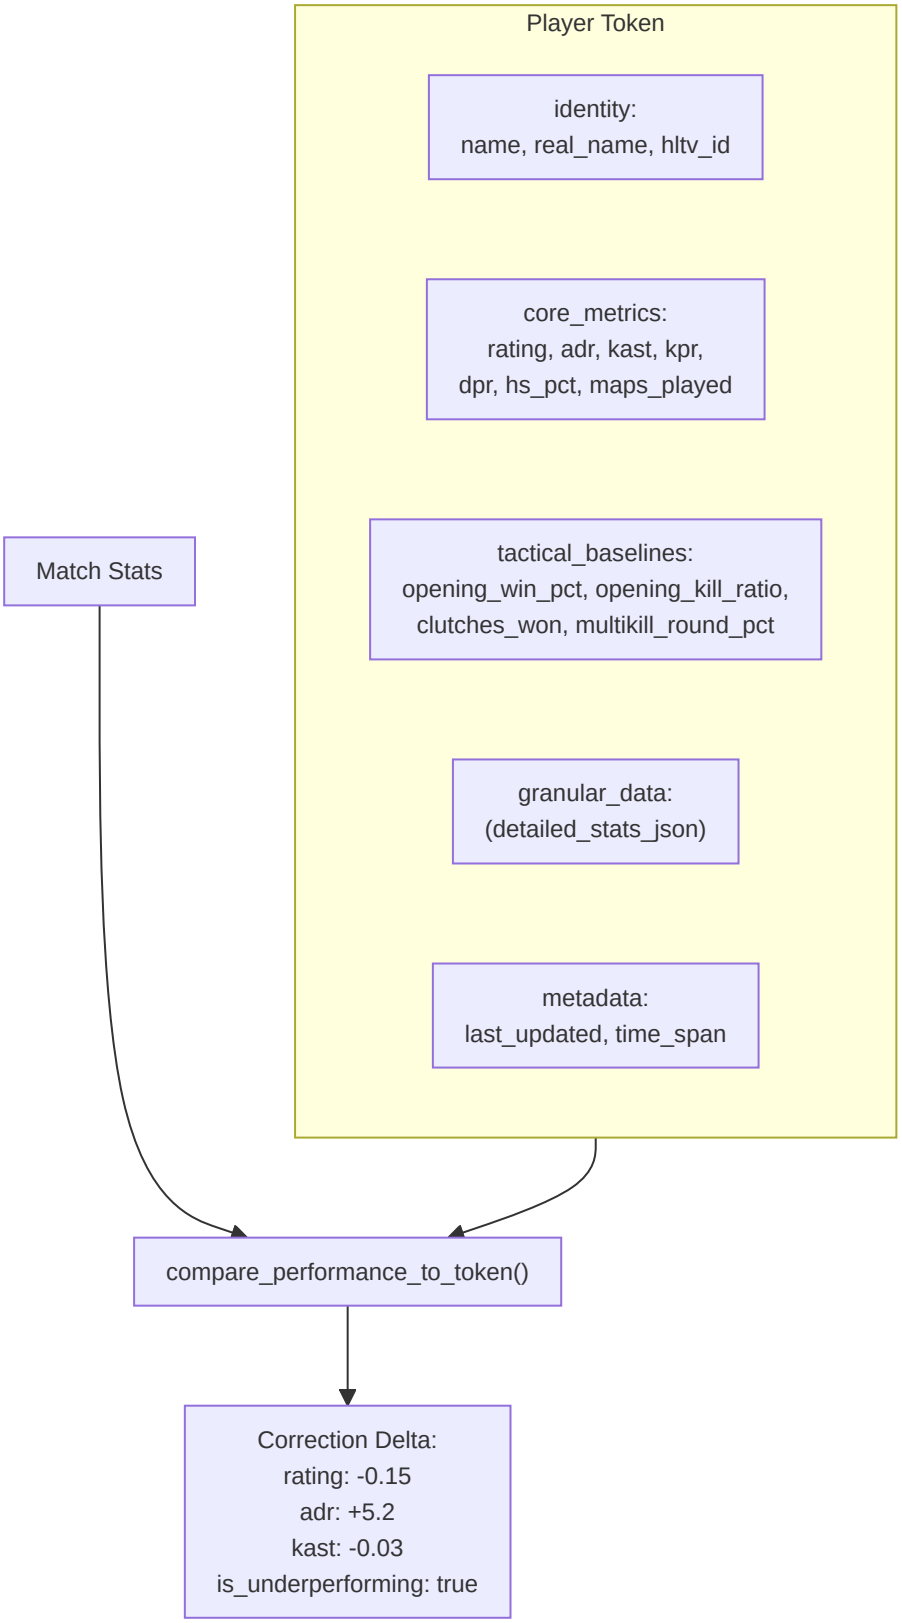

-LongitudinalEngine (`longitudinal_engine.py` , 49 righe)

Genera insight trend-aware comparando traiettorie di performance nel tempo con segnali di stabilità NN:

- **Input:** `List[FeatureTrend]` (dal modulo progress) + `nn_signals` (dal training pipeline)
- **Filtro confidenza:** Solo trend con `confidence ≥ 0.6`
- **Output:** Max 3 insight, categorizzati come:
  - **Regression:** slope < 0 → severità "Medium" (o "High" se `nn_signals.stability_warning` attivo)
  - **Improvement:** slope > 0 → severità "Positive", focus "Reinforcement"

> **Analogia:** Il LongitudinalEngine è come un **grafico dei voti nel tempo**. Non guarda solo il voto dell'ultimo esame, ma l'intera traiettoria: "I tuoi voti in matematica sono in calo da 3 mesi" (regressione) o "La tua precisione sta migliorando costantemente" (miglioramento). Se il sistema neurale è instabile (`stability_warning`), il medico alza il livello di allerta: "Questo calo potrebbe essere più serio di quanto sembra".

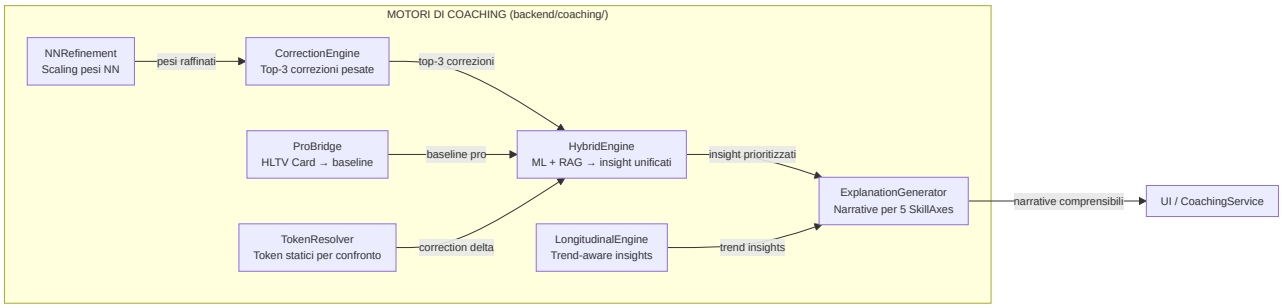

---

6. Sottosistema 4 — Conoscenza e Recupero

cartella nella repo: `backend/knowledge/` **File:** `rag_knowledge.py` , `experience_bank.py`

Questo sottosistema è la **biblioteca e il diario** dell'allenatore: memorizza le conoscenze tattiche (come un libro di testo) e le esperienze di allenamento passate (come un diario di ciò che ha funzionato e di ciò che non ha funzionato).

> **Analogia:** Immagina di avere due modi per studiare per un esame. Il primo è un **libro di testo** (RAG Knowledge Base) — contiene tutti i suggerimenti CS2 organizzati per argomento: "obiettivo", "posizionamento", "utilità", ecc. Puoi cercarli ponendo domande in inglese semplice e il sistema trova le pagine più pertinenti. Il secondo è il tuo **diario personale** (Experience Bank) — registra ogni sessione di allenamento che hai svolto, i consigli che ti sono stati dati e se sei effettivamente migliorato in seguito. Col tempo, il diario diventa più intelligente: i consigli che hanno funzionato vengono evidenziati, mentre quelli che non hanno funzionato vengono eliminati. Insieme, il libro di testo e il diario forniscono all'allenatore sia **conoscenza generale** che **esperienza personale** da cui attingere.

-Knowledge Base RAG (`rag_knowledge.py`)

Implementa una pipeline di **generazione aumentata dal recupero** utilizzando la ricerca per similarità vettoriale densa:

Componente	Dettaglio
Modello di incorporamento	`sentence-transformers/all-MiniLM-L6-v2` (vettori a 384 dimensioni)
Fallback	Incorporamenti basati su hash se Sentence-BERT non è disponibile
Archiviazione	Tabella SQLite `TacticalKnowledge` (embedding memorizzato come array float codificato in JSON)
Recupero	Similarità del coseno tramite `scipy.spatial.distance.cosine`
Top-k	Configurabile, predefinito k=5
Versioning	`CURRENT_VERSION = "v2"` ; incorporamenti obsoleti ricalcolati al momento del rilascio della versione
Categorie	11: obiettivo, posizionamento, utilità, movimento, economia, strategia, posizionamento del mirino, comunicazione, mentale, senso del gioco, trading

Analogia: RAG funziona come un **motore di ricerca intelligente per il cervello dell'allenatore**. Quando l'allenatore ha bisogno di consigli sul posizionamento su Dust2 come CT AWPer, non cerca per parole chiave come Google. Invece, converte la domanda in un "vettore di significato" di 384 numeri e trova suggerimenti memorizzati i cui vettori di significato puntano nella stessa direzione (somiglianza del coseno). È come se ogni libro in una biblioteca avesse una coordinata GPS che ne rappresenta l'argomento e, invece di cercare per titolo, si fornissero le coordinate GPS e si trovassero i 5 libri più vicini. Il moltiplicatore di rilevanza 1,2x è come dire "i libri dello stesso scaffale (stessa mappa/lato/tipo di arrotondamento) ottengono punti bonus". Il filtro di deduplicazione (soglia 0,85) impedisce di restituire 5 copie sostanzialmente dello stesso suggerimento.

Correzione M-07 — Rifiuto vettore norma-zero: `VectorIndex.search()` valida la norma del vettore query prima della ricerca. Se la norma è zero (tipicamente dovuto a un embedding fallback vuoto o a un input corrotto), il metodo ritorna `None` con un warning nel log anziché propagare un errore di divisione per zero nella similarità del coseno. Questo protegge il pipeline RAG da query degenerate senza interrompere il flusso di coaching.

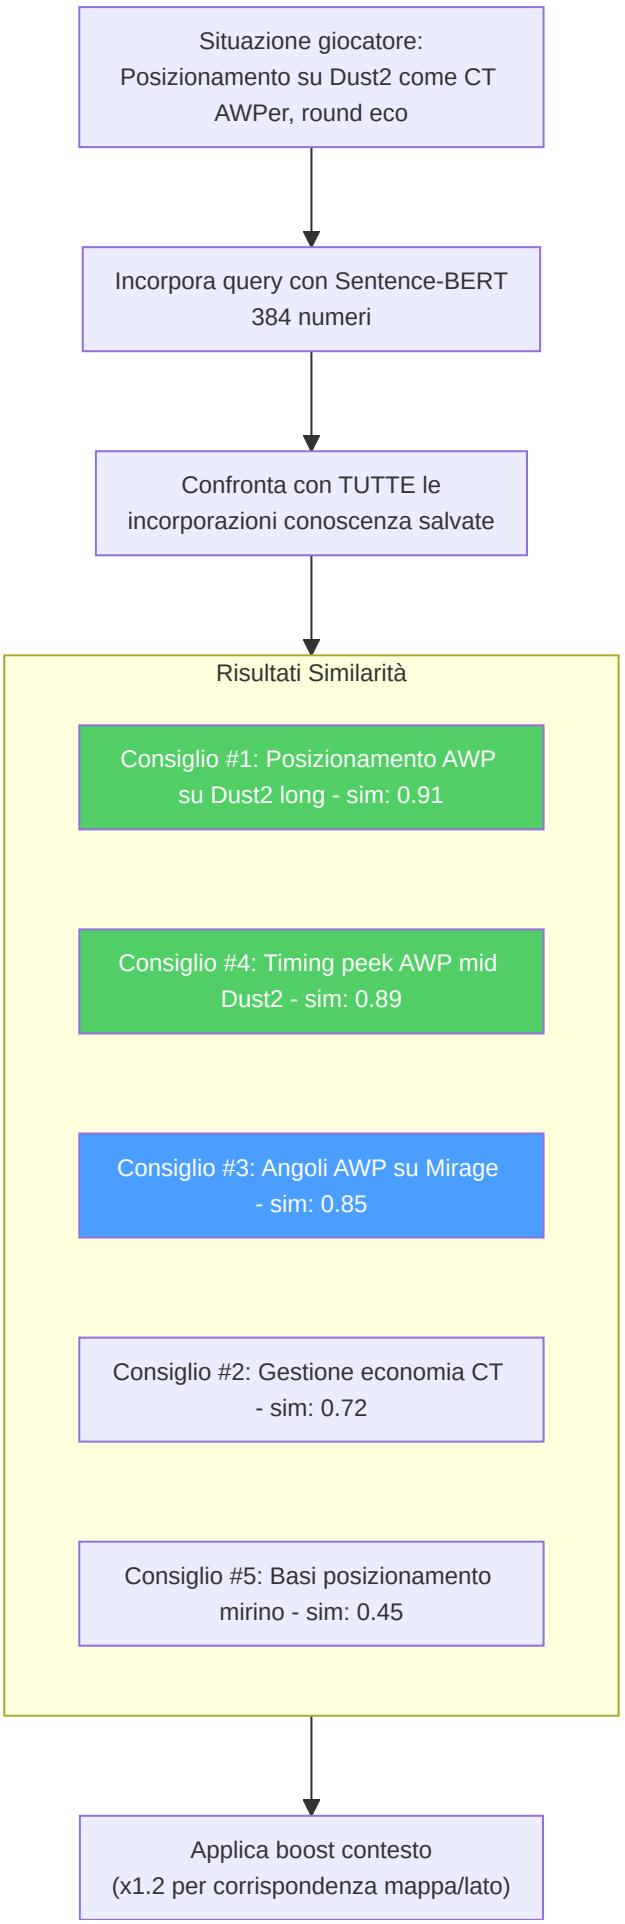
Situazione giocatore:
Posizionamento su Dust2 come CT
AWPer, round eco
Incorpora query con Sentence-BERT
384 numeri
Confronta con TUTTE le
incorporazioni conoscenza salvate
Risultati Similarità
Consiglio #1: Posizionamento AWP
su Dust2 long - sim: 0.91
Consiglio #4: Timing peek AWP mid
Dust2 - sim: 0.89
Consiglio #3: Angoli AWP su Mirage
- sim: 0.85
Consiglio #2: Gestione economia CT
- sim: 0.72
Consiglio #5: Basi posizionamento
mirino - sim: 0.45
Applica boost contesto
(x1.2 per corrispondenza mappa/lato)

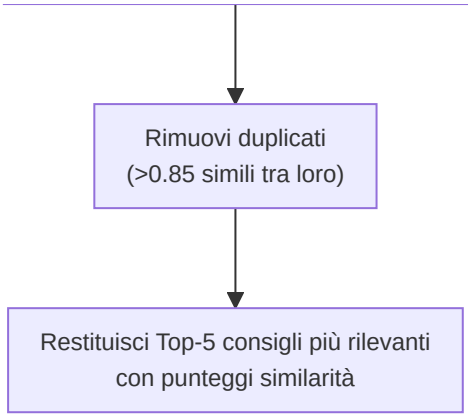

Costruzione query: query dinamiche in linguaggio naturale da statistiche giocatore, mappa, lato, ruolo. Gli elementi che corrispondono al contesto ottengono un moltiplicatore di rilevanza 1,2x. La deduplicazione filtra gli elementi con una similarità >0,85 rispetto ai risultati già selezionati.

-Banca Esperienza (`experience_bank.py`) — Framework COPER

Implementa il framework **Osservazione–Previsione–Esperienza–Recupero Contestuale (COPER)**:

> **Analogia:** COPER è il **diario personale dell'allenatore con superpoteri**. Ogni volta che l'allenatore dà un consiglio durante una partita, scrive una voce di diario: "In Dust2, round eco lato T, il giocatore era nei tunnel B con 60 HP e un Deagle. Gli ho detto di mantenere l'angolazione. Sono sopravvissuti e hanno ottenuto 2 uccisioni. Questo consiglio HA FUNZIONATO!" Più tardi, quando si presenta una situazione simile, l'allenatore sfoglia il suo diario e trova quella voce. Ma è ancora più intelligente: controlla anche cosa hanno fatto i giocatori professionisti in situazioni simili, cerca degli schemi ("Questo giocatore continua ad avere difficoltà nei round eco sul lato T") e adatta la fiducia in base alla data di convalida del consiglio.

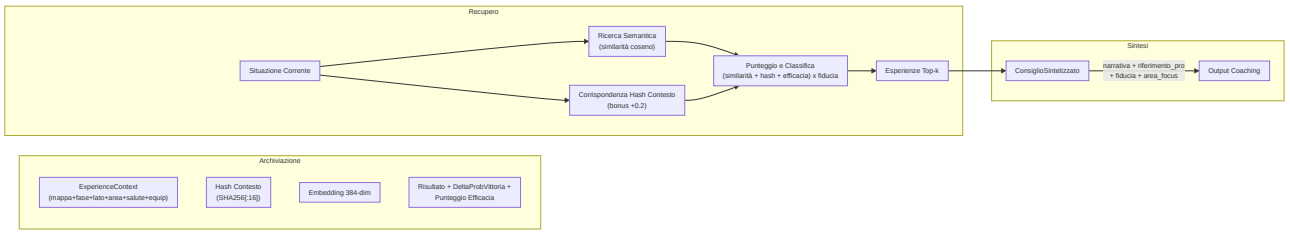

Strategia di doppio recupero:

1. **Esperienze utente:** Situazioni passate tratte dalla cronologia di gioco dell'utente.
2. **Esperienze professionali:** Come i professionisti hanno gestito situazioni analoghe.
3. **Analisi dei pattern:** Identifica debolezze ricorrenti, tendenze di miglioramento, correlazioni contestuali.

> **Analogia:** Il doppio recupero è come studiare per un esame utilizzando **sia i tuoi test passati che le risposte del genio della classe**. I tuoi test passati mostrano ciò in cui hai difficoltà personalmente. Le risposte del genio della classe mostrano l'approccio ideale. L'analisi dei pattern è come se il tuo insegnante esaminasse tutti i tuoi test e dicesse: "Ho notato che perdi sempre punti sullo stesso tipo di domanda: concentriamoci su quello".

Ciclo di feedback (basato su EMA):

- Ogni esperienza tiene traccia di `outcome_validated`, `effectiveness_score`, `times_advice_given`, `times_advice_followed`
- Le corrispondenze di follow-up aggiornano l'efficacia: `new_score = 0,7 × old_score + 0,3 × outcome_value`
- Esperienze obsolete (>90 giorni senza convalida): la fiducia diminuisce del 10%
- Il monitoraggio dell'utilizzo incrementa `usage_count` a ogni recupero

> **Analogia:** Il ciclo di feedback è il modo in cui l'allenatore **impara dai propri consigli**. Dopo aver fornito un consiglio, verifica: "Il giocatore ha effettivamente fatto quello che gli ho suggerito? Le sue prestazioni sono migliorate?". La formula EMA (0,7 vecchie + 0,3 nuove) significa che l'allenatore si fida della sua esperienza a lungo termine più di qualsiasi singolo risultato, come la valutazione di un ristorante che si basa su centinaia di recensioni, non solo sull'ultima. Se un consiglio non viene convalidato entro 90 giorni, perde il 10% di affidabilità, come una previsione meteorologica che diventa meno affidabile man mano che si procede nel futuro. Questo crea un sistema che si auto-migliora: i buoni consigli diventano più affidabili nel tempo, mentre quelli cattivi vengono gradualmente eliminati.

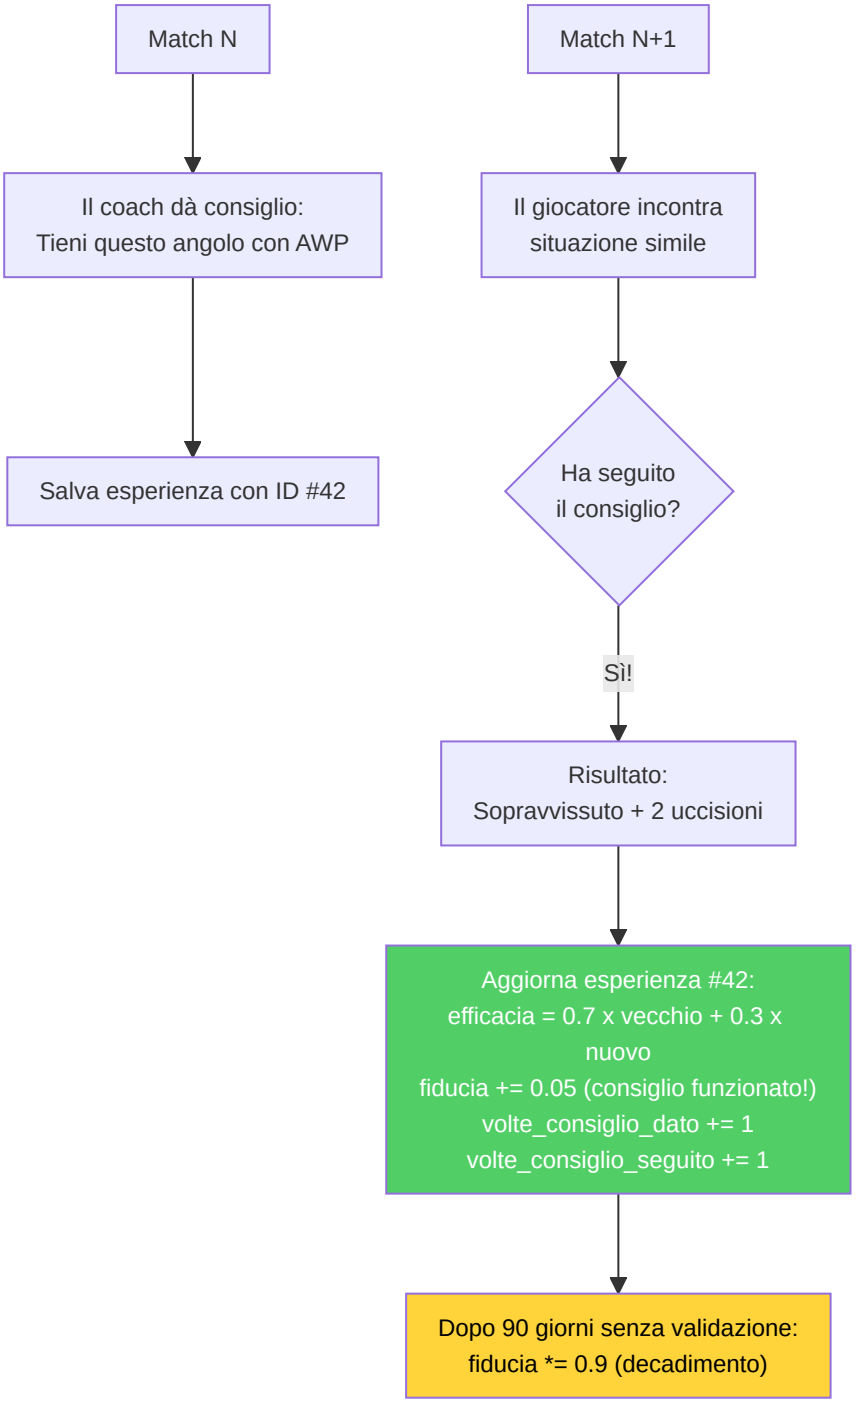

Estrazione dell'esperienza dalle demo: Raggruppa gli eventi per tick, identifica le uccisioni/morti dei giocatori, crea il contesto a partire da un'istantanea del tick, deduce l'azione (scoped_hold, crouch_peek, pushed, held_angle), determina l'esito.

-Knowledge Graph

Un **grafo entità-relazione** leggero memorizzato in SQLite (tabelle `kg_entities`, `kg_relations`). Supporta `query_subgraph(entity_name)` a 1 salto per il ragionamento multi-salto, al fine di integrare la similarità semantica.

> **Analogia:** Il Knowledge Graph è come una **rete di fatti connessi**. Invece di memorizzare suggerimenti come paragrafi isolati, collega concetti: "Fumo → blocchi → visione", "AWP → richiede → angoli lunghi", "Sito Dust2 B → si collega a → tunnel". Quando il coach cerca "posizionamento AWP", il Knowledge Graph può seguire le connessioni: "AWP necessita di angoli lunghi → Dust2 ha angoli lunghi in A lungo e a metà → quelle posizioni si collegano al sito A". Questa capacità di "seguire le connessioni" (chiamata ragionamento multi-hop) aiuta il coach a trarre inferenze logiche che la ricerca testuale pura potrebbe non cogliere.

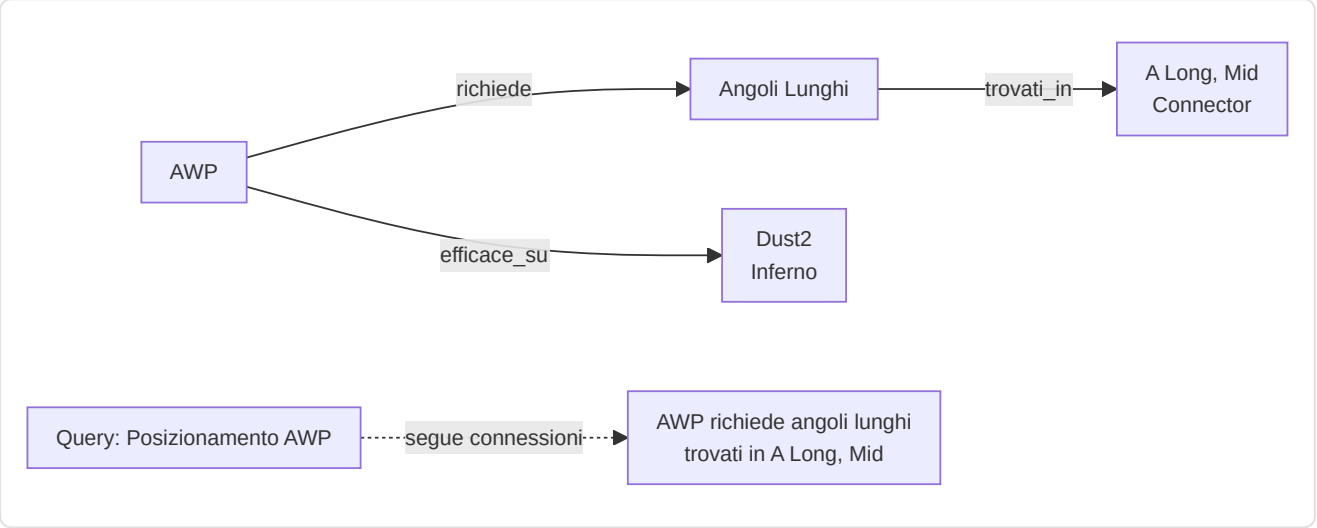

-Inizializzazione Knowledge Base (`init_knowledge_base.py`, 111 righe)

Script di orchestrazione che popola il database RAG con conoscenza tattica da due fonti:

1. **Conoscenza manuale:** Caricamento da file JSON (`data/tactical_knowledge.json`) con suggerimenti curati manualmente per categoria e mappa
2. **Mining automatico:** Invocazione di `ProDemoMiner.mine_all_pro_demos()` per estrarre pattern tattici dalle demo professionali

Dopo il caricamento, genera un report per categoria e mappa utilizzando query COUNT aggregate (senza caricare tutti i record in memoria).

-ProDemoMiner (`pro_demo_miner.py`, 277 righe)

Estrae conoscenza tattica dalle demo professionali utilizzando pattern detection:

Classe	Righe	Descrizione
`ProDemoMiner`	~180	Estrazione pattern da metadati match (map, team, success rate)
`AdvancedProDemoMiner(ABC)`	~60	Base astratta (F5-05) per parsing demo con demoparser2

Soglie di qualità:

Costante	Valore	Significato
`MIN_SUCCESS_RATE`	0.70	Pattern accettato solo se successo ≥70%
`MIN_SAMPLE_SIZE`	5	Minimo 5 occorrenze per pattern valido

Mappe supportate: mirage, dust2, inferno, nuke, overpass, vertigo, ancient, anubis.

Tipologie di conoscenza generata:

- Conoscenza specifica per mappa (posizionamento, utilità, rotazioni)
- Conoscenza specifica per team (strategie, tendenze, stili)
- Conoscenza per esecuzioni di successo (pattern con tasso ≥70%)

-Round Utils (`round_utils.py`, 35 righe)

Utility condivisa per classificazione fase economica del round, estratta per eliminare duplicazione tra i layer knowledge e services:

Valore Equipaggiamento	Fase	Costante
< $1.500	`pistol`	`_PISTOL_MAX_EQUIP`
$1.500 – $2.999	`eco`	`_ECO_MAX_EQUIP`
$3.000 – $3.999	`force`	`_FORCE_MAX_EQUIP`
≥ $4.000	`full_buy`	—

---

7. Sottosistema 5 — Motori di analisi

cartella nella repo: `backend/analysis/` **10 file, ~2.100 righe di codice di produzione**

Questo sottosistema contiene **10 motori di analisi specializzati**, ognuno progettato per indagare una diversa dimensione del gameplay. Funzionano come analisi di Fase 6, fornendo approfondimenti che vanno oltre ciò che le sole reti neurali possono offrire.

> **Analogia:** Pensate a questi 10 motori di analisi come a un **team di 10 diversi scienziati sportivi**, ognuno con la propria specializzazione. Uno scienziato studia le vostre meccaniche di tiro, un altro le vostre capacità decisionali sotto pressione, un altro ancora la vostra capacità di essere imprevedibili e così via. Ogni scienziato produce la propria mini-pagella e insieme dipingono un quadro completo dei vostri punti di forza e di debolezza. Nessuno scienziato da solo vede tutto, ma insieme coprono tutti gli aspetti importanti del gioco competitivo in CS2.

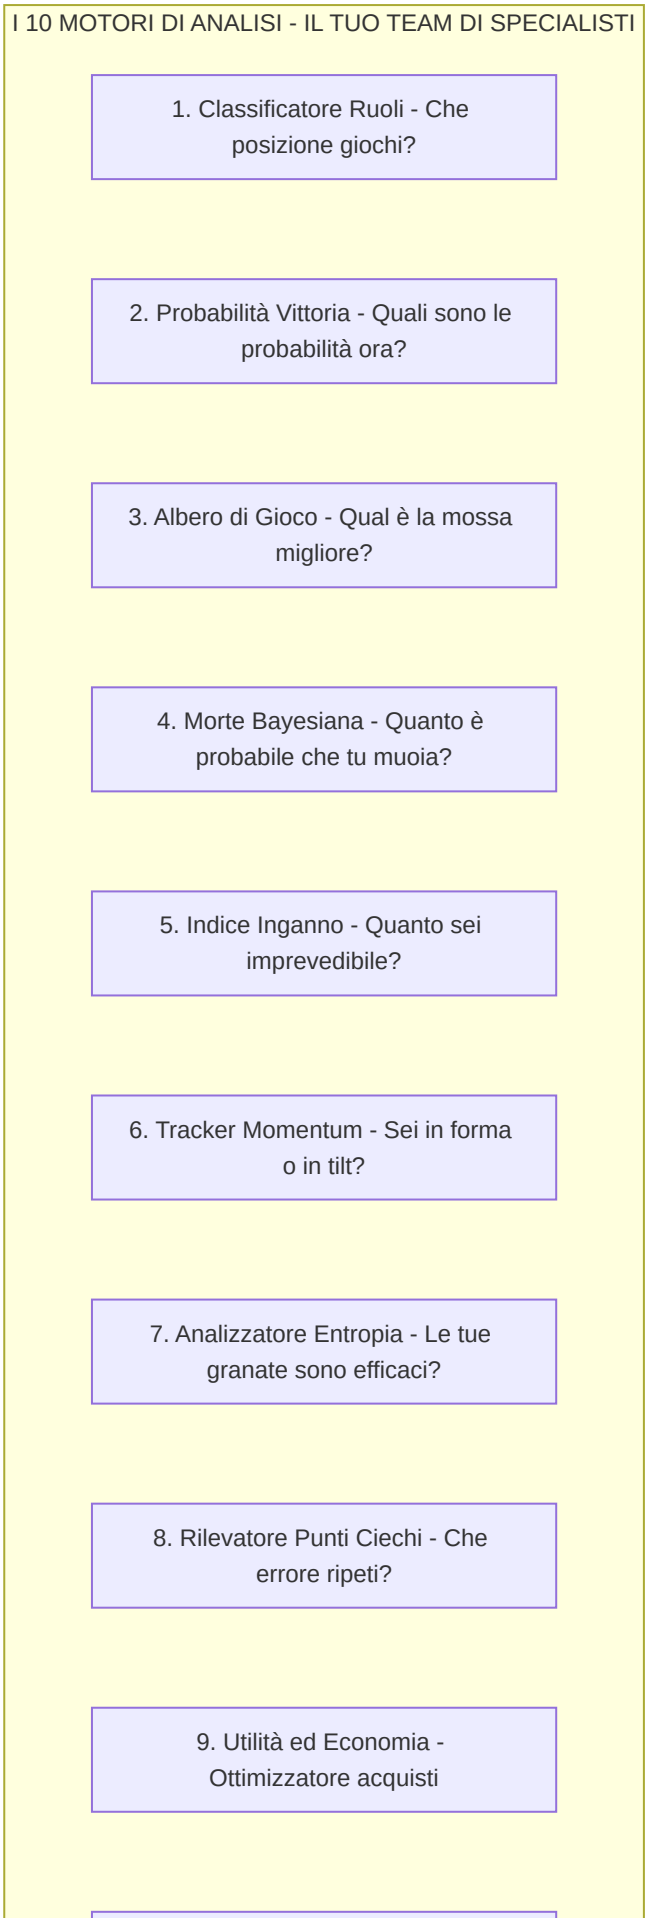
I 10 MOTORI DI ANALISI - IL TUO TEAM DI SPECIALISTI
1. Classificatore Ruoli - Che posizione giochi?
2. Probabilità Vittoria - Quali sono le probabilità ora?
3. Albero di Gioco - Qual è la mossa migliore?
4. Morte Bayesiana - Quanto è probabile che tu muoia?
5. Indice Inganno - Quanto sei imprevedibile?
6. Tracker Momentum - Sei in forma o in tilt?
7. Analizzatore Entropia - Le tue granate sono efficaci?
8. Rilevatore Punti Ciechi - Che errore ripeti?
9. Utilità ed Economia - Ottimizzatore acquisti

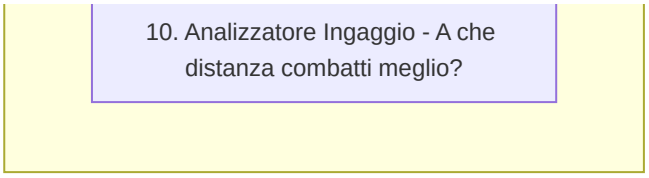

-Classificatore di Ruoli (`role_classifier.py`, ~400 righe)

Assegna uno dei 6 ruoli utilizzando **soglie statistiche apprese**:

Ruolo	Segnale Primario	Segnale Secondario
AWPer	Rapporto uccisioni AWP vs soglia	—
Entry Fragger	Tasso di ingresso + bonus alla prima morte (0,3×)	—
Supporto	Tasso di assistenza + bonus danni da utilità (max 0,3×)	—
IGL	Tasso di sopravvivenza + bonus bilanciamento KD	—
Lurker	Rapporto uccisioni in solitaria vs soglia	—
Flex	Ripiegamento quando la fiducia è bassa	—

> **Analogia:** Il Classificatore di Ruoli è come un **talent scout** che osserva il tuo stile di gioco e capisce in quale posizione ti trovi naturalmente. Se ottieni molte uccisioni AWP, probabilmente sei un AWPer. Se sei sempre il primo a morire (ma ottieni anche uccisioni iniziali), probabilmente sei un Entry Fragger. Se usi molti flash e aiuti i tuoi compagni di squadra, sei un Supporto. Se nessuno sa esattamente cosa fai meglio, sei classificato come Flex, un generalista. Le soglie non sono codificate; vengono apprese dai dati di veri giocatori professionisti (quale percentuale di uccisioni ottiene un vero AWPer con l'AWP?).

Protezione per avvio "da zero": `RoleThresholdStore` richiede ≥10 campioni e ≥3 soglie valide per uscire dall'avvio "da zero". Restituisce `(FLEX, 0.0)` se in avvio da zero. Le soglie vengono **mantenute nel database** tramite `persist_to_db()` e `load_from_db()` — completamente implementate, non come stub.

> **Analogia:** La protezione all'avvio a freddo è come un **nuovo insegnante che dice "Non conosco ancora abbastanza bene i miei studenti".** Finché il sistema non ha visto almeno 10 giocatori professionisti e appreso almeno 3 soglie di ruolo valide, si rifiuta di classificare nessuno, restituendo invece "Flex" con una probabilità dello 0%. Questo evita l'imbarazzante errore di chiamare qualcuno "AWPer" quando il sistema ha visto solo 2 esempi di come si presenta un AWPer.

Audit del bilanciamento del team (`audit_team_balance()`): rileva più AWPer (ALTA), Entry mancante (ALTA), Supporto mancante (MEDIA), nessuna diversità (CRITICA), più Lurker (MEDIA).

-Predittore di Probabilità di Vittoria (`win_probability.py`, ~250 righe)

Rete neurale a 12 funzioni che stima P(round_win | game_state):

> **Analogia:** Il predittore di Probabilità di Vittoria è come un **tabellone segnapunti in tempo reale in una partita di basket** che mostra "La squadra di casa ha il 72% di probabilità di vincere". Considera 12 fattori relativi al momento attuale – quanti soldi ha ciascuna squadra, quanti giocatori sono ancora vivi, se la bomba è stata piazzata, quanto tempo rimane – e ne prevede le probabilità. Utilizza una piccola rete neurale (molto più piccola del RAP Coach) perché deve essere veloce, aggiornandosi ogni pochi secondi durante l'analisi in tempo reale.

Architettura: `Lineare(12, 64) → ReLU → Dropout(0,2) → Lineare(64, 32) → ReLU → Dropout(0,1) → Lineare(32, 1) → Sigmoide`.

12 Caratteristiche:

#	Caratteristica	Normalizzazione
1	economia_team	/16000
2	economia_nemico	/16000
3	differenziale economia	(squadra−nemico)/16000
4	giocatori_vivi	/5
5	nemici_vivi	/5
6	differenziale conteggio giocatori	(vivi−nemico)/5
7	utilità_rimanente	/5
8	percentuale_controllo_mappa	[0, 1]
9	tempo_rimanente	/115
10	bomba_piantata	binario
11	is_ct	binario
12	rapporto valore equipaggiamento	min(squadra/nemico, 2)/2

Override euristici: 3+ vantaggio → limite minimo all'85%, 3+ svantaggio → limite massimo al 15%, 0 vivi → 0%, aggiustamenti bomba piazzata (T: +0,10, CT: −0,10) — additivi sulla probabilità base, limiti economici di ±8000$.

> **Analogia:** Gli override euristici sono **barriere di sicurezza basate sul buon senso**. Anche se la rete neurale si blocca e prevede una probabilità di vittoria del 50% quando l'intera squadra è morta, la barra di sicurezza dice "No — 0 giocatori vivi = 0% di probabilità. Punto." Allo stesso modo, se hai 3 giocatori in più in vita rispetto al nemico, la regola di sicurezza recita: "Hai ALMENO l'85% di probabilità di vincere, indipendentemente da ciò che pensa la rete neurale". Queste regole codificano le conoscenze di gioco più basilari che non dovrebbero mai essere violate, fungendo da controllo di sanità mentale sulle previsioni dell'IA.
>
> **Nota A-12 — Guard cross-load:** Questo predittore a 12 feature (`WinProbabilityNN`) è un modello *separato e incompatibile* rispetto al `WinProbabilityTrainerNN` a 9 feature descritto nella Sezione 12. I checkpoint non sono intercambiabili: al caricamento viene validata la dimensionalità del `state_dict` e, in caso di mismatch, il modello viene reinizializzato da zero con un warning nel log.

-Albero di gioco Expectiminimax (`game_tree.py` , ~445 righe)

Implementa la **ricerca expectiminimax** con modellazione adattiva dell'avversario:

> **Analogia:** L'albero di gioco è come un **motore di scacchi per CS2**. Chiede: "Se spingo, cosa potrebbe fare il nemico? E se lo fa, qual è la mia risposta migliore?". Costruisce un albero di possibilità profondo 3 livelli: la tua mossa, la probabile risposta del nemico e la tua contro-risposta. A differenza degli scacchi tradizionali, CS2 ha la casualità (potresti sbagliare un tiro, il nemico potrebbe ruotare), quindi usa "expectiminimax", il che significa che tiene conto delle probabilità a ogni passaggio. Il risultato è una classifica in cui "Spingere è la migliore, Tenere è la seconda, Ruotare è la terza, Utilità è la quarta" con un punteggio di affidabilità per ciascuna opzione.

- **Azioni:** spingi, tieni premuto, ruota, usa_utilità
- **Modello avversario:** Priorita' economiche (eco/forza/acquisto completo), aggiustamenti laterali, aggiustamenti del vantaggio, pressione temporale
- **Profondità:** 3 livelli (max → probabilità → min)
- **Budget nodo:** 1000 (impedisce l'esplosione)
- **Valutazione foglia:** `WinProbabilityPredictor` (caricamento lazy)
- **Apprendimento avversario:** Aggiornamento EMA incrementale (α limitato a 0,5)

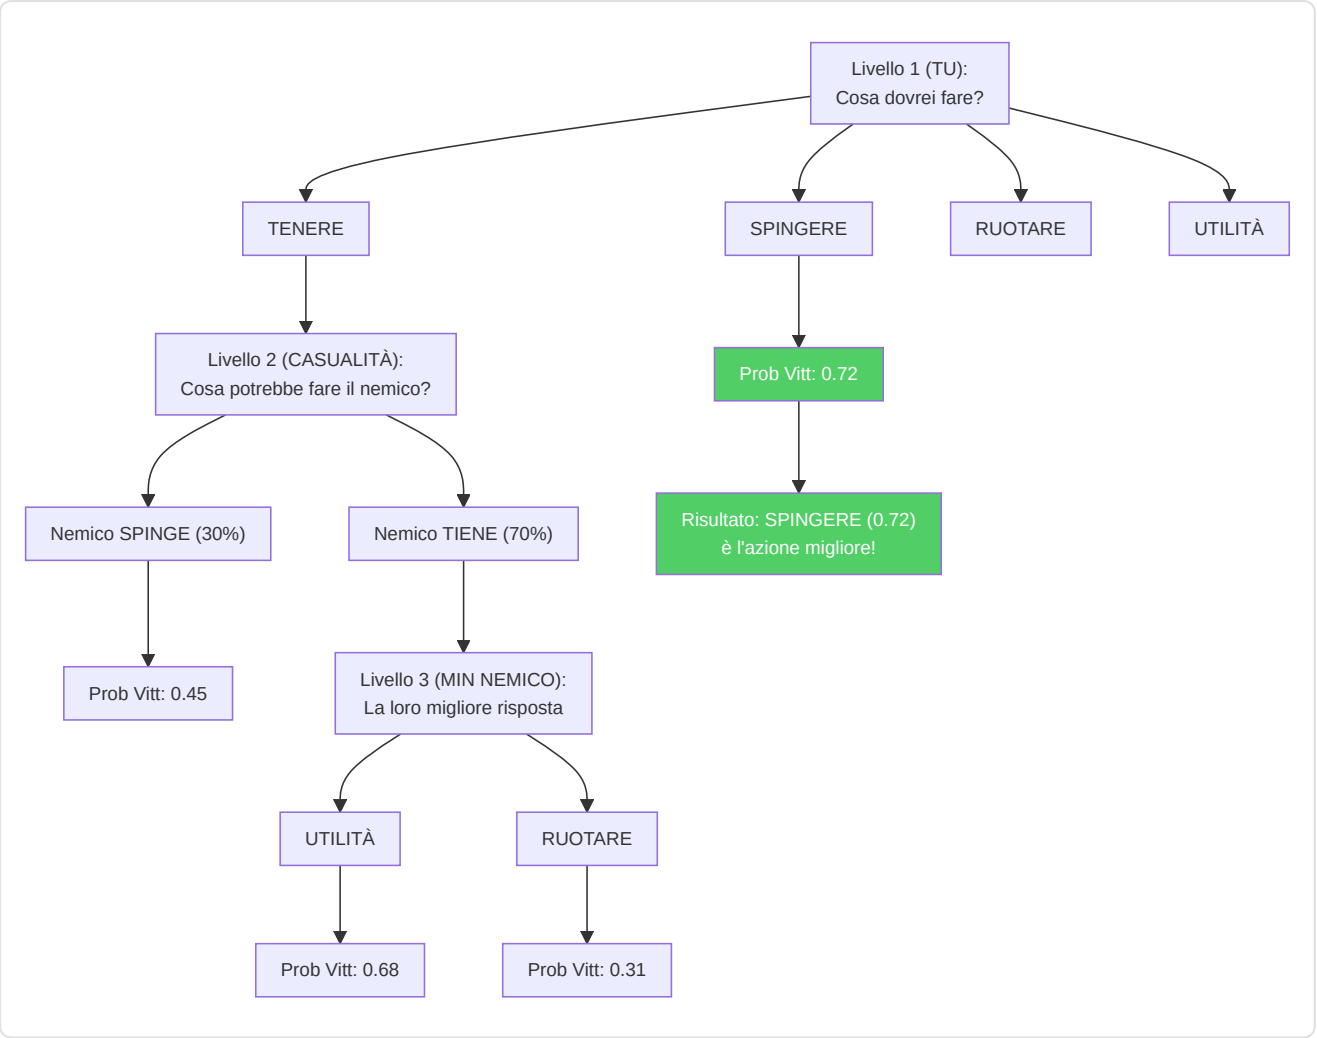

-Stimatore Bayesiano di Morte (`belief_model.py`, ~486 righe)

Modelli P(morte | credenza, HP, armatura, classe_arma):

> **Analogia:** La Stimatore di Morte è come un **indicatore di pericolo** che risponde a queste domande: "Data la tua posizione, il tuo stato di salute, l'arma del nemico e cosa pensiamo stia facendo, quanto è probabile che tu muoia nei prossimi secondi?". Utilizza statistiche bayesiane, un modo elegante per dire "inizia con un'ipotesi, poi aggiornala con le prove". L'ipotesi iniziale si basa sui PV: se hai la salute al massimo, la probabilità di morire è di circa il 35%; se hai pochi PV, la probabilità sale all'80%. Poi si adatta in base a ciò che sa: "Ma il nemico ha un AWP (più pericoloso di ×1,4) e la minaccia è recente (nessun decadimento)". Questo fornisce una probabilità finale che l'allenatore usa per decidere se consigliare un gioco aggressivo o difensivo.

- **Antecedente:** Tassi di mortalità per fascia HP (pieno ≥80: 0,35, danneggiato 40-79: 0,55, critico <40: 0,80)
- **Fattori di probabilità:** Livello di minaccia (con decadimento esponenziale exp(−0,1 × età)), riduzione dell'armatura (0,75×), moltiplicatori delle armi (AWP: 1,4×, Fucile: 1,0×, Mitragliatrice: 0,75×, Pistola: 0,6×, Coltello: 0,3×)

- **Posteriore:** Combinazione logistica nello spazio log-odds
- **Calibrazione:** `calibrate(historical_rounds)` apprende le priorità empiriche (≥10 campioni per fascia)

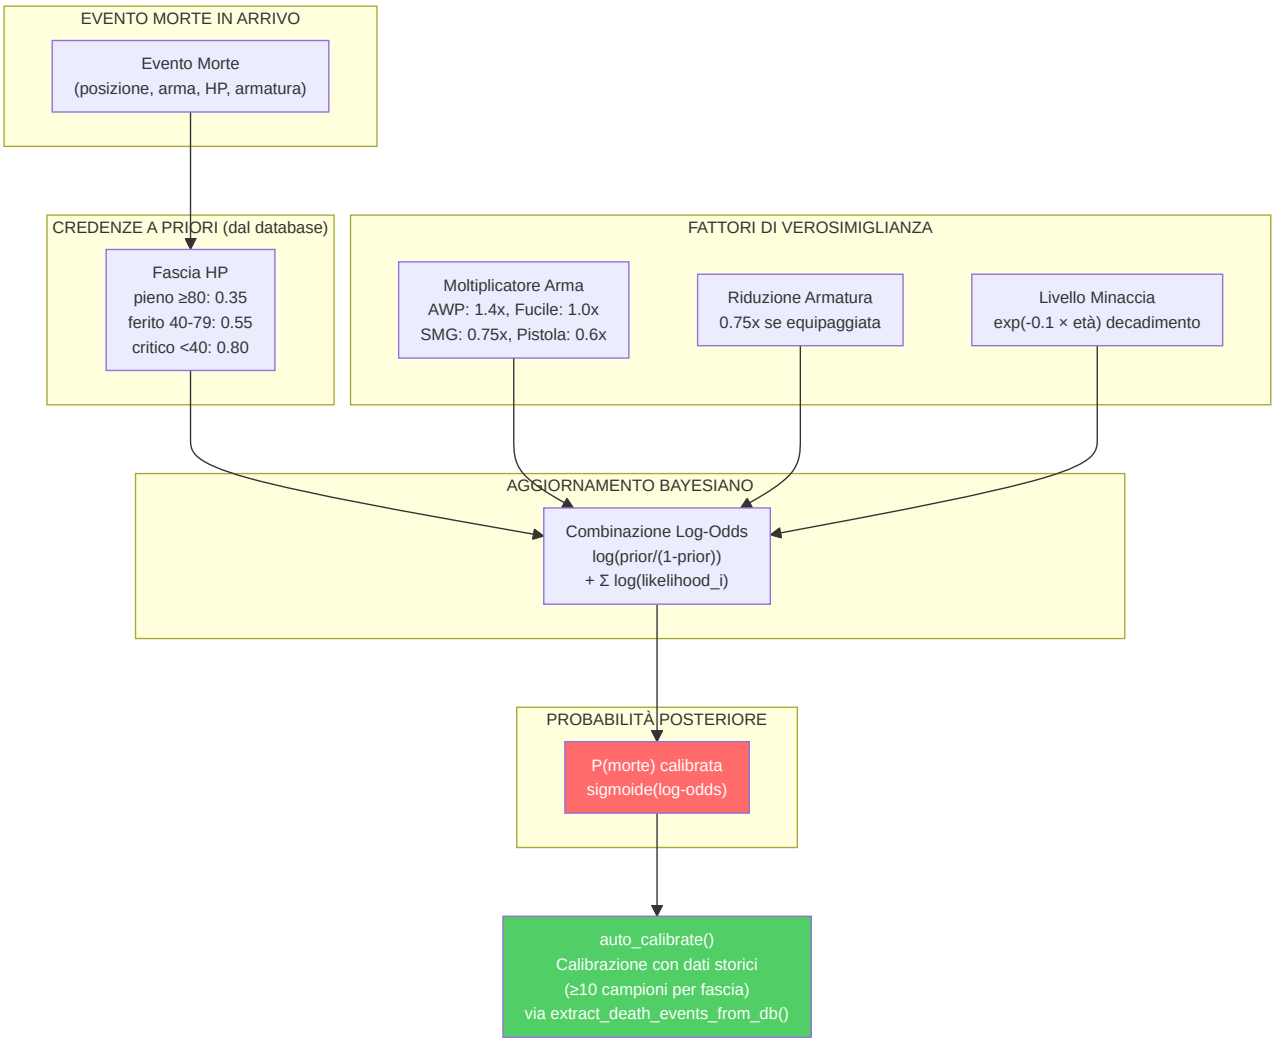

> **Nota sulla calibrazione (G-07):** Lo Stimatore Bayesiano di Morte è ora un **componente live** grazie al cablaggio completato durante la rimediazione. La funzione `extract_death_events_from_db()` nel Session Engine estrae automaticamente gli eventi di morte dal database e li passa ad `auto_calibrate()`, permettendo al modello di affinare le sue probabilità a priori sulla base dei dati reali accumulati. Questo ciclo di feedback trasforma lo stimatore da un modello statico a un sistema che si auto-calibra con l'esperienza.

-Indice di Inganno (`deception_index.py`, ~220 righe)

Quantifica l'inganno tattico tramite tre sottometriche:

> **Analogia:** L'Indice di Inganno misura quanto un giocatore sia **astuto e imprevedibile**. In CS2, essere prevedibili è pericoloso: se il nemico sa che guardi sempre dalla stessa angolazione, mirerà in anticipo. L'Indice di Inganno è come un **punteggio poker face**: un punteggio alto significa che sei difficile da interpretare (buono), un punteggio basso significa che sei trasparente (cattivo). Misura tre cose: (1) Lanci falsi flash per indurre le reazioni? (2) Fingi le prese del sito cambiando improvvisamente direzione? (3) Alterni camminata e corsa per confondere i nemici sulla tua posizione?

Sottometrica	Peso	Metodo di rilevamento
Frequenza di falsi flash	0,25	Flash che non accecano i nemici — `bait_rate = 1 - effettivo/totale`
Frequenza di finta rotazione	0,40	Cambiamenti di direzione >108° rilevati tramite campionamento della velocità angolare (20 intervalli di posizione)
Punteggio di inganno sonoro	0,35	Inverso del rapporto di accovacciamento — `1,0 - rapporto_accovacciamento × 2,0`

Composito: `DI = 0,25·fake_flash + 0,40·rotation_feint + 0,35·sound_deception`, fissato a [0, 1].

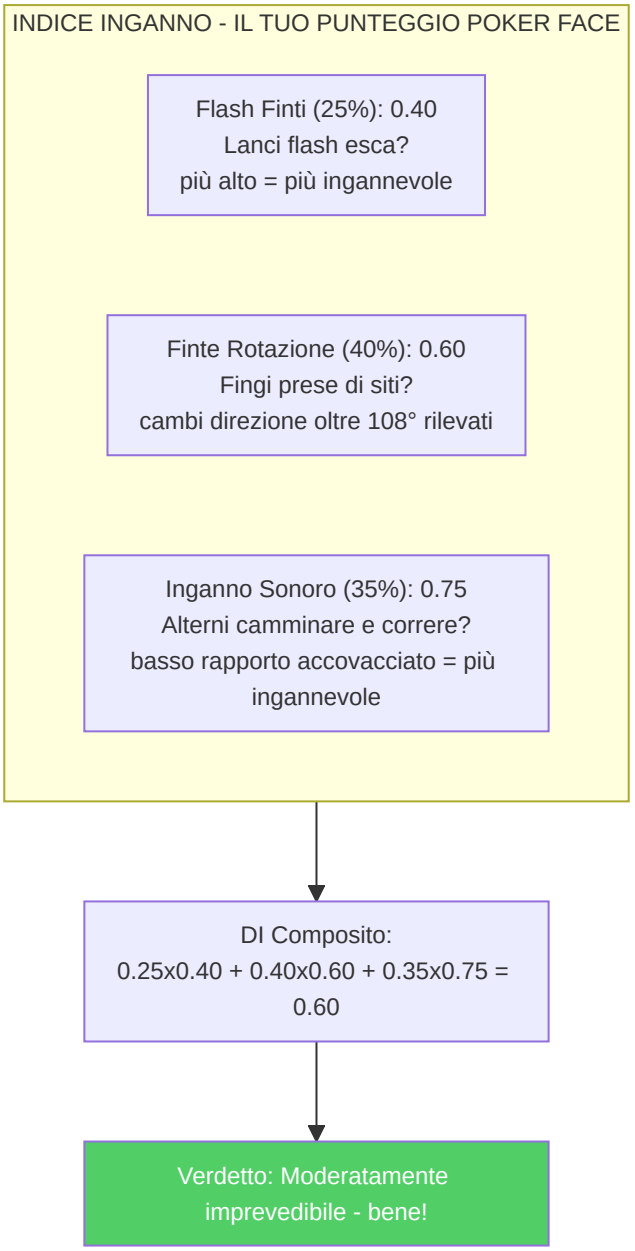

- Momentum Tracker (momentum.py, ~160 righe)

Modella il momentum psicologico come un moltiplicatore di prestazioni che decresce nel tempo:

> **Analogia:** il Momentum Tracker è come un anello dell'umore per il tuo gameplay. Quando vinci diversi round di fila, sei "in forma" - stai giocando con sicurezza, prendendo rischi più intelligenti e il tuo moltiplicatore di momentum supera 1,2. Quando perdi diversi round di fila, potresti essere "in tilt" - frustrato, commetti errori e il tuo moltiplicatore scende sotto 0,85. Il tracker tiene conto del fatto che il momentum svanisce nel tempo (vincere 3 round fa conta meno che vincere l'ultimo round) e si azzera all'intervallo (quando cambi campo). È come monitorare la "corsa" di una squadra di basket: un parziale di 10-0 crea momentum che influisce sulle prestazioni.

- Serie di vittorie: moltiplicatore = 1,0 + 0,05 × lunghezza della serie × decadimento
- Serie di sconfitte: moltiplicatore = 1,0 − 0,04 × lunghezza della serie × decadimento
- Decadimento: exp(−0,15 × gap_rounds)
- Limiti: [0,7, 1,4]
- Rilevamento inclinazione: moltiplicatore < 0,85
- Rilevamento hot: moltiplicatore > 1,2
- Reset di mezzo switch: Round 13 (MR12) e 16 (MR13)

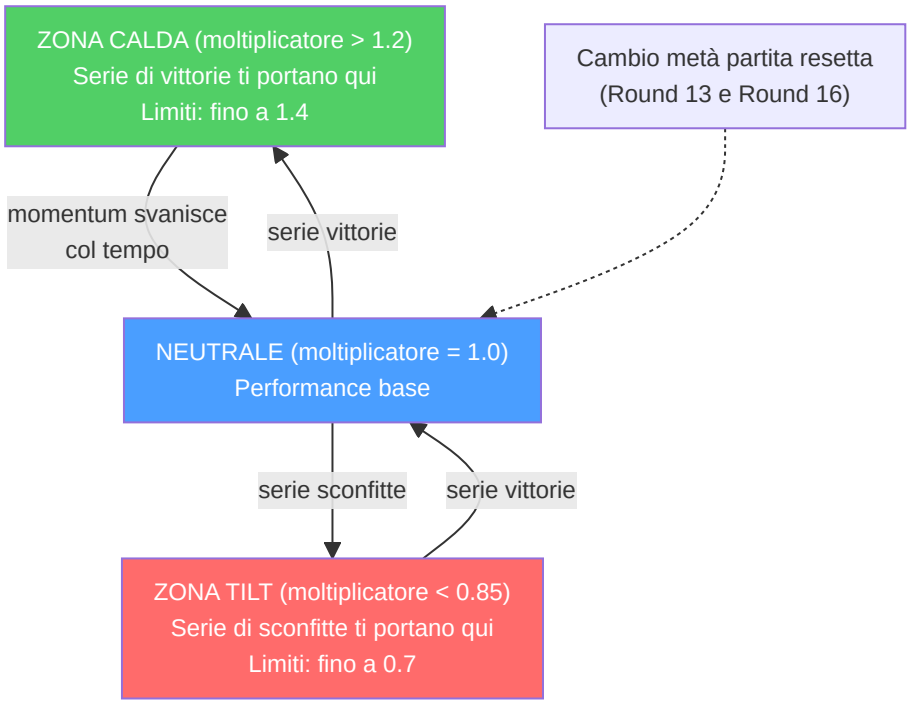

-Analizzatore di Entropia (`entropy_analysis.py`, ~145 righe)

Misura l'efficacia dell'utilità tramite la **riduzione di entropia di Shannon** delle posizioni nemiche:

> **Analogia:** L'entropia è una misura dell'**incertezza**: maggiore è l'entropia, maggiore è l'incertezza sulla posizione dei nemici. L'Analizzatore di Entropia chiede: "Prima di lanciare quel fumo, i nemici potevano trovarsi in 100 possibili posizioni (alta entropia). Dopo il fumo, potevano trovarsi solo in 30 posizioni (bassa entropia). Il tuo fumo ha ridotto l'incertezza del 70%, il che significa che è stato un fumo efficace!" È come giocare a nascondino: se stai perquisendo un'intera casa, ci sono molti nascondigli (alta entropia). Se chiudi la cucina e il bagno, ci sono meno nascondigli (bassa entropia). Una buona granata riduce il numero di posti di cui devi preoccuparti.

- Discretizza le posizioni in una griglia 32×32
- Calcola `H = −Σ p(cell) × log₂(p(cell))`
- Impatto di utilità = `H_pre − H_post` (positivo = informazione ottenuta)

- Riduzioni massime di entropia: Smoke 2,5 bit, Molotov 2,0, Flash 1,8, HE 1,5

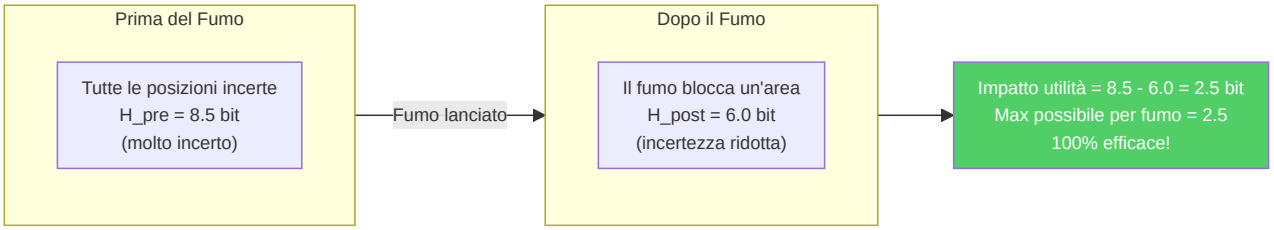

-Rilevatore di Punti Ciechi (`blind_spots.py`, ~210 righe)

Identifica decisioni ricorrenti non ottimali rispetto alle raccomandazioni dell'albero di gioco:

> **Analogia:** Il Rilevatore di Punti Ciechi è come un **istruttore di guida** che si accorge che dimentichi sempre di controllare gli specchietti prima di cambiare corsia. Confronta ciò che hai effettivamente fatto in ogni round con ciò che l'albero di gioco ha indicato come azione ottimale. Se continui a spingere quando dovresti tenere, o continui a tenere quando dovresti ruotare, segnala questo come un "punto cieco", un errore ricorrente di cui potresti non essere nemmeno consapevole. Più spesso si verifica un errore E maggiore è il suo impatto, maggiore è la sua priorità. Quindi genera un piano di allenamento specifico: "Tendi a spingere nelle situazioni post-atterraggio quando è meglio tenere. Esercitati nel posizionamento passivo post-atterraggio."

- Confronta le azioni reali dei giocatori con le azioni ottimali di `ExpectiminimaxSearch`
- Classifica le situazioni (post-impianto, frizione, eco, round avanzato, vantaggio numerico)
- Priorità = `frequenza × impact_rating`
- Genera piani di allenamento in linguaggio naturale per i punti ciechi principali

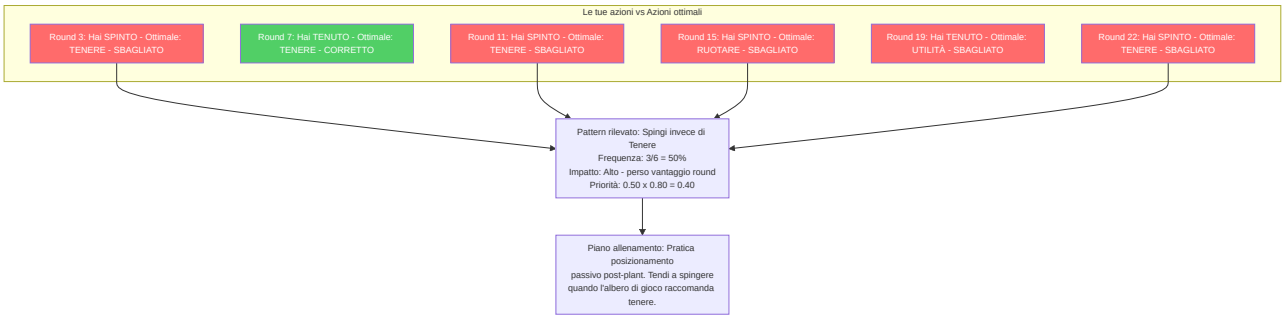

-Analizzatore distanza di ingaggio (`engagement_range.py`, ~442 righe)

Analizza le distanze di uccisione per costruire **profili di ingaggio** specifici per ruolo e posizione:

> **Analogia:** L'Analizzatore di Engagement Range è come un **analista sportivo che studia dove un giocatore segna i gol**. Un centravanti segna principalmente da dentro l'area (ravvicinata), un centrocampista da media distanza e un difensore da lontano su calci piazzati. Allo stesso modo, un AWPer dovrebbe ottenere più uccisioni a lunga distanza, mentre un Entry Fragger dovrebbe eccellere nel combattimento ravvicinato. Se il tuo profilo di distanza non corrisponde al tuo ruolo, il coach ti dice "Stai combattendo troppo da vicino per un AWPer" o "Non sfrutti abbastanza le linee di vista lunghe".

Componenti principali:

Componente	Scopo
`NamedPositionRegistry`	Registro di callout per mappa (es. "A Site", "Window", "Banana") con coordinate 3D e raggio
`EngagementRangeAnalyzer`	Calcolo distanza euclidea killer-vittima, classificazione e confronto con baseline pro
`EngagementProfile`	Distribuzione % per fascia: close (<500u), medium (500-1500u), long (1500-3000u), extreme (>3000u)

Baseline pro per ruolo:

Ruolo	Close	Medium	Long	Extreme
AWPer	10%	30%	45%	15%
Entry Fragger	40%	40%	15%	5%
Supporto	25%	45%	25%	5%
Lurker	35%	35%	20%	10%
IGL/Flex	25%	40%	25%	10%

Soglia di deviazione: Una differenza >15% rispetto alla baseline del ruolo genera un'osservazione di coaching (es. "Più uccisioni ravvicinate del tipico AWPer — considera angoli più lunghi").

Mappe supportate: de_mirage, de_inferno, de_dust2, de_anubis, de_nuke, de_ancient, de_overpass, de_vertigo, de_train (non nell'Active Duty pool attuale, supportata per demo storiche/workshop) — espandibile via JSON.

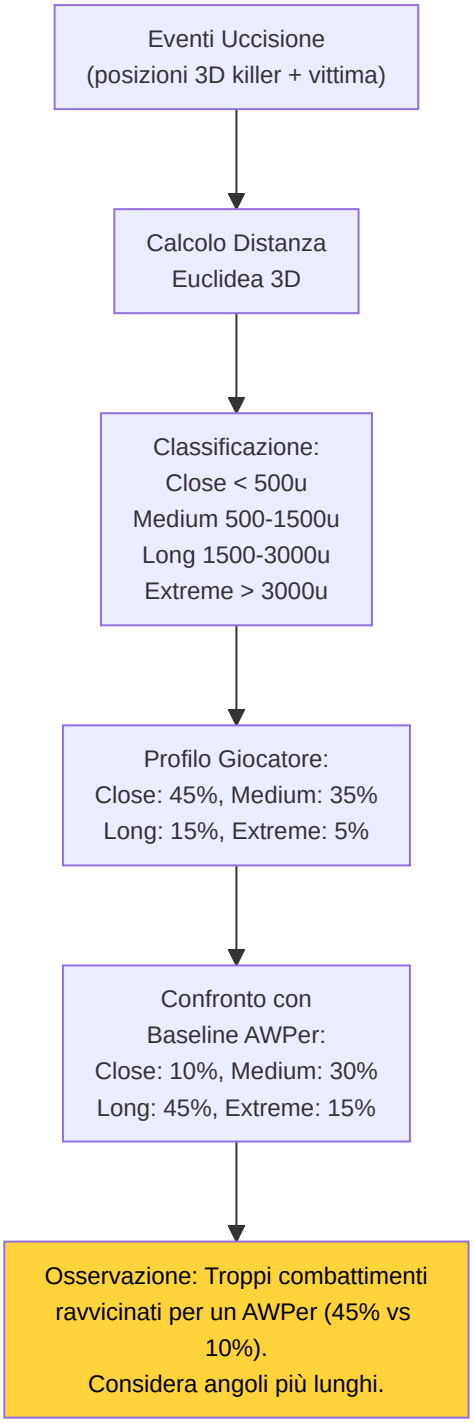

-Analizzatore di utilità ed economia (`utility_economy.py`, ~370 righe)

Analizzatore di utilità: Punteggio di efficacia per tipo rispetto alle basi dei professionisti (Molotov: 35 danni/lancio, Flash: 1,2 nemici/flash, ecc.)

Ottimizzatore di economia: Consigli di acquisto basati su soglie economiche ($5000 acquisto completo, $2000 forza, <$2000 economia), contesto del round, differenziale di punteggio e bonus di sconfitta.

Analogia: L'**Analizzatore di utilità** è come una **pagella delle granate**: controlla se le tue molotov stanno infliggendo lo stesso danno di quelle di un professionista (35 danni per lancio è il parametro di riferimento), se le tue granate accecanti stanno accecando abbastanza nemici (i professionisti infliggono in media 1,2 nemici per flash) e così via. **Economy Optimizer** è come un **consulente finanziario per CS2**: ti dice quando spendere molto (acquisto completo: oltre $5000), quando risparmiare (eco: meno di $2000) e quando correre un rischio calcolato (acquisto forzato: $2000-$5000). Considera anche il quadro generale: "Il punteggio è 12-10 e stai perdendo: forse un acquisto forzato vale il rischio".

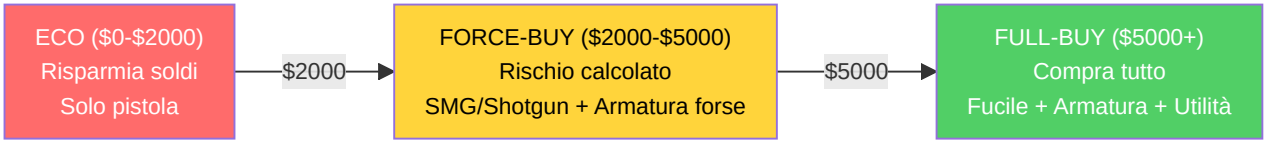

Riepilogo dei 10 Motori di Analisi

#	Motore	File	Input	Output	Complessità
1	Classificatore Ruoli	`role_classifier.py`	PlayerMatchStats	Ruolo (6 classi) + confidenza	O(n) features
2	Probabilità Vittoria	`win_probability.py`	12 feature stato round	P(CT win) ∈ [0,1]	O(1) forward pass
3	Albero di Gioco	`game_tree.py`	Stato round + azioni	Nodo ottimale (minimax)	O(b^d) branching
4	Morte Bayesiana	`belief_model.py`	Posizione + tempo + round	P(morte) + fattori rischio	O(n) prior update
5	Indice Inganno	`deception_index.py`	Storico round + posizioni	Score imprevedibilità [0,1]	O(n×m) pattern match
6	Tracker Momentum	`momentum.py`	Sequenza round	Stato hot/cold/neutral	O(n) sliding window
7	Analizzatore Entropia	`entropy_analysis.py`	Danni utility per tipo	Score efficacia vs pro	O(k) per tipo utility
8	Rilevatore Punti Ciechi	`blind_spots.py`	Posizioni morte + angoli	Pattern ripetuti	O(n²) clustering
9	Utilità ed Economia	`utility_economy.py`	Economia round + utility	Consiglio acquisto + rating	O(1) threshold check
10	Analizzatore Ingaggio	`engagement_range.py`	Kill events 3D	Profilo distanza (4 fasce)	O(n) euclidean dist

8. Sottosistema 6 — Elaborazione e Feature Engineering

Directory: `backend/processing/`

Questo sottosistema gestisce tutta la **preparazione dei dati**, trasformando le registrazioni grezze del gioco nei formati numerici precisi di cui le reti neurali hanno bisogno per l'addestramento e l'inferenza.

> **Analogia:** Questa è la **stazione di preparazione** della fabbrica. Prima che gli chef (reti neurali) possano cucinare, gli ingredienti (dati grezzi del gioco) devono essere lavati, sbucciati, tagliati e misurati. L'Estrattore di Feature è il capo cuoco che si assicura che tutto venga tagliato esattamente della stessa dimensione ogni volta. La Fabbrica dei Tensori crea "foto di cibo" perfette dello stato del gioco. La Pipeline dei Dati è il lavapiatti e l'organizzatore che pulisce i dati errati e ordina tutto in pile per l'addestramento/test. Senza questa stazione di preparazione, gli chef riceverebbero ingredienti grezzi e incoerenti e produrrebbero cibo pessimo.

-Estrattore di Feature Unificato (`vectorizer.py`)

L'**unica fonte di verità** per i vettori di feature a livello di tick. Sia l'addestramento (`RAPStateReconstructor`) che l'inferenza (`GhostEngine`) DEVONO utilizzare questa classe.

> **Analogia:** L'Estrattore di Feature è il **traduttore universale** del sistema. Prende dati complessi e disordinati sullo stato del gioco (la posizione di un giocatore nello spazio 3D, la salute, le armi, ciò che vede, ecc.) e li traduce esattamente in 25 numeri precisi, ciascuno scalato per adattarsi tra -1 e 1 (o 0 e 1). Immaginatelo come convertire ogni misura di una ricetta nella stessa unità: invece di mescolare tazze, cucchiai, grammi e litri, tutto viene convertito in millilitri. In questo modo, ogni parte del sistema parla lo stesso "linguaggio a 25 numeri". Se l'addestramento utilizza un traduttore e l'inferenza ne utilizza uno diverso, i risultati sarebbero spazzatura, quindi esiste un SOLO traduttore, condiviso ovunque.

Contratto vettoriale di feature a 25 dimensioni:

Indice	Feature	Normalizzazione	Intervallo
0	`health`	`/100`	[0, 1]
1	`armor`	`/100`	[0, 1]
2	`has_helmet`	binario	{0, 1}
3	`has_defuser`	binario	{0, 1}
4	`equipment_value`	`/10000`	[0, 1]
5	`is_crouching`	binario	{0, 1}
6	`is_scoped`	binario	{0, 1}
7	`is_blinded`	binario	{0, 1}
8	`enemies_visible`	`/5` (bloccato)	[0, 1]
9	`pos_x`	`/4096`	[−1, 1]
10	`pos_y`	`/4096`	[−1, 1]
11	`pos_z`	`/1024`	[−1, 1]
12	`view_yaw_sin`	`sin(yaw_rad)`	[−1, 1]
13	`view_yaw_cos`	`cos(yaw_rad)`	[−1, 1]
14	`view_pitch`	`/90`	[−1, 1]
15	`z_penalty`	`compute_z_penalty()`	[0, 1]
16	`kast_estimate`	KAST da statistiche o 0,70 predefinito	[0, 1]
17	`map_id`	Codifica deterministica basata su hash	[0, 1]
18	`round_phase`	0=pistola, 0,33=eco, 0,66=forza, 1=pieno	[0, 1]
19	`weapon_class`	Mappatura classi arma (0-1)	[0, 1]
20	`time_in_round`	`/115` (secondi nel round)	[0, 1]
21	`bomb_planted`	binario	{0, 1}
22	`teammates_alive`	`/4` (compagni vivi)	[0, 1]
23	`enemies_alive`	`/5` (nemici vivi)	[0, 1]
24	`team_economy`	`/16000` (media soldi team)	[0, 1]

Decisioni progettuali:

- **Codifica ciclica dell'imbardata** (sin/cos agli indici 12-13) elimina la discontinuità di ±180°
- **Penalità Z** (indice 15) quantifica il rischio di livello errato per mappe multilivello
- **Integrazione del contesto tattico** (indici 19-24) fornisce al modello consapevolezza della situazione di gioco

- **Catena di fallback della stima KAST:** valore esplicito → calcolo dalle statistiche → valore predefinito 0,70
- **Codifica dell'identità della mappa:** l'hash deterministico consente l'apprendimento specifico della mappa
- **HeuristicConfig** (`base_features.py`) consente di sovrascrivere tutti i limiti di normalizzazione tramite JSON

> **Spiegazione delle decisioni progettuali:** La **codifica ciclica dell'imbardata** (sin/cos) risolve un problema insidioso: se si codifica la direzione in cui un giocatore guarda come un singolo angolo, guardare a sinistra (-179°) e guardare a destra (+179°) sembrano molto distanti matematica, anche se sono quasi nella stessa direzione. Usando seno e coseno, la matematica capisce correttamente che sono vicini, come avvolgere un righello in un cerchio in modo che 0° e 360° si tocchino. La **penalità Z** è un "allarme piano sbagliato": su mappe multilivello come Nuke, trovarsi al piano sbagliato è un disastro, quindi il modello traccia esplicitamente questo rischio. L'**integrazione tattica** (economia, vivi, tempo) permette al coach di capire se una giocata aggressiva è corretta in base al tempo rimasto o al vantaggio numerico.

-Valutazione HLTV 2.0 (`rating.py`)

Il **modulo di valutazione unificato** che previene l'inferenza-distorsione nell'addestramento:

```
R = (R_kill + R_survival + R_kast + R_impact + R_damage) / 5

dove:
R_kill = KPR / 0,679
R_survival = (1 − DPR) / 0,317
R_kast = KAST / 0,70
R_impact = (2,13·KPR + 0,42·ADR/100) / 1,0
R_damage = ADR / 73,3
```

> **Analogia:** La valutazione HLTV 2.0 è come una **media dei voti (GPA)** per i giocatori di CS2. Invece di calcolare la media dei voti di Matematica, Inglese, Scienze, Storia e Arte, calcola la media di cinque "materie" di CS2: Tasso di uccisioni, Tasso di sopravvivenza, KAST (la frequenza con cui hai contribuito), Impatto (l'impatto delle tue uccisioni) e Danno (l'entità totale dei danni inflitti). Ogni materia è normalizzata dalla media dei professionisti (come una valutazione su una curva): se i professionisti hanno una media di 0,679 uccisioni a round, ottenere 0,679 KPR ti dà una "B" (1,0). Ottenere di più ti dà una "A+" e ottenerne di meno ti dà una "C". Il fatto che sia l'allenamento che l'inferenza utilizzino esattamente la stessa formula impedisce la "distorsione tra addestramento e inferenza", ovvero assicurarsi che la stessa griglia di valutazione venga utilizzata sia per i test di pratica che per l'esame finale.

Utilizzato da: demo_parser.py (analisi), base_features.py (aggregazione), coaching_service.py (insight).

-Tensor Factory (`tensor_factory.py`)

Converte i dati tick grezzi in tensori di immagini 64x64 per il livello di percezione RAP:

Tensor	Canali	Contenuto
Mappa	3 (R/G/B)	R: posizione del giocatore, G: compagni di squadra (α-blended), B: nemici (α-blended)
Vista	3	**Ch0:** maschera FOV corrente (90° predefinito, mascheramento trigonometrico); **Ch1:** zona di pericolo (= 1 − FOV accumulato sugli ultimi 8 tick), le aree mai controllate sono potenziali posizioni nemiche; **Ch2:** zona sicura (= 1 − FOV corrente − zona di pericolo), l'area tra la vista attuale e le zone inesplorate
Movimento	2 o 3	Mappe di calore di velocità/accelerazione (gocce 2D sfocate gaussiane)

Correzione G-02 (Zona di Pericolo): In precedenza, il tensore vista aveva 3 canali identici (placeholder). Dopo la rimediazione, i 3 canali codificano informazioni tattiche distinte: il **FOV corrente** mostra ciò che il giocatore vede adesso, la **zona di pericolo** accumula la storia FOV degli ultimi 8 tick (~125ms a 64 Hz) e inverte il risultato per identificare le aree mai controllate — dove i nemici potrebbero nascondersi — e la **zona sicura** rappresenta l'area intermedia tra vista attuale e zone inesplorate. Il calcolo della zona di pericolo usa `np.maximum(accumulated_fov, tick_fov)` per ogni tick storico, poi `danger_zone = 1.0 - accumulated_fov`. Questo fornisce al modello RAP una consapevolezza spaziale della copertura visiva, trasformando il tensore vista da un semplice input statico a un **indicatore tattico temporale**.

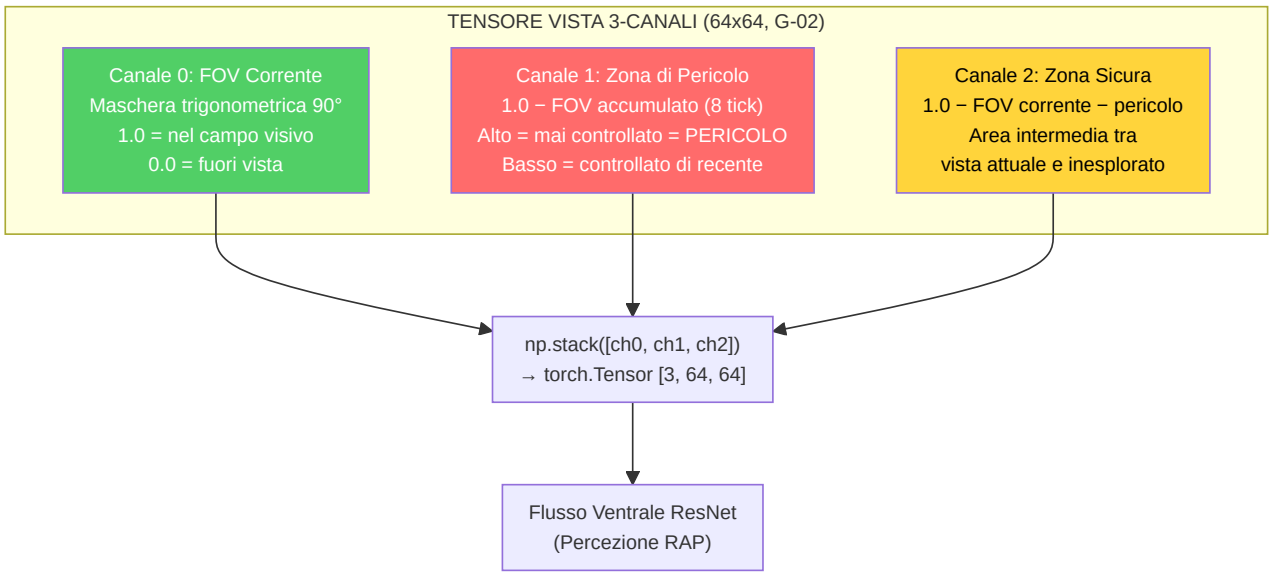

> **Analogia:** Tensor Factory crea **piccoli dipinti da 64x64 pixel** della situazione di gioco che l'allenatore RAP può osservare. Il **tensore mappa** è come un dipinto a volo d'uccello: il giocatore è un punto rosso, i compagni di squadra sono punti verdi, i nemici sono punti blu. Il **tensore vista** è lo stesso dipinto, ma con tutto ciò che si trova al di fuori del campo visivo di 90° del giocatore cancellato: è come indossare dei paraocchi, quindi il modello vede solo ciò che il giocatore poteva effettivamente vedere. Il **tensore movimento** è come una fotografia a lunga esposizione: i giocatori in rapido movimento lasciano scie luminose, i giocatori fermi sono invisibili. Insieme, questi tre "dipinti" offrono all'allenatore RAP una comprensione visiva completa di ogni momento.

-Heatmap Engine (`heatmap_engine.py`)

Mappe di occupazione gaussiane ad alte prestazioni per la visualizzazione tattica:

- Generazione di dati thread-safe (`generate_heatmap_data()`)
- Creazione di texture solo nel thread principale (OpenGL)
- Heatmap differenziali con rilevamento di hotspot per l'allenamento posizionale

> **Analogia:** Il motore Heatmap crea **mappe di calore**, simili alle mappe meteorologiche che si vedono in TV, ma per le posizioni dei giocatori. Le aree in cui si trova il giocatore spesso si illuminano di rosso, mentre le aree che non visita mai sono di un blu freddo. La heatmap "differenziale" mostra la differenza tra le TUE posizioni e quelle dei PRO: se un punto si illumina di rosso, ci stai troppo tempo rispetto ai professionisti; se si illumina di blu, non ci vai mai, ma i professionisti sì. Questa visualizzazione mostra immediatamente "passi troppo tempo in A e non abbastanza tempo a ruotare a centrocampo".

-Data Pipeline (`data_pipeline.py`)

`ProDataPipeline` gestisce la preparazione dei dati ML-ready:

1. **Recupera** tutti i `PlayerMatchStats` dal database
2. **Pulisce** i valori anomali (`avg_adr < 400`, `avg_kills < 3.0`)
3. **Ridimensiona** tramite `StandardScaler`
4. **Suddivide** temporalmente (70/15/15) con ordinamento cronologico per gruppo (pro/utente)
5. **Mantieni** la colonna `dataset_split` sul posto

> **Analogia:** Data Pipeline è come un **ufficio ammissioni scolastico** che prepara i fascicoli degli studenti per le lezioni. Per prima cosa, **estrae tutti i file** dal database. Quindi **rimuove gli imbroglioni**, ovvero chiunque abbia statistiche incredibilmente alte (un ADR superiore a 400 significa che probabilmente hanno usato hack o che i dati sono corrotti). Successivamente, **standardizza i voti** in modo che tutto sia sulla stessa scala. Quindi **ordina gli studenti cronologicamente** e assegna il 70% alla "classe di apprendimento" (formazione), il 15% alla "classe di quiz" (validazione) e il 15% alla "classe di esame finale" (test). La suddivisione temporale è fondamentale: significa che il modello non vede mai dati "futuri" durante l'addestramento, impedendo imbrogli dovuti ai viaggi nel tempo.

-Generatore di statistiche per round (`round_stats_builder.py`)

Collega gli eventi demo grezzi al **livello di isolamento per round** (`RoundStats` in `db_models.py`), impedendo la contaminazione statistica tra round e consentendo analisi dettagliate del coaching per round.

> **Analogia:** Invece di darti un voto per l'intero test, questo modulo valuta **ogni singola domanda individualmente** (statistiche per round), quindi ne calcola la media per la pagella finale (statistiche a livello di partita). Un brutto terzo round non abbassa silenziosamente il tuo punteggio del quindicesimo round: ogni round è indipendente. È come un insegnante che scrive commenti dettagliati su ogni problema dei compiti invece di assegnare solo un voto in lettere.

Funzioni chiave:

Funzione	Scopo
`build_round_stats(parser, demo_name)`	Analizza gli eventi round_end, player_death, player_hurt, player_blind e costruisce le statistiche per round
`enrich_from_demo(demo_path, demo_name)`	Arricchimento completo: uccisioni noscope/cieche, conteggio flash/fumo, assist flash, uccisioni con scambio, analisi delle utilità
`aggregate_round_stats_to_match(round_stats_list)`	Elabora le statistiche a livello di round → PlayerMatchStats a livello di partita
`compute_round_rating(round_stats)`	Valutazione HLTV 2.0 per round utilizzando il modulo di valutazione unificato

Pipeline di arricchimento:

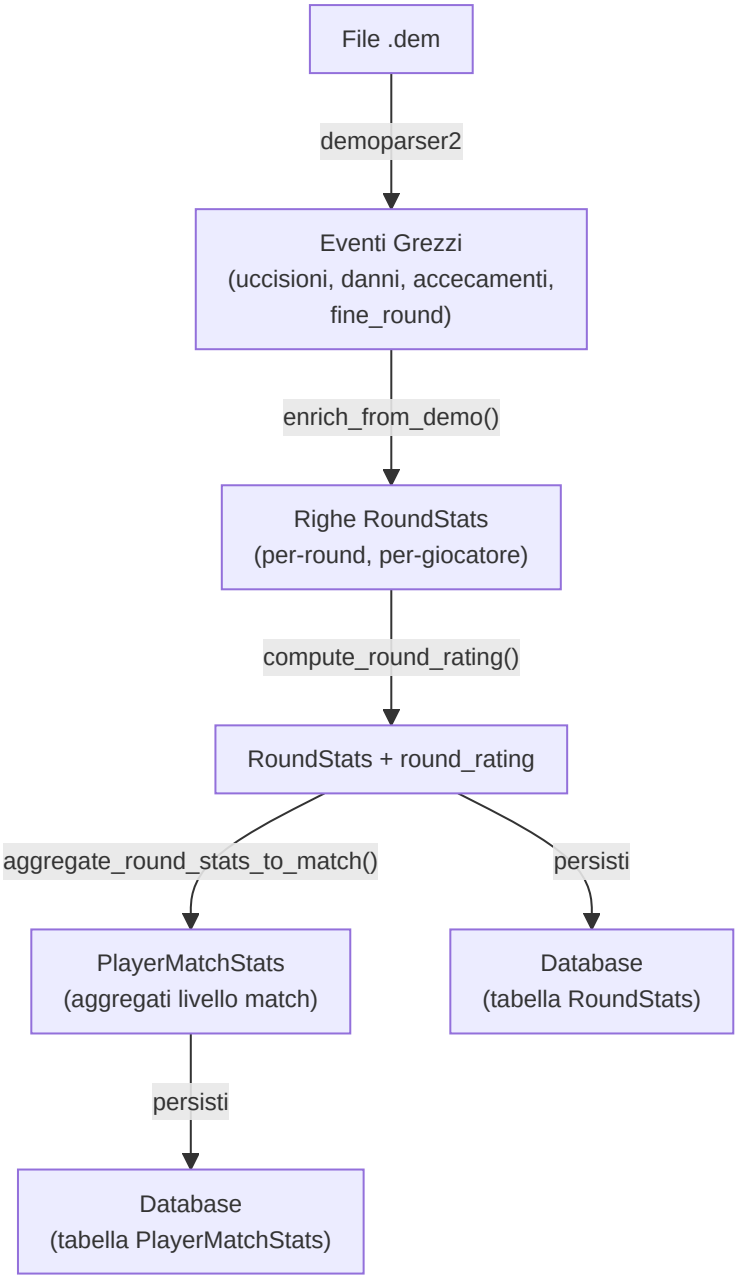

Campi di arricchimento uccisioni aggiunti da `enrich_from_demo()`:

Campo	Metodo di rilevamento
`noscope_kills`	Uccidi dove AWP/Scout/SSG è equipaggiato ma `is_scoped=False`
`blind_kills`	Uccidi dove `attacker_blinded=True` al momento della morte
`flash_assists`	Uccidi entro 128 tick (2 s) da un nemico colpito da un flash dalla stessa squadra
`thrusmoke_kills`	Uccidi attraverso granata fumogena (dai flag dell'evento demo)
`wallbang_kills`	Uccidi attraverso la penetrazione del muro (dai flag dell'evento demo)
`trade_kills`	Uccidi entro 5 s dalla morte di un compagno di squadra per mano dello stesso nemico

Integrazione con le pipeline di ingestione: Sia `user_ingest.py` che `pro_ingest.py` ora chiamano `enrich_from_demo()` dopo l'analisi della demo e rendono persistenti gli oggetti `RoundStats` risultanti nel database. Questo garantisce che ogni demo ingerita, utente o professionista, produca dati granulari a livello di round.

-Decadimento della baseline temporale (`pro_baseline.py`)

La classe `TemporalBaselineDecay` integra (non sostituisce) la funzione `get_pro_baseline()` esistente con una media ponderata nel tempo, garantendo che i confronti tra i coach riflettano l'**attuale meta CS2** piuttosto che le obsolete medie storiche.

> **Analogia:** I punteggi dei vecchi esami contano meno di quelli recenti nel calcolo della media della classe. Le statistiche di un giocatore professionista di 6 mesi fa sono "sbiadite" (meno importanti) rispetto alle statistiche della settimana scorsa. In questo modo, se il meta del gioco cambia, ad esempio l'utilizzo di AWP diminuisce dopo una patch di bilanciamento, la baseline si aggiorna automaticamente senza necessità di ricalibrazione manuale.

Formula di decadimento:

```
weight(age_days) = max(MIN_WEIGHT, exp(-ln(2) × age_days / HALF_LIFE))
```

Parametro	Valore	Significato
`HALF_LIFE_DAYS`	90	Il peso si dimezza ogni 90 giorni
`MIN_WEIGHT`	0,1	Soglia minima: dati molto vecchi contribuiscono ancora per il 10%
`META_SHIFT_THRESHOLD`	0,05	Una variazione del 5% tra le epoche segnala un cambiamento del meta

Metodi chiave:

Metodo	Scopo
`compute_weight(stat_date)`	Peso di decadimento esponenziale per una singola scheda statistica
`compute_weighted_baseline(stat_cards)`	Media/std ponderata nel tempo su tutti i record ProPlayerStatCard
`get_temporal_baseline(map_name)`	Pipeline completa: recupero schede → peso → unione con i valori predefiniti legacy
`detect_meta_shift(old, new)`	Segnala le metriche che hanno subito uno scostamento ≥ 5% tra le epoche di riferimento

Punti di integrazione:

- **CoachingService:** `_get_temporal_baseline()` lo utilizza per l'arricchimento COPER
- **Teacher Daemon:** `_check_meta_shift()` viene eseguito dopo ogni ciclo di riaddestramento, registrando le metriche che hanno subito uno scostamento

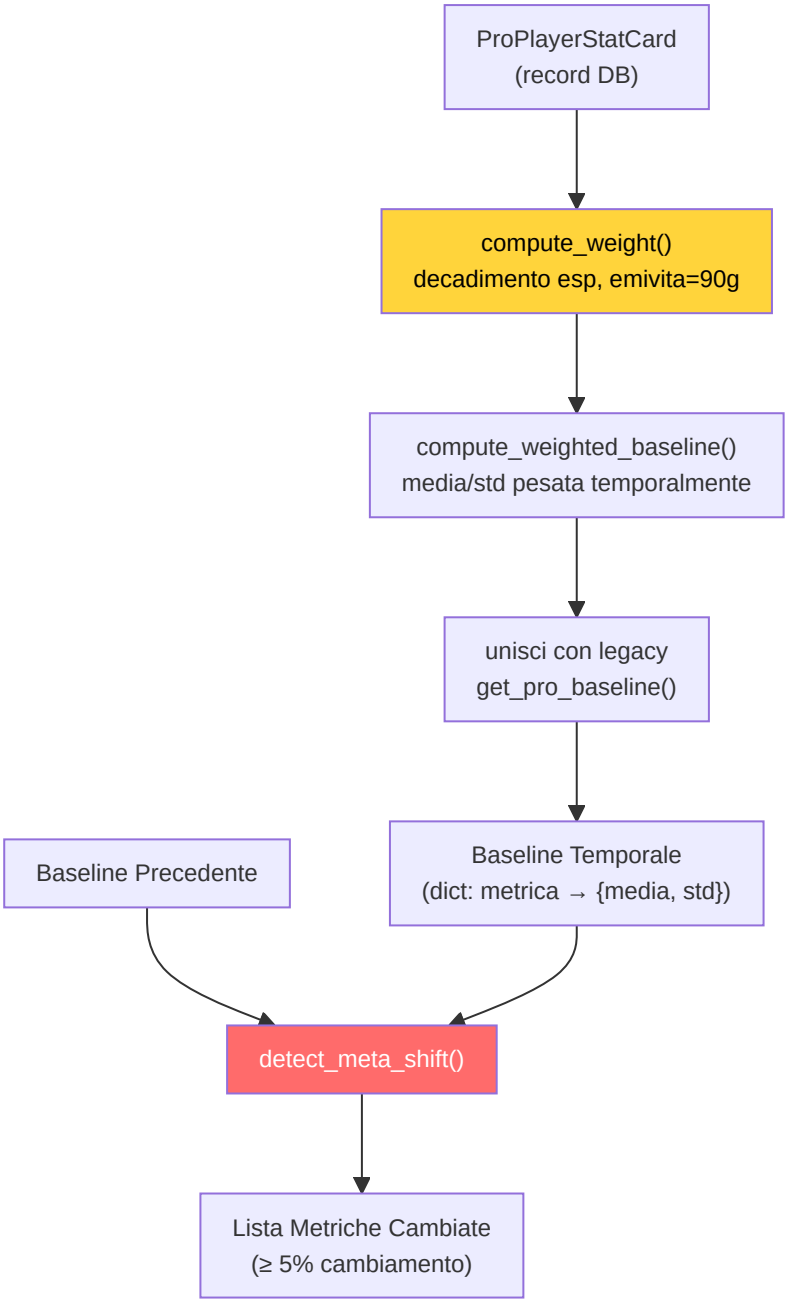

-Validazione (`validation/`)

- **drift.py:** Rilevamento della deriva nella distribuzione dei dati con oggetti DriftReport
- **schema.py:** Validazione dello schema per i record del database
- **sanity.py**** / dem_validator.py:** Controlli di integrità dei dati e dei file demo

> **Analogia:** Il sottosistema di convalida è l'**ispettore del controllo qualità** in fabbrica. Il rilevamento della deriva verifica: "I dati che riceviamo oggi sono simili a quelli su cui ci siamo formati o le cose sono cambiate?" (come controllare se la ricetta di un biscotto ha ancora lo stesso sapore del lotto del mese scorso). Controlli di convalida dello schema: "Ogni record del database ha tutti i campi obbligatori nel formato corretto?" (come assicurarsi che ogni modulo sia compilato completamente). I controlli di integrità verificano che i file demo siano reali, completi e non corrotti (come scuotere una scatola per assicurarsi che non sia vuota prima di spedirla).

Copertura quantitativa: Il progetto comprende **1.506 test** distribuiti su 78 file di test e **291+ controlli headless validator** articolati su 24+ fasi di validazione. Questa copertura spazia dall'integrità dello schema DB alla coerenza dei vettori di embedding, dalla correttezza delle pipeline di addestramento alla validazione end-to-end dei flussi di coaching.

-PlayerKnowledge — Sistema Percettivo NO-WALLHACK (`player_knowledge.py`, 527 righe)

Modello di percezione **Player-POV** che ricostruisce ciò che un giocatore legittimamente sa in ogni tick, senza informazioni da wallhack. Questo è il fondamento per coaching eticamente corretto: il coach vede solo ciò che il giocatore vedeva.

> **Analogia:** PlayerKnowledge è come le **regole della nebbia di guerra** in un gioco di strategia. In un RTS, non puoi vedere il nemico finché non entra nel tuo campo visivo. Allo stesso modo, questo sistema garantisce che il coach non "bari" usando informazioni che il giocatore non poteva avere: vede solo i nemici nel campo visivo, ricorda le ultime posizioni note con decadimento temporale (come la memoria umana che sbiadisce), e inferisce posizioni sonore entro distanze realistiche.

Dataclass di percezione:

Dataclass	Campi	Descrizione
`VisibleEntity`	position, distance, is_teammate, health, weapon	Entità visibile nel FOV
`LastKnownEnemy`	position, tick_seen, confidence	Posizione nemica dalla memoria (decadimento)
`HeardEvent`	position, distance, direction_rad, event_type	Evento sonoro percepito
`UtilityZone`	position, radius, utility_type, team	Zona utilità attiva
`PlayerKnowledge`	own_state, visible_entities, last_known, heard_events, utility_zones	Output completo

Costanti sensoriali:

Costante	Valore	Significato CS2
`FOV_DEGREES`	90.0	Campo visivo orizzontale CS2
`HEARING_RANGE_GUNFIRE`	2000.0	Distanza massima percezione spari (world units)
`HEARING_RANGE_FOOTSTEP`	1000.0	Distanza massima percezione passi
`MEMORY_DECAY_TAU`	160	Emivita memoria: 2.5s a 64 tick/s
`MEMORY_CUTOFF_TICKS`	320	Cutoff memoria: 5 secondi max
`SMOKE_RADIUS`	200.0	Raggio zona fumo
`MOLOTOV_RADIUS`	100.0	Raggio zona molotov

Pipeline percettiva:

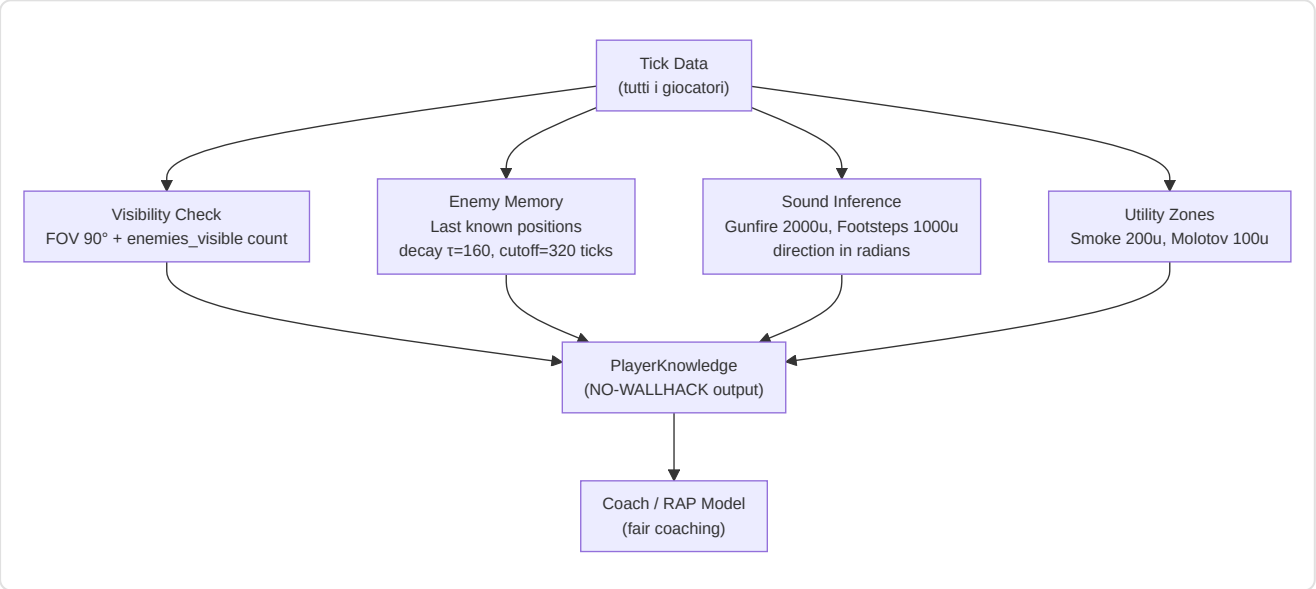

Verifica FOV: `_is_in_fov()` usa trigonometria (atan2 + angle_diff) per determinare se un target rientra nel campo visivo orizzontale del giocatore. Solo i nemici confermati visibili (dal contatore `enemies_visible` della demo) vengono inclusi.

-RAPStateReconstructor (`state_reconstructor.py`, 92 righe)

Vision Bridge Phase 1: Converte sequenze di `PlayerTickState` dal DB in tensori di percezione per il modello RAP-Coach:

- **Metadati:** Vettore METADATA_DIM (25) dal `FeatureExtractor` unificato
- **Percezione:** Tensori view/map/motion dalla `TensorFactory`
- **Player-POV:** Modalità opzionale via parametro `knowledge` (PlayerKnowledge)
- **Windowing:** Finestre temporali di `sequence_length=32` tick con overlap 50%

-ConnectMapContext (`connect_map_context.py`, 116 righe)

Feature spaziali Z-aware per mappe multilivello (Task 2.17.1):

Costante	Valore	Uso
`Z_LEVEL_THRESHOLD`	200	Separazione tra livelli (world units)
`Z_PENALTY_FACTOR`	2.0×	Moltiplicatore distanza cross-level

Output: Vettore di 6 feature spaziali normalizzate [0,1]: distanza da bombsite A/B, distanza da spawn T/CT, distanza da mid, penalità Z. Distanze calcolate con `distance_with_z_penalty()` per penalizzare percorsi cross-level su Nuke/Vertigo.

-CVFrameBuffer (`cv_framebuffer.py`, 183 righe)

Ring buffer thread-safe per frame RGB (Task 2.24.2) con estrazione regioni HUD:

Regione	Coordinate (1920×1080)	Contenuto
`MINIMAP_REGION`	(0, 0, 320, 320)	Minimappa (top-left)
`KILL_FEED_REGION`	(1520, 0, 1920, 300)	Kill feed (top-right)
`SCOREBOARD_REGION`	(760, 0, 1160, 60)	Scoreboard (top-center)

Dynamic resolution scaling: Tutte le regioni scalano automaticamente rispetto a `REFERENCE_RESOLUTION = (1920, 1080)` per supportare risoluzioni diverse. Conversione BGR→RGB integrata nel metodo `capture_frame()`.

-EliteAnalytics (`external_analytics.py`, 159 righe)

Carica e analizza dataset CSV di riferimento (top 100 giocatori, statistiche match, dati tornei):

- **7 dataset:** top100, top100_core, match_stats, player_stats, kills_processed, historical_stats, tournament_stats
- **Calcolo Z-score:** `_calc_z_scores()` confronta utente vs media storica per ADR, deaths, kills, rating, HS%
- **Z-score tornei:** `_calc_tournament_z()` confronta vs baseline tournament per accuracy, econ_rating, utility_value
- **Graceful degradation:** `is_healthy()` = True se ≥1 dataset caricato con successo

-MetaDriftEngine (`meta_drift.py`, 125 righe)

Pillar 2 Phase 3 — Meta-Drift Surveillance:

Confronta posizioni pro degli ultimi 30 giorni vs storico per rilevare cambiamenti nella meta:

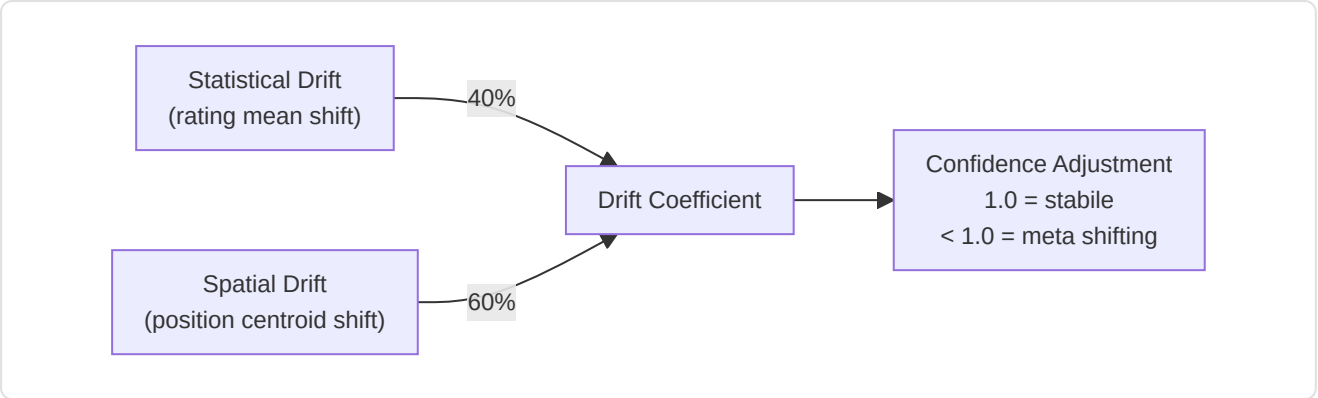

Integrazione: `HybridCoachingEngine._calculate_confidence()` chiama `MetaDriftEngine.get_meta_confidence_adjustment()` per penalizzare la confidenza degli insight quando la meta è instabile.

-NicknameResolver (`nickname_resolver.py`, 129 righe)

Task 2.18.2: Risolve nickname in-game delle demo in HLTV ProPlayer ID con matching a 3 livelli:

Livello	Metodo	Esempio
1. Esatto	Case-insensitive match	"s1mple" → ProPlayer.hltv_id
2. Sottostringa	Nickname contenuto nel nome demo	"FaZe_ropz" contiene "ropz"
3. Fuzzy	SequenceMatcher ≥ 0.8 threshold	"s1mpl3" ≈ "s1mple"

Gestisce tag di team e prefissi clan. Complessità O(n) per query, accettabile per <1.000 pro nel DB.

-ProBaseline (`pro_baseline.py`, 476 righe)

Task 2.18.1: Sistema di baseline pro con supporto map-specific e catena di fallback a 3 livelli:

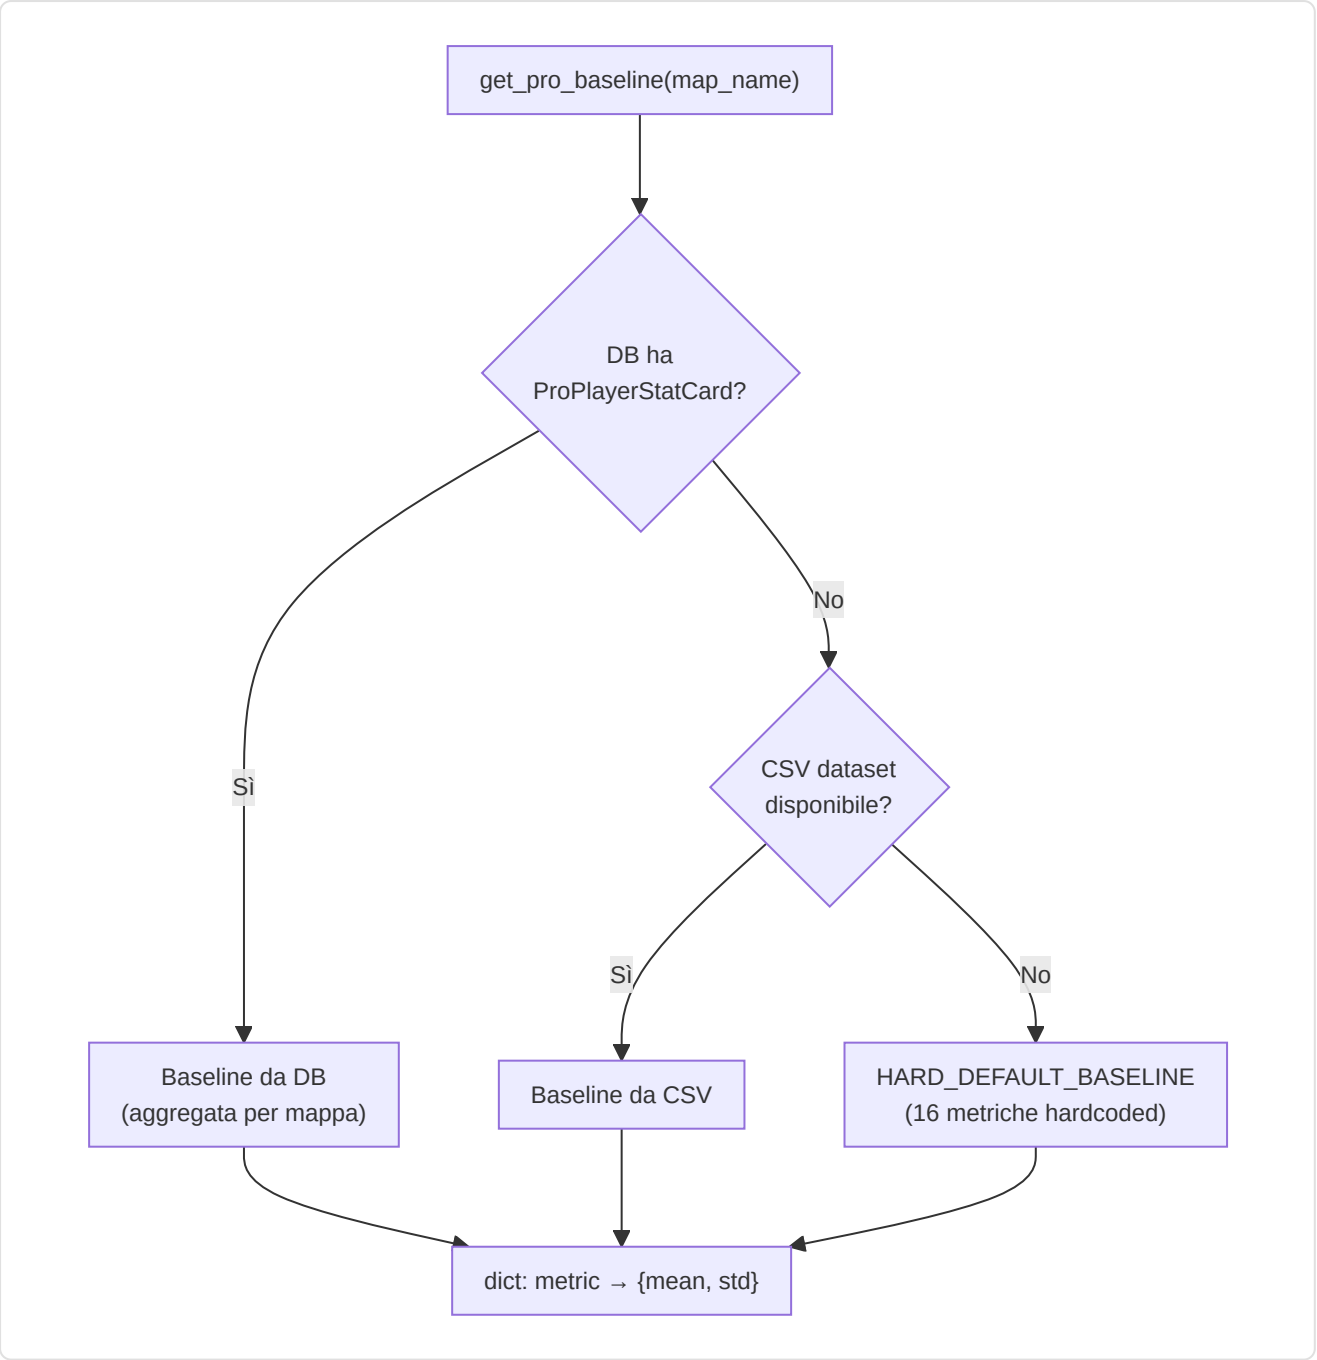

HARD_DEFAULT_BASELINE (16 metriche con mean + std):

Metrica	Mean	Std
rating	1.06	0.15
kpr	0.68	0.12
dpr	0.62	0.10
adr	77.8	12.0
kast	0.70	0.06
hs_pct	0.45	0.10
impact	1.05	0.20
opening_kill_ratio	1.05	0.30
clutch_win_pct	0.15	0.08
...	...	...

`calculate_deviations(player_stats, baseline)` — Calcola Z-score per ogni feature: `z = (player_value - mean) / std`. Gestisce sia baseline flat (legacy) che strutturate (dict con mean/std).

-RoleThresholdStore (`role_thresholds.py`, 268 righe)

Principio anti-mock: Tutte le soglie di ruolo apprendono esclusivamente da dati pro reali (HLTV, demo, ML):

Statistica	Descrizione	Cold-Start Default
`awp_kill_ratio`	% uccisioni con AWP	—
`entry_rate`	Tasso di entry frag	—
`assist_rate`	Tasso di assistenze	—
`survival_rate`	Tasso di sopravvivenza	—
`solo_kill_rate`	Tasso uccisioni solitarie	—
`first_death_rate`	Tasso prima morte	—
`utility_damage_rate`	Danno utilità per round	—
`clutch_rate`	Tasso di clutch vinti	—
`trade_rate`	Tasso di trade kill	—

Cold-start protection:

Requisito	Valore	Significato
`MIN_SAMPLES_FOR_VALIDITY`	10	Minimo campioni per soglia valida
Soglie valide minime	3	Per uscire dal cold-start
Cold-start output	`(FLEX, 0.0)`	Ruolo generico, 0% confidenza

Persistenza: `persist_to_db()` / `load_from_db()` — le soglie apprese sopravvivono ai riavvii. `validate_consistency()` verifica la coerenza interna (es. entry_rate non può essere negativo).

> **Analogia:** RoleThresholdStore è come un **medico che si rifiuta di diagnosticare** finché non ha visto abbastanza pazienti. "Non posso dirti se sei un AWPer perché ho visto solo 2 AWPer nella mia carriera. Torna quando avrò abbastanza esperienza." Ogni soglia è appresa dal percentile dei dati pro reali, non inventata. Se i dati cambiano (nuovo meta), le soglie si aggiornano automaticamente.

---

9. Sottosistema 7 — Modulo di Controllo

Cartella nella repo: `backend/control/` **File:** 4 moduli, ~900 righe totali

Questo sottosistema è la **torre di controllo** del sistema: supervisiona servizi background, governa i database, gestisce l'ingestione delle demo e controlla il ciclo di vita del training ML.

> **Analogia:** Se l'intero sistema è un **aeroporto**, il Modulo di Controllo è la **torre di controllo**. La Console è il controllore capo che vede tutti gli schermi. Il ServiceSupervisor è il responsabile del gate che avvia e ferma i voli (servizi). Il DatabaseGovernor è l'ispettore di sicurezza che verifica che le piste (database) siano integre. L'IngestionManager è il responsabile del carico bagagli che processa i bagagli (demo) in ordine. L'MLController è il responsabile della manutenzione che può avviare, fermare o mettere in pausa la manutenzione degli aerei (training).

-Console (`console.py`, 480 righe) — Singleton

La **Console di Controllo Unificata**: autorità centrale per ML, Ingestion e System State.

Componente	Ruolo
`ServiceSupervisor`	Supervisore background daemons (PID, liveness, auto-restart)
`IngestionManager`	Controller ingestione demo governato dall'operatore
`DatabaseGovernor`	Controller integrità database Tier 1/2/3
`MLController`	Supervisore ciclo di vita ML training

Sequenza di boot:

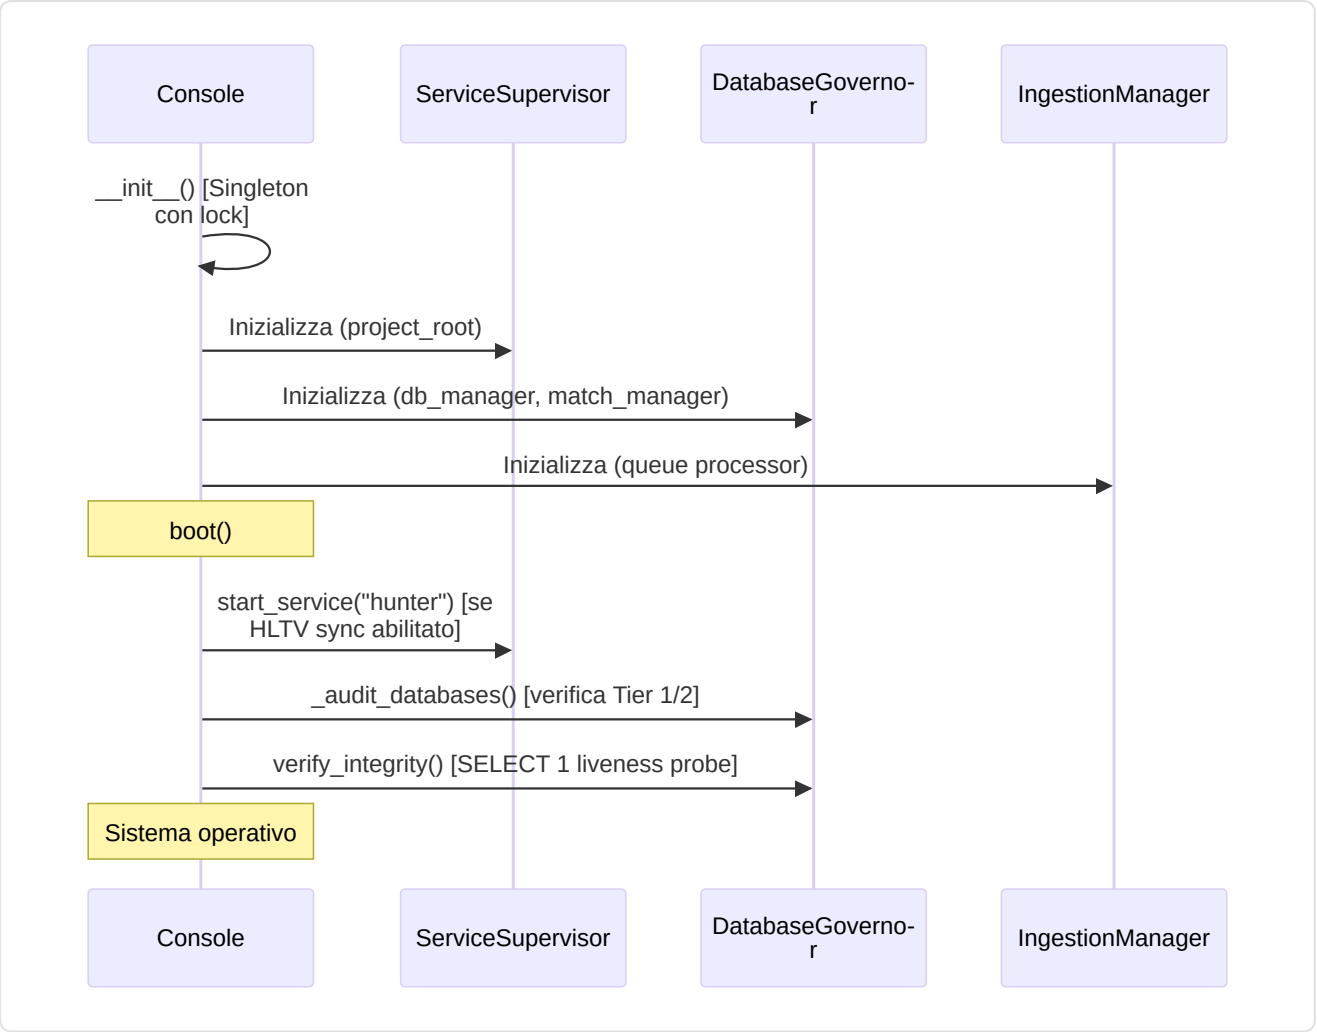

Cache di stato:

Cache	TTL	Contenuto
`_baseline_cache`	60s	Stato baseline temporale (stat_cards count, mode)
`_training_data_cache`	120s	Progresso demo (pro/user processed, on disk, trained_on)

Shutdown graceful: `shutdown()` → ferma hunter → ferma ingestion → ferma ML training → attende max 5s per conferma → log warning se timeout.

> **Correzione M-08 — Validazione file impostazioni:** `load_user_settings()` valida la struttura JSON al caricamento: verifica che il payload sia un `dict` (non una lista o un tipo primitivo), logga un errore dettagliato se la struttura è invalida, e applica un fallback graceful ai valori predefiniti. Questo impedisce che un file `settings.json` corrotto o manomesso provochi crash a cascata nel modulo di configurazione.
>
> **Correzione C-09 — Bootstrap anticipato:** Le fasi di bootstrap precedenti all'inizializzazione del logger utilizzano `print()` per i messaggi diagnostici. Questo evita il `NameError` che si verificava quando il codice tentava di chiamare `logger.info()` prima che il logger fosse stato configurato.

Aggregazione health report: `get_system_status()` → timestamp, state, services, teacher, ml_controller, ingestion, storage, baseline, training_data. Ogni sottosistema è isolato con `_safe_call()` — un errore in un sottosistema non impedisce il report degli altri.

-ServiceSupervisor (`console.py`, classe interna)

Gestore autorevole per daemon di background con auto-restart:

Costante	Valore	Descrizione
`_MAX_RETRIES`	3	Max auto-restart prima di arrendersi
`_RETRY_RESET_WINDOW_S`	3600 (1h)	Finestra reset contatore retry
`_RESTART_DELAY_S`	5.0	Delay tra tentativi di restart

Ciclo di vita servizio:

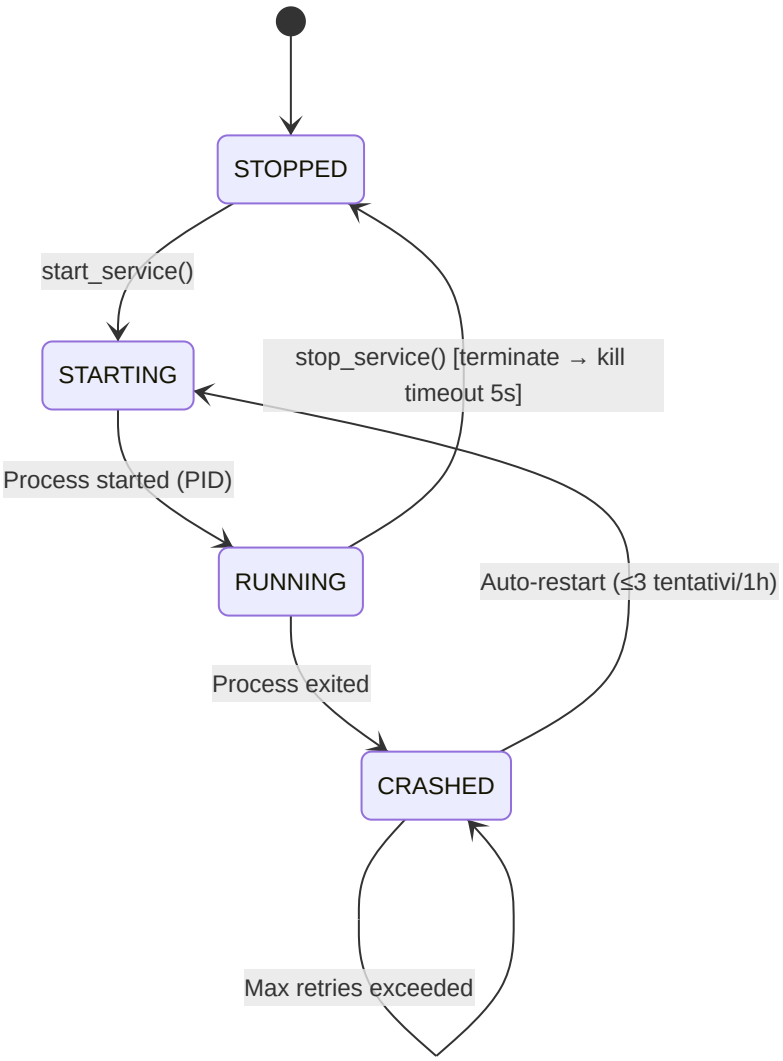

Servizi gestiti: Attualmente solo `hunter` (HLTV sync daemon: `hltv_sync_service.py`). Architettura estensibile per daemon aggiuntivi.

-DatabaseGovernor (`db_governor.py`, 111 righe)

Controller autorevole per Database Tier 1, 2 e 3:

Metodo	Scopo
`audit_storage()`	Calcola dimensione monolith + WAL + SHM, conta match Tier 3, rileva anomalie
`verify_integrity(full=False)`	Lightweight: `SELECT 1`; Full: `PRAGMA quick_check` (lento su DB grandi)
`prune_match_data(match_id)`	Cancellazione privilegiata dati telemetria match
`rebuild_indexes()`	Manutenzione: `REINDEX` via ORM engine

Anomalie rilevate:

- `CRITICAL: Monolith database.db not found!`
- `CRITICAL: hltv_metadata.db missing and no backup found.`
- `WARNING: hltv_metadata.db missing, but .bak exists. Restore required.`

Tier Architecture:

Tier	Database	Contenuto
Tier 1	`database.db` (monolith)	Giocatori, insight, profili, modelli, knowledge base
Tier 2	`hltv_metadata.db`	Metadati HLTV, ProPlayer, ProPlayerStatCard
Tier 3	`match_*.db` (per-match)	Dati telemetria tick-by-tick per partita

-IngestionManager (`ingest_manager.py`, 236 righe)

Controller di ingestione demo con 3 modalità operative:

Modalità	Comportamento
`SINGLE`	Processa una demo e si ferma
`CONTINUOUS`	Re-scan immediato, pausa 30s se nessun file trovato
`TIMED`	Re-scan ogni N minuti (default 30)

Ciclo unificato:

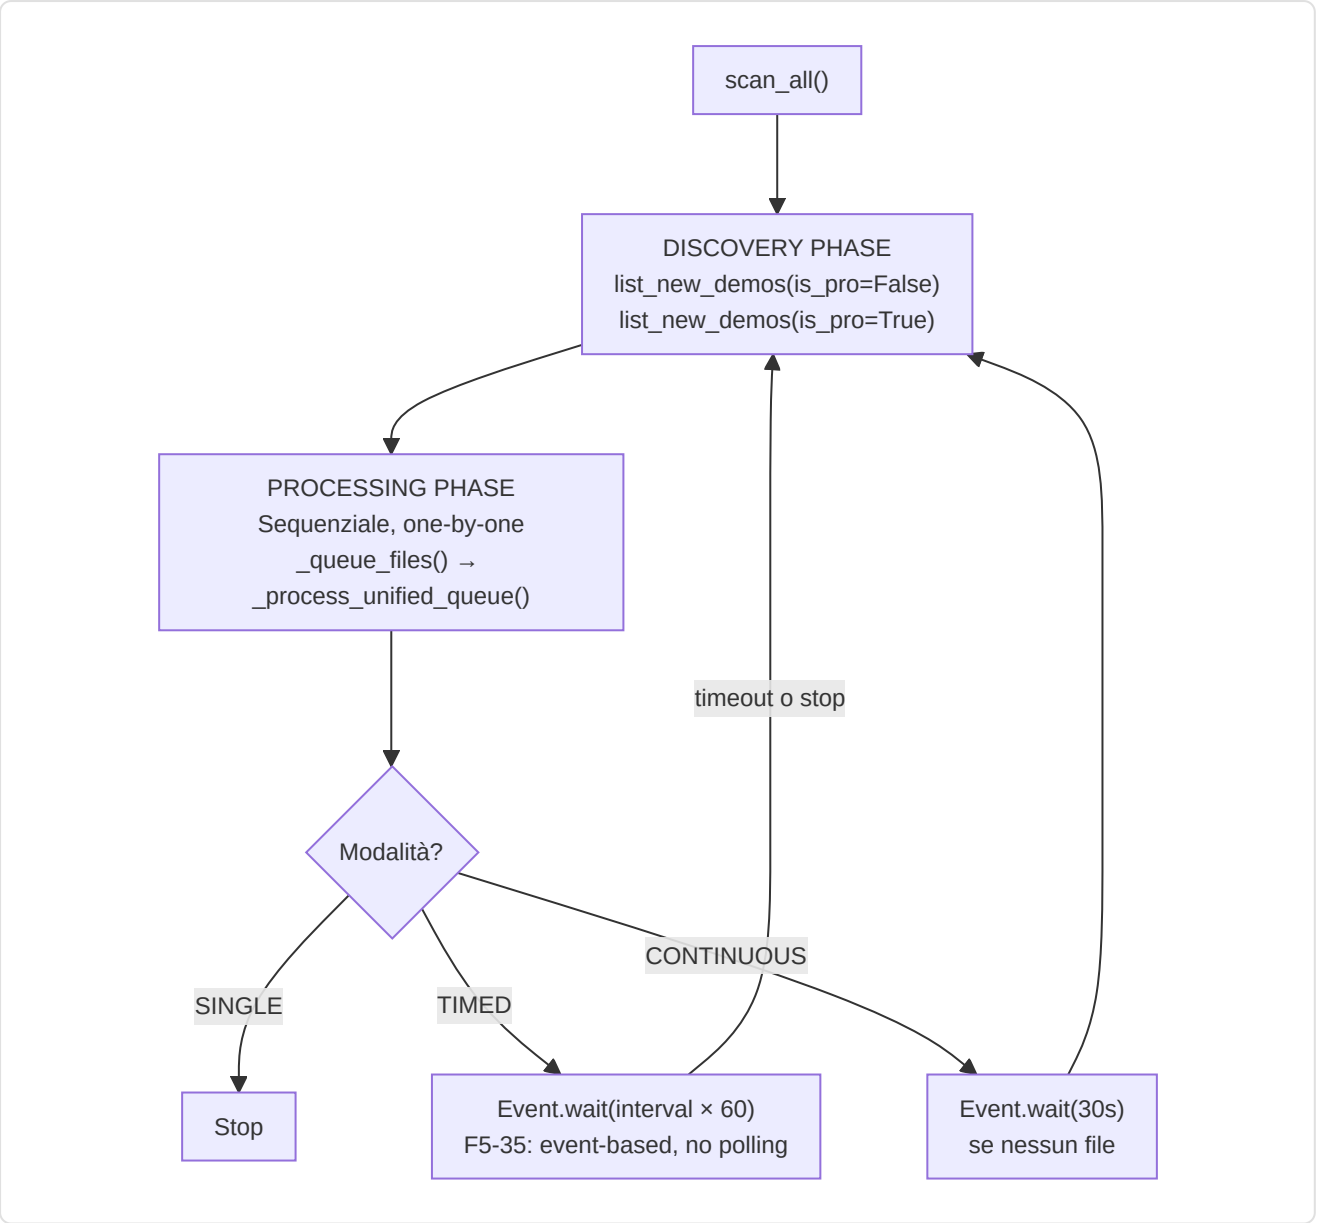

Segnale di stop (F5-35): `threading.Event()` per stop non-bloccante — elimina il polling a 1 secondo nelle wait loop.

Integrazione StateManager: Progresso parsing in tempo reale (0-100%) esposto via `state_manager.update_parsing_progress()`.

-MLController (`ml_controller.py`, 121 righe)

Supervisore del ciclo di vita ML con intervento in tempo reale:

Classe	Responsabilità
`MLControlContext`	Token di controllo passato ai loop ML
`MLController`	Supervisore thread-safe per training

MLControlContext — Comandi operatore:

Metodo	Effetto
`check_state()`	Blocca se pause attivo (F5-15 event-based), lancia `TrainingStopRequested` se stop
`request_stop()`	Soft-stop al prossimo checkpoint sicuro
`request_pause()`	Blocca `check_state()` via `_resume_event.clear()`
`request_resume()`	Sblocca via `_resume_event.set()`
`set_throttle(value)`	0.0 = full speed, 1.0 = max delay

Pipeline: `start_training()` → thread daemon → `CoachTrainingManager.run_full_cycle(context=self.context)` → `TrainingStopRequested` catturata per stop graceful → `set_error()` per crash.

> **Analogia:** MLController è come il **pannello di controllo di un reattore nucleare**. L'operatore può avviare il reattore (training), metterlo in pausa per ispezione, riprendere, o eseguire un arresto di emergenza (stop). Il `check_state()` che ogni loop ML deve chiamare è come le barre di controllo: il loop si ferma automaticamente al prossimo punto sicuro quando l'operatore tira la leva.

Coordinamento Inter-Daemon

Il Modulo di Controllo orchestra i 4 daemon del sistema (Hunter, Digester, Teacher, Pulse) attraverso canali di comunicazione basati su stato condiviso (`CoachState`) e segnali event-based:

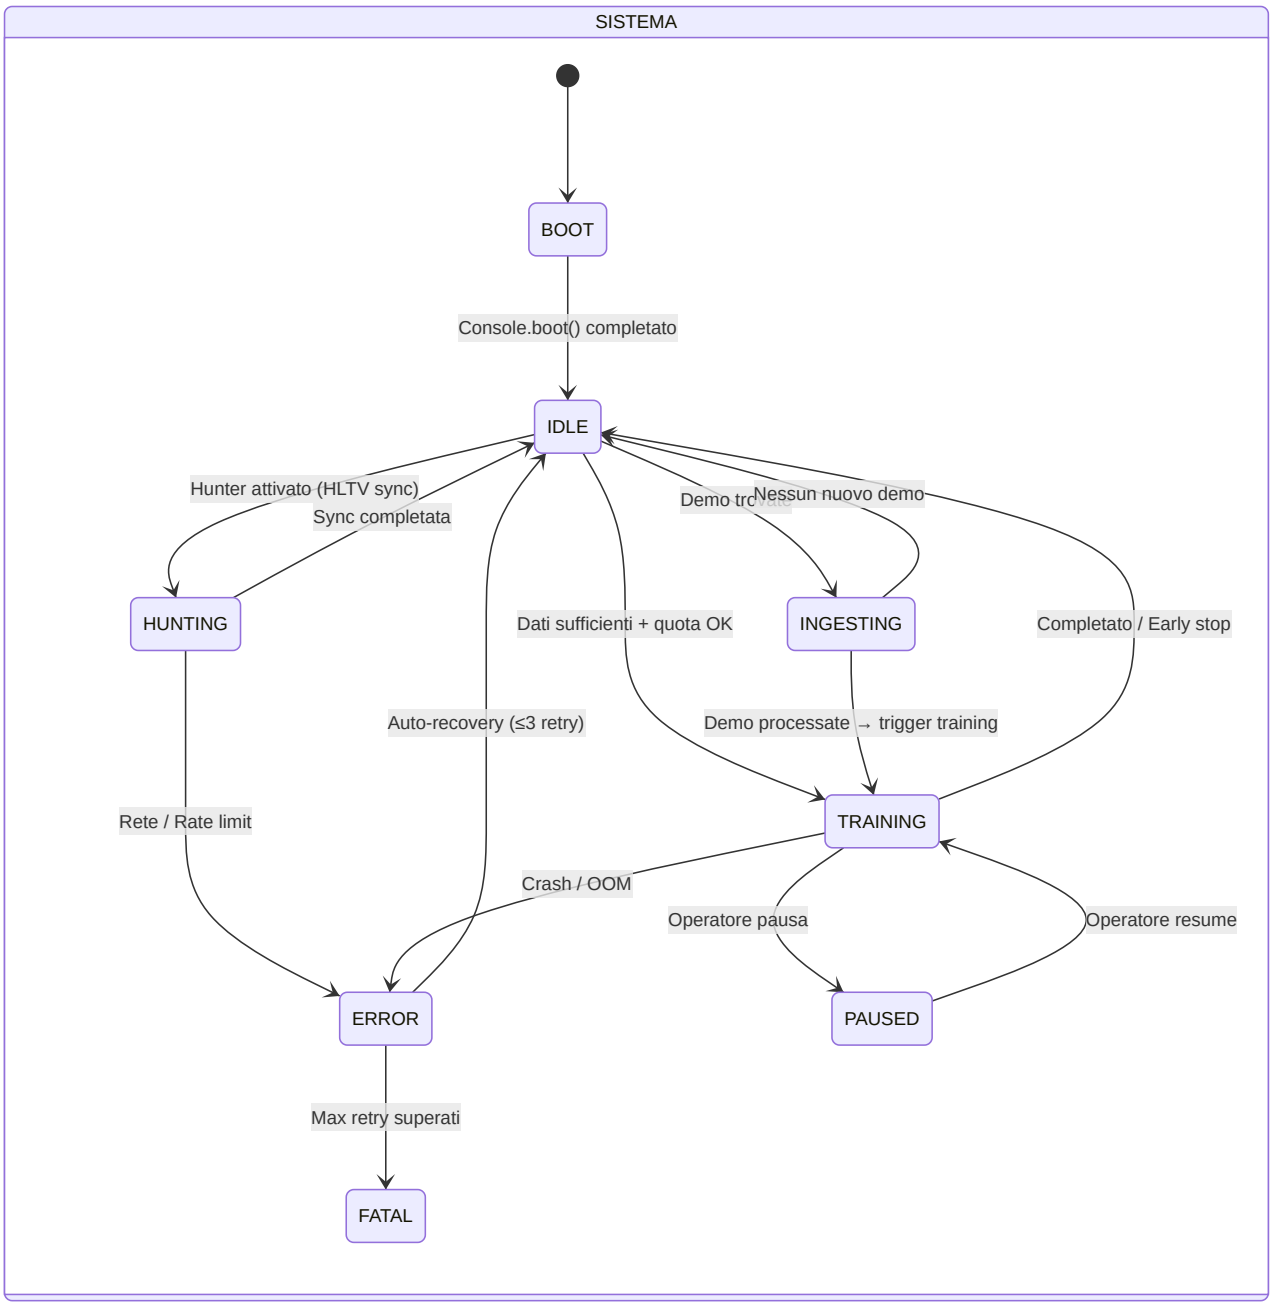

---

10. Sottosistema 8 — Progresso e Tendenze

Cartella nella repo: `backend/progress/` **File:** 2 moduli, 49 righe totali

Sottosistema leggero dedicato al tracciamento delle **traiettorie di performance** nel tempo.

-FeatureTrend (`longitudinal.py` , 10 righe)

Dataclass minimale che rappresenta il trend di una singola feature:

Campo	Tipo	Descrizione
`feature`	str	Nome della feature (es. "avg_adr")
`slope`	float	Pendenza della regressione lineare (positivo = miglioramento)
`volatility`	float	Deviazione standard dei valori (stabilità)
`confidence`	float	min(1.0, num_samples / 30) — richiede 30+ partite per piena fiducia

-TrendAnalysis (`trend_analysis.py`, 14 righe)

`compute_trend(values)` — Calcola slope, volatility e confidence da una serie di valori:

- **Slope:** Coefficiente lineare via `np.polyfit(x, y, 1)[0]`
- **Volatility:** `np.std(values)`
- **Confidence:** Scala linearmente con il numero di campioni, piena fiducia a 30+

Integrazione: I risultati di `compute_trend()` alimentano `FeatureTrend` → `LongitudinalEngine.generate_longitudinal_coaching()` → insight trend-aware nel coaching.

---

11. Sottosistema 9 — Database e Storage

Cartella nella repo: `backend/storage/` **File:** 10 moduli, ~2.600 righe totali

Questo sottosistema è il **sistema di archiviazione permanente** dell'intero progetto: ogni dato — dalle statistiche di una partita ai modelli addestrati, dalle esperienze di coaching ai profili dei giocatori professionisti — viene salvato, protetto, versionato e reso disponibile attraverso questa infrastruttura.

> **Analogia:** Se l'intero sistema di coaching è un **ospedale**, il sottosistema Storage è l'**archivio centrale e il sistema di cartelle cliniche**. Ci sono tre archivi separati (Tier 1, 2, 3) per evitare che chi consulta le cartelle dei pazienti (database.db) blocchi chi sta archiviando le statistiche dei medici specialisti (hltv_metadata.db) o chi sta registrando le telecamere di sorveglianza (match_*.db per-match). Il `DatabaseManager` è l'archivista capo che gestisce le chiavi degli armadi, il `BackupManager` è il responsabile della sicurezza che fa copie notturne di tutto, e il `MatchDataManager` è il tecnico che gestisce la sala delle telecamere dove ogni registrazione ha il suo nastro dedicato. Nessun dato viene mai perso: ci sono copie giornaliere, settimanali, verifiche di integrità e un sistema di migrazione che aggiorna gli archivi quando il formato delle cartelle cambia.

Architettura Tri-Database:

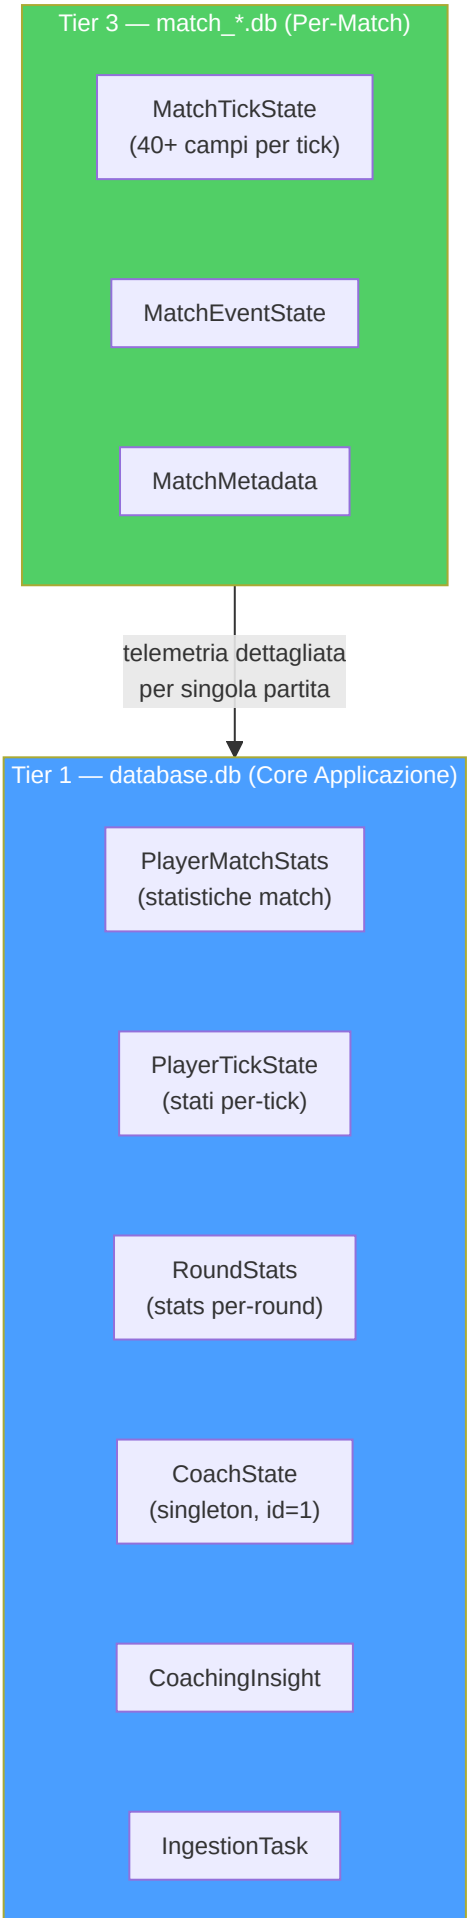
Tier 3 — match_*.db (Per-Match)
MatchTickState
(40+ campi per tick)
MatchEventState
MatchMetadata
telemetria dettagliata
per singola partita
Tier 1 — database.db (Core Applicazione)
PlayerMatchStats
(statistiche match)
PlayerTickState
(stati per-tick)
RoundStats
(stats per-round)
CoachState
(singleton, id=1)
CoachingInsight
IngestionTask

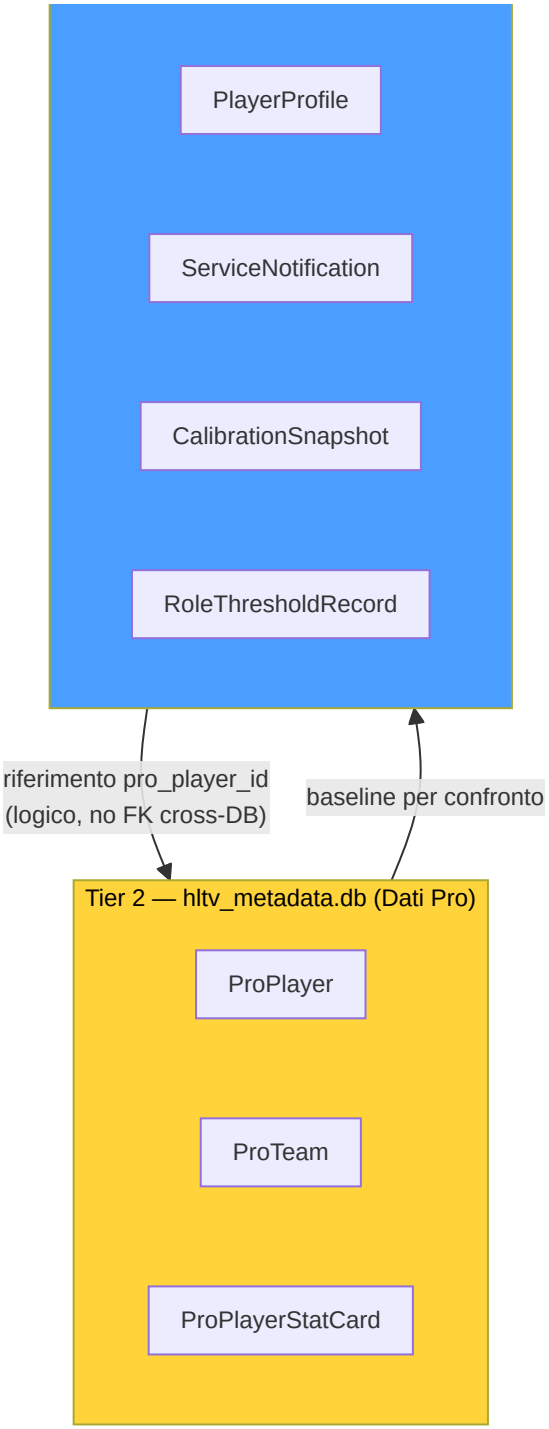

Spiegazione Diagramma: I tre database sono fisicamente separati: Tier 1 contiene i dati core dell'applicazione (17 tabelle), Tier 2 i dati professionali scaricati da HLTV (3 tabelle), e Tier 3 i dati di telemetria per-match in file SQLite individuali. La separazione evita contesa WAL: le scritture di ingestione (Tier 1) non bloccano le letture HLTV (Tier 2) né la registrazione di telemetria (Tier 3). I riferimenti cross-database sono **logici** (non FK reali) poiché SQLite non supporta FK cross-file.

-Modelli di Dati (`db_models.py` , 604 righe)

Il **codice genetico** di tutto il sistema: definisce ogni tabella, vincolo, indice e validatore tramite SQLModel (Pydantic + SQLAlchemy). Due enum e 20+ modelli organizzati per tier.

> **Analogia:** `db_models.py` è come il **progetto architettonico di un edificio**: specifica ogni stanza (tabella), le dimensioni delle porte (tipi dei campi), le serrature (vincoli CHECK e UNIQUE), e l'indice dell'edificio (indici del database). Se qualcuno prova a mettere un valore negativo per `avg_kills` , il progetto lo rifiuta prima ancora che venga scritto — come un architetto che rifiuta di costruire una stanza con altezza negativa.

Enum di integrità:

Enum	Valori	Uso
`DatasetSplit`	`TRAIN` , `VAL` , `TEST` , `UNASSIGNED`	Split ML nei `PlayerMatchStats`
`CoachStatus`	`Paused` , `Training` , `Idle` , `Error`	Stato pipeline ML nel `CoachState`

Costante di sicurezza: `MAX_GAME_STATE_JSON_BYTES = 16.384` (16 KB) — cap per `game_state_json` in `CoachingExperience` , validato da `@field_validator` Pydantic. Previene crescita illimitata del DB da snapshot di stato troppo grandi.

Catalogo dei modelli (Tier 1 — `database.db`):

Modello	Campi Chiave	Vincoli / Indici	Scopo
`PlayerMatchStats`	40+ campi: kills, ADR, rating, HLTV 2.0 components, trade metrics, utility breakdown	`UNIQUE(demo_name, player_name)`, `CHECK(avg_kills≥0)`, `CHECK(0≤rating≤5.0)`	Statistiche aggregate per partita per giocatore
`PlayerTickState`	pos_x/y/z, view_x/y, health, armor, weapon, enemies_visible, round context	`INDEX(demo_name, tick)`, `INDEX(player_name, demo_name)` (P2-05)	Stato giocatore per-tick per addestramento ML
`PlayerProfile`	player_name (unique), bio, role, profile_pic_path	`UNIQUE(player_name)`	Profilo utente con ruolo e bio
`Ext_TeamRoundStats`	equipment_value, damage, kills, deaths, accuracy	`INDEX(match_id)`, `INDEX(map_name)`	Statistiche round da CSV esterni (tornei)
`Ext_PlayerPlaystyle`	6 probabilità ruolo, metriche aggregate, config utente (social, specs, cfg)	`UNIQUE(steam_id)`	Dati playstyle + profilo utente (tabella conflata, candidata a split futuro)
`CoachingInsight`	title, severity, message, focus_area, user_id	`INDEX(player_name)`, `INDEX(demo_name)`	Feedback di coaching generati dal sistema
`IngestionTask`	demo_path (unique), status, retry_count, error_message	`UNIQUE(demo_path)`, `INDEX(status)`, R2-05: auto-refresh `updated_at`	Coda di ingestione demo con retry tracking
`TacticalKnowledge`	title, description, category, situation, embedding (384-dim JSON)	`INDEX(title)`, `INDEX(category)`, `INDEX(map_name)`	Base conoscenza RAG per coaching tattico
`CoachState`	status, daemon tracking (3 daemon), epoch/loss, heartbeat, resource limits	`CHECK(id=1)` singleton (P2-01)	Stato pipeline ML per la GUI — esattamente 1 riga
`ServiceNotification`	daemon, severity, message, is_read	`INDEX(daemon)`, `INDEX(is_read)`	Coda notifiche errori/eventi per la UI
`RoundStats`	kills, deaths, assists, damage, utility, economy, round_won, round_rating	`INDEX(demo_name, player_name)`, `INDEX(demo_name, round_number)` (P2-05)	Isolamento statistiche per-round per-giocatore
`CalibrationSnapshot`	calibration_type, parameters_json, sample_count, source	`INDEX(calibration_type)`	Storico calibrazione modello bayesiano
`RoleThresholdRecord`	stat_name (unique), value, sample_count, source	`UNIQUE(stat_name)`	Soglie ruolo apprese da dati pro

Modelli di match e pro (cross-tier):

Modello	Tier	Campi Chiave	Scopo
`MatchResult`	Tier 1	match_id (PK), team_a/b, winner, event_name	Metadati match
`MapVeto`	Tier 1	match_id (FK), map_name, action (pick/ban)	Veti mappe
`CoachingExperience`	Tier 1	context_hash, map/phase/side, game_state_json (16KB cap), action, outcome, embedding, effectiveness_score, feedback loop fields	Banca esperienze COPER con semantic search e feedback loop
`ProTeam`	Tier 2	hltv_id (unique), name, world_rank	Team professionistici
`ProPlayer`	Tier 2	hltv_id (unique), nickname, team_id (FK→ProTeam)	Giocatori professionisti
`ProPlayerStatCard`	Tier 2	player_id (FK), rating_2_0, kpr, adr, kast, detailed_stats_json	Schede statistiche HLTV con dati granulari

> **Nota architetturale:** `PlayerMatchStats.pro_player_id` è un riferimento **logico** (non una FK reale) a `ProPlayer.hltv_id` perché risiedono in database separati. SQLite non supporta FK cross-file — il join viene effettuato a livello applicativo.

> **Nota (P2-01):** Il vincolo `CHECK(id=1)` su `CoachState` garantisce che esista esattamente una riga nel database, trasformandolo in un singleton persistente. Qualsiasi tentativo di inserire una seconda riga fallisce a livello di database, non solo a livello applicativo.

-DatabaseManager (`database.py`, 289 righe)

Il **custode dell'archivio**: gestisce le connessioni SQLite con WAL mode obbligatorio, separando fisicamente il database monolite (Tier 1) dal database HLTV (Tier 2).

> **Analogia:** Il DatabaseManager è come il **custode di un edificio con due archivi separati**. Uno è l'archivio principale (database.db) dove si conservano le cartelle cliniche di tutti i pazienti, e l'altro è l'archivio dei consulenti esterni (hltv_metadata.db) dove si conservano le schede dei medici specialisti stranieri. Il custode ha una regola ferrea: ogni volta che qualcuno apre un archivio, deve impostare la serratura in modalità "WAL" (Write-Ahead Logging), che permette a più persone di leggere contemporaneamente mentre una sola scrive. Se la serratura si blocca, il custode aspetta fino a 30 secondi prima di dichiarare fallimento.

Due classi, due database:

Classe	Database	Tabelle	Engine
`DatabaseManager`	`database.db`	17 tabelle (`_MONOLITH_TABLES`)	`pool_size=1` , `max_overflow=4`
`HLTVDatabaseManager`	`hltv_metadata.db`	3 tabelle (`_HLTV_TABLES`)	`pool_size=1` , `max_overflow=4`

PRAGMA SQLite (applicati su ogni connessione via `@event.listens_for`):

PRAGMA	Valore	Scopo
`journal_mode`	`WAL`	Letture concorrenti + singola scrittura
`synchronous`	`NORMAL`	Bilanciamento performance/durabilità
`busy_timeout`	`30000` (30s)	Timeout contesa WAL lock

API pubblica:

Metodo	Descrizione
`create_db_and_tables()`	Crea schema nel monolite (solo `_MONOLITH_TABLES` , non tutte le tabelle SQLModel)
`get_session()`	Context manager transazionale: auto-commit su successo, auto-rollback su eccezione
`upsert(model_instance)`	Upsert atomico; gestione speciale per `PlayerMatchStats` (lookup per demo_name + player_name)
`get(model_class, pk)`	Lettura per chiave primaria

Singleton: `get_db_manager()` e `get_hltv_db_manager()` con double-checked locking (pattern identico). Evita la creazione di engine duplicati durante l'import da thread multipli.

Isolamento tabelle (critico): La lista esplicita `_MONOLITH_TABLES` impedisce che i modelli per-match (`MatchTickState` , `MatchEventState` , `MatchMetadata`) vengano creati nel database monolite se i loro moduli sono importati prima di `create_db_and_tables()` . Senza questa guardia, ogni modello SQLModel globalmente registrato verrebbe creato in `database.db` .

> **Nota sulla riconciliazione HLTV:** `HLTVDatabaseManager._reconcile_stale_schema()` rileva colonne mancanti in tabelle HLTV esistenti (schema aggiornato ma DB vecchio) e ricrea le tabelle interessate tramite `DROP TABLE` + `CREATE TABLE` , operando come una migrazione distruttiva di emergenza — accettabile perché i dati HLTV sono ri-scaricabili.

-MatchDataManager (`match_data_manager.py` , 748 righe)

Il **sistema di telecamere di sicurezza** del progetto: ogni partita riceve il suo file SQLite dedicato (`match_{id}.db`) contenente la telemetria tick-by-tick — fino a **1,7 milioni di righe per partita**.

> **Analogia:** Il MatchDataManager è come un **sistema di videosorveglianza dove ogni telecamera registra su il suo nastro dedicato**. Invece di registrare tutte le telecamere sullo stesso nastro (che diventerebbe enorme e impossibile da cercare), ogni telecamera (partita) ha il suo cassetto (file .db). Se vuoi rivedere la Partita #42, apri solo il cassetto #42 — le altre 500 partite non vengono toccate. Cancellare una partita? Cancella il file. Analizzare due partite in parallelo? Apri due cassetti contemporaneamente, nessuno blocca l'altro. Il sistema tiene anche una cache LRU di 50 cassetti aperti per velocità — i 50 più recentemente consultati restano aperti, gli altri vengono chiusi automaticamente.

3 modelli per-match (Tier 3):

Modello	Campi	Scopo
`MatchTickState`	40+ campi: posizione, stato, equipaggiamento, visibility, round context, cumulativi match	Stato giocatore ad ogni tick (128 Hz)
`MatchEventState`	tick, event_type, player/victim info, position, weapon, damage, entity_id	Eventi di gioco per ricostruzione Player-POV
`MatchMetadata`	match_id, demo_name, map_name, tick/round/player count, team names/scores	Metadati per accesso senza DB monolite

> **Nota (C-08):** `MatchEventState.entity_id` usa `-1` come sentinel (non `0`) per distinguere "ID non popolato dal parser" da "entity ID reale = 0", evitando accoppiamenti errati fumo/molotov.

Cache LRU (M-18):

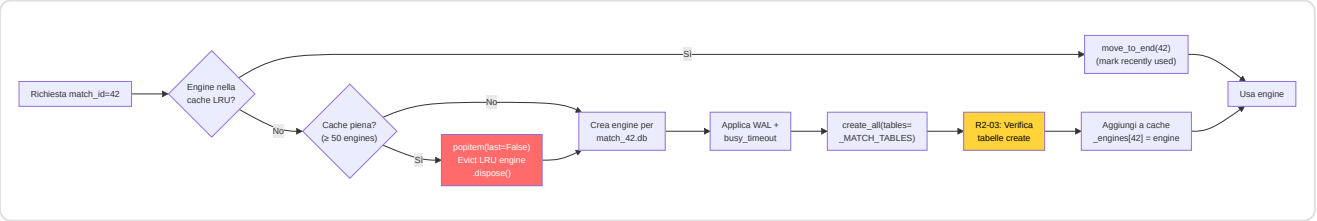

> **Nota (R2-03):** Il filtro `tables=_MATCH_TABLES` nel `create_all()` è **critico**. Senza di esso, SQLModel creerebbe tutte le ~20 tabelle globali in ogni file per-match. Un controllo difensivo post-creazione verifica che solo le 3 tabelle attese esistano nel DB, loggando un warning se compaiono tabelle inaspettate.

API pubblica:

Metodo	Descrizione
`get_match_session(match_id)`	Context manager transazionale per un match specifico
`store_tick_batch(match_id, ticks)`	Inserimento batch di `MatchTickState` — ritorna conteggio
`store_metadata(match_id, metadata)`	Upsert metadati match
`get_ticks_for_round(match_id, round)`	Query tick per round specifico
`get_player_ticks(match_id, player, start, end)`	Finestra tick per giocatore + intervallo
`get_all_players_at_tick(match_id, tick)`	Snapshot tutti i giocatori a un tick
`get_all_players_tick_window(match_id, start, end)`	Finestra tick per tutti i giocatori (addestramento RAP)

-BackupManager (`backup_manager.py`, 220 righe)

Il **responsabile della sicurezza dei dati**: crea copie di backup non-bloccanti tramite `VACUUM INTO` e le gestisce con una politica di rotazione.

> **Analogia:** Il BackupManager è come un **sistema di backup di una banca**. Ogni notte (o quando richiesto), il sistema fa una copia del caveau (database) in una cassaforte secondaria. La copia è fatta con una tecnica speciale (`VACUUM INTO`) che non blocca le operazioni in corso — è come fotocopiare un libro senza toglierlo dallo scaffale. Dopo la copia, il sistema verifica che la fotocopia sia leggibile (`PRAGMA quick_check`). Se fallisce il controllo, la copia viene distrutta. Le copie vecchie vengono eliminate con una politica di rotazione: 7 copie giornaliere + 4 copie settimanali. Questo bilancia sicurezza e spazio su disco.
>
> **Correzione H-02 — DB handle leak:** `_verify_integrity()` utilizza un blocco `try/finally` per garantire la chiusura della connessione `sqlite3` anche in caso di errore. Il PRAGMA utilizzato è `quick_check` (non `integrity_check`) per ridurre il tempo di verifica sui database di grandi dimensioni — `quick_check` omette la validazione degli indici, sufficiente per verificare l'integrità strutturale delle pagine del backup.

Pipeline di backup:

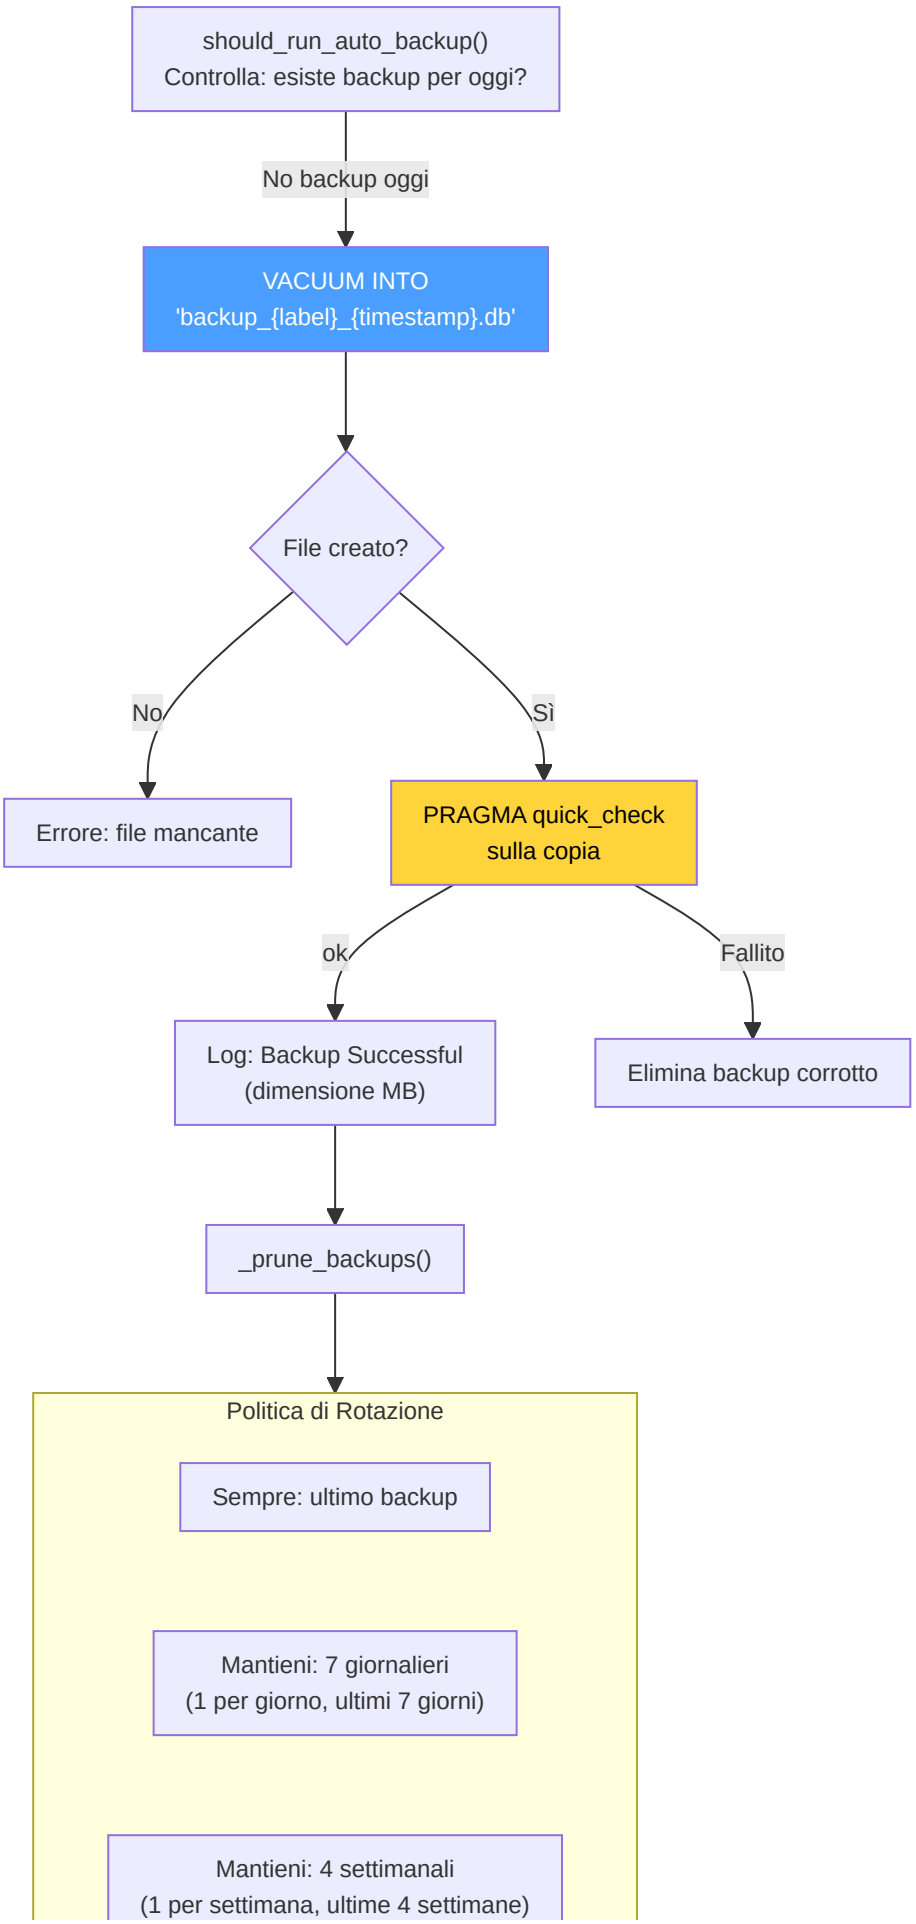
should_run_auto_backup()
Controlla: esiste backup per oggi?
No backup oggi
VACUUM INTO
'backup_{label}_{timestamp}.db'
File creato?
No
Sì
Errore: file mancante
PRAGMA quick_check
sulla copia
ok
Fallito
Log: Backup Successful
(dimensione MB)
Elimina backup corrotto
_prune_backups()
Politica di Rotazione
Sempre: ultimo backup
Mantieni: 7 giornalieri
(1 per giorno, ultimi 7 giorni)
Mantieni: 4 settimanali
(1 per settimana, ultime 4 settimane)

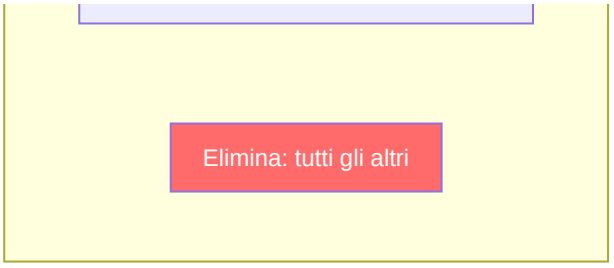

Sicurezza path: Il label del backup viene validato con regex `^[a-zA-Z0-9_\-]+$` e il path risolto viene verificato per prevenire path traversal attacks. Il path viene escapato per SQL injection (`'` → `''`).

-StorageManager (`storage_manager.py`, 258 righe)

Gestore dello **storage locale** per demo CS2: cartelle di ingestione, archivio post-elaborazione, e quote disco.

Funzionalità	Dettaglio
Cartella ingestione	Path configurabile (`DEFAULT_DEMO_PATH`), fallback a `data/` in-project
Archivio	`datasets/user_archive/` e `datasets/pro_archive/` nel "Brain Root"
Quote	`MAX_DEMOS_PER_MONTH` e `MAX_TOTAL_DEMOS_PER_USER` da config
Quota disco	`LOCAL_QUOTA_GB` (default 10 GB), verificata prima dell'archiviazione
Discovery	`list_new_demos(is_pro)` — cerca `.dem` non ancora elaborati in `PRO_DEMO_PATH` o `DEFAULT_DEMO_PATH`

-StateManager (`state_manager.py`, 206 righe)

DAO centralizzato per il singleton `CoachState`: interfaccia thread-safe tra i daemon e la GUI.

> **Analogia:** Il StateManager è come il **tabellone degli arrivi all'aeroporto**: ogni daemon (Hunter, Digester, Teacher) aggiorna il proprio stato sul tabellone, e la GUI lo legge per mostrare all'utente cosa sta succedendo. Un `threading.Lock()` impedisce che due daemon scrivano contemporaneamente sullo stesso campo, corrompendo il display.

Metodo	Descrizione
`get_state()`	Recupera il singleton (lo crea se non esiste, lock P0-04)
`update_status(daemon, status, detail)`	Aggiorna stato di un daemon specifico (hunter/digester/teacher/global)
`update_training_progress(epoch, total, train_loss, val_loss, eta)`	Progresso real-time addestramento per la GUI
`update_parsing_progress(progress)`	Barra di progresso parsing demo (0.0–100.0)
`push_notification(daemon, severity, message)`	Inserisce una `ServiceNotification` nella coda per la UI
`get_unread_notifications(limit)`	Recupera notifiche non lette per visualizzazione

-Servizi Storage Aggiuntivi

`stat_aggregator.py` (99 righe) — Persistenza dati spider HLTV: `persist_player_card(card_data, player_hltv_id)` converte i dati estratti dallo spider in un `ProPlayerStatCard` e lo salva nel database HLTV. `persist_team(team_data)` salva/aggiorna un `ProTeam`.

`db_migrate.py` (112 righe) — Orchestrazione migrazioni Alembic: `ensure_database_current()` viene chiamata all'avvio dell'applicazione per auto-aggiornare lo schema. Confronta `current_rev` vs `head_rev` e se diversi esegue `alembic.command.upgrade(cfg, "head")`. Se `alembic.ini` non esiste (sviluppo senza Alembic), ritorna `True` silenziosamente.

`maintenance.py` (53 righe) — Manutenzione database: `prune_old_metadata(days=90)` elimina record vecchi in batch da 500 (`SQLITE_MAX_VARIABLE_NUMBER` safety), evitando query DELETE con migliaia di parametri che SQLite rifiuterebbe.

`remote_file_server.py` (213 righe) — Servizio di backup remoto e gestione file: supporta sincronizzazione con drive esterno o backup cloud.

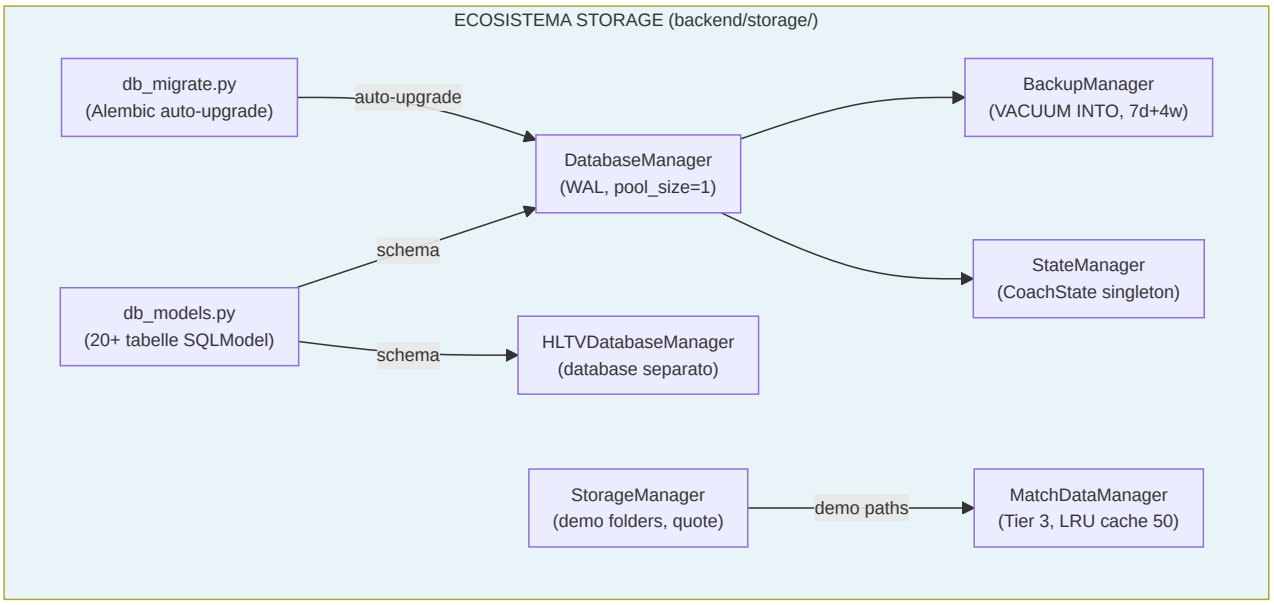

---

12. Pipeline di Addestramento e Orchestrazione

> **Analogia:** Se i modelli neurali (Sezione 1-2) sono gli strumenti dell'orchestra, il `TrainingOrchestrator` è il **direttore d'orchestra** che decide quando iniziare, controlla il tempo di ogni esecuzione, corregge le stonature (early stopping), e alla fine registra la performance migliore su disco (checkpoint). Senza di lui, gli strumenti produrrebbero solo caos.

Il sottosistema di addestramento ha tre responsabilità distinte:

1. **Orchestrazione** — Ciclo di vita completo: caricamento dati → epoche → checkpoint → arresto anticipato
2. **Preparazione Tensori** — Conversione tick grezzi dal database in batch tensoriali pronti per il modello
3. **Calcolo Target** — Generazione di etichette di addestramento: funzione vantaggio (continua) e ruolo tattico (10 classi)

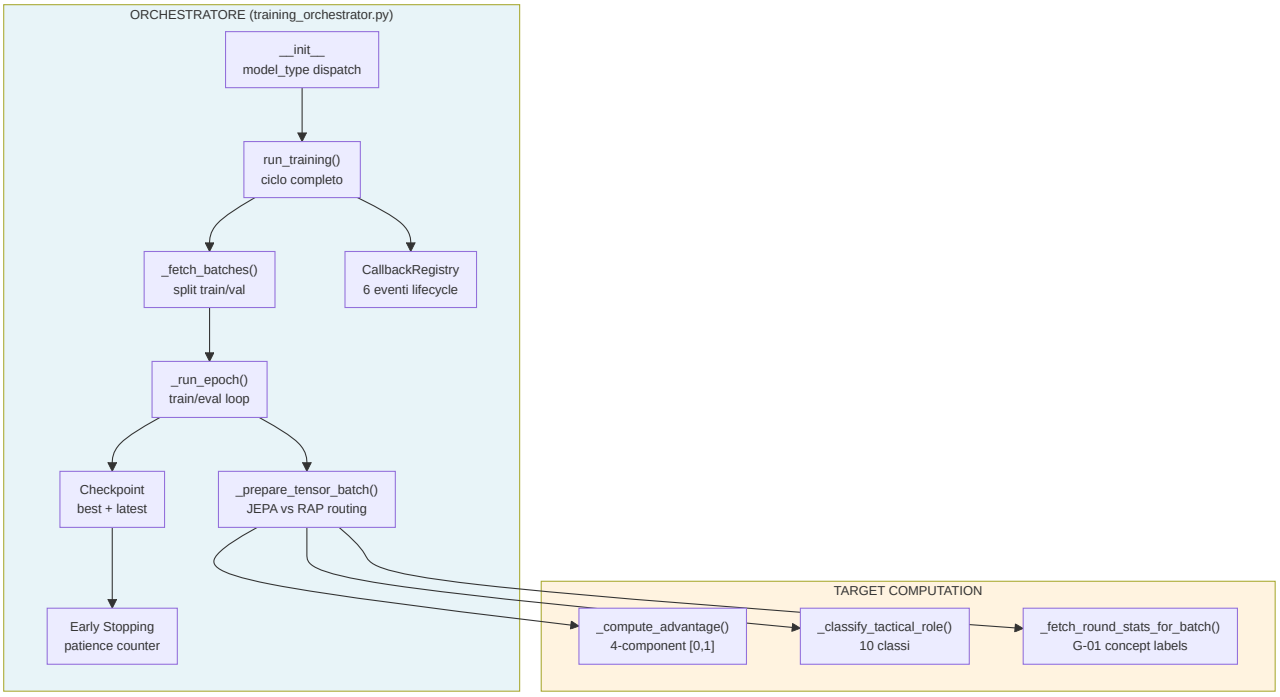

-TrainingOrchestrator (training_orchestrator.py, 890 righe)

La classe centrale della pipeline di addestramento. Gestisce JEPA, VL-JEPA e RAP da un punto di ingresso unificato, con dispatch basato su `model_type`.

Costruttore e Configurazione:

Parametro	Default	Descrizione
`model_type`	`"jepa"`	Routing: `"jepa"` → JEPATrainer, `"vl-jepa"` → JEPATrainer (VL mode), `"rap"` → RAPTrainer
`max_epochs`	100	Limite superiore epoche
`patience`	10	Epoche senza miglioramento prima di early stopping
`batch_size`	32	Campioni per batch
`callbacks`	`CallbackRegistry()`	Sistema plugin per TensorBoard, logging, etc.

Dettagli notevoli del costruttore:

- **RNG deterministico** (F3-02): `np.random.default_rng(seed=42)` per il campionamento negativi JEPA — garantisce riproducibilità
- **Contatori fallback** (F3-11): `_total_samples` e `_total_fallbacks` tracciano il tasso aggregato di tensori-zero nell'intero ciclo
- **RAP gated**: Il modello RAP richiede `USE_RAP_MODEL=True` nelle impostazioni — se disabilitato, `ValueError` immediato
- **Learning rate**: JEPA 1e-4, RAP 5e-5 (più conservativo per il multi-task)

Ciclo di Vita: `run_training()`

Il metodo principale esegue 6 fasi sequenziali:

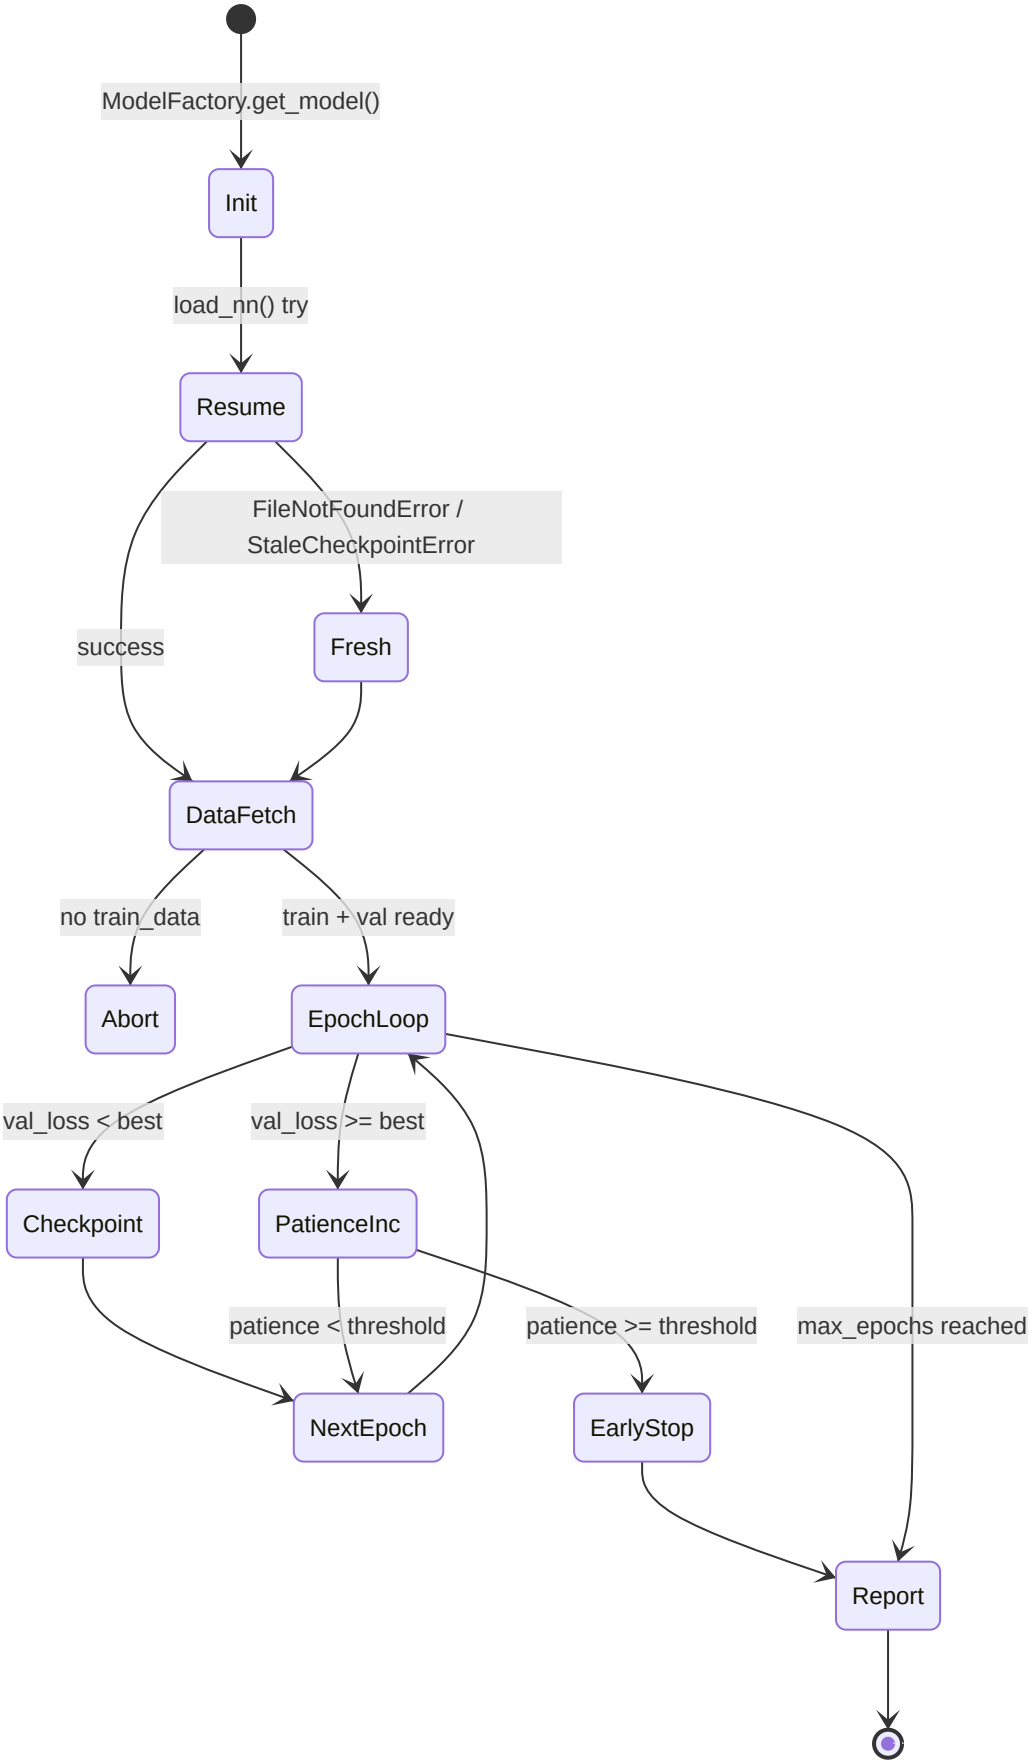
ModelFactory.get_model()
Init
load_nn() try
Resume
FileNotFoundError /
StaleCheckpointError
success
Fresh
DataFetch
no train_data
train + val ready
Abort
EpochLoop
val_loss < best
val_loss >= best
Checkpoint
PatienceInc
patience < threshold
patience >= threshold
max_epochs reached
NextEpoch
EarlyStop
Report

1. **Init**: `ModelFactory.get_model(type)` istanzia il modello, poi tenta `load_nn()` per riprendere da checkpoint esistente. Gestisce 3 eccezioni: `FileNotFoundError` (primo addestramento), `StaleCheckpointError` (architettura cambiata), e generico (corruzione)
2. **Data Fetch**: `_fetch_batches(is_train=True/False)` con split train/val
3. **Epoch Loop**: Per ogni epoca, `_run_epoch()` in modalità train e poi eval. Il `context.check_state()` permette interruzione cooperativa (TrainingStopRequested)
4. **Checkpoint**: Doppio salvataggio — `model_name` (best) e `model_name_latest` (sempre). Solo il best viene salvato quando `val_loss` migliora
5. **Early Stopping**: Contatore `patience_counter` incrementato ad ogni epoca senza miglioramento
6. **Report**: Callback `on_train_end` con metriche finali + log del tasso di fallback F3-11

Preparazione Dati: `_fetch_batches()`

Recupera tick dal database tramite il manager, rispettando lo split train/val:

- Chiama `manager._fetch_jepa_ticks(is_pro, split)` per tutti i tipi di modello (RAP incluso — pipeline dati RAP-specifica non ancora implementata, con warning esplicito)
- **Ordinamento temporale preservato** — nessuno shuffle, perché i modelli sono sequenziali
- Suddivisione in batch di dimensione `self.batch_size`

Routing Tensori: `_prepare_tensor_batch()`

Il metodo più critico: converte oggetti `PlayerTickState` dal database in dizionari di tensori PyTorch.

Flusso JEPA (context/target/negatives):

Tensore	Shape	Costruzione
`context`	`(1, 10, METADATA_DIM)`	Primi 10 tick del batch, padding se < 10
`target`	`(1, METADATA_DIM)`	Media dell'ultimo tick (next-item prediction)
`negatives`	`(1, 5, METADATA_DIM)`	5 campioni casuali dal batch (RNG deterministico)

Richiede almeno 5 campioni reali per i negativi contrastivi — se il batch è troppo piccolo, ritorna `None` (skip).

> **Correzione G-01:** Per VL-JEPA, viene anche chiamato `_fetch_round_stats_for_batch()` per fornire etichette concettuali basate sugli esiti reali dei round (elimina label leakage da labeling euristico).

Flusso RAP (Player-POV completo):

Il percorso RAP è significativamente più complesso — delegato a `_prepare_rap_batch()`:

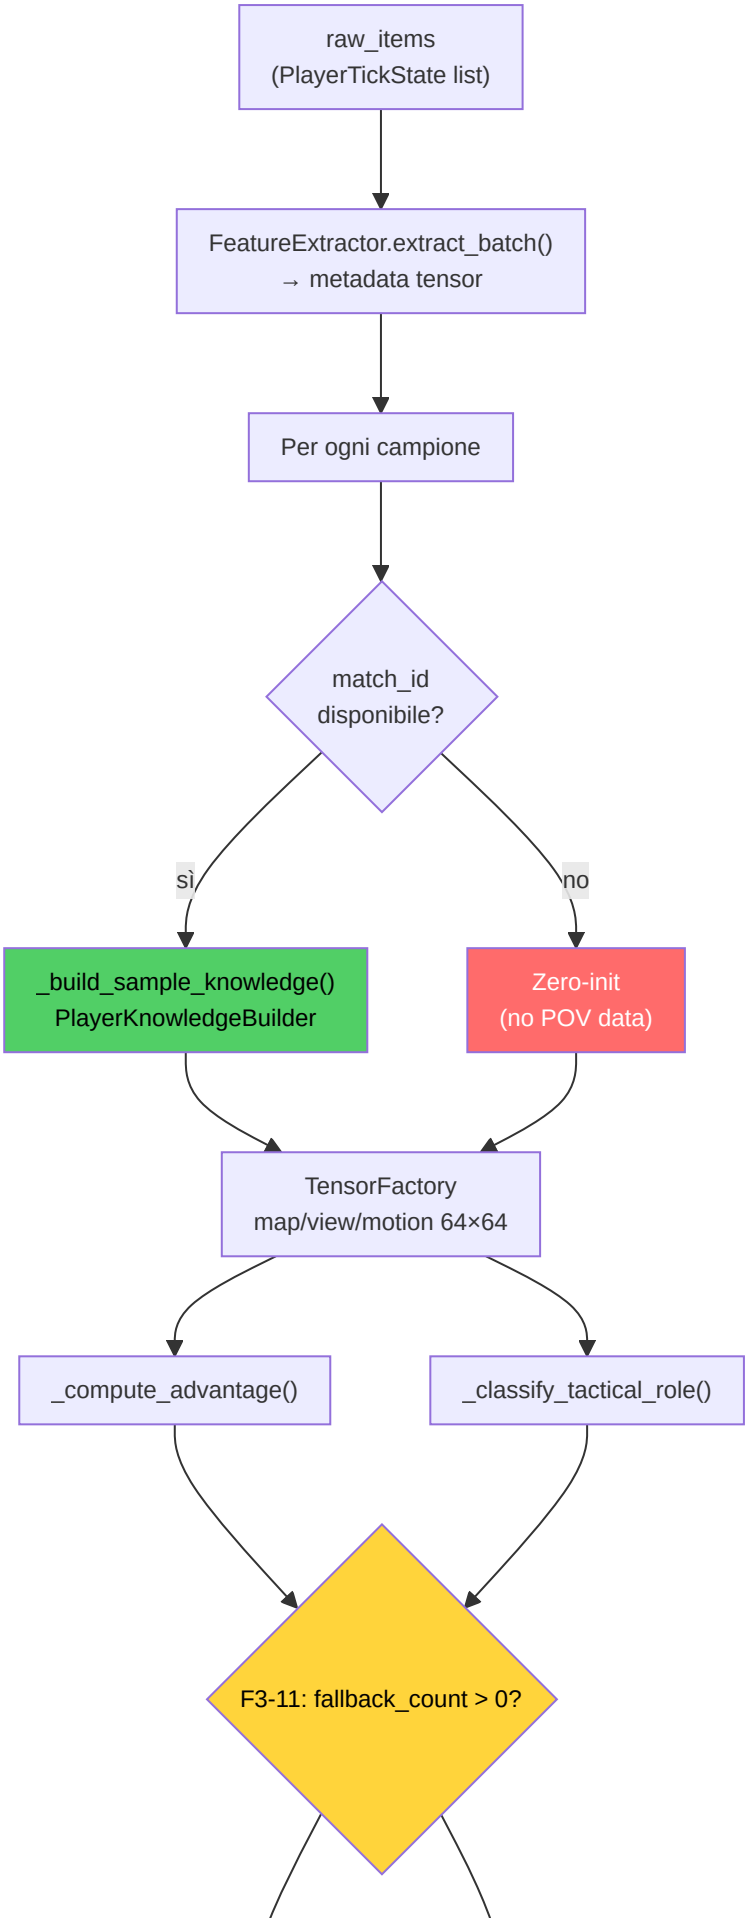
raw_items
(PlayerTickState list)
FeatureExtractor.extract_batch()
→ metadata tensor
Per ogni campione
match_id
disponibile?
sì
no
_build_sample_knowledge()
PlayerKnowledgeBuilder
Zero-init
(no POV data)
TensorFactory
map/view/motion 64×64
_compute_advantage()
_classify_tactical_role()
F3-11: fallback_count > 0?

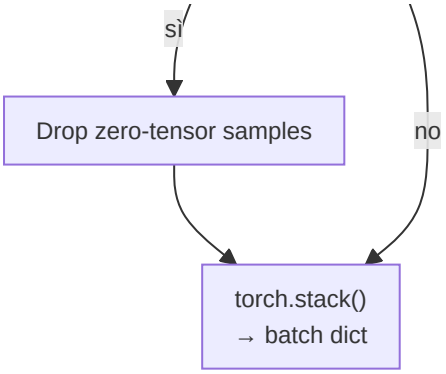

Per ogni campione nel batch:

1. **Risoluzione match_id** → query al `MatchDataManager` per tutti i giocatori al tick
2. **PlayerKnowledgeBuilder** → modello sensoriale NO-WALLHACK (visibilità, suono, utilità)
3. **TensorFactory** → tensori map/view/motion a 64×64 (risoluzione training)
4. **Target computation** → advantage [0,1] + ruolo tattico (10 classi)

Cache per-batch (4 dizionari) evitano query ridondanti sullo stesso match/tick:

Cache	Chiave	Valore
`_all_players_cache`	`(match_id, tick)`	Lista giocatori al tick
`_window_cache`	`(match_id, tick)`	Storico 320 tick per enemy memory
`_event_cache`	`(match_id, tick)`	Eventi nell'intervallo [-320, +64]
`_metadata_cache`	`match_id`	Metadati match (mappa, etc.)

> **Correzione F3-11:** I campioni con fallback a zero-tensor vengono **scartati** (non usati per training). Il tasso aggregato viene tracciato e se supera il 10%, un warning viene emesso. Se l'intero batch è fallback, viene saltato completamente.
>
> **Correzione H-03 — Rimozione batch swallowing silenzioso:** I loop di training e validazione del RAP non contengono più il blocco `except (KeyError, TypeError): continue` che mascherava silenziosamente errori nei dati. Ora `train_step()` deve restituire un `dict` con chiave `'loss'` o viene sollevato un `ValueError` esplicito. Questo garantisce che errori strutturali nei batch vengano rilevati immediatamente anziché ignorati, migliorando la diagnosticabilità del pipeline di addestramento.

Funzione Vantaggio: `_compute_advantage()`

Formula continua [0, 1] che sostituisce il target binario vinto/perso (G-04):

```
advantage = 0.4 × alive_diff + 0.2 × hp_ratio + 0.2 × equip_ratio + 0.2 × bomb_factor
```

Componente	Peso	Calcolo	Range
`alive_diff`	0.4	`(team_alive - enemy_alive + 5) / 10`	[0, 1]
`hp_ratio`	0.2	`team_hp / (team_hp + enemy_hp)`	[0, 1]
`equip_ratio`	0.2	`team_equip / (team_equip + enemy_equip)`	[0, 1]
`bomb_factor`	0.2	Planted: T=0.7, CT=0.3 / Not planted: 0.5	{0.3, 0.5, 0.7}

L'`alive_diff` ha il peso maggiore (0.4) perché la superiorità numerica è il singolo fattore più predittivo nel CS2. La normalizzazione `(diff + 5) / 10` mappa il range [-5, +5] (5v0 → 0v5) in [0, 1].

Classificazione Ruolo Tattico: `_classify_tactical_role()`

Assegna uno di 10 ruoli tattici ad ogni tick basandosi su euristiche informate dal `PlayerKnowledge`:

Indice	Ruolo	Condizione
0	Site Take	T default (nessuna condizione speciale)
1	Rotation	— (riservato)
2	Entry Frag	Nemici visibili + distanza < 800u
3	Support	T + distanza media team < 500u + ≥2 compagni
4	Anchor	CT + accovacciato
5	Lurk	Distanza media dal team > 1500u + nessun nemico visibile
6	Retake	CT + bomba piazzata
7	Save	Equipaggiamento < $1500 (priorità massima)
8	Aggressive Push	Nemici visibili + distanza ≥ 800u
9	Passive Hold	CT default (senza knowledge)

La catena di priorità è: Save → Retake → Lurk → Entry Frag → Aggressive Push → Anchor/Passive Hold → Support → Site Take. Senza `PlayerKnowledge`, si ricade su default basati sul team (CT → Passive Hold, T → Site Take).

Risoluzione Mappa: `_resolve_map_name()`

Catena di fallback a 3 livelli per determinare la mappa di ogni campione:

1. **Match metadata DB** → `MatchDataManager.get_metadata(match_id).map_name`
2. **Regex su demo_name** → cerca nomi mappa noti (mirage, inferno, dust2, etc.)
3. **Fallback statico** → `"de_mirage"` (mappa più giocata)

Validazione Contrastiva (Evaluation)

Durante la validazione, il calcolo della loss JEPA richiede un passaggio extra per i negativi:

1. Raw negatives `[batch, n_neg, feat_dim]` → flatten a `[batch*n_neg, feat_dim]`
2. Encode tramite `target_encoder` → `[batch*n_neg, latent_dim]`
3. Reshape a `[batch, n_neg, latent_dim]`
4. Calcolo `jepa_contrastive_loss(pred, target, neg_latent)`

Per RAP, la validazione usa `trainer.criterion_val` (MSE su value_estimate vs target_val).

-JEPATrainer (jepa_trainer.py, 296 righe)

Il trainer specializzato per l'architettura JEPA. Gestisce pre-training self-supervised, monitoraggio drift, e il protocollo VL-JEPA a tripla loss.

> **Analogia:** Se l'Orchestratore è il direttore d'orchestra, il `JEPATrainer` è il **primo violino** — esegue il lavoro tecnico più delicato (InfoNCE, EMA update, drift detection) mentre il direttore controlla il tempo e decide quando fermarsi.

Costruttore:

Parametro	Default	Dettaglio
`lr`	1e-4	Learning rate per AdamW
`weight_decay`	1e-4	Regolarizzazione L2
`drift_threshold`	2.5	Soglia z-score per DriftMonitor

- **NN-36**: I parametri del `target_encoder` vengono **esclusi** dall'ottimizzatore — sono aggiornati solo via EMA (Exponential Moving Average), mai con gradienti diretti
- **Scheduler**: `CosineAnnealingLR` con `T_max=100`, step una volta per epoca

Due modalità di training step:

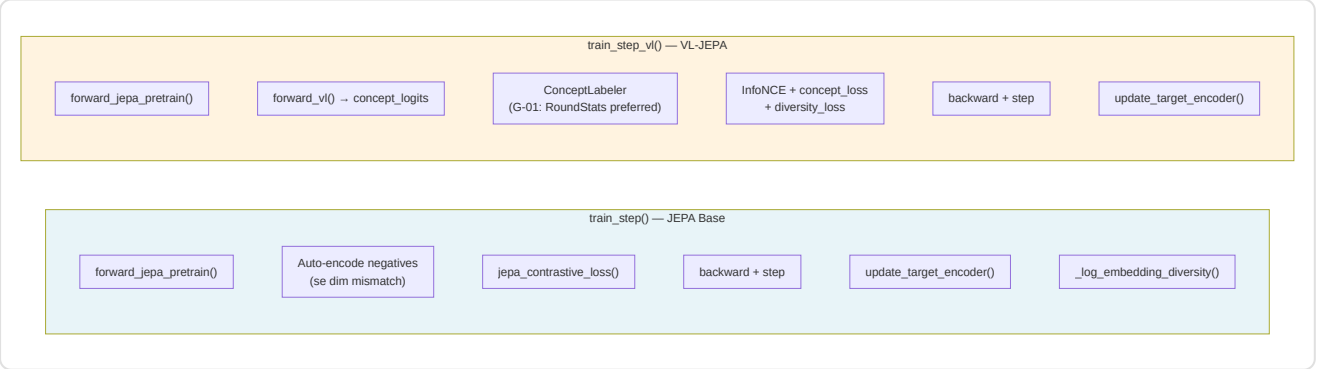

`train_step()` (JEPA base):

1. Forward → `pred_embedding`, `target_embedding`
2. Auto-detect negativi raw (dim mismatch con `pred_embedding`) → encode via `target_encoder`
3. `jepa_contrastive_loss(pred, target, negatives)` — InfoNCE

4. Backward + optimizer step
5. EMA update del target encoder
6. **P9-02**: Monitoraggio varianza embeddings — warning se < 0.01 (rischio collapse)

`train_step_vl()` **(VL-JEPA):**

Tre componenti di loss:

Loss	Peso	Funzione
InfoNCE	1.0	Contrastive self-supervised
Concept alignment	α = 0.5	Allineamento concetti a etichette
Diversity regularization	β = 0.1	Previene concept collapse

> **Correzione G-01:** Le etichette concettuali vengono preferibilmente generate da `ConceptLabeler.label_from_round_stats(rs)` usando i dati reali di esito round. Solo come fallback viene usato il labeling euristico (con warning logged una volta sola).

Sistema Drift (Task 2.19.3):

- `check_val_drift(val_df, reference_stats)` → `DriftMonitor.check_drift()` con z-threshold 2.5
- `should_retrain(history, window=5)` → True se drift persistente nelle ultime 5 epoche
- `retrain_if_needed()` → ciclo completo di riaddestramento con scheduler resettato

-RAPTrainer (rap_coach/trainer.py, 110 righe)

Il trainer multi-task per il modello RAP Coach. Gestisce 4 componenti di loss simultaneamente.

> **Analogia:** Il RAPTrainer è come un **insegnante di guida** che valuta contemporaneamente la scelta di percorso (strategia), la valutazione del rischio (value), lo stile di guida (sparsità), e il parcheggio (posizionamento) — tutto in una singola lezione.

Loss Composition:

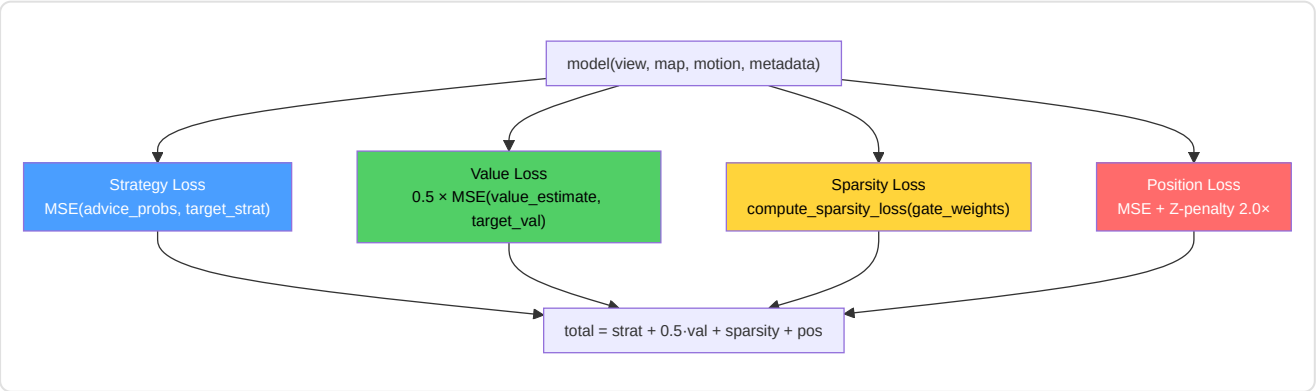

Loss	Peso	Criterio	Target
Strategy	1.0	MSE	`target_strat` (ruolo tattico one-hot, 10 classi)
Value	0.5	MSE	`target_val` (advantage [0,1])
Sparsity	1.0	L1 su gate weights	Interpretabilità: pesi gate → ~0
Position	1.0	MSE + Z×2.0	`target_pos` delta (opzionale)

Task 2.17.1 — Penalità Z-axis: La `compute_position_loss()` applica un peso 2× sull'errore asse Z (verticalità), perché nel CS2 gli errori di elevazione (es. nemico su una scala vs piano terra) sono tatticamente critici.

F3-07: I `gate_weights` vengono passati esplicitamente a `compute_sparsity_loss()` anziché letti dall'istanza del modello — garantisce thread-safety.

-Punto di Ingresso Training (train.py, 275 righe)

Modulo entry-point che fornisce la funzione `train_nn()` con dispatch automatico e funzioni standalone.

`train_nn(X, y, X_val, y_val, model, config_name, context)`:

config_name	Percorso	Pipeline
`"jepa"`	`_train_jepa_self_supervised()`	Self-supervised, InfoNCE, 5 epoche prototype
altro	`_execute_validated_loop()`	Supervised, MSE, DataLoader standard

Funzioni helper:

Funzione	Responsabilità
`_prepare_splits(X, y)`	Train/val split 80/20 con `random_state=42`. Rifiuta se < 20 campioni (P1-04)
`_train_jepa_self_supervised()`	Prototipo JEPA: `SelfSupervisedDataset`, context_len=10, prediction_len=5, clip_grad=1.0
`_execute_validated_loop()`	Loop supervisionato con `EarlyStopping(patience=10)`, throttling configurabile
`run_training()`	Standalone entry: usa `CoachTrainingManager` per fetch dati pro

> **Nota P1-02:** Tutti i percorsi chiamano `set_global_seed()` prima dell'addestramento per garantire riproducibilità. Il seed globale è configurato nel modulo `config.py`.

-WinProbabilityTrainer (win_probability_trainer.py, ~138 righe)

Modulo dedicato al modello di probabilità vittoria — la rete più semplice dell'ecosistema.

Architettura `WinProbabilityTrainerNN`:

```
Input(9) → Linear(32) → ReLU → Linear(16) → ReLU → Linear(1) → Sigmoid
```

9 Feature di Input:

#	Feature	Tipo
1	`ct_alive`	Giocatori CT vivi
2	`t_alive`	Giocatori T vivi
3	`ct_health`	HP totale CT
4	`t_health`	HP totale T
5	`ct_armor`	Armatura totale CT
6	`t_armor`	Armatura totale T
7	`ct_eqp`	Valore equipaggiamento CT
8	`t_eqp`	Valore equipaggiamento T
9	`bomb_planted`	Bomba piazzata (0/1)

Training:

- Loss: **BCELoss** (Binary Cross-Entropy — output è probabilità [0,1])
- Optimizer: Adam (lr=0.001) — non AdamW, più semplice per questa rete
- Early stopping: patience=10, min_delta=1e-4
- Target: `did_ct_win` (binario)
- Split: 80/20 con `random_state=42`
- Minimo campioni: 20 (AR-6)
- Salvataggio: `torch.save(state_dict, model_path)` — persistenza diretta, non tramite `save_nn()`

`predict_win_prob(model, state_dict)` — Inferenza singola: costruisce il tensore dalle 9 feature e ritorna la probabilità CT-win come float.

> **Nota A-12 — Architetture distinte:** Questo `WinProbabilityTrainerNN` (9 feature, addestramento offline) è un modello *separato e incompatibile* rispetto al `WinProbabilityNN` a 12 feature descritto nella Sezione 7. Il primo viene addestrato sui dati aggregati delle demo; il secondo opera in tempo reale durante l'analisi live. I checkpoint non sono intercambiabili.

-Utilità di Addestramento

I seguenti moduli forniscono l'infrastruttura di supporto al ciclo di addestramento — configurazione, controllo, monitoraggio, dataset, e arresto anticipato.

`training_config.py` (69 righe) — Dataclass centralizzate per iperparametri:

Dataclass	Parametri Chiave	Uso
`TrainingConfig`	`base_lr=1e-4`, `max_epochs=100`, `patience=10`, `batch_size=1`, `gradient_clip=1.0`, `ema_decay=0.999`	Configurazione base per tutti i modelli
`JEPATrainingConfig`	Estende TrainingConfig + `latent_dim=256`, `contrastive_temperature=0.07`, `momentum_target=0.996`, `pretraining_epochs=50`	Specifica per JEPA self-supervised

`training_controller.py` (160 righe) — Gatekeeper che decide **se** un nuovo demo debba essere usato per addestramento:

- **Quota mensile**: `MAX_DEMOS_PER_MONTH = 10` — conta i `PlayerMatchStats` processati negli ultimi 30 giorni
- **Score di diversità**: Confronta il nuovo demo con gli ultimi 5 match via similarità coseno su 6 feature normalizzate (kills, deaths, ADR, HS%, utility, opening duels). Se `diversity < 0.3`, il demo viene rifiutato
- Ritorna un `TrainingDecision(should_train, reason, diversity_score)` — il chiamante decide se procedere

`training_monitor.py` (123 righe) — Persistenza metriche in JSON per monitoraggio real-time e analisi post-training. Traccia: epoche, train_loss, val_loss, learning_rate, best_val_loss, stato (in progress / early stopped / completed).

`early_stopping.py` (86 righe) — Implementazione callable dell'arresto anticipato:

```
stopper = EarlyStopping(patience=10, min_delta=1e-4)
if stopper(val_loss):  # True = ferma l'addestramento
    break
```

Logica: se `val_loss < best_loss - min_delta`, reset del contatore. Altrimenti incrementa. Quando `counter >= patience`, ritorna `True`. Usato da tutti i trainer (JEPA, RAP, Legacy, WinProb).

`dataset.py` (64 righe) — Due Dataset PyTorch:

Dataset	Input	Output	Uso
`ProPerformanceDataset`	`(X, y)` tensori	`(x[i], y[i])` tuple	Training supervisionato Legacy
`SelfSupervisedDataset`	`X` sequenziale	`(context, target)` finestre scorrevoli	JEPA self-supervised

Il `SelfSupervisedDataset` usa una **finestra scorrevole**: `context_len=10` tick come input, `prediction_len=5` tick come target. Il numero totale di campioni è `len(X) - context_len - prediction_len`. Solleva `ValueError` se i dati sono insufficienti (F3-34).

-Sistema di Callback (training_callbacks.py + tensorboard_callback.py)

Architettura plugin a due livelli per l'osservabilità del training, senza modificare il loop principale.

> **Analogia:** Il sistema di callback è come i **sensori di un'auto da corsa** — termometro olio, pressione pneumatici, G-force — che raccolgono dati senza mai interferire con la guida. Il pilota (orchestratore) corre, i sensori (callback) registrano.

Layer 1 — `training_callbacks.py` (110 righe):

`TrainingCallback` (ABC) definisce 7 hook di lifecycle:

Hook	Quando	Parametri
`on_train_start`	Prima della prima epoca	model, config dict
`on_epoch_start`	Inizio di ogni epoca	epoch
`on_batch_end`	Dopo ogni batch di training	batch_idx, loss, outputs dict
`on_epoch_end`	Fine di ogni epoca	epoch, train_loss, val_loss, model, optimizer
`on_validation_end`	Dopo il passaggio di validazione	epoch, val_loss, model
`on_train_end`	Dopo il completamento	model, final_metrics dict
`close`	Rilascio risorse	—

> **Nota F3-31:** Nessun metodo è `@abstractmethod` — pattern opt-in dove le sottoclassi implementano solo gli hook necessari. Tutti i metodi base sono no-op.

`CallbackRegistry` è il dispatcher: `fire(event, **kwargs)` chiama l'hook corrispondente su ogni callback registrato. Errori nei callback vengono catturati e loggati — **mai crashano il training**.

Layer 2 — `tensorboard_callback.py` (228 righe):

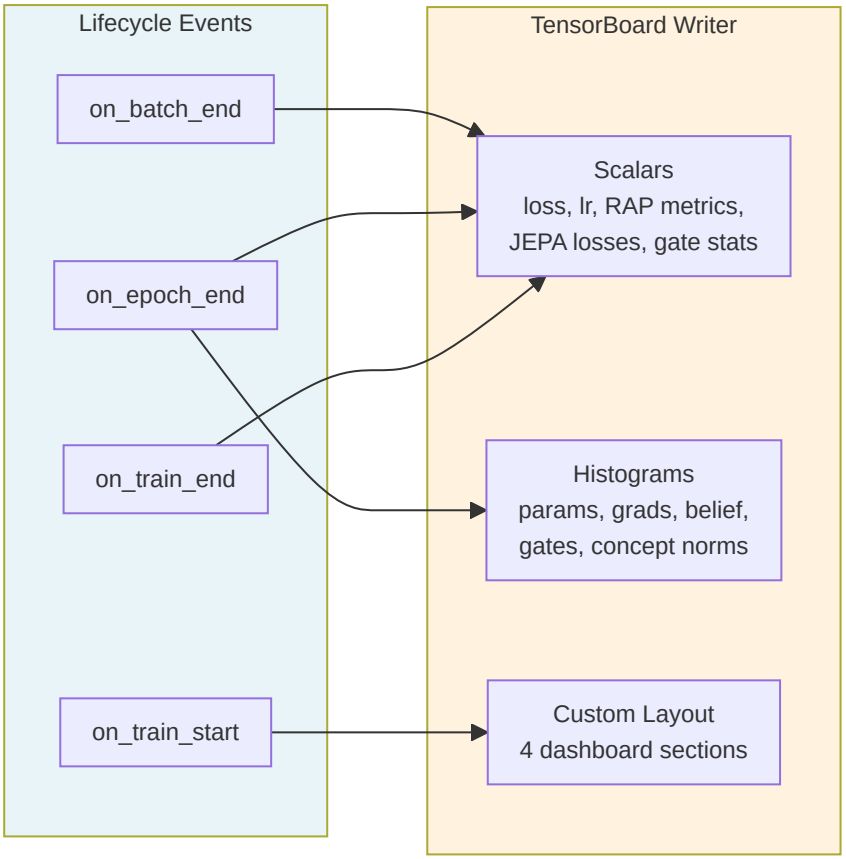

Segnali registrati per tipo di modello:

Categoria	Metriche	Tipo
Core	`loss/train`, `loss/val`, `loss/gap`, `loss/batch`	Scalari per-epoch/batch
RAP	`rap/sparsity_ratio`, `rap/z_axis_error`, `rap/loss_position`	Scalari per-batch
JEPA	`jepa/infonce_loss`, `jepa/concept_loss`, `jepa/diversity_loss`	Scalari per-batch
Gates	`gates/mean_activation`, `gates/sparsity`, `gates/active_ratio`	Scalari per-batch
Diagnostica	`params/*`, `grads/*`, `belief/vector`, `concepts/embedding_norms`, `gates/activations`	Istogrammi per-epoch

4 dashboard custom: **Coach Vital Signs**, **RAP Coach Internals**, **JEPA Self-Supervised**, **Superposition Gates**.

Import graceful: se `tensorboard` non è installato, il callback diventa un no-op completo (`_TB_AVAILABLE = False`).

---

13. Funzioni di Perdita — Dettaglio Implementativo

> **Analogia:** Le loss function sono il **sistema nervoso del dolore** dei modelli neurali — senza di esse, il modello non saprebbe mai se sta migliorando o peggiorando. Ogni tipo di loss è specializzata: il dolore acuto (contrastive) per JEPA, il dolore diffuso (MSE multi-task) per RAP, e il dolore binario (BCE) per la probabilità di vittoria.

Catalogo delle Loss Functions

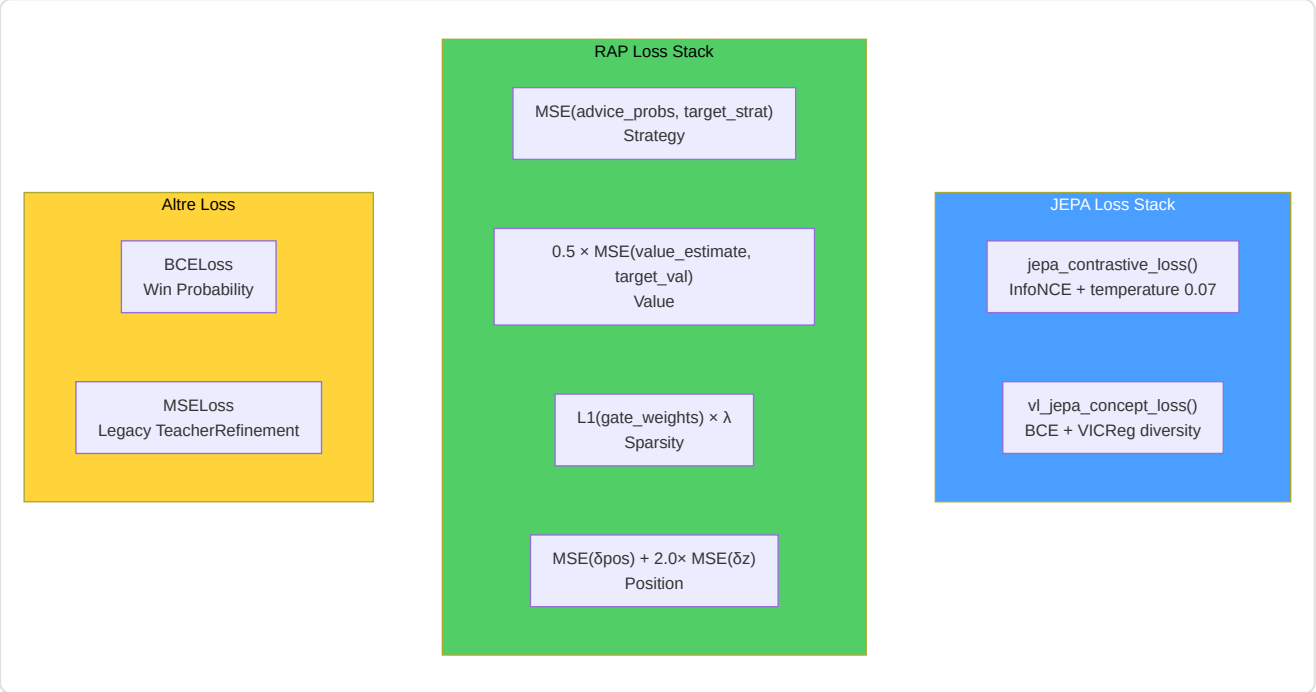

-jepa_contrastive_loss() — InfoNCE

File: `jepa_model.py:326` | **Signature:** `(pred, target, negatives, temperature=0.07) → scalar`

Formula InfoNCE (Noise Contrastive Estimation):

```
L = -log( exp(sim(pred, target) / τ) / (exp(sim(pred, target) / τ) + Σ exp(sim(pred, neg_i) / τ
```

Passaggi:

1. **Normalizzazione L2** di pred, target, negatives (cosine similarity space)
2. **Similitudine positiva**: `pos_sim = (pred · target) / τ` con `τ = 0.07`
3. **Similitudini negative**: `neg_sim = bmm(negatives, pred)` / τ
4. **Cross-entropy**: concat `[pos_sim, neg_sim]` → `F.cross_entropy` con labels=0 (il positivo è sempre l'indice 0)

La temperatura `τ = 0.07` è bassa, il che rende la loss **sensibile a piccole differenze** — appropriato per le embedding CS2 dove i tick consecutivi sono molto simili.

-vl_jepa_concept_loss() — Allineamento Concettuale

File: `jepa_model.py:913` | **Signature:** `(concept_logits, concept_labels, concept_embeddings, α=0.5, β=0.1) → (total, concept, diversity)`

Due componenti:

Componente	Formula	Peso	Scopo
Concept alignment	`BCE_with_logits(logits, labels)`	α = 0.5	Multi-label: ogni concetto attivato indipendentemente
Diversity (VICReg)	`-mean(std(emb_norm, dim=0))`	β = 0.1	Previene collapse: penalizza bassa varianza delle embedding concettuali

I 16 concetti di coaching (`COACHING_CONCEPTS`) coprono: positioning (aggressivo/passivo/esposto), economy (eco/force/full), timing (trade/rotate/patience), utility (flash/smoke/molotov), e communication (info/callout).

-compute_sparsity_loss() — Sparsità Gate RAP

File: `rap_coach/model.py:105` | **Signature:** `(gate_weights) → scalar`

```
L_sparsity = λ × mean(|gate_weights|)
```

L1 norm sui pesi del `ContextGate` (SuperpositionLayer). L'obiettivo è che la maggior parte dei gate sia vicina a 0, con poche attivazioni forti — questo rende il modello **interpretabile** (quali input influenzano davvero la decisione?).

> **Nota F3-07:** I `gate_weights` vengono passati come parametro esplicito anziché letti da `self._last_gate_weights` — previene race condition in ambienti multi-thread.

-Position Loss RAP — Penalità Z-axis

File: `rap_coach/trainer.py:89` | **Signature:** `(pred_delta, target_delta) → (loss, z_error)`

```
L_pos = MSE(Δx) + MSE(Δy) + 2.0 × MSE(Δz)
```

Il peso 2× sull'asse Z riflette l'importanza critica della verticalità nel CS2: confondere il piano terra con il primo piano (es. Nuke, Vertigo) porta a decisioni tattiche completamente errate.

-Loss Legacy e Win Probability

- **TeacherRefinementNN**: `MSELoss` standard su predizioni supervised (train.py)
- **WinProbabilityNN**: `BCELoss` per output sigmoid [0,1] → probabilità CT-win

---