CS2 AI COACHING SYSTEM

Book-Coach-3-pt

Autore: Renan Augusto Macena

Marzo 2026

Ultimate CS2 Coach — Parte 3: Programa, UI, Ferramentas e Build

Topicos: Schema completo do banco de dados (three-tier storage, SQLite WAL, SQLModel ORM), Regime de treinamento e limites de maturidade (CALIBRATING/LEARNING/MATURE), Catalogo das funcoes de perda, Logica Completa do Programa (do lancamento ao conselho): Session Engine, Digester, Teacher, Hunter, Pulse; Interface desktop Qt/PySide6 (13 telas, ViewModels, Qt Signals); Pipeline de ingestao (demo e pro); Console de controle unificada; Onboarding de novo usuario; Arquitetura de storage; Motor de playback e viewer tatico; Dados espaciais e mapas; Observabilidade e logging; Reporting; Quotas e limites; Tolerancia a falhas; Jornada completa do usuario (4 fluxos); Suite de ferramentas (validacao e diagnostico); Test suite; Pre-commit hooks; Build, packaging, deployment; Migracoes Alembic; HLTV sync service; RASP Guard; MatchVisualizer; Arquivos de configuracao runtime; Entry point root-level; Glossario.

Autor: Renan Augusto Macena

Este documento e a continuacao da **Parte 2** — *Servicos, Analise e Banco de Dados*, que cobre os servicos de coaching, os motores de analise, o conhecimento e o Banco de Dados. A Parte 3 desce ao nivel de programa: como o sistema inteiro se inicializa, como os daemons se orquestram, como a interface desktop torna visivel o coaching, como o codigo e testado, validado e implantado.

Indice

Parte 3 — Programa, UI, Ferramentas e Build (este documento)

9. Schema do banco de dados e ciclo de vida dos dados
10. Regime de treinamento e limites de maturidade
11. Catalogo das funcoes de perda
12. Logica Completa do Programa — Do Lancamento ao Conselho
    - 12.1 Inicializacao da aplicacao e bootstrap
    - 12.2 Session Engine e Quad-Daemon
    - 12.3 Daemon Digester e pipeline de ingestao
    - 12.4 Daemon Teacher e training orchestrator
    - 12.5 Interface Desktop (Qt/PySide6, 13 telas, ViewModels)
    - 12.6 Pipeline de Ingestao (`ingestion/`)

- 12.7 Console de Controle Unificada (`backend/control/`)
- 12.8 Onboarding e Fluxo de Novo Usuario
- 12.9 Arquitetura de Storage (`backend/storage/`)
- 12.10 Motor de Playback e Viewer Tatico
- 12.11 Dados Espaciais e Gestao de Mapas
- 12.12 Observabilidade e Logging
- 12.13 Reporting e Visualizacao
- 12.14 Gestao de Quotas e Limites
- 12.15 Tolerancia a Falhas e Recuperacao
- 12.16 Jornada Completa do Usuario — 4 Fluxos Principais
- 12.17 Suite de Ferramentas — Validacao e Diagnostico (`tools/`)
- 12.18 Arquitetura da Test Suite (`tests/`)
- 12.19 As 12 Fases de Remediacao Sistematica
- 12.20 Pre-commit Hooks e Quality Gates
- 12.21 Build, Packaging e Deployment
- 12.22 Sistema de Migracoes Alembic
- 12.23 Orquestrador de Ingestao Principal (`run_ingestion.py`)
- 12.24 HLTV Sync Service e Background Daemon
- 12.25 RASP Guard — Integridade Runtime do Codigo
- 12.26 MatchVisualizer — Rendering Avancado
- 12.27 Arquivos de Dados e Configuracao Runtime
- 12.28 Entry Point Root-Level

- Resumo Arquitetural
- Mapa das Interconexoes entre as 3 Partes
- Glossario Tecnico

---

9. Schema do banco de dados e ciclo de vida dos dados

O projeto usa **SQLModel** (Pydantic + SQLAlchemy) com SQLite (modo WAL) e uma **arquitetura three-tier storage** especializada. No total **24 tabelas SQLModel** (`backend/storage/db_models.py` : 21 tabelas monolite+HLTV; `backend/storage/match_data_manager.py` : 3 tabelas por-match) distribuidas em 3 tiers de storage:

1. **`database.db`** — Banco de dados monolite principal da aplicacao (**18 tabelas**, listadas explicitamente em `database.py:_MONOLITH_TABLES` linhas 54-73). Contem todas as tabelas core: estatisticas de jogadores (`PlayerMatchStats`), estado do coach (`CoachState`), tasks de ingestao (`IngestionTask`), insights de coaching (`CoachingInsight`), perfis de usuario (`PlayerProfile`), notificacoes de sistema (`ServiceNotification`), base RAG (`TacticalKnowledge`), banco de

experiencias COPER (`CoachingExperience`), resultados de partidas (`MatchResult` , `MapVeto`), calibracoes (`CalibrationSnapshot`), limites de papel (`RoleThresholdRecord`), rastreamento de proveniencia (`DataLineage` , `DataQualityMetric`), e tabelas estendidas para round team (`Ext_TeamRoundStats`) e estilo de jogo (`Ext_PlayerPlaystyle`), alem de `RoundStats` e `PlayerTickState` arquival.

2. **`hltv_metadata.db`** — Banco de dados dos metadados profissionais (**3 tabelas**, `database.py:_HLTV_TABLES` linhas 78-82): perfis dos jogadores pro (`ProPlayer` , `ProTeam`) e cartoes estatisticos (`ProPlayerStatCard`). Separado do monolite porque e escrito por um processo separado (HLTV sync service) para eliminar a contencao WAL com os daemons do session engine.
3. **`match_data/{id}.db`** — Banco de dados por-match de telemetria (**3 tabelas**, definidas em `match_data_manager.py` : `MatchTickState` :110, `MatchEventState` :190, `MatchMetadata` :242). Cada partida tem seu proprio arquivo SQLite dedicado contendo os dados tick-a-tick (~100.000 linhas por partida). Gerenciado por `MatchDataManager` . Essa separacao resolve o problema do "Telemetry Cliff" — evita que o banco de dados monolite cresca indefinidamente com dados de alta frequencia.

Essa separacao em tres niveis garante que as operacoes de escrita intensivas do session engine (ingestao demo, treinamento ML → `database.db`) nao disputem locks WAL com o scraping HLTV em processo separado (`hltv_metadata.db`), e que a telemetria de alta frequencia por-match nao sobrecarregue o monolite (`match_data/{id}.db`).

hltv_metadata.db (Dados Pro — 3 tabelas)
ProPlayer
ProTeam
ProPlayerStatCard
baseline pro para comparacao coaching
database.db (Core + Conhecimento — 18 tabelas)
PlayerMatchStats
RoundStats
CoachState
IngestionTask
CoachingInsight
PlayerProfile
ServiceNotification

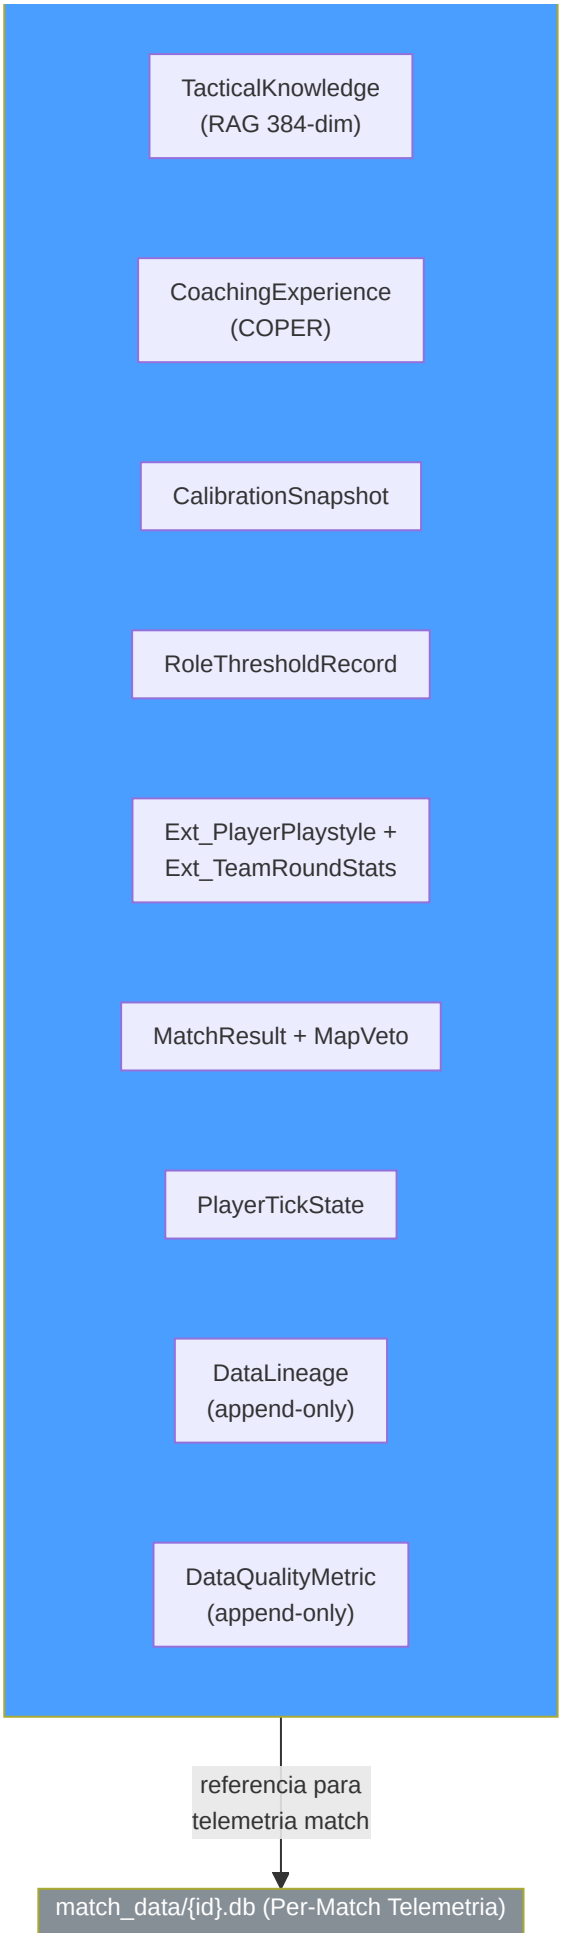
TacticalKnowledge
(RAG 384-dim)
CoachingExperience
(COPER)
CalibrationSnapshot
RoleThresholdRecord
Ext_PlayerPlaystyle +
Ext_TeamRoundStats
MatchResult + MapVeto
PlayerTickState
DataLineage
(append-only)
DataQualityMetric
(append-only)
referencia para
telemetria match
match_data/{id}.db (Per-Match Telemetria)

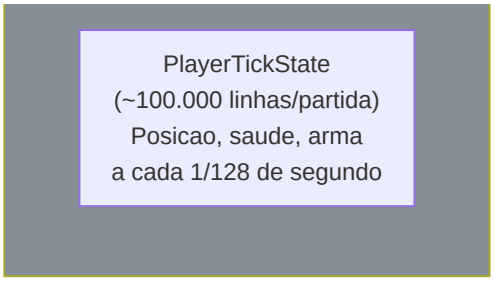

Analogia: O banco de dados e o **arquivo** do sistema: cada informacao tem uma gaveta e uma pasta especificas. A arquitetura three-tier storage e como ter **tres arquivos especializados**: o arquivo principal (dados do jogo, conhecimentos taticos, experiencias de coaching — tudo em um unico grande arquivario WAL), o arquivario dos profissionais (dados HLTV, atualizado por um processo separado para evitar contencao), e os **dossies por-partida** (telemetria tick-a-tick, cada um em um arquivo separado para evitar que o arquivo principal fique pesado demais). Separando-os, o processo principal pode escrever e ler do arquivo geral enquanto o servico HLTV atualiza o arquivario dos pros e os dados de telemetria ficam isolados por partida, sem travarem uns aos outros. SQLite em modo WAL permite que varios programas leiam cada arquivo simultaneamente. SQLModel combina Pydantic (para validacao de dados: "garanta que o campo idade seja realmente um numero") com SQLAlchemy (para operacoes no banco: "salve isso na tabela certa"). As 21 tabelas sao organizadas como o arquivo escolar: perfis dos alunos, notas dos testes, anotacoes de aula, avaliacoes dos professores e livros da biblioteca.

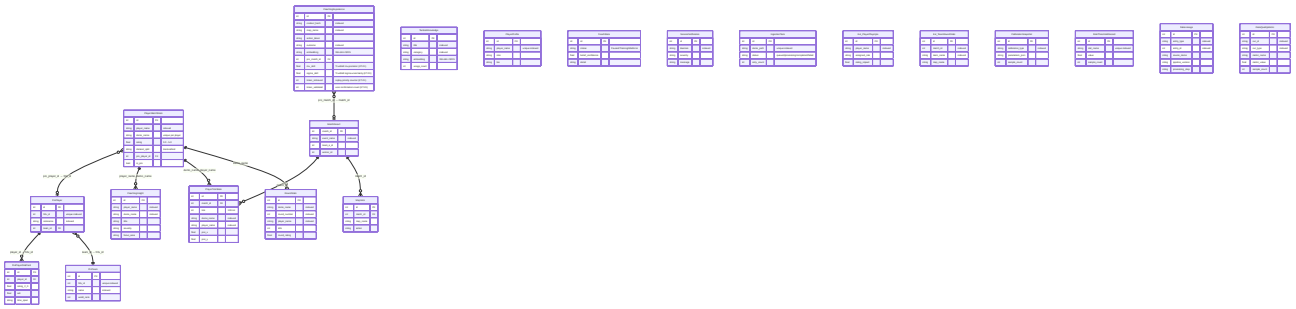

Explicacao do diagrama ER: Cada caixa representa um **tipo de registro** no banco de dados. `PlayerMatchStats` e como um **boletim** para cada jogador em cada partida (quantas mortes, quantas vezes morreu, sua avaliacao, etc). `PlayerTickState` e como um **diario frame a frame**: 128 entradas por segundo que registram exatamente onde o jogador estava, quao saudavel estava, em que direcao estava olhando. `RoundStats` e a **decomposicao por questao**: avaliacoes individuais para cada round (kills, deaths, damage, noscope kills, flash assists, round rating), permitindo analises detalhadas. `CoachingExperience` e o **diario** do treinador: cada momento de treinamento, se os conselhos funcionaram e o quanto foram eficazes. `CoachingInsight` e o **conselho efetivo** fornecido ao jogador. `TacticalKnowledge` e o **livro didatico**: sugestoes e estrategias que o treinador pode consultar. `RoleThresholdRecord` e a **rubrica de avaliacao**, ou seja, os limites aprendidos para classificar os papeis dos jogadores. `CalibrationSnapshot` e o **registro de controle do instrumento**, que registra quando o modelo de crenca foi recalibrado e com quantas amostras. `Ext_PlayerPlaystyle` e o **relatorio de scouting externo**, ou seja, as metricas do estilo de jogo obtidas dos dados CSV usados para treinar NeuralRoleHead. `ServiceNotification` e o **sistema de interfone**, ou seja, as mensagens de erro e evento provenientes dos daemons em background mostradas na interface do usuario. As linhas entre as tabelas mostram os relacionamentos: cada registro de partida esta vinculado ao perfil de um jogador, as experiencias de treinamento estao vinculadas a partidas especificas e RoundStats esta vinculado a PlayerMatchStats via demo_name. `DataLineage` e o **registro de proveniencia**: rastreia qual demo originou cada entidade e atraves de qual step do pipeline foi processada (append-only, para audit trail completo). `DataQualityMetric` e o **painel de metricas de qualidade**: registra valores numericos de qualidade para cada execucao do pipeline (ex. percentual de amostras descartadas, taxa de fallback zero-tensor), permitindo o monitoramento da saude do sistema ao longo do tempo.

Ciclo de vida dos dados:

Fase	Tabelas escritas	Volume
Insercao demo	`PlayerMatchStats`, `PlayerTickState`, `MatchMetadata`	~100.000 tick/partida
Enriquecimento round	`RoundStats` (isolamento por round, por jogador)	~30 linhas/partida (round x jogadores)
Scan HLTV	`ProPlayer`, `ProTeam`, `ProPlayerStatCard`	~500 jogadores
Importacao CSV	Tabelas externas via `csv_migrator.py`	~10.000 linhas
Dados de estilo de jogo	`Ext_PlayerPlaystyle` (de CSV para NeuralRoleHead)	~300+ jogadores
Engenharia de features	`PlayerMatchStats.dataset_split` atualizado	In-place
Populacao RAG	`TacticalKnowledge`	~200 artigos
Extracao de experiencia	`CoachingExperience`	~1.000 por partida
Output de coaching	`CoachingInsight`	~5-20 por partida
Aprendizado de limites de papel	`RoleThresholdRecord`	9 limites
Calibracao de crencas	`CalibrationSnapshot` (apos retreinamento)	1 por cada calibracao executada
Telemetria de sistema	`CoachState`, `ServiceNotification`, `IngestionTask`	Continuo
Rastreamento de proveniencia	`DataLineage` (append-only por cada entidade processada)	~N linhas por demo ingerida
Metricas de qualidade pipeline	`DataQualityMetric` (append-only por cada execucao pipeline)	~5-10 metricas por run
Backup	Automatizado via `BackupManager` (7 rotacoes diarias + 4 semanais)	Copia completa do banco

Indices e otimizacao de query:

As tabelas mais consultadas tem indices estrategicos para garantir queries rapidas:

Tabela	Indice	Colunas	Tipo de query otimizada
`PlayerMatchStats`	`idx_pms_player`	`player_name`	Busca por jogador
`PlayerMatchStats`	`idx_pms_demo`	`demo_name`	Busca por partida
`PlayerMatchStats`	`idx_pms_processed`	`processed_at`	Ordenacao cronologica
`RoundStats`	`idx_rs_demo_round`	`demo_name, round_number`	Busca por round especifico
`IngestionTask`	`idx_it_status`	`status`	Fila de trabalho (status=queued)
`CoachingInsight`	`idx_ci_player`	`player_name`	Insight por jogador
`TacticalKnowledge`	`idx_tk_category`	`category`	Busca RAG por categoria
`ProPlayer`	`idx_pp_name`	`nickname`	Busca pro por nome
`DataLineage`	`idx_dl_entity`	`entity_type, entity_id`	Rastreamento proveniencia por entidade
`DataQualityMetric`	`idx_dqm_run`	`run_id, run_type`	Metricas qualidade por execucao

Restricoes de integridade:

Restricao	Tabelas	Enforcement
`player_name` NOT NULL	PlayerMatchStats, RoundStats	Nivel de schema
`demo_name` UNIQUE por player	PlayerMatchStats	Previne duplicatas
`status` CHECK IN ('queued', 'processing', 'completed', 'failed')	IngestionTask	Enum enforcement
`dataset_split` CHECK IN ('train', 'val', 'test')	PlayerMatchStats	Split validity
Foreign key demo_name	RoundStats → PlayerMatchStats	Relacao round-partida

Detalhe de tabelas-chave:

`PlayerMatchStats` (32 campos) — a tabela mais consultada do sistema:

A tabela PlayerMatchStats contem todas as estatisticas agregadas por jogador por partida. E o "boletim" de cada partida analisada:

Campo	Tipo	Descricao
`id`	Integer PK	Identificador unico
`player_name`	String	Nome do jogador (indexed)
`demo_name`	String	Nome do arquivo demo (unique por player)
`kills`, `deaths`, `assists`	Integer	KDA base
`adr`	Float	Average Damage per Round
`kast`	Float	Kill/Assist/Survive/Trade %
`headshot_percentage`	Float	HS%
`hltv_rating`	Float	Rating HLTV 2.0 calculado
`dataset_split`	String	"train" / "val" / "test"
`is_pro`	Boolean	Flag jogador profissional
`processed_at`	DateTime	Timestamp de processamento
`map_name`	String	Mapa jogado
...	...	20+ campos adicionais para features avancadas

`TacticalKnowledge` — a base RAG:

Campo	Tipo	Descricao
`id`	Integer PK	Identificador
`title`	String	Titulo do documento (indexed)
`description`	String	Descricao do conteudo tatico
`category`	String	"positioning" / "economy" / "utility" / "aim" (indexed)
`map_name`	String	Mapa especifico (indexed, opcional)
`situation`	String	Contexto situacional: "T-side pistol round", "CT retake A site"
`pro_example`	String	Referencia a demo pro (opcional)
`embedding`	String	Vetor 384-dim JSON (sentence-transformers)
`created_at`	DateTime	Timestamp de criacao
`usage_count`	Integer	Contador de uso

A busca semantica RAG funciona calculando a **cosine similarity** entre o embedding da query do usuario e os embeddings precomputados de cada documento. Os top-3 resultados com similarity > 0.5 sao usados para enriquecer o contexto de coaching. O campo `situation` permite o filtro contextual (ex. "T-side pistol round") antes da busca semantica.

`CoachingExperience` — o banco COPER (22+ campos):

Campo	Tipo	Descricao
`id`	Integer PK	Identificador
`context_hash`	String	Hash do estado de jogo para lookup rapido (indexed)
`map_name`	String	Mapa (indexed)
`round_phase`	String	"pistol" / "eco" / "full_buy" / "force"
`side`	String	"T" / "CT"
`position_area`	String	"A-site" / "Mid" / etc. (indexed, opcional)
`game_state_json`	String	Snapshot completo do tick (max 16KB, validado com `field_validator`)
`action_taken`	String	"pushed" / "held_angle" / "rotated" / "used_utility" / etc.
`outcome`	String	"kill" / "death" / "trade" / "objective" / "survived" (indexed)
`delta_win_prob`	Float	Variacao da probabilidade de vitoria desta acao
`confidence`	Float	Confiabilidade/generalizabilidade 0.0-1.0
`usage_count`	Integer	Quantas vezes recuperada para coaching
`pro_match_id`	Integer FK	Referencia a MatchResult (ON DELETE SET NULL)
`pro_player_name`	String	Nome jogador pro de referencia (indexed, opcional)
`embedding`	String	Vetor 384-dim JSON para busca semantica (opcional)
`source_demo`	String	Demo de origem (opcional)
`created_at`	DateTime	Timestamp de criacao
`outcome_validated`	Boolean	Se o resultado foi validado
`effectiveness_score`	Float	Score -1.0 a 1.0
`follow_up_match_id`	Integer	Partida de follow-up para tracking
`times_advice_given`	Integer	Quantas vezes o conselho foi dado
`times_advice_followed`	Integer	Quantas vezes o conselho foi seguido
`last_feedback_at`	DateTime	Ultimo feedback recebido
`mu_skill`	Float	TrueSkill mu posterior — estimativa da qualidade da experiencia (KT-01)
`sigma_skill`	Float	TrueSkill sigma uncertainty — incerteza sobre a qualidade (KT-01)
`times_retrieved`	Integer	Contador replay priority — quantas vezes recuperada (KT-01)
`times_validated`	Integer	Contador de confirmacoes do usuario — quantas vezes validada (KT-01)

O sistema COPER usa essas experiencias para **aprender com seus proprios conselhos**: o campo `context_hash` permite o lookup rapido de situacoes similares, `outcome` e `delta_win_prob` medem a eficacia da acao, e o ciclo de feedback (`outcome_validated`, `times_advice_given/followed`, `effectiveness_score`) permite ao sistema priorizar conselhos que historicamente produziram resultados

positivos. O campo `game_state_json` e limitado a 16KB para prevenir crescimento descontrolado do banco. Os campos TrueSkill `mu_skill` / `sigma_skill` (KT-01) fornecem uma estimativa bayesiana da qualidade da experiencia, usada para a priorizacao do replay: `confidence_score = mu_skill - kappa x sigma_skill`. O contador `times_retrieved` implementa a replay priority, enquanto `times_validated` rastreia as confirmacoes do usuario para o CRUD semantico.

> **Analogia:** O ciclo de vida dos dados mostra **como as informacoes fluem atraves do sistema ao longo do tempo**, como o rastreamento de um pacote da fabrica ate a entrega. Primeiro chegam as gravacoes das partidas (100.000 pontos de dados por partida!). Depois as estatisticas dos jogadores profissionais sao extraidas do HLTV (como baixar um almanaque esportivo). Sao importados arquivos CSV externos (como obter dados historicos). A IA processa tudo, gera conselhos para os treinadores, aprende os limites de papel e registra constantemente o estado de saude do sistema. Os backups sao executados automaticamente: 7 copias diarias e 4 copias semanais, como se voce salvasse suas tarefas tanto no computador quanto em um drive USB, por precaucao.

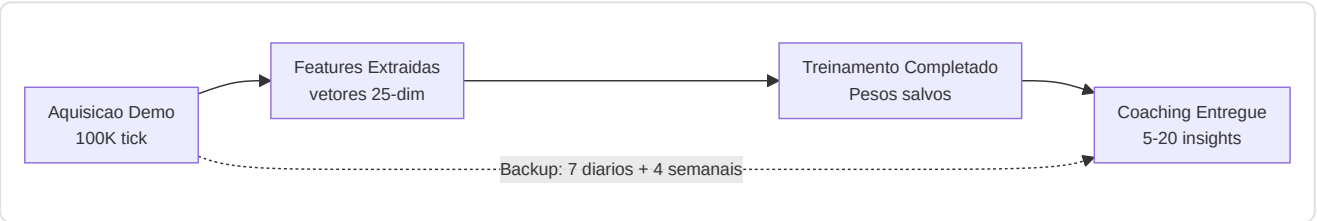

10. Regime de treinamento e limites de maturidade

> **Analogia:** O regime de treinamento e o **curriculo escolar completo**, do jardim de infancia ao diploma. Um aluno (o modelo de inteligencia artificial) comeca com zero conhecimento e aprende gradualmente atraves de 4 fases, desbloqueando cursos mais avancados conforme se prova a altura. Os limites de maturidade sao como os **requisitos de avaliacao**: voce nao pode fazer o exame de Fisica AP (Otimizacao RAP) ate ter passado em Matematica basica (Pre-Treinamento JEPA), Algebra (Baseline Pro) e Pre-Calculo (Fine-Tuning Usuario). Cada limite verifica: "Voce estudou demos suficientes para estar pronto para o proximo nivel?"

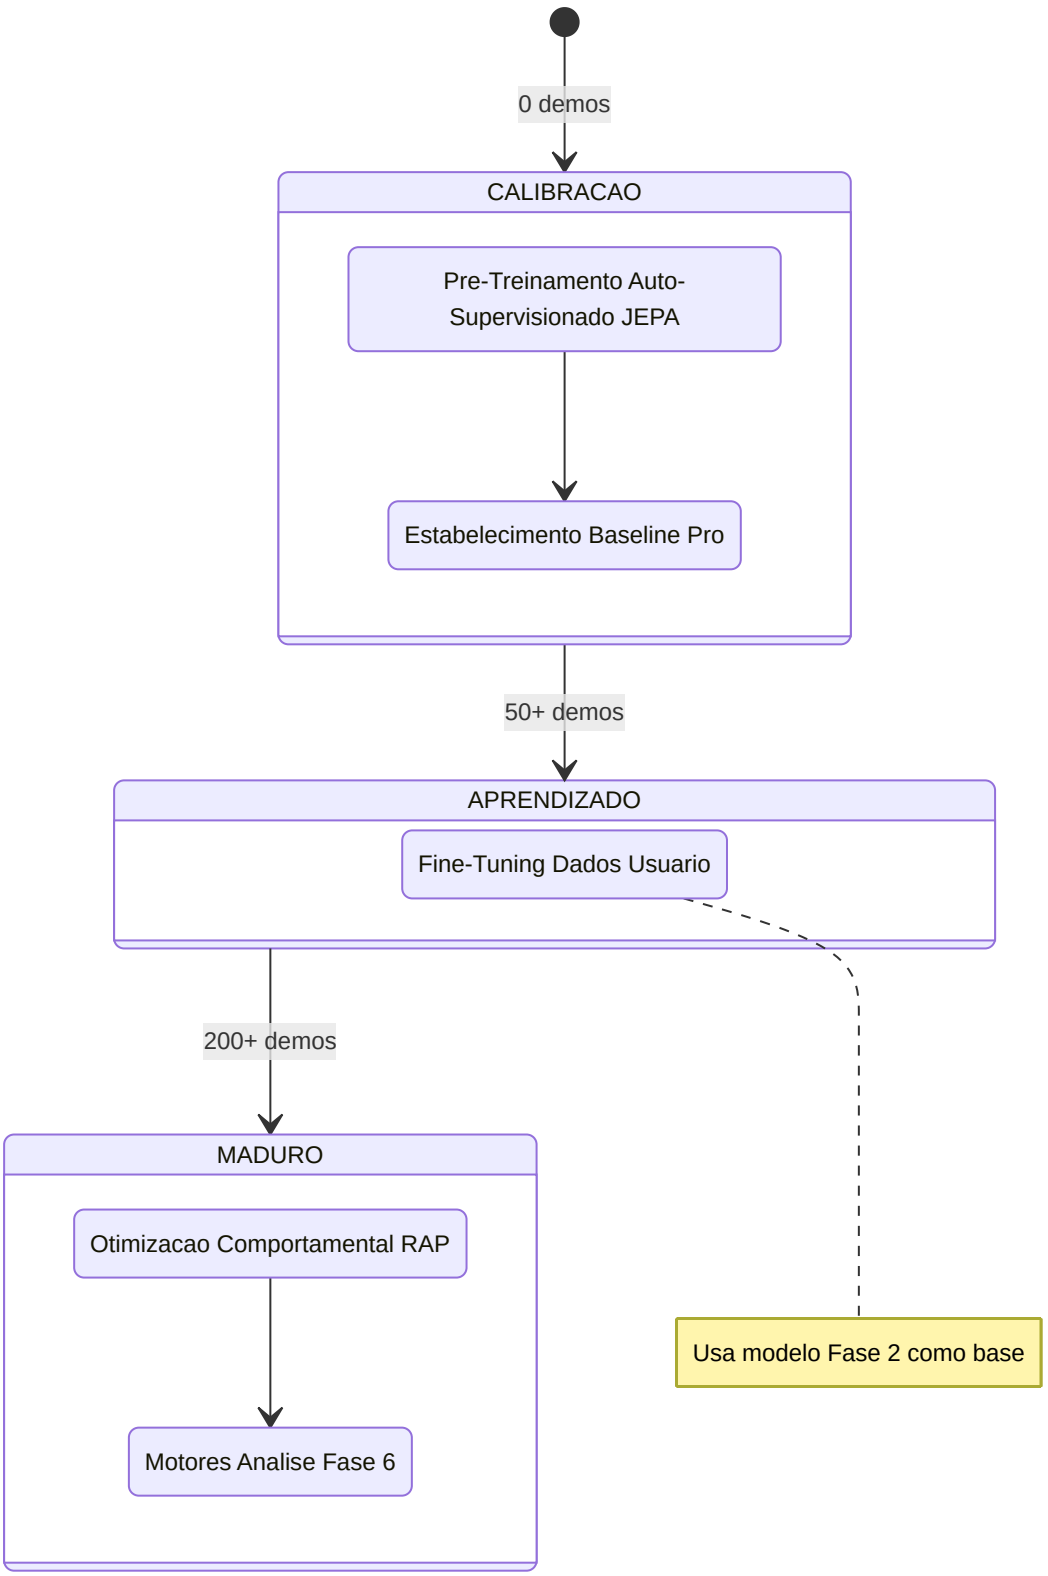

Requisitos de dados por fase:

Fase	Dados minimos	Tipo de treinamento	Perda primaria
1. Pre-treinamento JEPA	10 demos pro	Auto-supervisionado (InfoNCE)	Contrastivo com negativos em batch
2. Baseline pro	50 partidas pro	Supervisionado	MSE(pred, pro_stats)
3. Otimizacao usuario	50 partidas usuario	Supervisionado (transferencia)	MSE(pred, user_stats)
4. Otimizacao RAP	200 partidas totais	Multi-task	Estrategia + Valor + Sparsidade + Posicao

> **Analogia:** A fase 1 e como **assistir programas de culinaria**: o modelo aprende os padroes apenas observando (auto-supervisionado, sem necessidade de labels). A fase 2 e como **uma escola de culinaria com um livro didatico**: "Aqui esta como um profissional faz a massa" (supervisionado com dados profissionais). A fase 3 e como **cozinhar para sua familia**: "Sua familia prefere o picante, entao adaptamos a receita" (fine-tuning com dados do usuario). A fase 4 e um **treinamento de chef experiente**: aprender a balancear simultaneamente sabor, apresentacao, tempo e nutricao (multi-task: estrategia + valor + parcimonia + posicao). Voce precisa de pelo menos 10 programas de culinaria para comecar, 50 receitas para aprender e 200 pratos no total preparados antes de se formar.

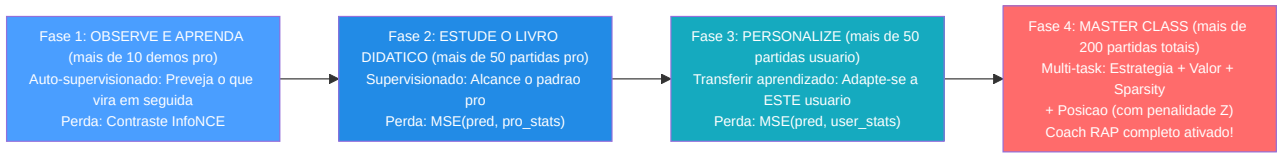

Protocolo VL-JEPA Two-Stage (Alinhamento de Conceitos):

Quando o VL-JEPA esta ativo, as Fases 1-2 sao estendidas com um **protocolo two-stage** que alinha as representacoes latentes aos 16 coaching concepts:

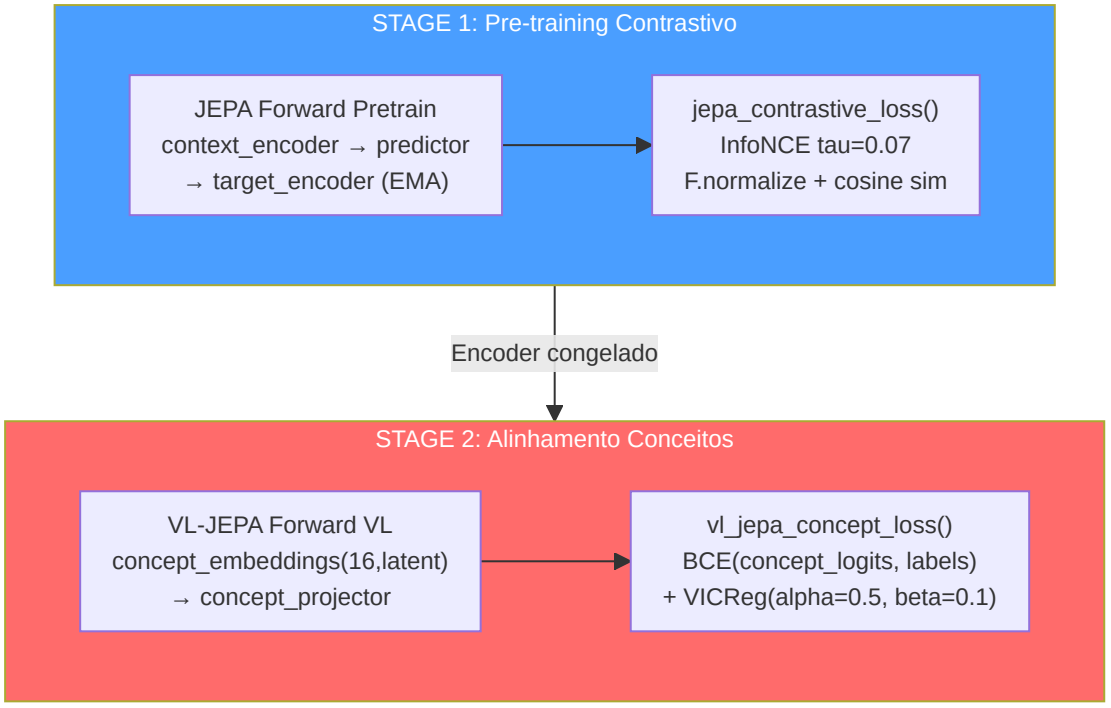

Stage	O que se treina	O que esta congelado	Loss	Proposito
1	Context encoder, predictor	Target encoder (EMA)	InfoNCE (tau=0.07)	Representacoes latentes gerais
2	Concept embeddings, concept projector, concept temperature	Encoder (opcional fine-tuning)	BCE + VICReg diversity	Alinhamento aos 16 coaching concepts

Os 16 Coaching Concepts (taxonomia):

Indice	Conceito	Categoria	Descricao
0	Positioning Quality	Posicionamento	Qualidade da posicao em relacao ao contexto
1	Trade Readiness	Posicionamento	Prontidao para o trade kill
2	Rotation Speed	Posicionamento	Velocidade de rotacao entre sites
3	Utility Usage	Utility	Frequencia e qualidade do uso de granadas
4	Utility Effectiveness	Utility	Eficacia das utilities usadas
5	Decision Quality	Decisao	Qualidade das decisoes in-game
6	Risk Assessment	Decisao	Avaliacao de risco pre-acao
7	Engagement Timing	Engajamento	Timing dos engajamentos
8	Engagement Distance	Engajamento	Distancia otima de engajamento
9	Crosshair Placement	Engajamento	Posicionamento de mira pre-peek
10	Recoil Control	Engajamento	Controle do recoil
11	Economy Management	Decisao	Gestao da economia do time
12	Information Gathering	Decisao	Coleta de informacoes (peek, utility info)
13	Composure Under Pressure	Psicologia	Compostura sob pressao
14	Aggression Control	Psicologia	Controle da agressividade
15	Adaptation Speed	Psicologia	Velocidade de adaptacao ao meta adversario

> **Analogia dos 16 Conceitos:** Os 16 coaching concepts sao como as **16 materias de um curriculo escolar completo**. Tres materias sao sobre **geografia** (posicionamento — onde voce esta). Duas sao sobre **quimica** (utility — como voce usa seus instrumentos). Cinco sao sobre **estrategia** (decisao e economia — as escolhas que voce faz). Quatro sao sobre **ginastica** (engajamento — as habilidades fisicas: mira, recoil, timing). Tres sao sobre **psicologia** (compostura, agressividade, adaptacao). O Stage 2 do VL-JEPA ensina ao modelo a "entender" essas 16 materias e a dar uma nota a cada uma para cada acao do jogador.

AdamW + CosineAnnealing (JEPA Trainer):

Hiperparametro	Valor	Proposito
Optimizer	AdamW	Weight decay separado dos gradientes
Learning rate	1e-4 (default)	Taxa de aprendizado inicial
Weight decay	0.01	Regularizacao L2
Scheduler	CosineAnnealingLR	Decaimento cosseno do LR ate 0
EMA decay	0.996	Target encoder momentum update
Gradient clip	1.0	Prevencao de gradient explosion

DriftMonitor (z_threshold=2.5):

O `DriftMonitor` integrado no JEPA Trainer monitora o **drift das features** durante o training. Se o Z-score de uma feature superar 2.5, emite um warning que indica possivel distribuicao shifting:

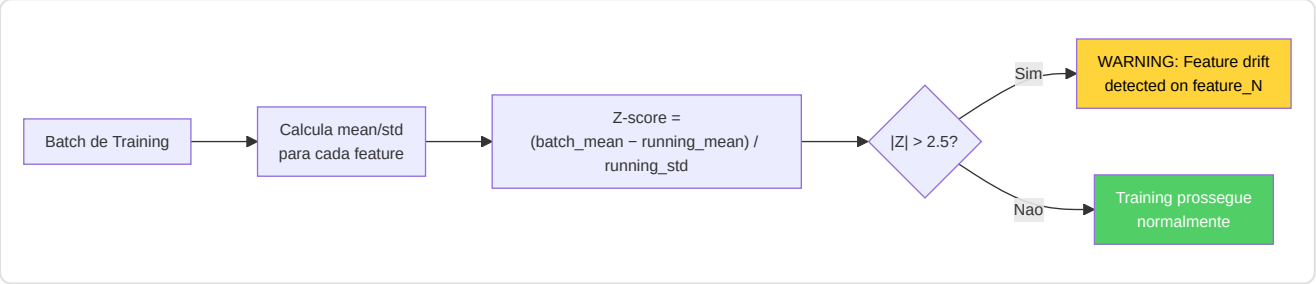

Trigger de retreinamento: O daemon Teacher monitora o crescimento do numero de demos profissionais; ativa o retreinamento quando `count >= last_count x 1,10`.

> **Analogia:** O trigger de retreinamento e como uma **escola que atualiza seu curriculo quando chegam livros didaticos novos suficientes**. O daemon Teacher (um processo em background) verifica constantemente: "Quantas demos profissionais temos agora?". Quando o numero cresce 10% ou mais desde o ultimo treinamento, diz: "Temos material novo suficiente: e hora de requalificar o modelo para que ele permaneca a par da evolucao do meta profissional."

JEPAPretrainDataset (`jepa_train.py`):

O dataset de pre-training JEPA usa **janelas temporais** para criar pares contexto-target:

Parametro	Valor	Proposito
`context_len`	10 ticks	Tamanho janela de contexto (input)
`target_len`	10 ticks	Tamanho janela target (a prever)
Gap	0-5 ticks (random)	Distancia variavel entre contexto e target
Batch size	32	Numero de pares por batch

Analogia do Dataset: O dataset de pre-training e como um **exercicio de leitura rapida**. Ao modelo e mostrada uma pagina do livro (10 ticks de contexto) e entao e perguntado: "O que esta escrito na proxima pagina?" (10 ticks target). O gap variavel torna o exercicio mais dificil — as vezes a proxima pagina vem logo em seguida, as vezes sao separadas por algumas paginas em branco. Isso forca o modelo a aprender padroes gerais, nao sequencias especificas.

---

11. Catalogo das funcoes de perda

Analogia: As funcoes de perda sao os **pontuacoes dos testes** que a IA tenta minimizar. Cada modelo tem seu proprio tipo de teste. Uma pontuacao mais baixa significa um desempenho melhor, o oposto das notas escolares! Pense em cada funcao de perda como uma questao especifica do teste: "Quao proxima sua previsao estava da resposta correta?" (MSE), "Voce escolheu a resposta correta entre varias opcoes?" (InfoNCE/BCE), "Voce usou muitos recursos?" (Sparsidade). A tabela a seguir e similar ao **calendario completo do exame**: cada teste, para cada modelo, com a formula de avaliacao exata.

Modelo	Nome da perda	Formula	Proposito
JEPA	InfoNCE Contrastive	`-log(exp(sim(pred, target)/tau) / Sigma exp(sim(pred, neg_i)/tau))`, tau=0.07, `F.normalize` antes da similaridade cosseno	Alinhamento das previsoes de contexto com os embeddings do target
JEPA	Otimizacao	`MSE(coaching_head(Z_ctx), y_true)`	Pontuacao de coaching supervisionado
AdvancedCoachNN	Supervisionado	`MSELoss(MoE_output, y_true)`	Treinamento a nivel de partida
RAP	Estrategia	`MSELoss(advice_probs, target_strat)`	Recomendacao tatica correta
RAP	Valor	`0,5 x MSE(V(s), true_advantage)`	Estimativa precisa da vantagem
RAP	Sparsidade	`L1(gate_weights)`	Especializacao de especialistas
RAP	Posicao	`MSE(xy) + 2x MSE(z)`	Posicionamento otimo com penalidade no eixo Z
WinProb	Previsao	`BCEWithLogitsLoss(pred, resultado)`	Previsao do resultado do round
NeuralRoleHead	KL-Divergence	`KLDivLoss(log_softmax(pred), target)` com smoothing de labels epsilon=0,02	Correspondencia da distribuicao de probabilidade do papel
VL-JEPA	Alinhamento de conceitos	`BCE(concept_logits, concept_labels)` + `VICReg(concept_diversity)`	Fundamentos do conceito de linguagem visual

> **Analogia para as funcoes de perda das chaves: InfoNCE** e como um teste de multipla escolha: "Aqui estao 32 respostas possiveis: qual e a correta?" O modelo obtem uma pontuacao mais alta por escolher a certa E por ter certeza disso. A **MSE** (Erro Quadratico Medio) e como medir a distancia do seu dardo do centro do alvo: mais perto = menor perda. A **BCE** (Entropia Cruzada Binaria) e como um quiz verdadeiro/falso: "Seu time venceu? Sim ou nao?". A **Perda de Sparsidade** e como um professor que diz "Use menos palavras na sua redacao": encoraja o modelo a ativar menos especialistas, tornando-o mais eficiente e interpretavel. A **Perda de Posicao com penalidade Z 2x** e como dizer "errar para a esquerda ou para a direita e grave, mas cair de um precipicio (do andar errado) e duas vezes pior". A **KL-Divergence** e como comparar dois rankings: "Sua classificacao de papeis corresponde a real?" — mede o quanto a distribuicao prevista se desvia da target.

Detalhe: InfoNCE Contrastive Loss (JEPA)

O InfoNCE e a loss principal do pre-training JEPA. Seu proposito e alinhar as predicoes do contexto com os embeddings do target, rejeitando simultaneamente os negativos (outras amostras no batch):

```
L_InfoNCE = -log( exp(sim(pred, target+) / tau) / Sigma_i exp(sim(pred, target_i) / tau) )
```

Componente	Valor	Papel
`sim()`	Cosine similarity apos `F.normalize`	Medida de similaridade [-1, +1]
`tau` (temperature)	0.07	Sharpness da distribuicao — valores baixos = mais seletivos
`target+`	O embedding target correto para este contexto	O "positivo" — a resposta correta
`target_i`	Todos os embeddings no batch	Negativos in-batch — as respostas erradas
Batch size	32	Numero de negativos = batch_size - 1 = 31

> **Analogia InfoNCE:** Imagine estar em uma sala com 32 pessoas. E mostrada uma foto (contexto) e voce deve encontrar a pessoa certa (target positivo) entre as 32. A temperatura tau=0.07 e como a **nitidez dos oculos**: valores baixos significam oculos muito precisos — voce precisa ter muita certeza da sua escolha para obter uma boa pontuacao. Valores altos significam oculos embacados — ate uma escolha aproximada e ok. O tau baixo do JEPA forca o modelo a aprender representacoes muito precisas.

Detalhe: VL-JEPA Concept Loss (VICReg Components)

A loss de alinhamento de conceitos do VL-JEPA combina dois componentes:

```
L_concept = BCE(concept_logits, concept_labels) + alpha*VICReg_diversity
```

Onde `VICReg_diversity` e composto por:

Termo VICReg	Formula	Peso	Proposito
Variance	`max(0, gamma - std(z))` para cada dimensao	alpha=0.5	Previne o colapso das representacoes — cada dimensao deve variar
Covariance	`Sigma_i!=j cov(z_i, z_j)^2`	beta=0.1	Decorrelacao — cada dimensao deve capturar informacoes diferentes

> **Analogia VICReg:** A **Variance** e como um professor que diz "Cada um de voces deve ter uma opiniao diferente — nao copiem todos a mesma resposta!" (previne o colapso onde todos os concept embeddings se tornam identicos). A **Covariance** e como dizer "Cada aluno deve se especializar em uma materia diferente — nao precisamos de 16 especialistas em historia e zero em matematica!" (forca diversidade entre as dimensoes). Juntas, garantem que os 16 concept embeddings sejam **diversos entre si** e **significativos individualmente**.

Detalhe: RAP Multi-Task Loss

O RAP Coach combina 4 losses em uma loss total ponderada:

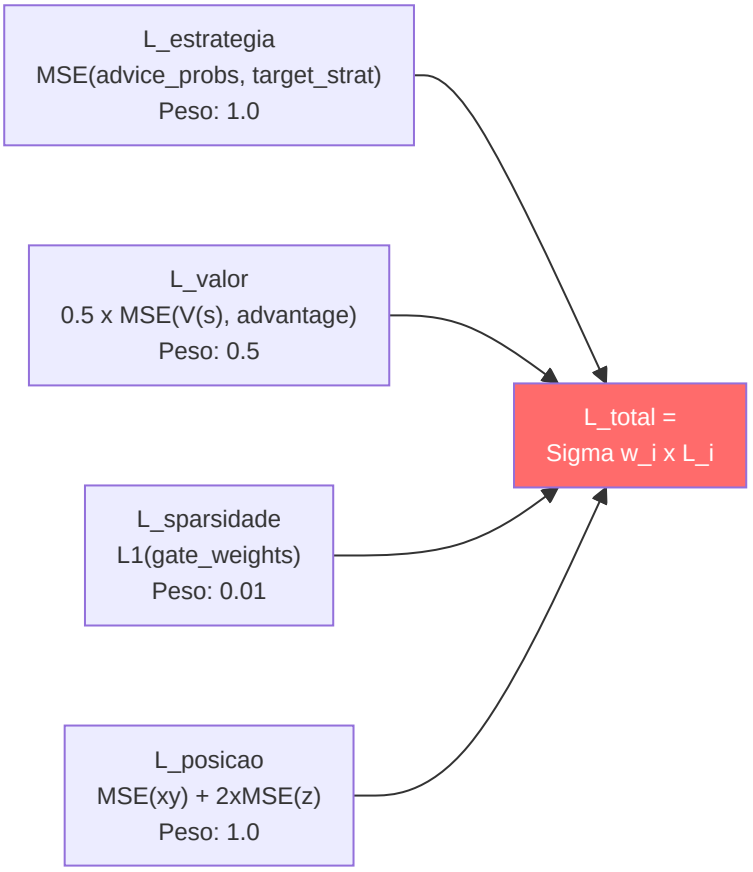

A penalidade Z 2x na loss de posicao reflete o fato de que em CS2 errar o **andar** (em cima vs embaixo em Nuke/Vertigo) e muito mais grave do que errar a posicao horizontal. Um erro de 100 unidades no eixo Z (andar errado) e estrategicamente catastrofico, enquanto o mesmo erro em X/Y pode ser irrelevante.

---

12. Logica Completa do Programa — Do Lancamento ao Conselho

Este capitulo documenta a **logica completa** do Macena CS2 Analyzer, desde o momento em que o usuario lanca a aplicacao ate quando recebe os conselhos de coaching. Ao contrario dos capitulos anteriores que se concentram nos subsistemas AI, aqui e explicado como **cada componente do programa** trabalha em conjunto: a interface desktop, a arquitetura quad-daemon, a pipeline de ingestao, o sistema de storage, o playback tatico, a observabilidade e o ciclo de vida da aplicacao.

> **Analogia:** Se os capitulos 1-11 descrevem os **orgaos individuais** de um corpo humano (cerebro, coracao, pulmoes, figado), este capitulo descreve o **corpo inteiro em acao**: como acorda pela manha, como respira, caminha, come, pensa e fala. Entender os orgaos e essencial, mas entender como trabalham juntos e o que da vida ao sistema. Imagine o Macena CS2 Analyzer como uma **pequena cidade**: tem uma prefeitura (o processo principal Kivy), uma central operacional subterranea (o Session Engine com seus 4 daemons), um arquivo municipal (o banco de dados SQLite), um correios (a pipeline de ingestao), uma escola (o sistema de treinamento ML), uma biblioteca (o sistema de conhecimento RAG/COPER), um hospital (o servico de coaching) e um sistema de monitoramento de saude publica (a observabilidade). Este capitulo os guia atraves de cada edificio e mostra como os cidadaos (os dados) se movem de um lugar para outro.

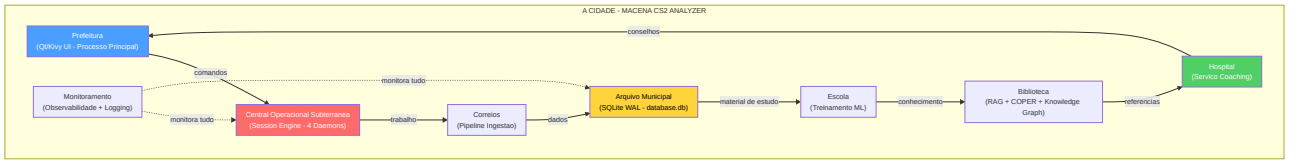

12.1 Ponto de Entrada e Sequencia de Inicializacao

O sistema dispoe de **dois entry points principais** (Qt primario, Kivy legacy) e tres entry points de utilidade:

#	Entry Point	Comando	Papel
1	**Qt (primario)**	`python -m Programma_CS2_RENAN.apps.qt_app.app`	UI desktop PySide6
2	Kivy (legacy)	`python -m Programma_CS2_RENAN.main`	UI desktop Kivy/KivyMD
3	Session Engine	`python -m Programma_CS2_RENAN.backend.console`	Backend headless
4	Headless Validator	`python -m Programma_CS2_RENAN.tools.headless_validator`	Validacao CI/CD
5	HLTV Sync	`python -m Programma_CS2_RENAN.tools.hltv_sync`	Scraping dados pro

12.1.1 Entry Point Qt (Primario) — `apps/qt_app/app.py`

Arquivo: `Programma_CS2_RENAN/apps/qt_app/app.py`

A sequencia de inicializacao Qt segue uma abordagem mais moderna baseada em **QApplication** e **signal/slot** em vez do loop de eventos Kivy:

1. **High-DPI setup** — Habilita scaling automatico para displays de alta densidade
2. **QApplication** — Cria a instancia aplicacao Qt com gestao de args
3. **Tema e font** — Registra os 3 temas (CS2, CSGO, CS1.6) via QSS e as fontes personalizadas
4. **MainWindow** — Constroi `QMainWindow` com sidebar + `QStackedWidget` (14 telas)
5. **Signal wiring** — Conecta os sinais Qt entre sidebar, telas e backend
6. **First-run gate** — Se `SETUP_COMPLETED=False`, mostra o wizard; caso contrario a home
7. **Backend console boot** — Lanca o Session Engine como subprocess
8. **Window show** — Mostra a janela e inicia o loop de eventos Qt
9. **CoachState polling** — Timer Qt para atualizacao periodica do estado

> **Analogia:** A inicializacao Qt e como o **acionamento de um carro moderno com start/stop eletronico**. Um unico botao (QApplication) inicia a sequencia: o computador de bordo configura o display (High-DPI), carrega o tema do painel (QSS), monta todos os instrumentos (14 telas no QStackedWidget), conecta os sensores (signal wiring), verifica se e a primeira inicializacao (first-run gate), liga o motor (backend console) e finalmente ilumina o painel (window show).

12.1.2 Entry Point Kivy (Legacy) — `main.py`

Arquivo: `Programma_CS2_RENAN/main.py`

Quando o usuario lanca a aplicacao atraves do entry point legacy, `main.py` orquestra uma **sequencia de inicializacao de 9 fases** rigorosamente ordenada. Cada fase deve completar com sucesso antes que a proxima possa comecar. Se uma fase critica falhar, a aplicacao termina com uma mensagem explicita — nunca silenciosamente.

> **Analogia:** A inicializacao do programa e como a **checklist pre-voo de um aviao**. Antes que o aviao possa decolar, o piloto (main.py) deve completar uma serie de verificacoes em ordem: verificar a integridade da fuselagem (audit RASP), configurar os instrumentos (configuracao de paths), verificar o combustivel (migracao do banco), ligar os motores (inicializacao Kivy), embarcar os passageiros (registro das telas), ativar o piloto automatico (lancamento daemons) e finalmente decolar (mostrar a interface). Se uma verificacao falhar — por exemplo o combustivel e insuficiente (banco corrompido) — o voo e cancelado, nao tenta decolar esperando que de certo.

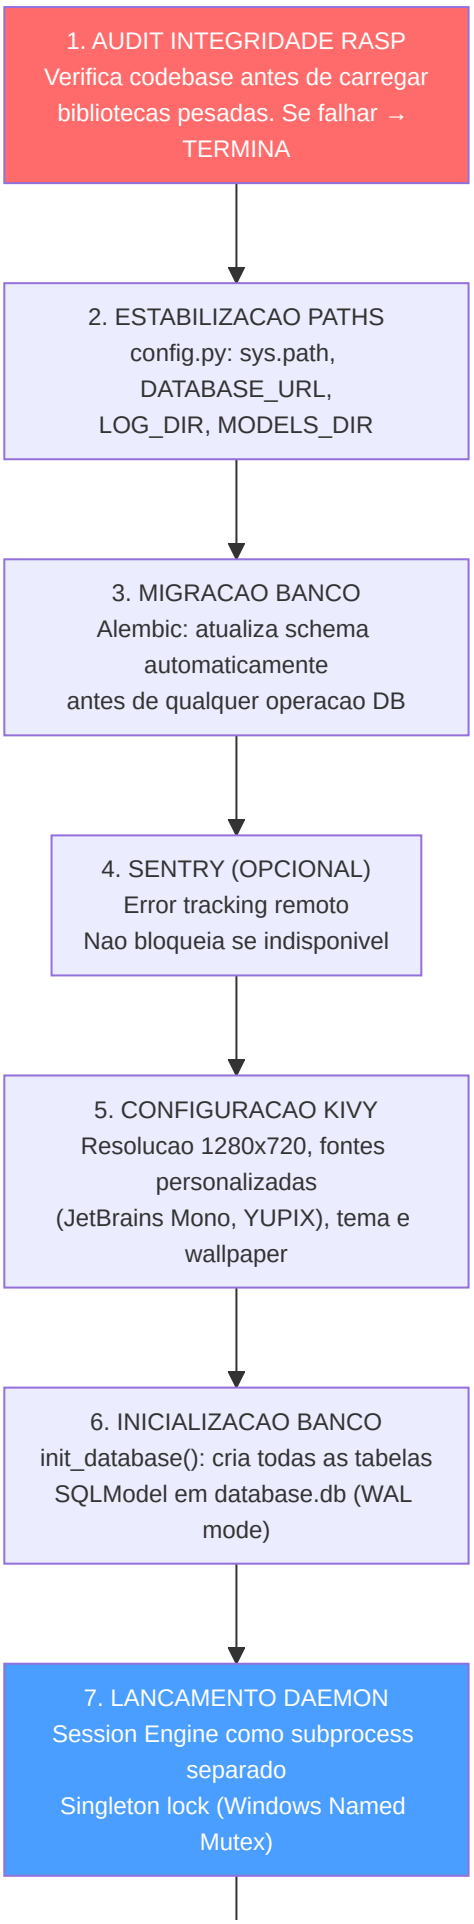
1. AUDIT INTEGRIDADE RASP
Verifica codebase antes de carregar bibliotecas pesadas. Se falhar → TERMINA
2. ESTABILIZACAO PATHS
config.py: sys.path, DATABASE_URL, LOG_DIR, MODELS_DIR
3. MIGRACAO BANCO
Alembic: atualiza schema automaticamente
antes de qualquer operacao DB
4. SENTRY (OPCIONAL)
Error tracking remoto
Nao bloqueia se indisponivel
5. CONFIGURACAO KIVY
Resolucao 1280x720, fontes personalizadas
(JetBrains Mono, YUPIX), tema e wallpaper
6. INICIALIZACAO BANCO
init_database(): cria todas as tabelas SQLModel em database.db (WAL mode)
7. LANCAMENTO DAEMON
Session Engine como subprocess separado
Singleton lock (Windows Named Mutex)

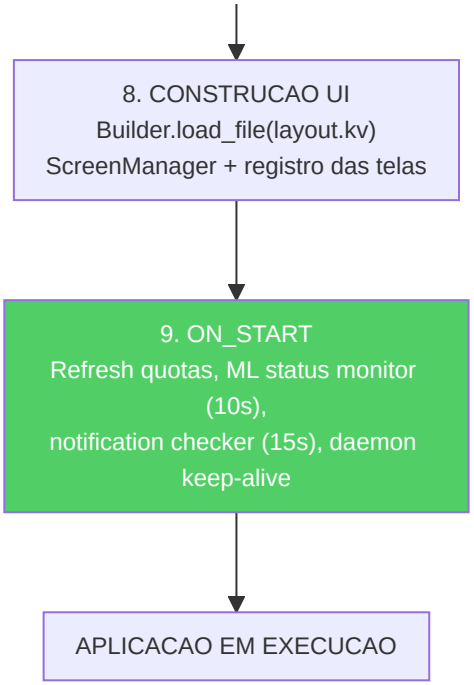

Detalhes das fases criticas:

Fase	Componente	O que faz	Consequencia da falha
1	`integrity.py` (RASP)	Verifica hash dos arquivos fonte contra o manifesto	Terminacao imediata — possivel adulteracao
2	`config.py`	Estabiliza `sys.path`, define todas as constantes de path	Erros de importacao em cascata
3	`db_migrate.py`	Executa migracoes Alembic pendentes	Schema incompativel — crash em operacoes DB
5	Kivy `Config`	Configura `KIVY_NO_CONSOLELOG`, registra fontes, carrega `.kv`	UI nao renderizavel
6	`database.py`	`create_all()` em engine SQLite com `check_same_thread=False`	Nenhuma persistencia possivel
7	`lifecycle.py`	Lanca subprocess com PYTHONPATH correto, verifica mutex	Nenhuma automacao em background

> **Analogia:** As consequencias da falha sao dispostas como **pecas de domino**: se a fase 2 (paths) falhar, as fases 3-9 cairao todas porque nenhuma sabe onde encontrar o banco, os modelos ou os logs. Se a fase 6 (banco) falhar, as fases 7-9 funcionarao aparentemente, mas nao poderao salvar nem recuperar nada — como um restaurante que abriu as portas mas esqueceu de ligar os fogoes.

12.2 Gestao do Ciclo de Vida (`lifecycle.py`)

Arquivo: `Programma_CS2_RENAN/core/lifecycle.py`

O `AppLifecycleManager` e um **Singleton** que gerencia o ciclo de vida da aplicacao inteira: desde a garantia de que exista uma unica instancia ativa, ao lancamento do subprocess daemon, ate o shutdown coordenado.

> **Analogia:** O Lifecycle Manager e como o **diretor de um teatro**. Antes do espetaculo, verifica que nao haja outros espetaculos em andamento na mesma sala (Single Instance Lock). Entao contrata o diretor (Session Engine daemon) que trabalhara nos bastidores. Durante o espetaculo, o diretor esta sempre presente em caso de emergencia. No final, o diretor garante que todos saiam do teatro em ordem: primeiro o diretor de cena termina seu trabalho, depois as luzes se apagam, depois as portas se fecham.

Mecanismos principais:

Mecanismo	Implementacao	Proposito
Single Instance Lock	Windows Named Mutex / file lock em Linux	Impede instancias multiplas (corrupcao DB)
Lancamento Daemon	`subprocess.Popen(session_engine.py)` com PYTHONPATH	Processo separado para trabalho pesado
Deteccao Morte do Pai	O daemon monitora EOF em `stdin`	Se o processo principal morre, o daemon para
Shutdown Graceful	Envio "STOP" via stdin → daemon termina em 5s	Nenhuma perda de dados ou tasks zumbis
Status Polling	UI consulta `CoachState` a cada 10s	Atualizacao status daemon sem IPC direto
Error Recovery	Se daemon morre, erro registrado + ServiceNotification	Usuario informado, nenhum crash silencioso
Keep-Alive	UI verifica heartbeat a cada 15s	Se heartbeat > 30s stale → warning "Daemon nao responde"

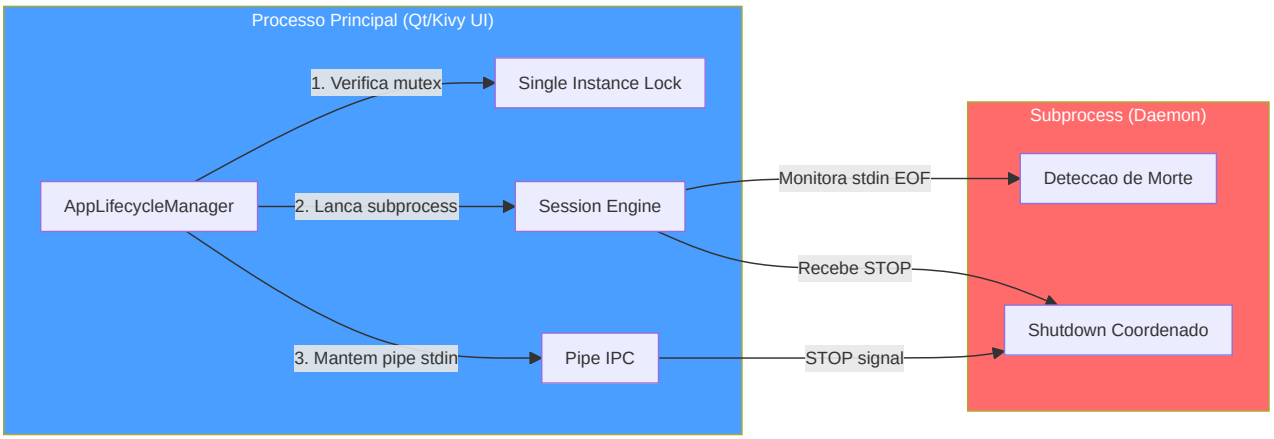

> **Analogia:** O pipe `stdin` e como um **fio de telefone** entre o diretor e o diretor de cena. Enquanto o fio estiver conectado, o diretor de cena sabe que o diretor ainda esta presente. Se o fio se rompe subitamente (EOF — o processo principal crasha), o diretor de cena entende que o espetaculo acabou e fecha tudo de forma ordenada. Se o diretor quer terminar normalmente, envia a mensagem "STOP" atraves do fio e espera que o diretor de cena confirme que terminou.

12.3 Sistema de Configuracao (`config.py`)

Arquivo: `Programma_CS2_RENAN/core/config.py`

O sistema utiliza **tres niveis de configuracao**, cada um com um diferente nivel de persistencia e seguranca:

> **Analogia:** Os tres niveis de configuracao sao como as **tres camadas de uma armadura medieval**. A camada interna (hardcoded) e a armadura base que nunca muda — os fundamentos do sistema. A camada intermediaria (JSON) e a cota de malha personalizavel — o usuario pode ajusta-la como preferir. A camada externa (Keyring) e o elmo com visiera — protege os segredos mais preciosos (chaves API) em um cofre do sistema operacional, inacessivel a olhos curiosos.

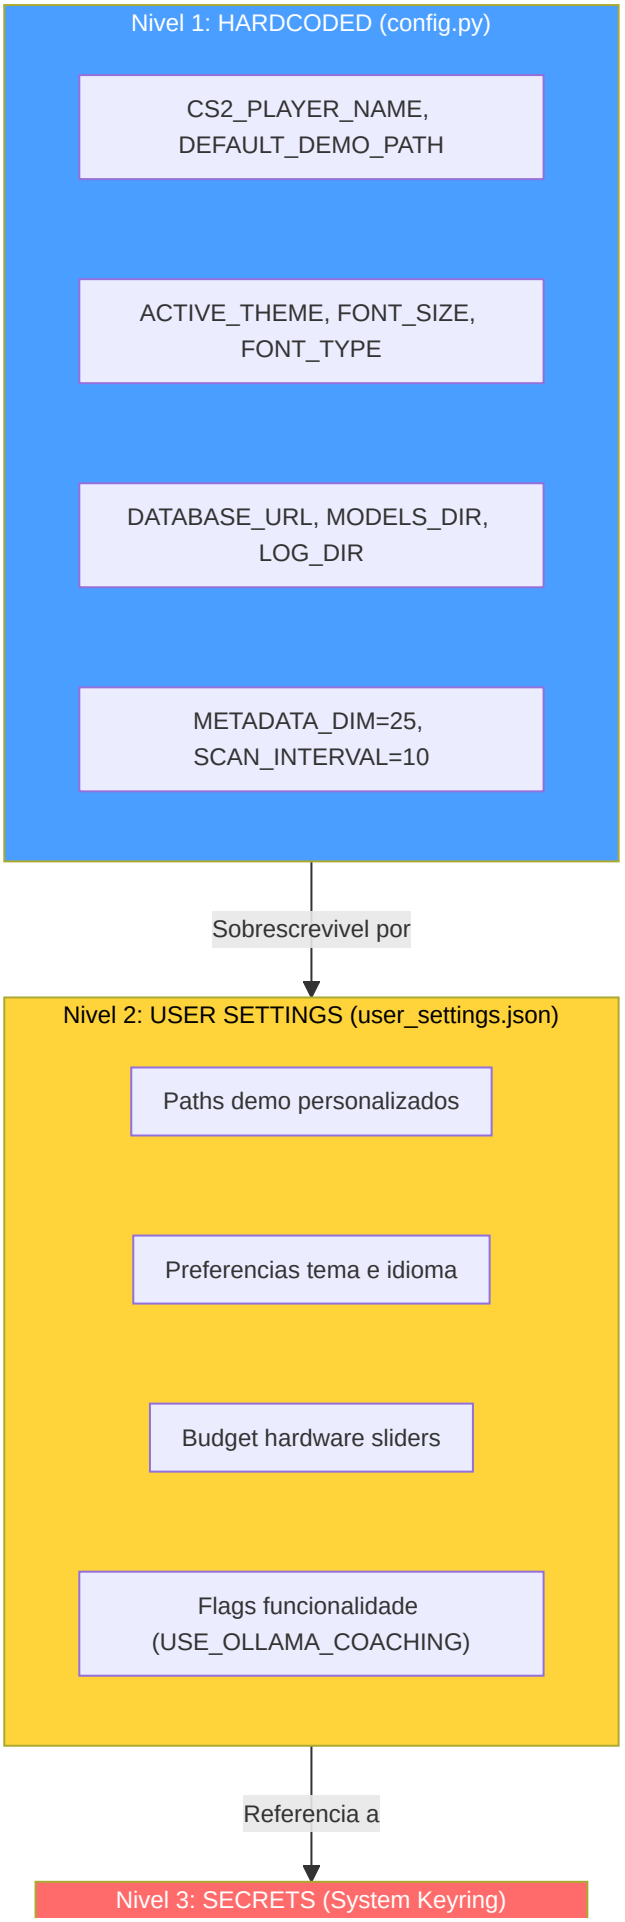
Nivel 1: HARDCODED (config.py)
CS2_PLAYER_NAME, DEFAULT_DEMO_PATH
ACTIVE_THEME, FONT_SIZE, FONT_TYPE
DATABASE_URL, MODELS_DIR, LOG_DIR
METADATA_DIM=25, SCAN_INTERVAL=10
Sobrescrevivel por
Nivel 2: USER SETTINGS (user_settings.json)
Paths demo personalizados
Preferencias tema e idioma
Budget hardware sliders
Flags funcionalidade (USE_OLLAMA_COACHING)
Referencia a
Nivel 3: SECRETS (System Keyring)

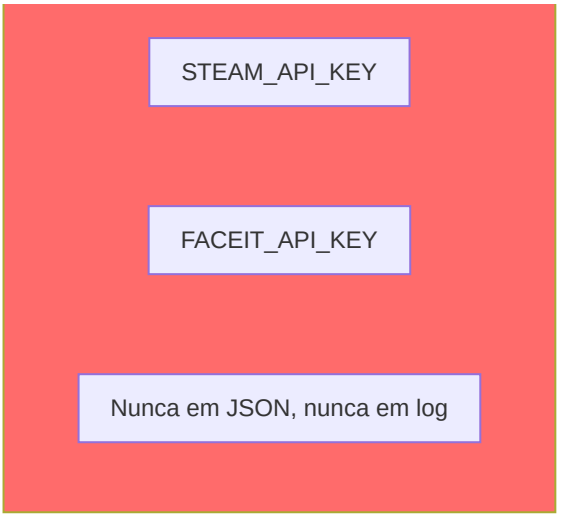

Constantes criticas do sistema:

Constante	Valor	Arquivo	Proposito
`METADATA_DIM`	25	`config.py`	Dimensao do feature vector — contrato unificado
`SCAN_INTERVAL`	10	`config.py`	Intervalo scan Scanner (segundos)
`MAX_DEMOS_PER_MONTH`	10	`config.py`	Quota mensal upload demo
`MAX_TOTAL_DEMOS`	100	`config.py`	Limite total de demos por vida
`MIN_DEMOS_FOR_COACHING`	10	`config.py`	Limite para coaching personalizado completo
`TRADE_WINDOW_TICKS`	192	`trade_kill_detector.py`	Janela temporal trade kill (~3 segundos a 64 ticks)
`HLTV_BASELINE_KPR`	0.679	`demo_parser.py`	Baseline HLTV 2.0 para KPR
`HLTV_BASELINE_SURVIVAL`	0.317	`demo_parser.py`	Baseline HLTV 2.0 para survival
`FOV_DEGREES`	90	`player_knowledge.py`	Campo de visao simulado do jogador
`MEMORY_DECAY_TAU`	160	`player_knowledge.py`	Constante de decaimento memoria tick
`CONFIDENCE_ROUNDS_CEILING`	300	`correction_engine.py`	Teto de rounds para confianca maxima
`SILENCE_THRESHOLD`	0.2	`explainability.py`	Limite abaixo do qual o silencio e acao valida
`MIN_SAMPLES_FOR_VALIDITY`	10	`role_thresholds.py`	Amostras minimas para limite papel valido
`HALF_LIFE_DAYS`	90	`pro_baseline.py`	Decaimento temporal dados pro
`Z_LEVEL_THRESHOLD`	200	`connect_map_context.py`	Limite Z para classificacao de andar

> **Analogia das Constantes:** As constantes sao como os **parametros vitais de referencia** em medicina. `METADATA_DIM=25` e como dizer "a pressao sistolica normal e 120" — todos os medicos (modelos ML) usam a mesma referencia. `TRADE_WINDOW_TICKS=192` e como a "golden hour" em traumatologia: se um companheiro e morto e voce mata o assassino dele dentro de 3 segundos, e um trade kill. `SILENCE_THRESHOLD=0.2` e como o "primum non nocere" (primeiro, nao ferir): se o coach nao tem nada significativo a dizer, e melhor ficar em silencio do que dar conselhos inuteis.

Arquitetura de paths:

O sistema gerencia paths com uma atencao especial a **portabilidade Windows/Linux**. O coracao e `BRAIN_DATA_ROOT`: um diretorio configuravel pelo usuario que contem modelos, logs e dados derivados. Se nao existe, o sistema recai na pasta do projeto.

Path	Conteudo	Configuravel
`DATABASE_URL`	Banco monolite principal (`database.db`)	Nao — sempre na pasta do projeto
`BRAIN_DATA_ROOT`	Raiz para dados derivados (modelos, logs)	Sim — via `user_settings.json`
`MODELS_DIR`	Checkpoints dos modelos `.pt`	Derivado de `BRAIN_DATA_ROOT`
`LOG_DIR`	Arquivos de log da aplicacao	Derivado de `BRAIN_DATA_ROOT`
`MATCH_DATA_PATH`	Bancos por-match (`match_XXXX.db`)	Derivado de `BRAIN_DATA_ROOT`
`DEFAULT_DEMO_PATH`	Pasta demo do usuario	Sim — via UI Settings
`PRO_DEMO_PATH`	Pasta demos profissionais	Sim — via UI Settings

> **Analogia:** `BRAIN_DATA_ROOT` e como o **endereco de casa do cerebro** do treinador. Voce pode move-lo para um disco maior (SSD externo) simplesmente mudando o endereco, e tudo o resto — modelos, logs, dados das partidas — seguira automaticamente. O banco principal (`database.db`), por outro lado, e como o **registro municipal**: fica sempre no mesmo lugar por razoes de integridade.

12.4 Motor de Sessao — Arquitetura Quad-Daemon (`session_engine.py`)

Arquivo: `Programma_CS2_RENAN/core/session_engine.py`

O Session Engine e o **coracao pulsante** da automacao do sistema. Vive como subprocess separado e hospeda **4 daemon threads** que trabalham em paralelo, cada um com uma responsabilidade bem definida. Esse design separa completamente o trabalho pesado (parsing demo, treinamento ML) da interface do usuario, garantindo que a GUI Kivy permaneca sempre responsiva.

> **Analogia:** O Session Engine e como uma **central nuclear subterranea** que alimenta a cidade inteira. Tem 4 reatores (daemons), cada um que produz um tipo diferente de energia. O Reator 1 (Scanner) e o **scanner de radar**: escaneia constantemente o horizonte procurando novas demos para processar. O Reator 2 (Digester) e a **refinaria**: pega as demos brutas e as transforma em dados estruturados. O Reator 3 (Teacher) e o **laboratorio de pesquisa**: usa os dados refinados para treinar o cerebro do treinador. O Reator 4 (Pulse) e o **sistema de monitoramento cardiaco**: emite uma batida a cada 5 segundos para confirmar que a central esta viva. Se a cidade na superficie (GUI Kivy) e destruida por um terremoto (crash), a central detecta a perda de comunicacao e se desliga com seguranca.

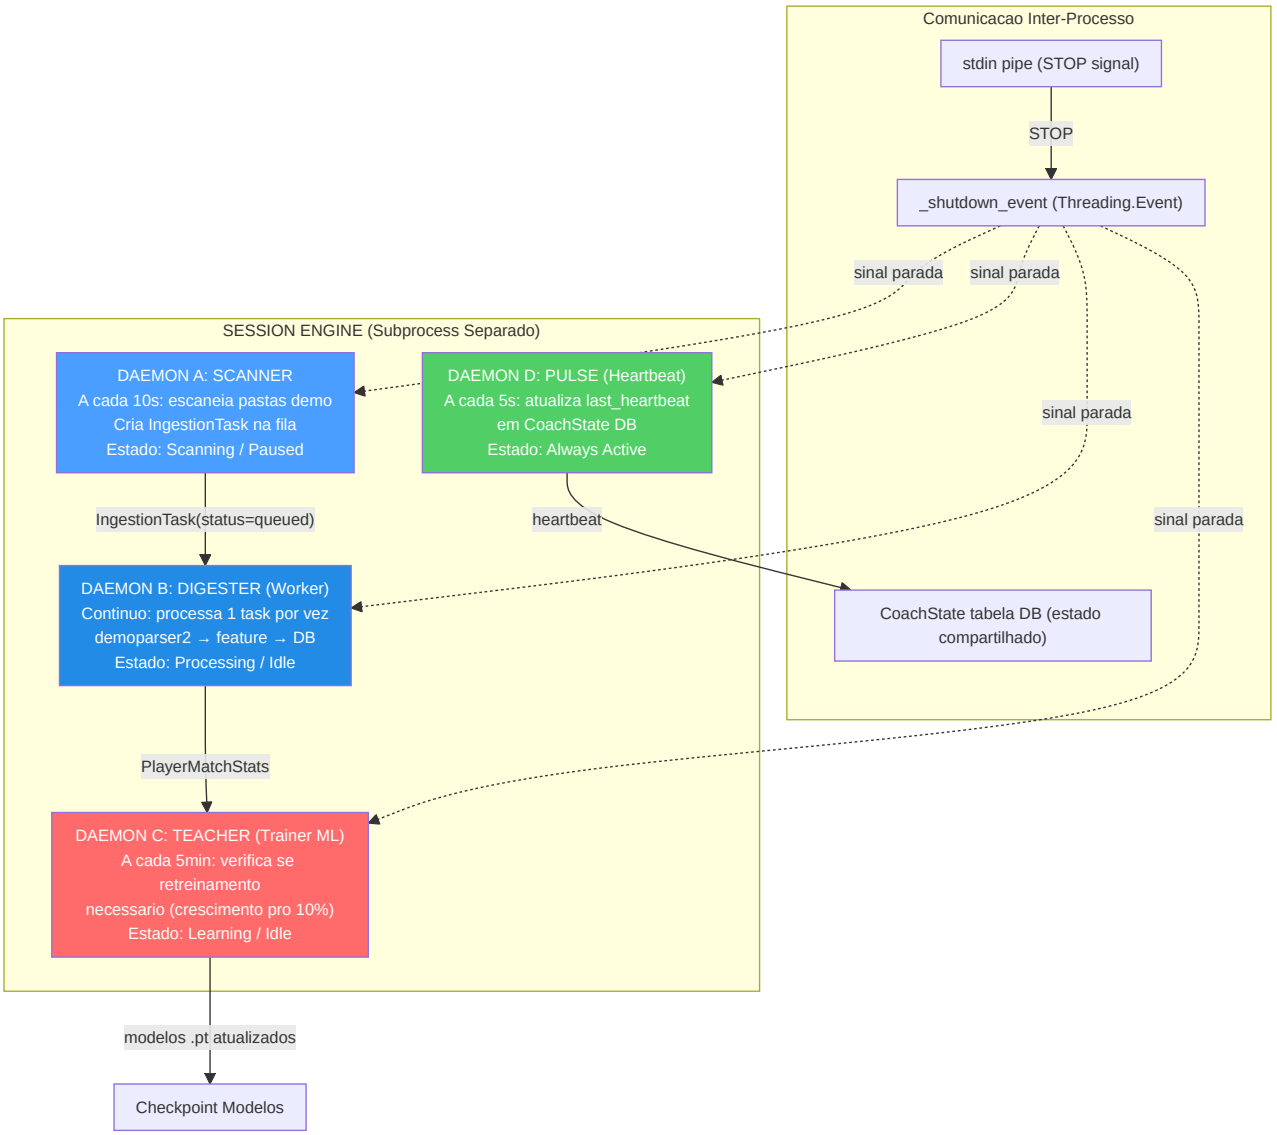

Ciclo de vida de cada daemon:

Daemon	Intervalo	Trabalho por ciclo	Trigger
Scanner	10 segundos	Escaneia pastas pro e usuario, cria `IngestionTask` para novos `.dem`	Sempre ativo (se estado = Scanning)
Digester	Continuo	Pega 1 task da fila, executa parsing completo	`_work_available_event` (sinalizado por Scanner)
Teacher	300 segundos (5 min)	Verifica crescimento sample pro; se >=10% → `run_full_cycle()`	`pro_count >= last_count x 1.10`
Pulse	5 segundos	Atualiza `CoachState.last_heartbeat` no banco	Sempre ativo

> **Analogia do Digester:** O Digester e como uma **lava-louca incansavel**: pega um prato sujo (demo bruta) da pilha, lava cuidadosamente (parsing com demoparser2, extracao feature, calculo rating HLTV 2.0, enriquecimento RoundStats), seca (normalizacao), coloca na prateleira certa (salva no banco) e entao pega o proximo prato. Nunca pega 2 pratos de uma vez — um de cada vez, para evitar erros. Se a pilha esta vazia, espera pacientemente (sleep 2s + `_work_available_event`) ate que alguem traga novos pratos sujos.

> **Analogia do Teacher:** O Teacher e como um **professor universitario que atualiza seus cursos**. A cada 5 minutos verifica: "Chegaram artigos cientificos novos suficientes (demos pro)?" Se o numero cresceu 10% desde a ultima atualizacao, diz: "E hora de reescrever as apostilas!" e lanca um ciclo completo de treinamento. Apos o treinamento, tambem executa uma verificacao meta-shift: "A media dos profissionais mudou? O meta do jogo se deslocou?" — garantindo que o coaching permaneca sempre atual.

Sequencia de shutdown:

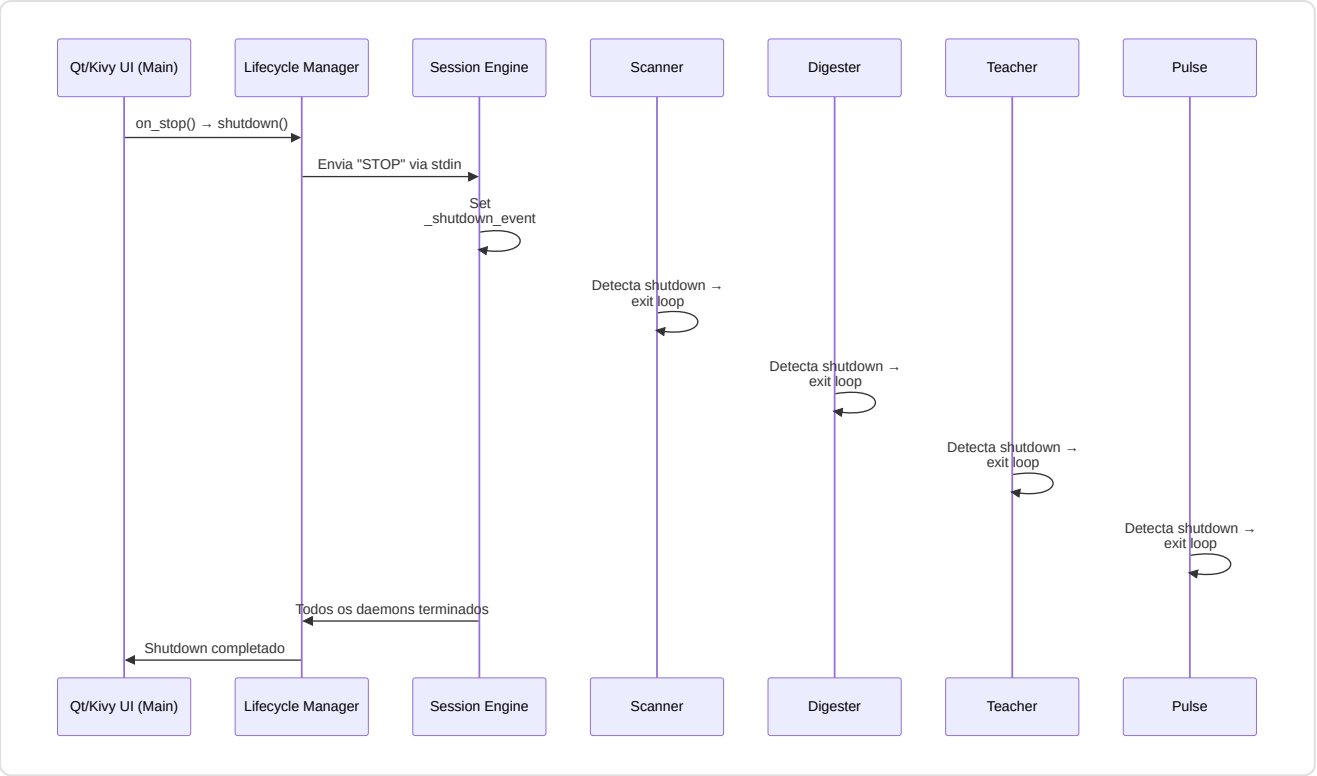

Detalhes de implementacao dos daemons:

Daemon	Metodo Principal	Loop Interno	Condicao de Saida
Scanner	`_scanner_daemon_loop()`	`while not _shutdown_event.is_set()` → `scan_all_paths()` → `sleep(10)`	`_shutdown_event` set
Digester	`_digester_daemon_loop()`	`while not _shutdown_event.is_set()` → `_work_available_event.wait(2)` → `process_next_task()`	`_shutdown_event` set
Teacher	`_teacher_daemon_loop()`	`while not _shutdown_event.is_set()` → `_check_retrain_needed()` → `sleep(300)`	`_shutdown_event` set
Pulse	`_pulse_daemon_loop()`	`while not _shutdown_event.is_set()` → `state_mgr.heartbeat()` → `sleep(5)`	`_shutdown_event` set

Gestao de erros nos daemons:

Cada daemon e protegido por um `try/except` global. Se um daemon crasha:

1. O erro e logado com traceback completo
2. O `StateManager` registra o erro (`set_error(daemon, message)`)
3. Uma `ServiceNotification` e criada para o usuario
4. O daemon **nao e reiniciado automaticamente** (por design: crash de um daemon indica um bug, nao um erro transitorio)
5. Os outros daemons continuam a funcionar independentemente

> **Analogia:** Cada daemon e um **trabalhador com seu proprio escritorio e sua propria porta**. Se um trabalhador tem um mal-estar (crash), fecha sua porta e coloca um aviso "Temporariamente indisponivel" (ServiceNotification). Os outros trabalhadores nos outros escritorios continuam a trabalhar normalmente. O diretor (Session Engine) toma nota do incidente mas nao tenta reanimar o trabalhador — prefere que um tecnico (o desenvolvedor) investigue a causa antes de faze-lo voltar ao trabalho.

Zombie Task Cleanup: Na inicializacao, o Session Engine procura tasks com `status="processing"` restantes de um crash anterior e os reseta para `status="queued"`, permitindo o restauro automatico sem perda de dados.

Backup Automatico: Na inicializacao do Session Engine, `BackupManager.should_run_auto_backup()` verifica se um backup e necessario e, em caso afirmativo, cria um checkpoint com label `"startup_auto"`. O backup segue uma rotacao de 7 copias diarias + 4 semanais.

12.5 Interface Desktop

A interface desktop tem duas implementacoes: **Qt/PySide6** (primaria) e **Kivy/KivyMD** (legacy). Ambas seguem o pattern **MVVM** (Model-View-ViewModel).

12.5.1 Interface Qt (Primaria) — `apps/qt_app/`

Diretorio: `Programma_CS2_RENAN/apps/qt_app/` **Arquivos-chave:** `app.py`, `main_window.py`, `core/i18n_bridge.py`, `core/theme_engine.py`, `screens/`

A interface Qt e construida com **PySide6 (Qt 6)** e utiliza um pattern **MVVM com Qt Signals/Slots**. A `MainWindow` (`QMainWindow`) e composta por uma **sidebar de navegacao** e um **`QStackedWidget`** que hospeda as 14 telas.

> **Analogia:** A interface Qt e como um **painel digital de um carro esportivo moderno**. O painel (QStackedWidget) tem diferentes modos de visualizacao selecionaveis pela barra lateral: a vista "Viagem" (Home), a vista "Navegacao" (Tactical Viewer com QPainter), a vista "Diagnostico" (Coach), a vista "Configuracoes" (Settings). O pattern MVVM com Signals/Slots garante que cada interacao do usuario emita um "sinal" que e capturado pelo "slot" apropriado — como os sensores do carro que se comunicam com o computador de bordo via barramento CAN.

Especificacao	Detalhe
Framework	PySide6 (Qt 6 para Python)
Pattern	MVVM com Qt Signals/Slots
Plataformas	Windows, macOS, Linux
Resolucao	Adaptativa, High-DPI nativo
Temas	3: CS2 (laranja), CSGO (azul-cinza), CS1.6 (verde) — QSS + QPalette
i18n	3 idiomas: EN, IT, PT — JSON + `QtLocalizationManager`
Graficos	QPainter para mapa tatico, widgets nativos Qt para chart

Sistema i18n: O `QtLocalizationManager` (`core/i18n_bridge.py`) carrega arquivos JSON por idioma (`en.json` , `it.json` , `pt.json`) e gerencia a troca de idioma em runtime via sinais Qt. Cada string UI e resolvida dinamicamente via chave de localizacao.

Sistema de temas: O `ThemeEngine` (`core/theme_engine.py`) aplica stylesheets QSS e configura a `QPalette` Qt para cada tema:

- **CS2** — Palette laranja (#FF6600) com fundo escuro, inspirada na UI do CS2
- **CSGO** — Palette azul-cinza (#4A90D9) com tons frios, inspirada no CS:GO
- **CS1.6** — Palette verde (#33CC33) sobre fundo preto, inspirada no look retro do CS 1.6

12.5.2 Interface Kivy (Legacy) — `apps/desktop_app/`

Diretorio: `Programma_CS2_RENAN/apps/desktop_app/` **Arquivos-chave:** `layout.kv` , `wizard_screen.py` , `player_sidebar.py` , `tactical_viewer_screen.py` , `tactical_viewmodels.py` , `tactical_map.py` , `timeline.py` , `widgets.py` , `help_screen.py` , `ghost_pixel.py`

A interface legacy e construida com **Kivy + KivyMD** e segue o pattern **MVVM** (Model-View-ViewModel). O `ScreenManager` gerencia a navegacao entre as telas com transicoes `FadeTransition` .

> **Analogia:** A interface Kivy e como um **painel de um carro esportivo classico**. O painel (ScreenManager) tem diferentes modos de visualizacao que voce pode selecionar: a vista "Viagem" (Home — dashboard geral), a vista "Navegacao" (Tactical Viewer — mapa 2D), a vista "Diagnostico" (Coach — analise detalhada), a vista "Configuracoes" (Settings — personalizacao). Cada vista tem seus indicadores especializados. O pattern MVVM garante que o "motor" (ViewModel) e o "display" (View) sejam separados: se voce mudar o design do painel, o motor continua a funcionar identicamente, e vice-versa.

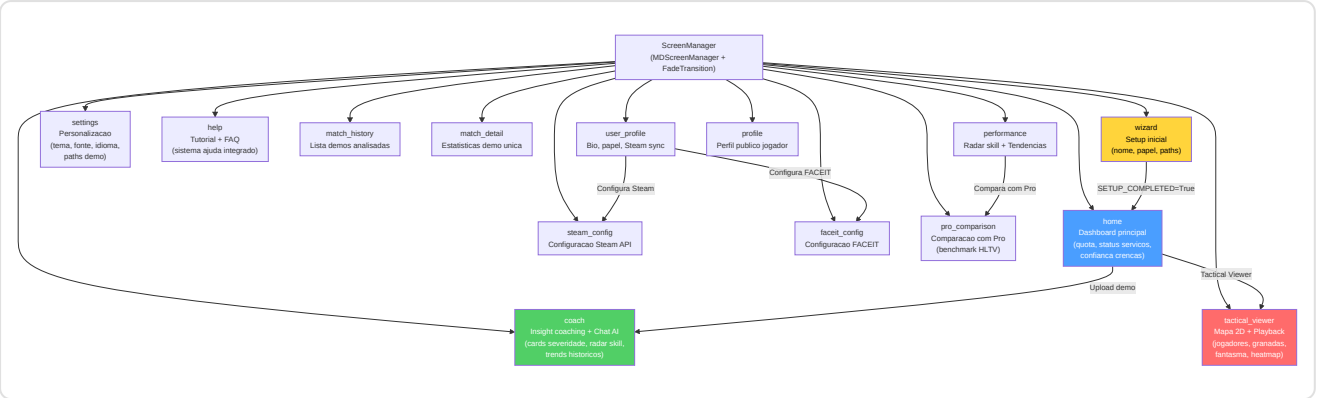

14 telas da interface:

Tela	Papel	Componentes-chave
Wizard	Primeira configuracao	Nome jogador, papel, paths pastas demo
Home	Dashboard	Quota mensal (X/10), status servicos (verde/vermelho), confianca crencas (0-1), tasks ativos, contador partidas processadas
Coach	Insight coaching	Cards coloridos por severidade, radar skill multi-dimensional, trends historicos, chat AI (Ollama/Claude), tasks ativos
Tactical Viewer	Reproducao tatica	Mapa 2D com jogadores/granadas/fantasma, timeline com marcadores de eventos, sidebar jogadores CT/T, controles de velocidade (0.25x→8x)
Settings	Personalizacao	Tema (CS2/CSGO/CS1.6), fonte, tamanho texto, idioma, paths demo, wallpaper
Help	Suporte usuario	Tutorial interativo, FAQ, troubleshooting
Match History	Historico partidas	Lista demos analisadas com filtros e ordenacao
Match Detail	Detalhe partida	Estatisticas detalhadas para uma unica demo analisada
Performance	Progressos	Radar skill de 5 eixos, graficos de tendencia, comparacoes temporais
User Profile	Perfil usuario	Bio, papel preferido, sincronizacao Steam/FACEIT
Profile	Perfil publico	Visualizacao perfil publico do jogador
Steam Config	Configuracao Steam	Insercao e validacao API key Steam
Pro Comparison	Comparacao pro	Comparacao estatisticas usuario com jogadores profissionais HLTV, benchmark prestacional
FACEIT Config	Configuracao FACEIT	Insercao e validacao API key FACEIT

> **Analogia da Home Screen:** A Home e como a **cabine de comando de uma nave espacial**. O indicador de quota ("5/10 demos este mes") e o **medidor de combustivel**. O status do servico (verde/vermelho) e o **painel dos sistemas vitais**: verde = todos os sistemas operacionais, vermelho = alarme. A confianca das crencas (0.0-1.0) e o **nivel de estabilidade da IA**: 0.0 = a IA nao sabe nada, 1.0 = a IA esta segura de suas analises. O contador das partidas processadas e o **odometro**: quanto caminho o sistema percorreu.

Widgets personalizados:

Widget	Arquivo	Funcao
`PlayerSidebar`	`player_sidebar.py`	Lista CT/T com icones de papel, saude/armadura, arma atual, dinheiro, e estado vivo/morto
`TacticalMap`	`tactical_map.py`	Canvas 2D com rendering multi-nivel: textura mapa → heatmap → jogadores → granadas → fantasma (QPainter em Qt, Canvas Kivy em legacy)
`Timeline`	`timeline.py`	Scrubber horizontal com tick numbers, marcadores de eventos coloridos, drag-to-seek, double-click jump
`GhostPixel`	`ghost_pixel.py`	Rendering do circulo fantasma semi-transparente (posicao otima predita por RAP)

Temas disponiveis:

A aplicacao suporta **3 temas** selecionaveis da tela Settings, cada um com uma palette de cores e wallpaper personalizados:

Tema	Palette primaria	Inspiracao
CS2 (default)	Azul aco + laranja	Counter-Strike 2 UI moderna
CSGO	Verde militar + amarelo	Counter-Strike: Global Offensive
CS 1.6	Marrom escuro + verde lima	Counter-Strike 1.6 classico (nostalgia)

Coach Screen — Layout detalhado:

A tela Coach e a mais complexa da aplicacao, com 5 areas funcionais:

> **Analogia do Coach Screen:** A tela Coach e como o **consultorio do medico apos a consulta**. Os **Insight Cards** sao o laudo imediato: "Pressao alta!" (vermelho), "Colesterol para monitorar" (amarelo), "Boa forma fisica" (verde). O **Radar** e a visualizacao das capacidades fisicas. Os **Trends** sao a comparacao com as consultas anteriores. O **Chat AI** e a possibilidade de fazer perguntas ao medico. Os **Tasks Ativos** mostram os exames ainda em andamento.

Pattern MVVM no Tactical Viewer:

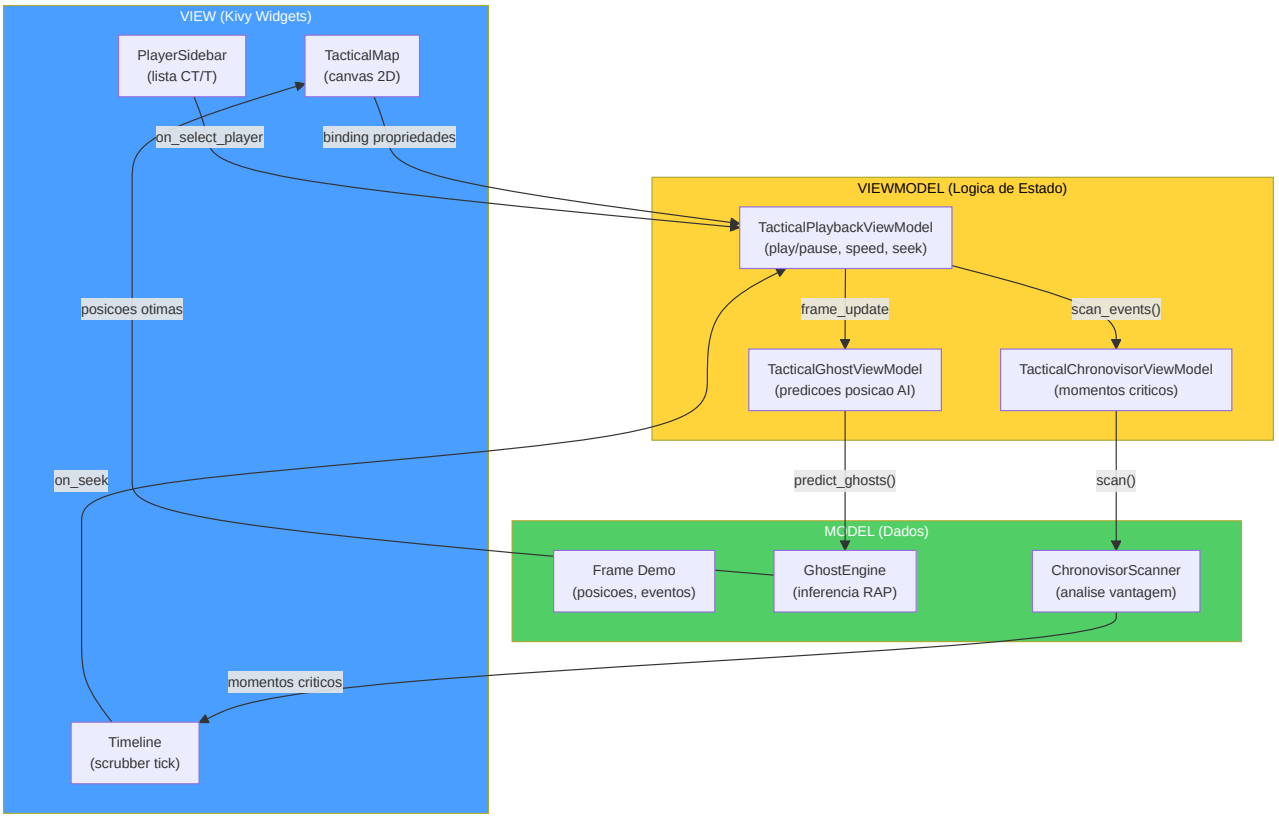

> **Analogia MVVM:** O pattern MVVM e como um **telejornal**: o **Modelo** e o jornalista em campo que coleta os fatos (dados demo, inferencia AI). O **ViewModel** e o editor que organiza as noticias e decide o que e importante (estado de reproducao, velocidade, selecao). A **View** e o apresentador que le as noticias ao publico (rendering na tela Kivy). O jornalista nao sabe como a noticia e apresentada. O apresentador nao sabe como foi coletada. O editor e a ponte entre os dois. Se voce muda o apresentador (novo design UI), a noticia permanece a mesma.

12.6 Pipeline de Ingestao (`ingestion/`)

Diretorio: `Programma_CS2_RENAN/ingestion/` **Arquivos-chave:** `demo_loader.py`, `steam_locator.py`, `integrity.py`, `registry/`, `pipelines/user_ingest.py`, `pipelines/json_tournament_ingestor.py`

A pipeline de ingestao e o **caminho completo** que um arquivo `.dem` percorre do filesystem ate se tornar insight de coaching no banco. E orquestrada pelo daemon Scanner (descoberta) e pelo daemon Digester (processamento).

Analogia: A pipeline de ingestao e como o **caminho de uma carta atraves dos correios**. (1) O carteiro (Scanner) coleta a carta (arquivo .dem) da caixa postal (pasta demo). (2) O escritorio de triagem (DemoLoader) abre o envelope e extrai o conteudo (parsing com demoparser2). (3) O arquivista (FeatureExtractor) mede e cataloga cada detalhe (25 features por tick). (4) O historiador (RoundStatsBuilder) escreve um resumo por capitulo (estatisticas por round). (5) O bibliotecario (data_pipeline) classifica e organiza o material (normalizacao, split dataset). (6) O medico (CoachingService) examina tudo e escreve um diagnostico (insights de coaching). (7) Por fim, tudo e arquivado (persistencia em banco) para consulta futura.

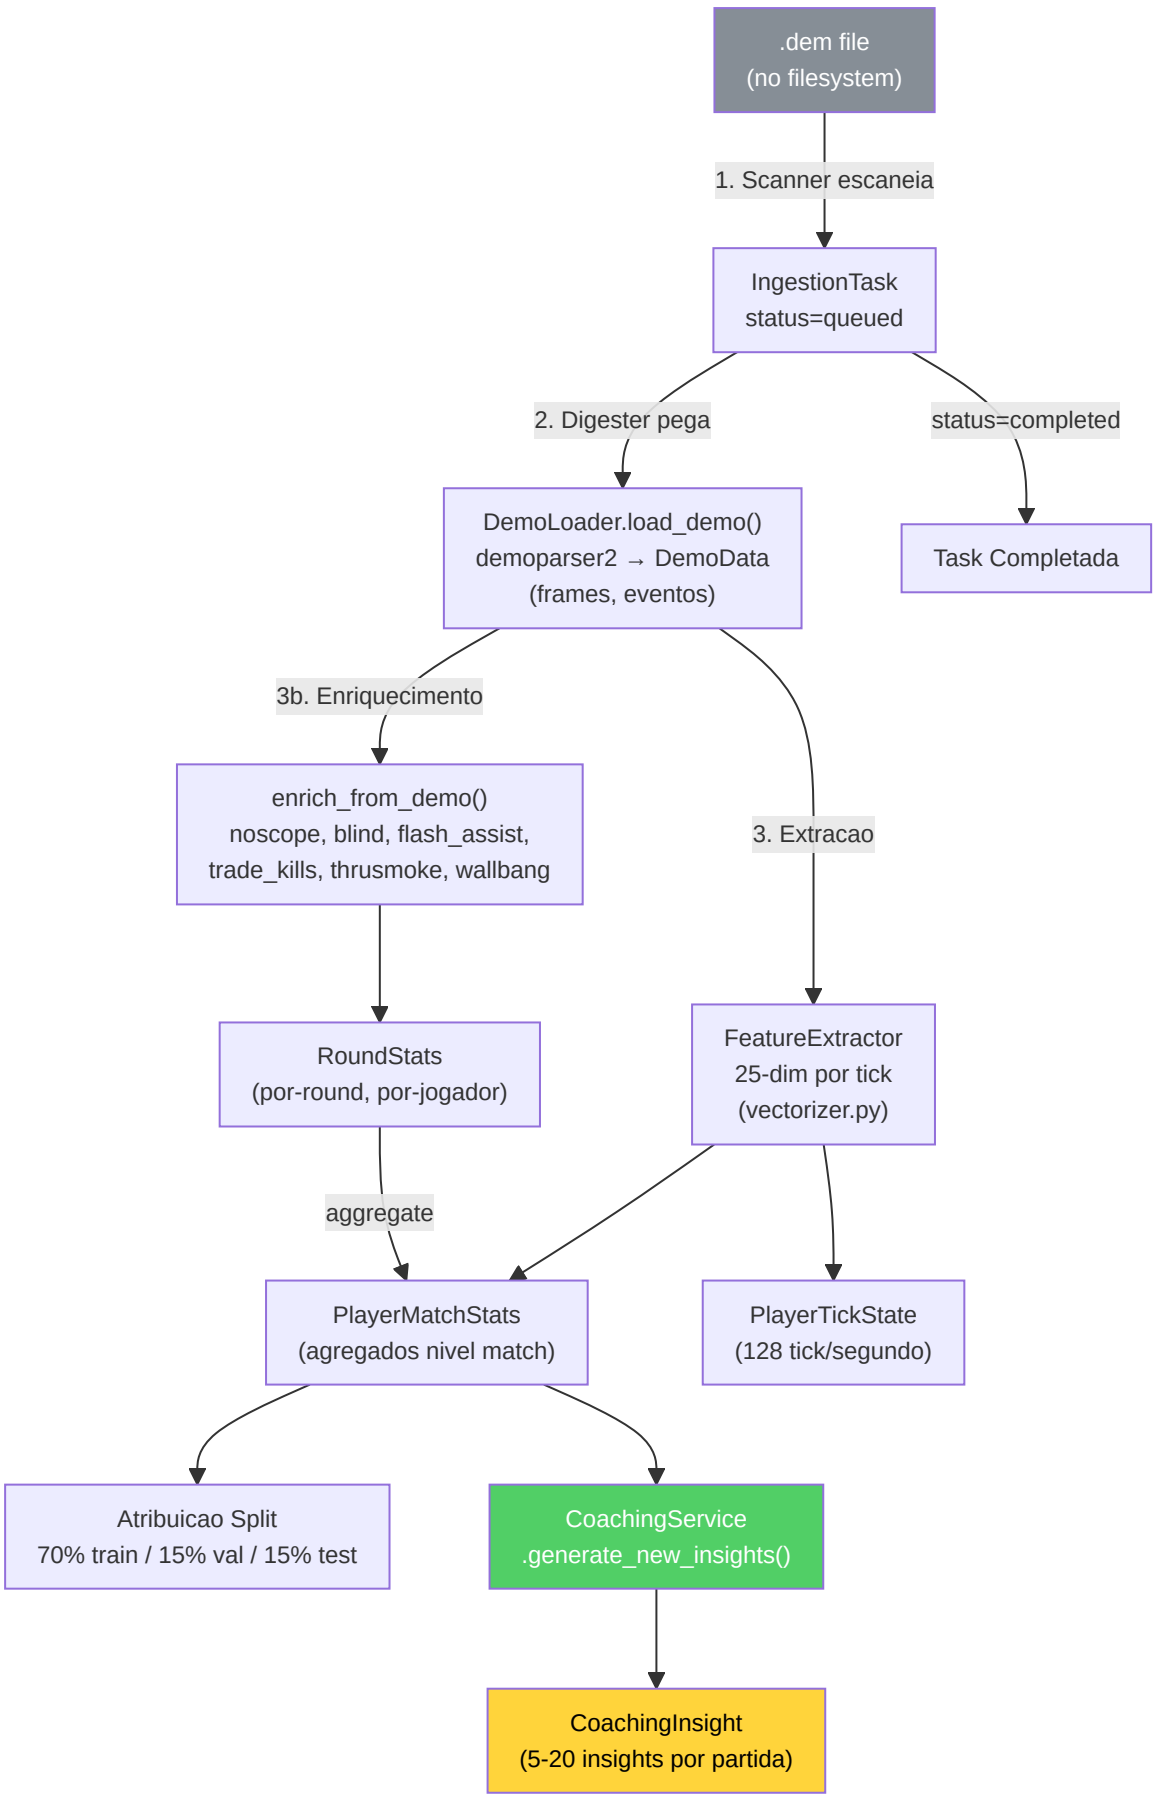
.dem file
(no filesystem)
1. Scanner escaneia
IngestionTask
status=queued
2. Digester pega
status=completed
DemoLoader.load_demo()
demoparser2 → DemoData
(frames, eventos)
Task Completada
3b. Enriquecimento
enrich_from_demo()
noscope, blind, flash_assist,
trade_kills, thrusmoke, wallbang
3. Extracao
RoundStats
(por-round, por-jogador)
FeatureExtractor
25-dim por tick
(vectorizer.py)
aggregate
PlayerMatchStats
(agregados nivel match)
PlayerTickState
(128 tick/segundo)
Atribuicao Split
70% train / 15% val / 15% test
CoachingService
.generate_new_insights()
CoachingInsight
(5-20 insights por partida)

DemoLoader — O parser do coracao da pipeline:

O `DemoLoader` e o wrapper em torno do **demoparser2** (biblioteca Rust de alto desempenho) que transforma um arquivo `.dem` binario em estruturas de dados Python:

Fase de Parsing	Output	Tamanho tipico
1. Header parsing	Metadata (map, server, duration)	~100 bytes
2. Frame extraction	Lista de frames (posicao, saude, arma por cada tick)	~100.000 frames/partida
3. Event extraction	Lista de eventos (kill, death, bomb_plant, round_start, etc.)	~500-2.000 eventos/partida
4. Player summary	Estatisticas agregadas por jogador	~10 registros

FeatureExtractor (`backend/processing/feature_engineering/vectorizer.py`):

O FeatureExtractor e o componente que transforma os dados brutos do demo em **vetores numericos de 25 dimensoes** (`METADATA_DIM=25`) utilizaveis pelas redes neurais. **Importante:** estas sao features **a nivel de tick** (128 Hz), nao estatisticas agregadas a nivel de partida. Cada frame individual do jogo produz um vetor 25-dim que captura o estado instantaneo do jogador:

Dim	Feature	Tipo	Range	Descricao
0	health	Float	[0, 1]	Saude normalizada
1	armor	Float	[0, 1]	Armadura normalizada
2	has_helmet	Binary	0/1	Capacete equipado
3	has_defuser	Binary	0/1	Kit defuse equipado
4	equipment_value	Float	[0, 1]	Valor equipamento normalizado
5	is_crouching	Binary	0/1	Agachado
6	is_scoped	Binary	0/1	Scope ativo
7	is_blinded	Binary	0/1	Cego por flash
8	enemies_visible	Float	[0, 1]	Inimigos visiveis (normalizado, clamped)
9	pos_x	Float	[-1, 1]	Posicao X (normalizada +/-pos_xy_extent)
10	pos_y	Float	[-1, 1]	Posicao Y (normalizada +/-pos_xy_extent)
11	pos_z	Float	[0, 1]	Posicao Z (normalizada, trata Nuke/Vertigo)
12	view_x_sin	Float	[-1, 1]	sin(yaw) — continuidade ciclica angulo horizontal
13	view_x_cos	Float	[-1, 1]	cos(yaw) — continuidade ciclica angulo horizontal
14	view_y	Float	[-1, 1]	Pitch normalizado (angulo vertical)
15	z_penalty	Float	[0, 1]	Distincao nivel vertical (penalidade andar)
16	kast_estimate	Float	[0, 1]	Estimativa KAST (taxa participacao)
17	map_id	Float	[0, 1]	Hash deterministico do mapa
18	round_phase	Float	{0, 0.33, 0.66, 1}	Fase economica: pistol/eco/force/full_buy
19	weapon_class	Float	{0-1.0}	Classe arma: 0=faca, 0.2=pistola, 0.4=SMG, 0.6=rifle, 0.8=sniper, 1.0=pesada
20	time_in_round	Float	[0, 1]	Segundos no round / 115 (clamped)
21	bomb_planted	Binary	0/1	Bomba plantada
22	teammates_alive	Float	[0, 1]	Companheiros vivos (count / 4)
23	enemies_alive	Float	[0, 1]	Inimigos vivos (count / 5)
24	team_economy	Float	[0, 1]	Media dinheiro time / 16000 (clamped)

Normalizacao e bounds:

A normalizacao e integrada diretamente no FeatureExtractor, com bounds configuraveis via `HeuristicConfig` (externalizada em JSON). A codificacao ciclica dos angulos de vista (sin/cos para o yaw) previne descontinuidades nas bordas 0/360. O `z_penalty` distingue automaticamente os andares

em mapas multi-nivel (Nuke, Vertigo). A classe arma utiliza um mapeamento categorico ordinal (6 classes) definido na constante `WEAPON_CLASS_MAP` (inclui tambem granadas=0.1 e equipamento especial=0.05).

Dataset Split Temporal:

A subdivisao do dataset segue uma **ordenacao cronologica** rigorosa para prevenir o data leakage temporal:

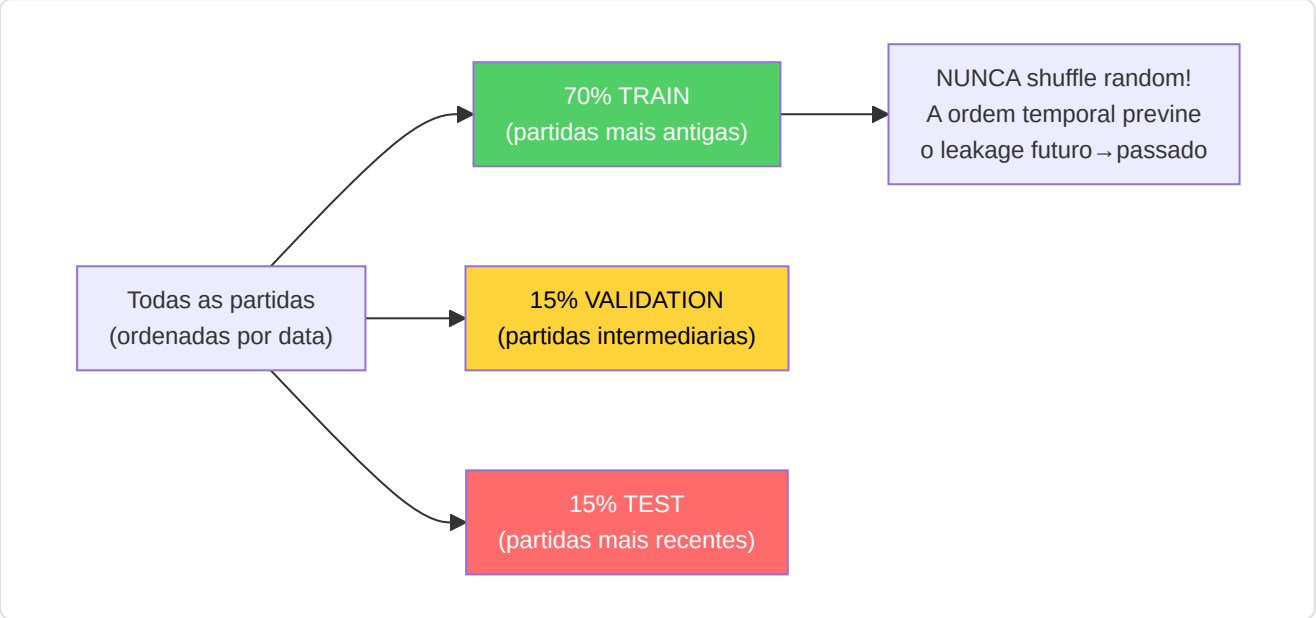

> **Analogia:** A divisao temporal e como preparar um **exame escolar justo**. As questoes do teste (15% test) devem tratar de topicos ensinados DEPOIS dos exercicios (70% train) e das tarefas de casa (15% val). Se as questoes do teste tratassem de topicos estudados antes dos exercicios, o aluno (o modelo) pareceria mais habil do que realmente e — um truque, nao conhecimento verdadeiro.

> **Analogia do Feature Vector:** O vetor de 25 dimensoes e como a **leitura instantanea de 25 sensores** conectados ao jogador a cada momento: 5 sensores "corporais" (saude, armadura, capacete, defuse kit, valor equipamento), 3 sensores "posturais" (agachado, com scope, cego), 1 sensor "visual" (inimigos visiveis), 6 sensores "espaciais" (posicao X/Y/Z e angulos de vista sin/cos/pitch), 1 sensor "andar" (penalidade Z para Nuke/Vertigo), 1 sensor "tatico" (KAST), 3 sensores "contextuais" (mapa, fase economica, classe arma), e 5 sensores "situacionais" (tempo no round, bomba plantada, companheiros/inimigos vivos, economia do time). Diferentemente das estatisticas agregadas a nivel de partida, cada tick produz um novo vetor — 128 leituras por segundo.

Enrich From Demo — Enriquecimento pos-parsing:

Apos o parsing base, `enrich_from_demo()` adiciona metricas avancadas calculadas dos eventos:

Metrica enriquecida	Calculo	Fonte
Trade kills	`TradeKillDetector.detect()` com TRADE_WINDOW_TICKS=192	Eventos kill/death
Flash assists	Contagem blind dentro de janela temporal antes de um kill	Eventos blind + kill
Noscope kills	Kill com arma sniper sem scope ativo	Evento kill + weapon state
Wallbang kills	Kill atraves de superficies penetraveis	Evento kill com flag penetration
Through-smoke kills	Kill com fumo ativo na linha de tiro	Evento kill + smoke position
Blind kills	Kill enquanto o jogador esta flashado	Evento kill + flash state

Componentes especificos:

Componente	Arquivo	Papel
DemoLoader	`demo_loader.py`	Wrappa `demoparser2`, extrai frames e eventos do arquivo `.dem`
SteamLocator	`steam_locator.py`	Localiza automaticamente a pasta demo do CS2 via registro Steam / libraryfolders.vdf
IntegrityChecker	`integrity.py`	Verifica que os arquivos demo sejam validos, completos e nao corrompidos antes do parsing
UserIngestPipeline	`pipelines/user_ingest.py`	Pipeline completa para demo usuario: parse → enrich → stats → coaching
JsonTournamentIngestor	`pipelines/json_tournament_ingestor.py`	Importa dados de torneio de arquivos JSON estruturados
Registry	`registry/registry.py`	Rastreia todas as demos processadas, previne duplicatas
ResourceManager	`ingestion/resource_manager.py`	Gestao de recursos hardware: CPU/RAM throttling, espaco disco
JsonTournamentIngestor	`pipelines/json_tournament_ingestor.py`	Importa dados de torneio de arquivos JSON estruturados
RegistryLifecycle	`registry/lifecycle.py`	Gestao ciclo de vida dos registros de ingestao

SteamLocator (`ingestion/steam_locator.py`) — localizacao automatica demo CS2:

O SteamLocator implementa um algoritmo de **discovery cross-platform** para encontrar automaticamente a pasta das demos do CS2:

Plataforma	Estrategia	Path tipico
Windows	Registro do sistema → `libraryfolders.vdf`	`C:\Program Files (x86)\Steam\steamapps\common\Counter-Strike Global Offensive\game\csgo\replays`
Linux	`~/.steam/steam/` → `libraryfolders.vdf`	`~/.steam/steam/steamapps/common/...`
Fallback	Pergunta ao usuario via UI Settings	Path personalizado

IntegrityChecker (`ingestion/integrity.py`):

Verificacao preliminar de cada arquivo demo antes do parsing custoso:

- **Magic bytes**: `PBDEMS2\0` (CS2 Source 2) ou `HL2DEMO\0` (legacy Source 1)
- **Size bounds**: minimo 1KB (nao vazio), maximo 5GB (nao corrompido/excessivo)
- **Read test**: tenta ler os primeiros N bytes para verificar que o arquivo seja acessivel

> **Analogia do SteamLocator:** O SteamLocator e como um **cao de caca que farreja a pasta do CS2** no seu computador. Sabe que a Steam armazena suas bibliotecas em lugares especificos (registro Windows, `libraryfolders.vdf` em Linux/Mac), e segue os rastros ate a pasta `csgo/replays` onde as demos sao salvas. Se nao consegue encontra-la automaticamente, pede ao usuario que indique o caminho manualmente — mas na maioria dos casos, encontra sozinho.

12.7 Console de Controle Unificada (`backend/control/`)

Arquivo: `Programma_CS2_RENAN/backend/control/console.py` , `ingest_manager.py` , `db_governor.py` , `ml_controller.py`

A Console e um **Singleton** que atua como ponto de coordenacao central para todos os subsistemas backend. E o "quadro de comando" atraves do qual cada parte do sistema pode ser controlada.

> **Analogia:** A Console e como a **torre de controle de um aeroporto**. Tem 4 telas: uma para o radar (ServiceSupervisor — monitora os servicos em execucao), uma para as pistas (IngestionManager — coordena a chegada das demos), uma para a manutencao (DatabaseGovernor — verifica a integridade do storage) e uma para o treinamento dos pilotos (MLController — gerencia o ciclo de vida do aprendizado automatico). O controlador de trafego aereo (Console Singleton) coordena tudo de um unico posto.

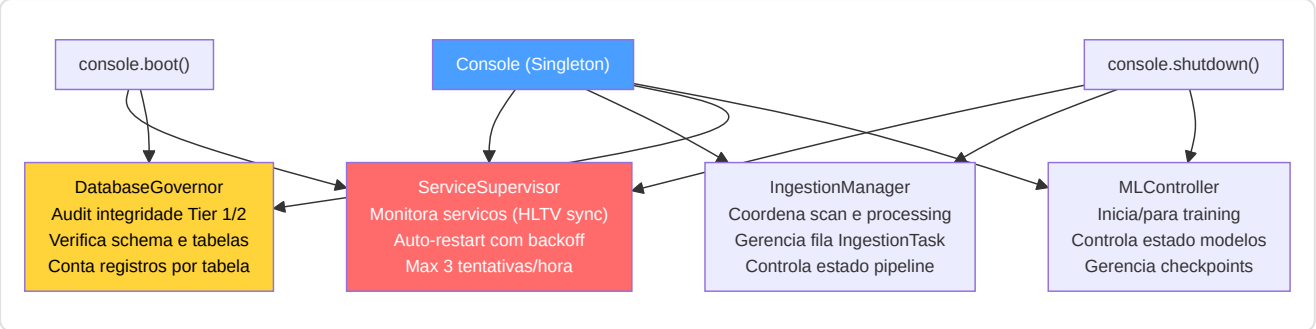

Sequencia de boot da Console:

1. `ServiceSupervisor` inicia o servico "hunter" (HLTV sync) como processo monitorado
2. `DatabaseGovernor` executa um audit de integridade: verifica todas as tabelas, conta registros, controla schema
3. `MLController` permanece em estado de espera — o training e gerenciado pelo daemon Teacher
4. `IngestionManager` permanece idle — o trabalho ativo e gerenciado pelos daemons Scanner/Digester

MLControlContext — Controle Live do Treinamento:

O `MLController` utiliza um token de controle chamado `MLControlContext` (`backend/control/ml_controller.py`) que e passado aos ciclos de treinamento para permitir **intervencao em tempo real** pelo operador. Isso substitui a abordagem anterior baseada em `StopIteration` por um sistema thread-safe mais robusto.

> **Analogia:** MLControlContext e como o **controle remoto de um player de video**. O operador pode pressionar **Pausa** (o training para imediatamente, sem perda de dados), **Play** (o training retoma do ponto exato onde havia parado), **Stop** (o training termina com uma excecao controlada `TrainingStopRequested`) ou ajustar a **velocidade** (throttle: 0.0 = velocidade maxima, 1.0 = atraso maximo). O mecanismo usa `threading.Event` para evitar busy-wait durante a pausa — o thread de training simplesmente dorme ate receber o sinal de retomada.

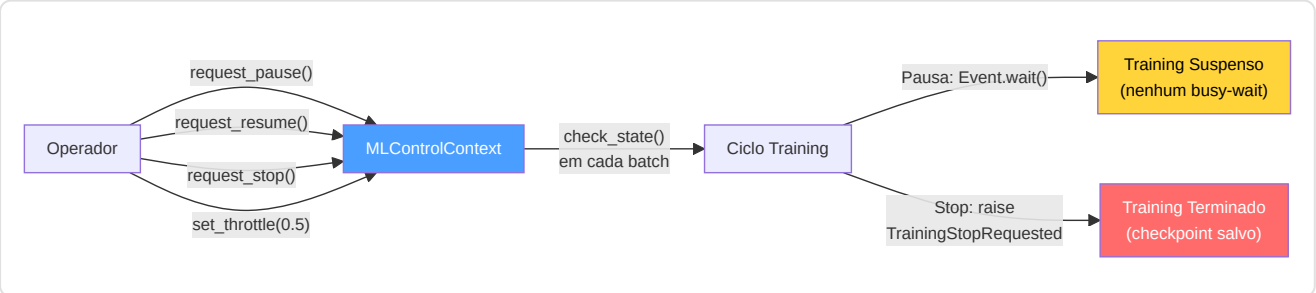

Comando	Metodo	Efeito
Pausa	`request_pause()`	`_resume_event.clear()` → bloqueia `check_state()`
Retomar	`request_resume()`	`_resume_event.set()` → desbloqueia o training
Stop	`request_stop()`	Lanca `TrainingStopRequested` (excecao custom)
Throttle	`set_throttle(factor)`	Adiciona `time.sleep(factor)` apos cada batch

12.8 Onboarding e Fluxo de Novo Usuario

Arquivo: `Programma_CS2_RENAN/backend/onboarding/new_user_flow.py`

O `OnboardingManager` guia os novos usuarios atraves de uma **progressao de 3 fases** que se adapta automaticamente a quantidade de dados disponiveis.

> **Analogia:** O onboarding e como o **tutorial de um videogame RPG**. Quando voce comeca um novo jogo (nenhuma demo carregada), o jogo o guia passo a passo: "Bem-vindo, aventureiro! Carregue sua primeira demo para comecar." Apos 1-2 demos, o sistema diz: "Bom comeco! Carregue mais N demos para desbloquear a analise estavel." Apos 3+ demos, o sistema anuncia: "Seu coach esta pronto! As analises personalizadas agora estao ativas." Cada fase desbloqueia gradualmente as funcionalidades do programa, impedindo que o sistema mostre resultados nao confiaveis quando nao tem dados suficientes.

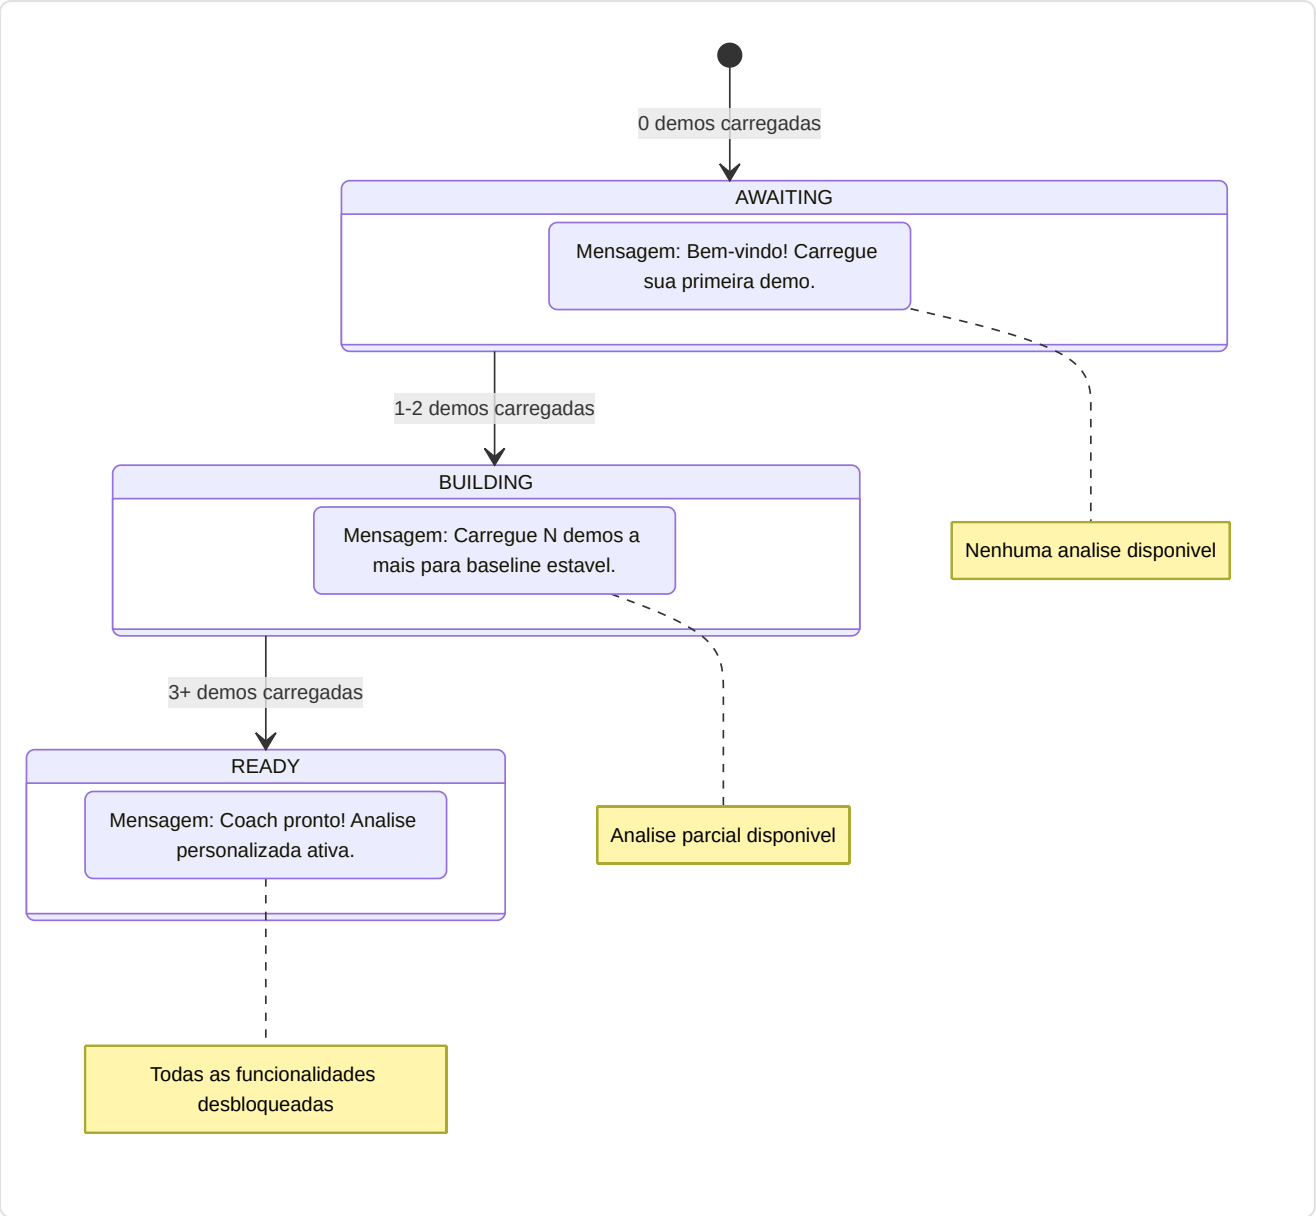

Wizard Screen (Primeira Configuracao):

Na primeira execucao (`SETUP_COMPLETED = False`), o usuario e guiado atraves do Wizard:

1. **Nome jogador** — O nome que aparecera nas analises
2. **Papel preferido** — Entry Fragger, AWPer, Lurker, Support ou IGL
3. **Paths pastas demo** — Onde o sistema procura automaticamente as demos
4. Ao completar: `SETUP_COMPLETED = True` , redirect para a Home

Cache das quotas (Task 2.16.1): A contagem de demos e cacheada por 60 segundos para evitar queries DB repetidas. `invalidate_cache()` e chamado apos cada novo upload, garantindo que a UI sempre mostre a contagem correta sem sobrecarregar o banco.

Help System (`backend/knowledge/help_system.py`):

O sistema de ajuda integrado fornece suporte contextual ao usuario:

Funcionalidade	Implementacao
Tutorial interativo	Guias step-by-step para as funcionalidades principais
FAQ contextuais	Perguntas frequentes filtradas por tela atual
Troubleshooting	Arvore decisoria para problemas comuns (Steam path nao encontrado, demo nao parsed, coaching vazio)
Tooltips	Explicacoes inline para metricas complexas (KAST, HLTV 2.0 Rating, ADR)

> **Analogia:** O Help System e como ter um **assistente bibliotecario** sempre disponivel. Se voce esta na secao "Narrativa" (Tactical Viewer), ele te ajuda com as duvidas sobre a leitura dos mapas. Se voce esta em "Ciencias" (Coach), ele te explica o que significam as metricas. Se algo nao funciona, ele te guia passo a passo na resolucao do problema — como um fluxograma "Se a torneira nao da agua → verifique a valvula → verifique o cano → chame o encanador."

12.9 Arquitetura de Storage (`backend/storage/`)

Diretorio: `Programma_CS2_RENAN/backend/storage/` **Arquivos-chave:** `database.py` , `db_models.py` , `match_data_manager.py` , `storage_manager.py` , `maintenance.py` , `state_manager.py` , `stat_aggregator.py` , `backup.py`

O sistema de storage utiliza uma arquitetura **three-tier storage** baseada em SQLite em modo WAL (Write-Ahead Logging), que permite leituras e escritas concorrentes sem bloqueios.

> **Analogia:** A arquitetura de storage e como um **sistema bibliotecario de 3 niveis**. O **terreo** (`database.db` , 18 tabelas) contem o catalogo geral, os cartoes de todos os leitores (jogadores), a base de conhecimento tatica (RAG), o banco de experiencias COPER, as resenhas dos criticos (insights de coaching) e o registro de emprestimos (tasks de ingestao) — tudo em um unico grande arquivario sempre disponivel. O **arquivario separado** (`hltv_metadata.db` , 3 tabelas) contem os perfis dos jogadores profissionais e suas estatisticas — separado porque e atualizado por um processo diferente (HLTV sync) para evitar contencao de locks. Alem desses, os **bancos por-match** (`match_XXXX.db`) contem os manuscritos originais completos (dados tick-a-tick das partidas) — cada um em uma caixa separada para evitar que o arquivario principal fique pesado demais. O modo WAL e como ter uma **porta giratoria**: muitas pessoas podem entrar para ler simultaneamente, e alguem pode escrever sem bloquear a entrada.

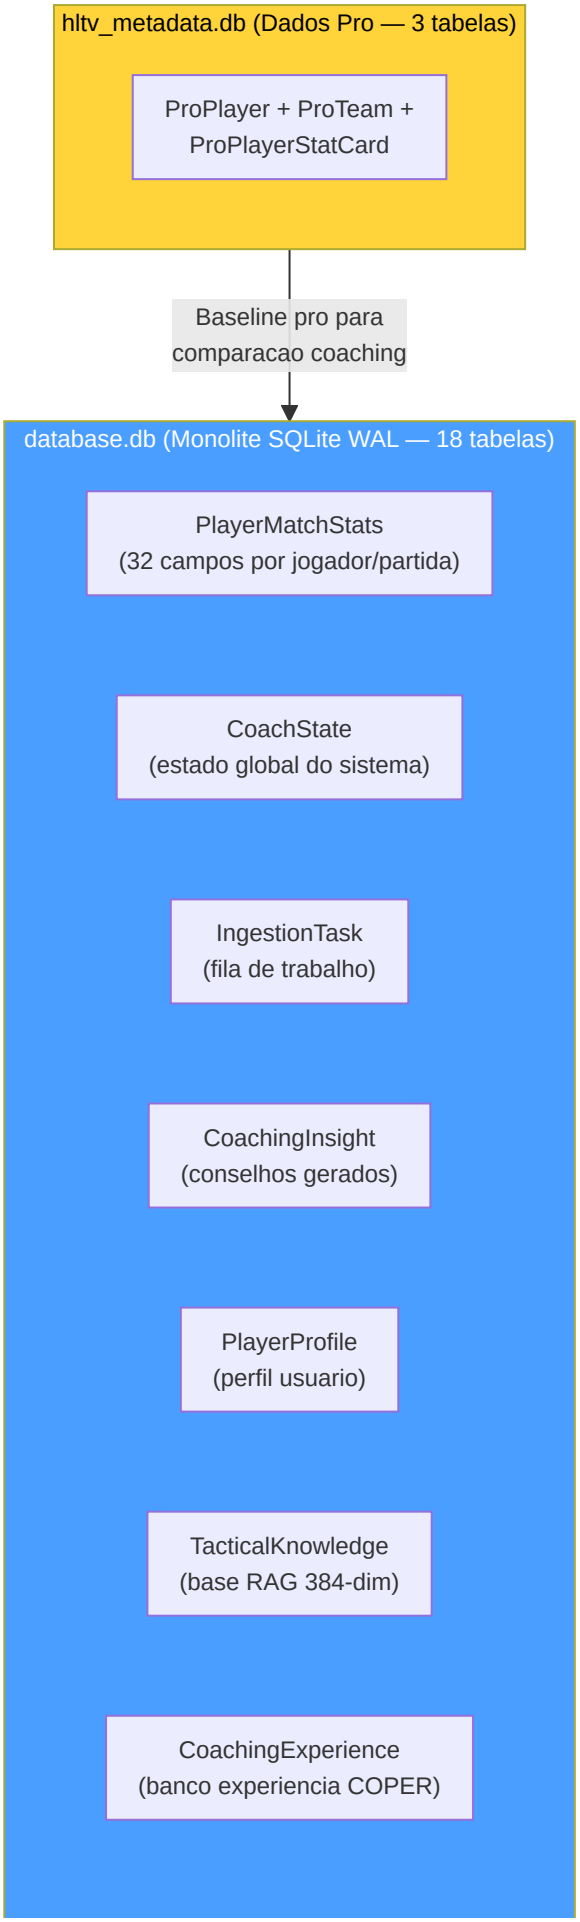
hltv_metadata.db (Dados Pro — 3 tabelas)
ProPlayer + ProTeam + ProPlayerStatCard
Baseline pro para comparacao coaching
database.db (Monolite SQLite WAL — 18 tabelas)
PlayerMatchStats (32 campos por jogador/partida)
CoachState (estado global do sistema)
IngestionTask (fila de trabalho)
CoachingInsight (conselhos gerados)
PlayerProfile (perfil usuario)
TacticalKnowledge (base RAG 384-dim)
CoachingExperience (banco experiencia COPER)

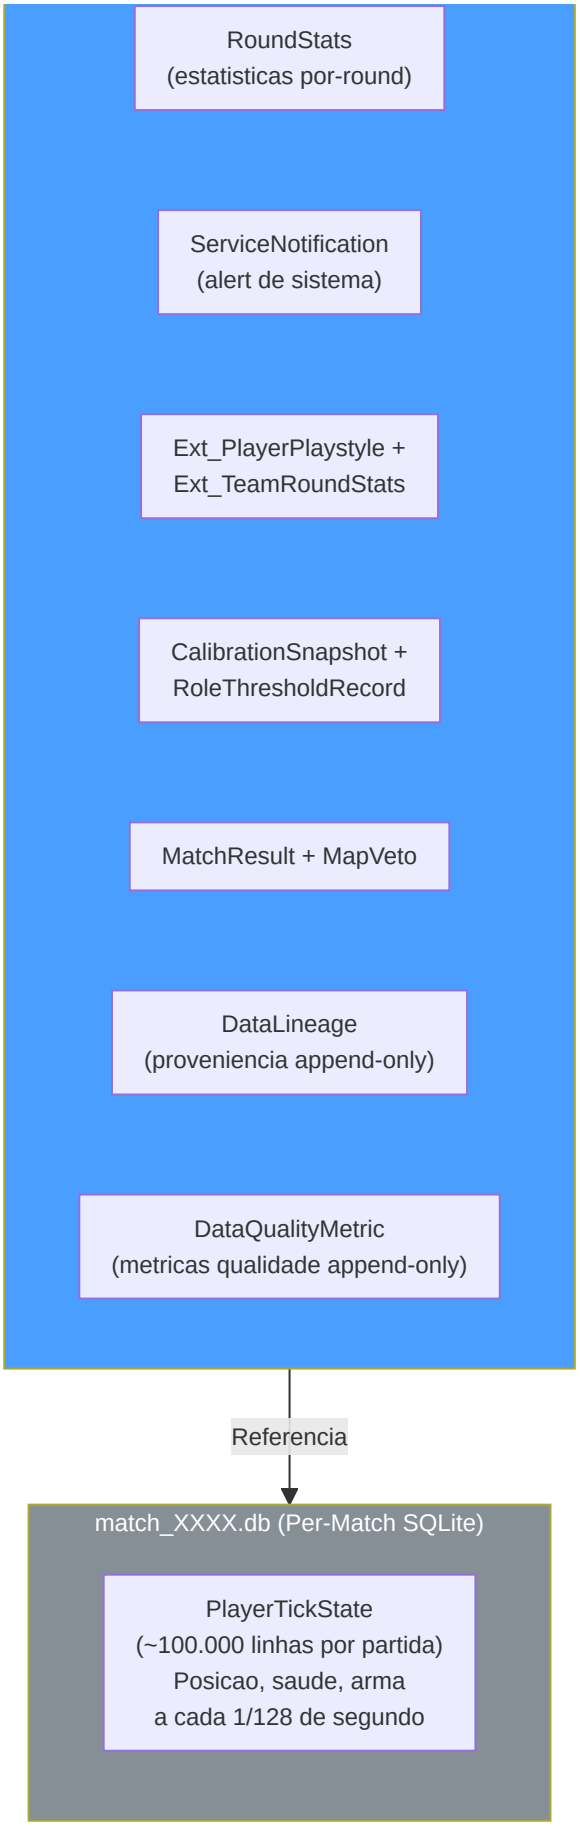

As 21 tabelas SQLModel:

#	Tabela	Banco	Categoria	Descricao
1	`PlayerMatchStats`	database.db	Core	Estatisticas agregadas por jogador/partida (32 campos)
2	`PlayerTickState`	database.db	Core	Estado por-tick (128 Hz), tambem arquivado em DBs por-match separados
3	`PlayerProfile`	database.db	Usuario	Perfil usuario (nome, papel, Steam ID, quota mensal)
4	`RoundStats`	database.db	Core	Estatisticas isoladas por round (kills, rating, enriquecimento)
5	`CoachingInsight`	database.db	Coaching	Conselhos gerados pelo servico de coaching
6	`CoachingExperience`	database.db	Coaching	Banco de experiencias COPER (contexto, outcome, eficacia, TrueSkill mu/sigma, replay priority — KT-01)
7	`IngestionTask`	database.db	Sistema	Fila de trabalho para o daemon Digester
8	`CoachState`	database.db	Sistema	Estado global (training metrics, heartbeat, status)
9	`ServiceNotification`	database.db	Sistema	Mensagens de erro/evento dos daemons → UI
10	`TacticalKnowledge`	database.db	Conhecimento	Base RAG (embedding 384-dim em JSON)
11	`ProPlayer`	hltv_metadata.db	Pro	Perfis jogadores profissionais
12	`ProTeam`	hltv_metadata.db	Pro	Metadata times profissionais
13	`ProPlayerStatCard`	hltv_metadata.db	Pro	Estatisticas sazonais por jogador pro
14	`Ext_PlayerPlaystyle`	database.db	Externo	Dados estilo de jogo de CSV (para NeuralRoleHead)
15	`Ext_TeamRoundStats`	database.db	Externo	Estatisticas torneio externas
16	`MatchResult`	database.db	Partidas	Resultados das partidas
17	`MapVeto`	database.db	Partidas	Historico selecao de mapas
18	`CalibrationSnapshot`	database.db	Sistema	Registro de calibracao do modelo de crenca (timestamp, amostras, resultado)
19	`RoleThresholdRecord`	database.db	Sistema	Limites aprendidos para a classificacao dos papeis (persistidos entre reinicios)
20	`DataLineage`	database.db	Proveniencia	Registro append-only de proveniencia de dados: entity_type, entity_id, source_demo, pipeline_version, processing_step
21	`DataQualityMetric`	database.db	Proveniencia	Metricas qualidade append-only por run: run_id, run_type, metric_name, metric_value, sample_count

Enum de suporte (nao tabelas):

Enum	Tipo	Descricao
`DatasetSplit`	`str, Enum`	Categorias split (train/val/test/unassigned) — usado como constraint em `PlayerMatchStats.dataset_split`
`CoachStatus`	`str, Enum`	Estados do coach (Paused/Training/Idle/Error) — usado como constraint em `CoachState.status`

Componentes de Storage detalhados:

MatchDataManager (`backend/storage/match_data_manager.py`) — o componente maior do storage layer:

O MatchDataManager e responsavel pela gestao dos dados por-partida de alta densidade (PlayerTickState com ~100.000 linhas por partida). Para evitar que o banco principal cresca de forma descontrolada, cada partida tem seu proprio banco SQLite separado (`match_XXXX.db`).

Metodo	Descricao
`create_match_db(demo_name)`	Cria um novo banco por-match com schema `PlayerTickState`
`store_tick_data(demo_name, ticks)`	Bulk insert de tick data no DB dedicado
`load_match_frames(demo_name)`	Carrega todos os frames para o Tactical Viewer
`get_match_db_path(demo_name)`	Resolve o path do DB por-match
`list_available_matches()`	Lista todos os matches com DB disponiveis
`delete_match_data(demo_name)`	Remove o DB por-match e atualiza o registro
`get_match_statistics(demo_name)`	Calcula estatisticas agregadas do tick data

> **Analogia:** O MatchDataManager e como um **arquivista que gerencia as caixas dos manuscritos originais**. Cada partida e um manuscrito volumoso demais para caber no arquivario geral (database.db), entao e conservada em uma caixa separada com uma etiqueta (match_XXXX.db). O arquivista sabe exatamente onde esta cada caixa, pode abri-la sob demanda e, quando a caixa fica muito velha, pode move-la para o arquivo frio.

StorageManager (`backend/storage/storage_manager.py`):

O StorageManager e o **coordenador de alto nivel** do storage que gerencia quotas, uploads e ciclo de vida dos dados:

Responsabilidade	Implementacao
Quota mensal	`can_user_upload()` → verifica `MAX_DEMOS_PER_MONTH=10` e `MAX_TOTAL_DEMOS=100`
Upload flow	`handle_demo_upload(path)` → validacao → copia em working dir → cria IngestionTask
Limpeza	`cleanup_old_data(days)` → remove match DB e tasks antigos
Espaco disco	`get_storage_usage()` → report dimensoes para cada banco e diretorio

StateManager (`backend/storage/state_manager.py`):

O StateManager e um **Singleton** que mantem o estado runtime do sistema e o persiste no banco via a tabela `CoachState` :

Metodo	Proposito
`update_status(daemon, text)`	Atualiza o estado de um daemon especifico
`heartbeat()`	Atualiza o timestamp `last_heartbeat`
`get_state()`	Retorna o estado atual como objeto `CoachState`
`set_error(daemon, message)`	Registra um erro para um daemon com timestamp
`update_training_metrics(epoch, loss, val_loss, eta)`	Atualiza as metricas de training em tempo real
`get_belief_confidence()`	Retorna o nivel de confianca do modelo de crenca (0.0-1.0)

StatAggregator (`backend/storage/stat_aggregator.py`):

Calcula estatisticas agregadas a partir dos dados brutos por-round:

Agregacao	Formula	Uso
`avg_kills`	`mean(RoundStats.kills)`	Dashboard, radar chart
`avg_adr`	`mean(RoundStats.damage_dealt / rounds)`	Comparacao pro
`avg_kast`	`mean(rounds_with_kast / total_rounds)`	Metrica HLTV
`accuracy`	`sum(hits) / sum(shots_fired)`	Performance mecanica
`trade_kill_rate`	`trade_kills / team_deaths`	Trabalho de equipe

BackupManager (`backend/storage/backup.py`):

Caracteristica	Detalhe
Rotacao diaria	7 copias — a mais antiga e sobrescrita
Rotacao semanal	4 copias — backup semanal adicional
Trigger automatico	Na inicializacao do Session Engine via `should_run_auto_backup()`
Trigger manual	Via Console ou UI Settings
Formato	Copia completa do arquivo `.db` (nao dump SQL)
Etiquetagem	`startup_auto` , `manual` , `pre_migration`

Maintenance (`backend/storage/maintenance.py`):

Operacao	Frequencia	Proposito
`vacuum()`	Mensal	Compacta o banco, recupera espaco de registros deletados
`analyze()`	Apos cada bulk insert	Atualiza as estatisticas do otimizador query SQLite
`wal_checkpoint()`	Na inicializacao	Forca o merge do WAL no banco principal
`integrity_check()`	Na inicializacao	`PRAGMA integrity_check` — verifica coerencia estrutural

DbMigrate (`backend/storage/db_migrate.py`):

Wrapper em torno do Alembic que automatiza a execucao das migracoes:

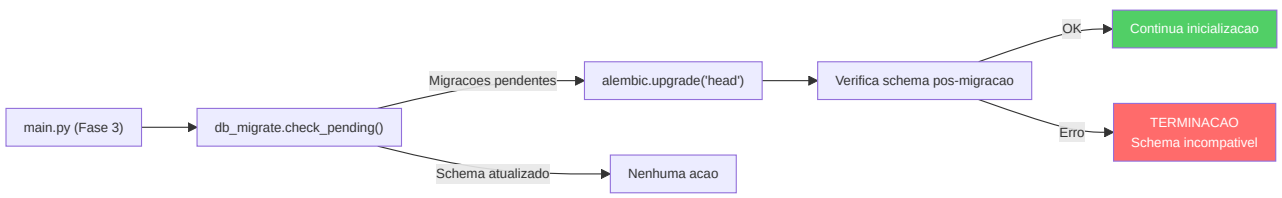

Connection Pooling e Concorrencia:

Parametro	Valor	Proposito
`check_same_thread`	`False`	Permite acesso multi-thread
`timeout`	30 segundos	Busy timeout para contencao WAL
`pool_size`	1	Unico escritor SQLite (seguranca single-writer)
`max_overflow`	4	Conexoes overflow para picos de carga
WAL mode	Habilitado	Leituras concorrentes ilimitadas

12.10 Motor de Playback e Viewer Tatico

Arquivos: `Programma_CS2_RENAN/core/playback.py` , `playback_engine.py` , `apps/desktop_app/tactical_viewer_screen.py` , `tactical_map.py` , `timeline.py` , `player_sidebar.py`

O sistema de playback tatico permite ao usuario **reviver as proprias partidas** em um mapa 2D interativo, com overlay AI (posicao fantasma otima), marcadores de eventos (kills, plantagens de bomba) e controles de reproducao completos.

> **Analogia:** O Tactical Viewer e como um **sistema de replay esportivo de nivel profissional**. Imagine poder assistir as suas partidas de futebol da perspectiva de um drone aereo, com a possibilidade de desacelerar, acelerar, pausar, e com um assistente AI que te mostra "onde voce deveria ter estado" como uma sombra transparente no campo. Alem disso, uma timeline inteligente destaca automaticamente os momentos-chave: "Minuto 23:15 — voce perdeu a vantagem aqui" (marcador vermelho) ou "Minuto 34:02 — jogada excelente!" (marcador verde). Voce pode clicar em qualquer marcador e o replay pula diretamente para aquele momento.

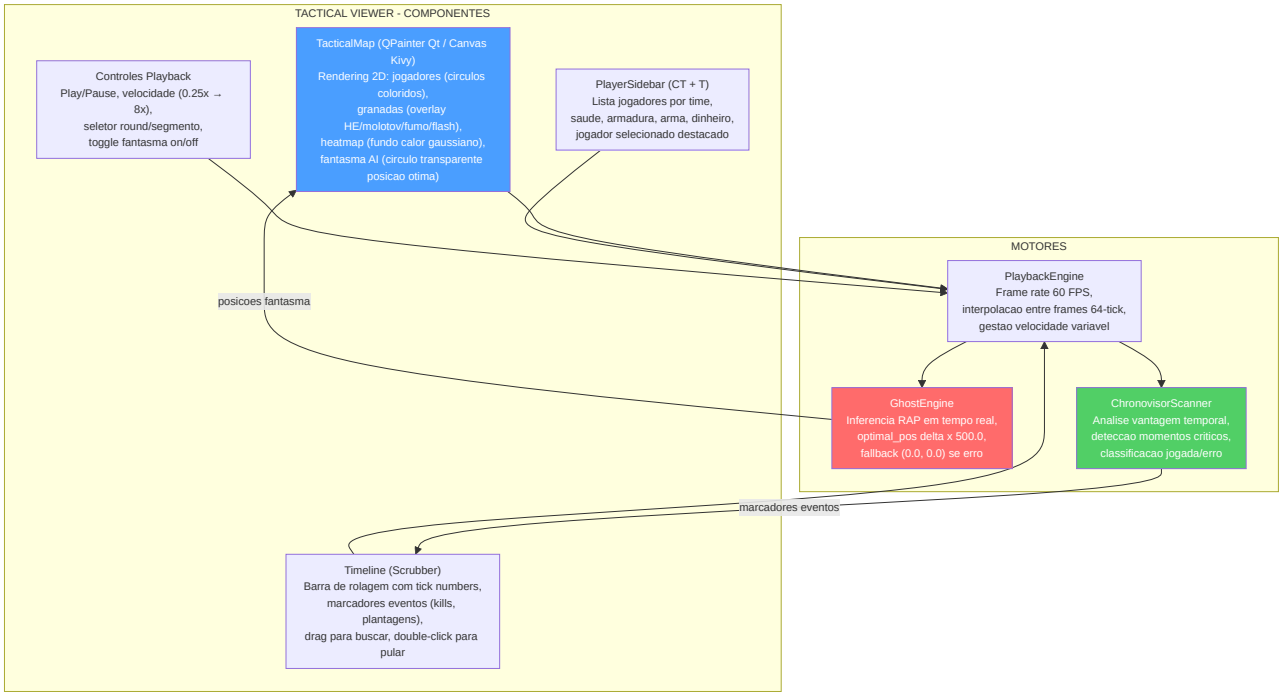

PlaybackEngine — Arquitetura interna:

O PlaybackEngine gerencia a reproducao frame-by-frame com interpolacao temporal. Na implementacao Qt, o timer de atualizacao utiliza `QTimer` em vez de `Kivy Clock.schedule_interval`, mantendo a mesma logica de interpolacao e buffering:

Caracteristica	Detalhe
Frame rate	60 FPS (interpolacao de 64-tick nativo do demo)
Velocidade variavel	0.25x (slow-mo), 0.5x, 1x (normal), 2x, 4x, 8x (fast-forward)
Interpolacao	Linear entre frames adjacentes para movimentos fluidos
Buffering	Pre-carrega 120 frames antecipadamente para evitar lag
Seek	Acesso direto a qualquer tick via indice
Round selection	Pula diretamente ao inicio de um round especifico

GhostEngine — Inferencia em tempo real:

O GhostEngine e o componente que transforma as predicoes do RAP Coach em **posicoes fantasma visiveis no mapa**:

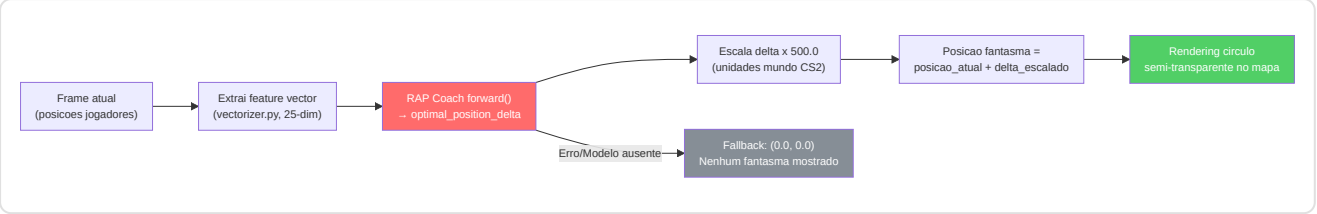

> **Analogia do GhostEngine:** O fantasma e como um **treinador invisivel** que corre no campo ao seu lado. Assiste a mesma partida que voce, mas conhece a posicao otima onde voce deveria estar. Sua sombra semi-transparente no mapa diz: "Voce teria estado mais seguro e mais eficaz aqui." O fator x500.0 converte os pequenos deltas do modelo (numeros entre -1 e +1) em distancias reais no mapa (centenas de unidades mundo). Se o modelo nao esta carregado, o fantasma simplesmente desaparece — nao mostra posicoes erradas.

ChronovisorScanner — Deteccao de momentos criticos:

O ChronovisorScanner analisa a partida inteira e identifica os **momentos decisivos** baseando-se na mudanca de vantagem:

Tipo momento	Condicao	Cor marcador
Erro critico	Morte em vantagem numerica (ex. 4v3 → 3v3)	Vermelho
Jogada excelente	Kill em desvantagem numerica (ex. 2v3 → 2v2)	Verde
Plantagem bomba	Evento bomb_planted com timer	Amarelo
Clutch	Vitoria 1vN (N >= 2)	Ouro
Eco round win	Vitoria com equipamento < $2.000	Azul

Cada momento e posicionado na Timeline como um marcador clicavel. O clique pula o playback diretamente para aquele tick.

Fluxo de carregamento do viewer (One-Click):

1. O usuario clica "Tactical Viewer" da Home
2. Se nenhuma demo esta carregada → `trigger_viewer_picker()` abre o file picker automaticamente
3. O usuario seleciona um arquivo `.dem`
4. Aparece um dialogo "Reconstrucao Dinamica 2D em Andamento..."
5. Uma thread em background executa `_execute_viewer_parse(path)` → `DemoLoader.load_demo()`
6. Ao completar: dismissao do dialogo, carregamento frames no PlaybackEngine
7. O mapa e renderizado com os jogadores no frame 0

12.11 Dados Espaciais e Gestao de Mapas

Arquivos: `Programma_CS2_RENAN/core/spatial_data.py`, `spatial_engine.py`, `data/map_config.json`

O sistema de gestao de mapas traduz as **coordenadas mundo do CS2** (valores tipicos: -2000 a +2000 em X/Y) em **coordenadas pixel** na textura do mapa (0.0 a 1.0 normalizado), e vice-versa.

> **Analogia:** A gestao de mapas e como um **sistema GPS para o mundo do CS2**. Cada mapa tem sua "projecao cartografica": um ponto de origem (canto superior esquerdo), uma escala (quantas unidades de jogo por pixel) e, para mapas multi-nivel como Nuke, um **separador de andares** (z_cutoff = -495 para Nuke). O GPS sabe que se sua coordenada Z esta acima de -495, voce esta no andar superior, caso contrario no andar inferior. Essa informacao e crucial para o GhostEngine e para o rendering correto no mapa tatico.

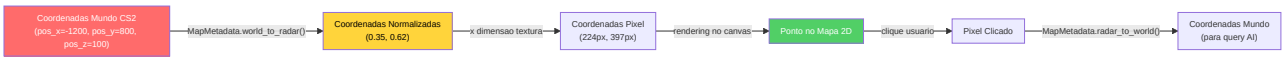

MapMetadata (dataclass imutavel para cada mapa):

Campo	Exemplo (Dust2)	Proposito
`pos_x`	-2476	X do canto superior esquerdo em unidades mundo
`pos_y`	3239	Y do canto superior esquerdo em unidades mundo
`scale`	4.4	Unidades de jogo por pixel da textura
`z_cutoff`	`None`	Separador de nivel (apenas mapas multi-nivel)
`level`	`"single"`	Tipo: "single", "upper", "lower"
`texture_width`	1024	Largura textura radar em pixel
`texture_height`	1024	Altura textura radar em pixel

MapManager (`core/map_manager.py`):

O MapManager e o componente de alto nivel que coordena o carregamento dos mapas para a interface:

Metodo	Proposito
`get_map_metadata(map_name)`	Retorna MapMetadata para o mapa requisitado
`load_radar_texture(map_name)`	Carrega textura PNG do mapa radar do cache ou disco
`get_available_maps()`	Lista dos mapas suportados com metadata
`world_to_pixel(pos, map_name)`	Shortcut para conversao coordenadas mundo → pixel

Mapas multi-nivel suportados:

Mapa	z_cutoff	Niveis	Notas
Nuke	-495	upper / lower	Dois plant sites em andares diferentes
Vertigo	11700	upper / lower	Arranha-ceu com duas areas jogaveis
Todos os outros	`None`	single	Mapas de nivel unico

SpatialEngine (`core/spatial_engine.py`):

O SpatialEngine adiciona capacidades de **raciocinio espacial** ao sistema de coordenadas base:

Metodo	Input	Output	Uso
`distance_2d(pos_a, pos_b)`	Duas coordenadas mundo	Float (unidades mundo)	Calculo distancia de engajamento
`is_visible(pos_a, pos_b, obstacles)`	Duas pos + obstaculos	Bool	Linha de visao (simplificada)
`get_zone(pos, map_name)`	Coordenada + mapa	String (ex. "A_site")	Classificacao zona tatica
`nearest_cover(pos, map_name)`	Coordenada + mapa	Coordenada cobertura	Sugestao posicional

AssetManager (`core/asset_manager.py`):

Gerencia o carregamento das texturas dos mapas e dos assets UI:

Asset	Formato	Tamanho tipico	Cache
Textura mapa (radar)	PNG 1024x1024	~500KB	Sim (in-memory)
Icones jogador	PNG 32x32	~2KB	Sim
Fontes (JetBrains Mono, YUPIX)	TTF	~200KB	Sim (registradas no Kivy)
Wallpapers temas	PNG 1920x1080	~2MB	Lazy load

> **Analogia do AssetManager:** O AssetManager e como o **almoxarife do teatro**. Sabe exatamente onde estao armazenados todos os objetos de cena (texturas, fontes, icones), os carrega sob demanda, e mantem os mais usados no **bolso** (cache) para nao ter que voltar ao almoxarifado toda vez. Se um objeto nao existe, retorna um placeholder generico — o show deve continuar.

12.12 Observabilidade e Logging

Arquivo: `Programma_CS2_RENAN/observability/logger_setup.py` **Arquivos relacionados:** `backend/storage/state_manager.py` , `backend/services/telemetry_client.py`

O sistema de observabilidade garante que cada evento significativo seja **rastreavel, estruturado e persistente**. O client de telemetria (`telemetry_client.py`) utiliza `**httpx**` (HTTP assincrono) para o envio nao-bloqueante de metricas e eventos, evitando que latencias de rede afetem o desempenho da aplicacao.

> **Analogia:** A observabilidade e como o **sistema de cameras de seguranca e registros de um edificio**. O logging estruturado (`get_logger()`) e a camera que registra tudo com timestamp e etiquetas ("quem fez o que, onde e quando"). O StateManager e o **quadro no saguao** que mostra o estado atual de cada andar (daemon): "Andar 1 (Scanner): Scanning. Andar 2 (Digester): Idle. Andar 3 (Teacher): Learning." As ServiceNotification sao os **anuncios do interfone** que informam os residentes (o usuario) de eventos importantes ou erros.

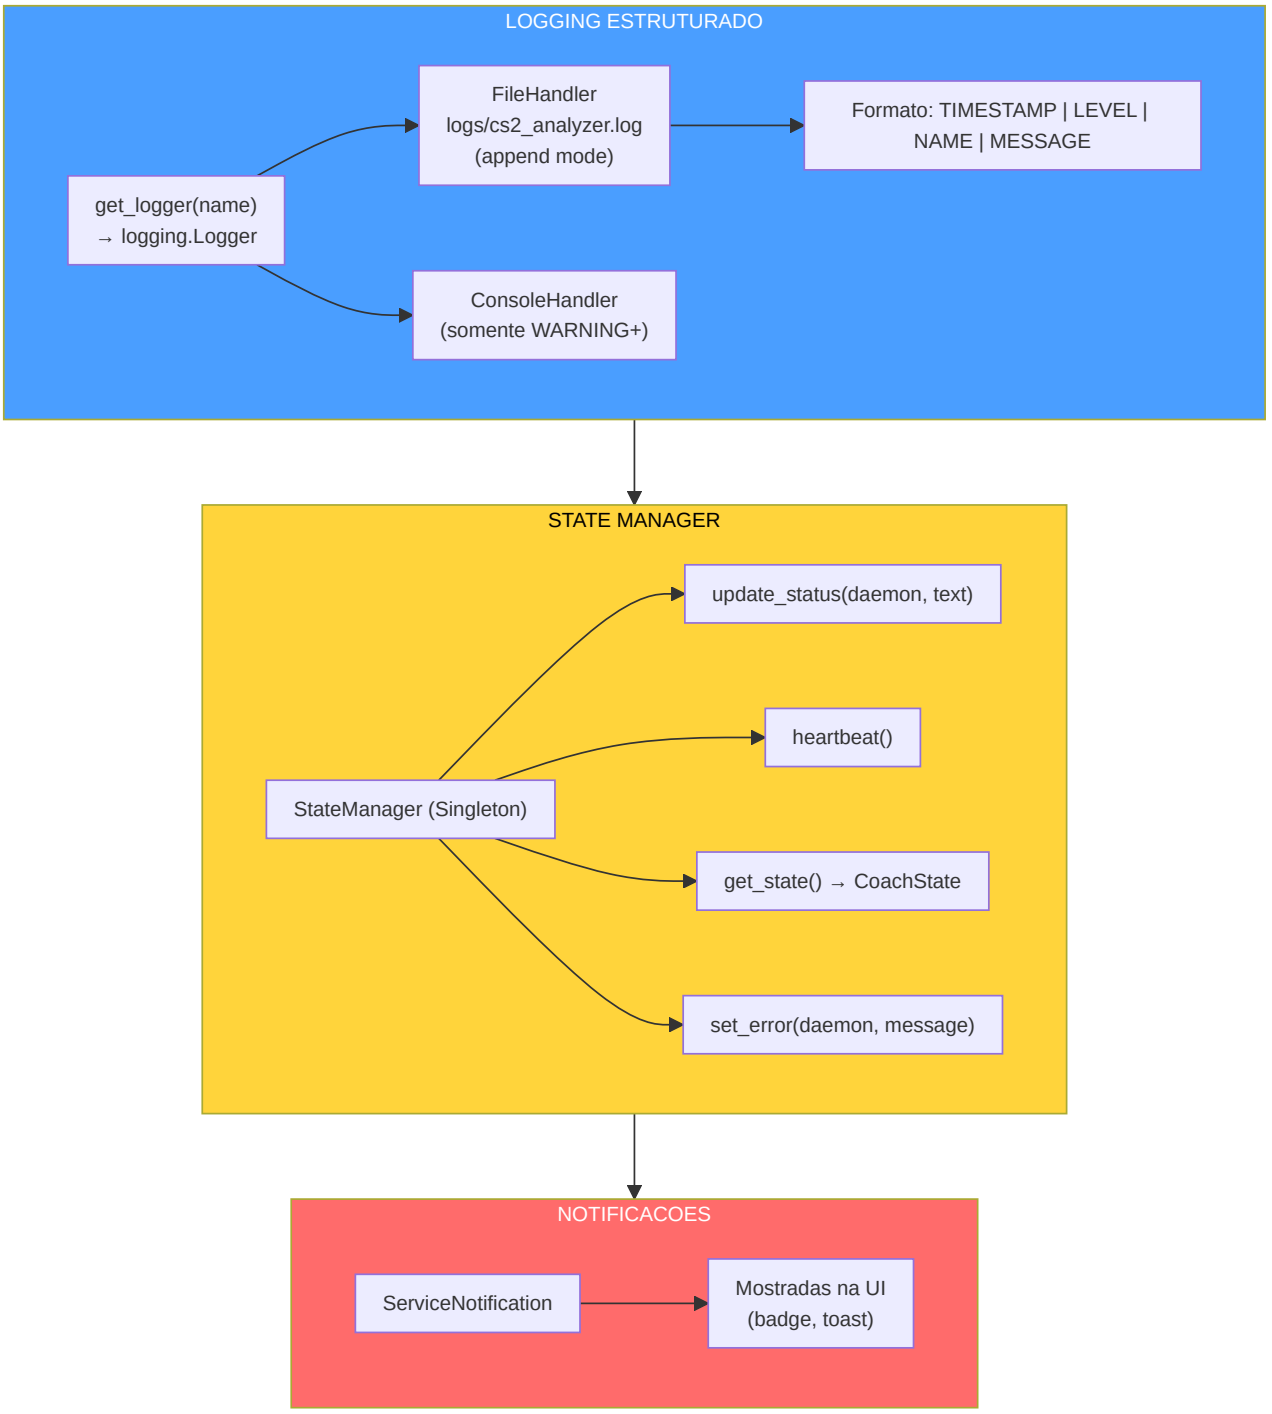

Daemons monitorados pelo StateManager:

Daemon	Campo em CoachState	Valores tipicos
Scanner	`hltv_status`	"Scanning", "Paused", "Error"
Digester (worker)	`ingest_status`	"Processing", "Idle", "Error"
Teacher (trainer)	`ml_status`	"Learning", "Idle", "Error"
Global	`status`	"Paused", "Training", "Idle", "Error"

Sentry Integration (`observability/sentry_setup.py`):

O sistema inclui integracao opcional com **Sentry** para error tracking remoto, com uma abordagem **double opt-in** para a privacidade:

Caracteristica	Implementacao
Double opt-in	O usuario deve (1) configurar `SENTRY_DSN` como variavel de ambiente E (2) ativar o flag nas configuracoes
PII Scrubbing	Todos os dados pessoais (nomes jogadores, Steam ID, paths) sao removidos antes do envio
Breadcrumb sanitization	Os breadcrumbs de navegacao sao limpos de informacoes sensiveis
Nao bloqueante	Se Sentry nao esta configurado, o sistema prossegue normalmente (Fase 4 da inicializacao)
Contexto enriquecido	Cada erro inclui: versao app, estado daemon, contagem demo, sistema operacional

> **Analogia:** Sentry e como um **servico de telemedicina opcional**. Se voce o ativa (double opt-in), quando seu corpo (a aplicacao) tem um mau funcionamento grave, envia automaticamente um laudo anonimizado ao medico remoto (servidor Sentry). O laudo nao contem seu nome nem seu endereco (PII scrubbing) — apenas os sintomas e as circunstancias do incidente. Se voce prefere privacidade total, nao ativa o servico e tudo fica local.

Logger Setup (`observability/logger_setup.py`):

O sistema de logging centralizado fornece logs estruturados com:

Caracteristica	Detalhe
Formato	`TIMESTAMP
File handler	`logs/cs2_analyzer.log` (append mode, rotacao automatica)
Console handler	Somente `WARNING+` para nao poluir o output
Naming convention	`get_logger("cs2analyzer.<module>")` — namespace hierarquico
Niveis usados	`DEBUG` (desenvolvimento), `INFO` (operacoes normais), `WARNING` (anomalias nao criticas), `ERROR` (falhas), `CRITICAL` (terminacao)

Metricas de training expostas em CoachState: `current_epoch` , `total_epochs` , `train_loss` , `val_loss` , `eta_seconds` , `belief_confidence` , `system_load_cpu` , `system_load_mem` .

> **Analogia:** As metricas de training sao como o **painel de instrumentos de um carro durante uma corrida**: a epoca atual e o **odometro** (em que ponto voce esta), a train_loss e o **consumo de combustivel** (mais baixo = mais eficiente), a val_loss e o **cronometro de volta** (seu tempo na pista de teste), e o ETA e o **GPS** que estima quanto falta ate o destino. O usuario pode ver tudo isso em tempo real na Home screen, atualizado a cada 10 segundos.

12.13 Reporting e Visualizacao

Arquivos: `Programma_CS2_RENAN/reporting/visualizer.py`, `report_generator.py` **Arquivos relacionados:** `backend/processing/heatmap_engine.py`

O sistema de reporting transforma os dados brutos em **visualizacoes compreensiveis** para o usuario.

> **Analogia:** O sistema de reporting e como um **designer grafico** que pega numeros aridos e os transforma em posteres coloridos e infograficos. O **Visualizer** cria graficos radar (pentagonos que mostram suas 5 habilidades em comparacao com os pros), graficos de tendencia (como voce esta melhorando ao longo do tempo) e tabelas de comparacao. O **HeatmapEngine** cria mapas de calor (onde voce esta demais vs. onde deveria estar). O **ReportGenerator** monta tudo em um documento PDF completo, como um laudo medico que o "paciente" (jogador) pode estudar com calma.

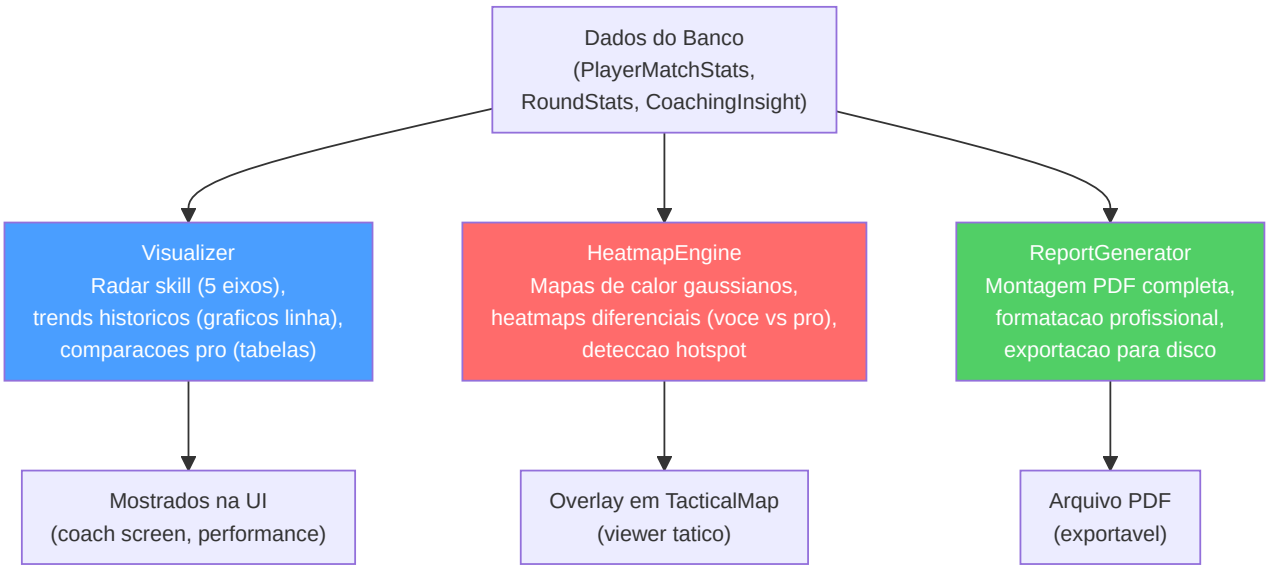

HeatmapEngine — Detalhes tecnicos:

Caracteristica	Detalhe
Thread-safety	`generate_heatmap_data()` roda em thread separada (nao bloqueia UI)
Texture creation	Apenas no thread principal (requisito OpenGL Kivy)
Tipo	Ocupacao gaussiana 2D (blur kernel parametrico)
Diferencial	Subtrai heatmap pro de heatmap usuario → vermelho (tempo demais), azul (pouco tempo)
Hotspot	Identifica clusters de posicao para training posicional

MatchVisualizer (`reporting/visualizer.py`) — metodos de rendering especializados:

O MatchVisualizer estende a capacidade de reporting com 6 metodos de rendering de alta qualidade (cf. secao 12.26 para os detalhes algoritmicos):

Metodo	Input	Output	Descricao
`render_skill_radar(user, pro)`	Dict metricas	PNG radar chart	Pentagono 5 eixos com overlay pro baseline
`render_trend_chart(history, metric)`	Lista historica	PNG line chart	Andamento temporal com media movel
`render_heatmap(positions, map_name)`	Coordenadas tick	PNG heatmap	Gaussiana 2D em textura mapa
`render_differential(user_pos, pro_pos)`	Dois sets posicoes	PNG heatmap diff	Vermelho (excesso) / Azul (deficit) / Verde (alinhamento)
`render_critical_moments(events)`	Lista eventos round	PNG timeline	Marcadores coloridos para kill/death/bomb
`render_comparison_table(user, pro)`	Dois perfis stats	HTML/PNG tabela	Delta percentual para cada metrica

ReportGenerator (`reporting/report_generator.py`):

Monta todos os elementos visuais em um **documento PDF completo**:

1. **Header**: Nome jogador, data, demo analisada
2. **Executive Summary**: Metricas chave (KPR, ADR, KAST, Rating)
3. **Radar Chart**: Comparacao 5 eixos com pro baseline
4. **Trend Charts**: Tendencias das ultimas N partidas
5. **Heatmap Diferencial**: Onde se posicionar melhor
6. **Momentos Criticos**: Os 5 momentos decisivos da partida
7. **Conselhos do Coach**: Top-3 insights priorizados
8. **Footer**: Gerado por Macena CS2 Analyzer v.X.X

> **Analogia do Report PDF:** O report e como um **laudo medico completo apos um check-up**. A primeira pagina tem o resumo ("paciente em boa saude, melhorar colesterol"). Depois vem os graficos detalhados (analise de sangue = radar chart, TAC = heatmap, ECG = trend). Por fim as recomendacoes do medico (os conselhos do coach). O paciente pode estuda-lo com calma em casa e leva-lo a proxima consulta.

12.14 Gestao de Quotas e Limites

O sistema implementa um mecanismo de **quota mensal** para prevenir o abuso dos recursos de processamento e garantir uma distribuicao justa da carga.

> **Analogia:** O sistema de quotas e como uma **assinatura de academia com sessoes limitadas**. Cada mes voce tem 10 sessoes (demos) disponiveis. Cada vez que voce carrega uma demo, o contador diminui. No inicio do mes seguinte, o contador e resetado. Alem disso, ha um limite total a vida de 100 demos: como um diario que tem apenas 100 paginas. Essas limitacoes garantem que o sistema nao seja sobrecarregado por usuarios que carregam centenas de demos de uma vez, e que o banco nao cresca de forma descontrolada.

Limite	Valor	Enforcement
MAX_DEMOS_PER_MONTH	10	`StorageManager.can_user_upload()`
MAX_TOTAL_DEMOS	100	`StorageManager.can_user_upload()`
MIN_DEMOS_FOR_COACHING	10	Limite para coaching personalizado completo
Reset mensal	Automatico	`PlayerProfile.last_upload_month` vs. mes atual

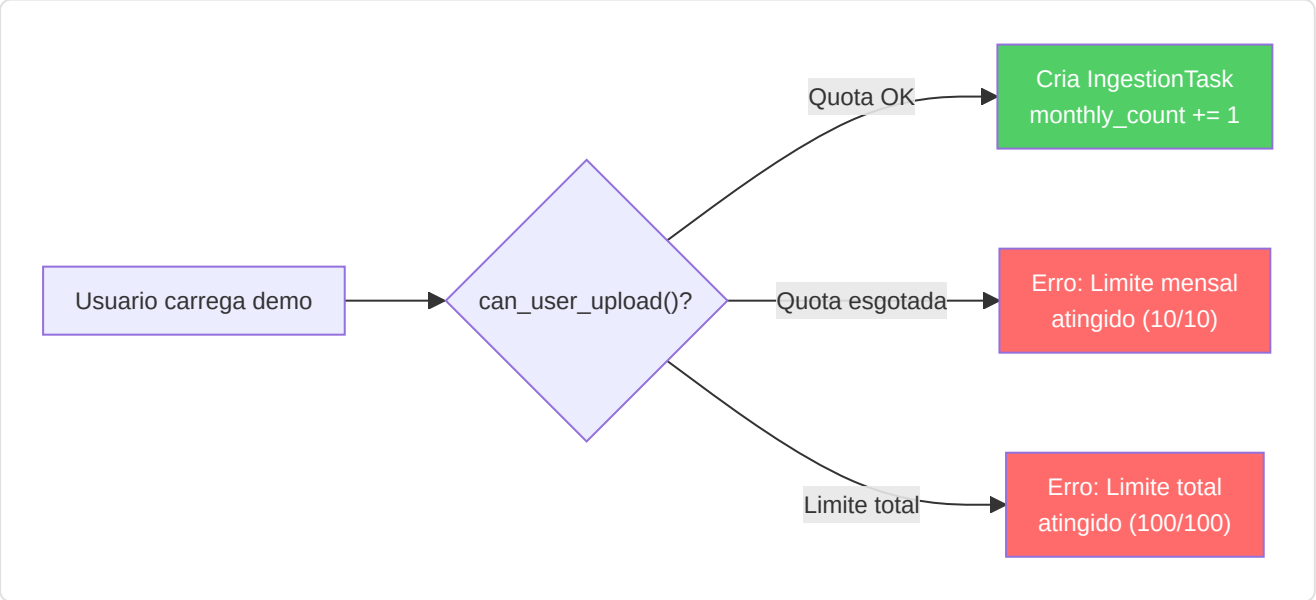

12.15 Tolerancia a Falhas e Recuperacao

O sistema e projetado para **nunca perder dados** e **se recuperar automaticamente** de quase todos os tipos de falha.

> **Analogia:** A tolerancia a falhas e como um **sistema de seguranca em uma central nuclear**: ha multiplos niveis de protecao, cada um independente dos outros. Se um nivel falha, o proximo se ativa. (1) O **Zombie Task Cleanup** e como o turno da noite que limpa os instrumentos esquecidos: se o turno anterior (sessao anterior) deixou tasks em estado "processing" por causa de um crash, o turno seguinte os reseta e os recomeca. (2) O **Backup Automatico** e como o cofre a prova de fogo: mesmo se o edificio inteiro queima, os documentos no cofre sobrevivem. (3) O **Service Supervisor** e como o guardiao que reinicia os geradores de emergencia se eles se apagam. (4) O **Connection Pooling** e como ter reservas de chaves: se uma fechadura trava, ha outras 19 disponiveis.

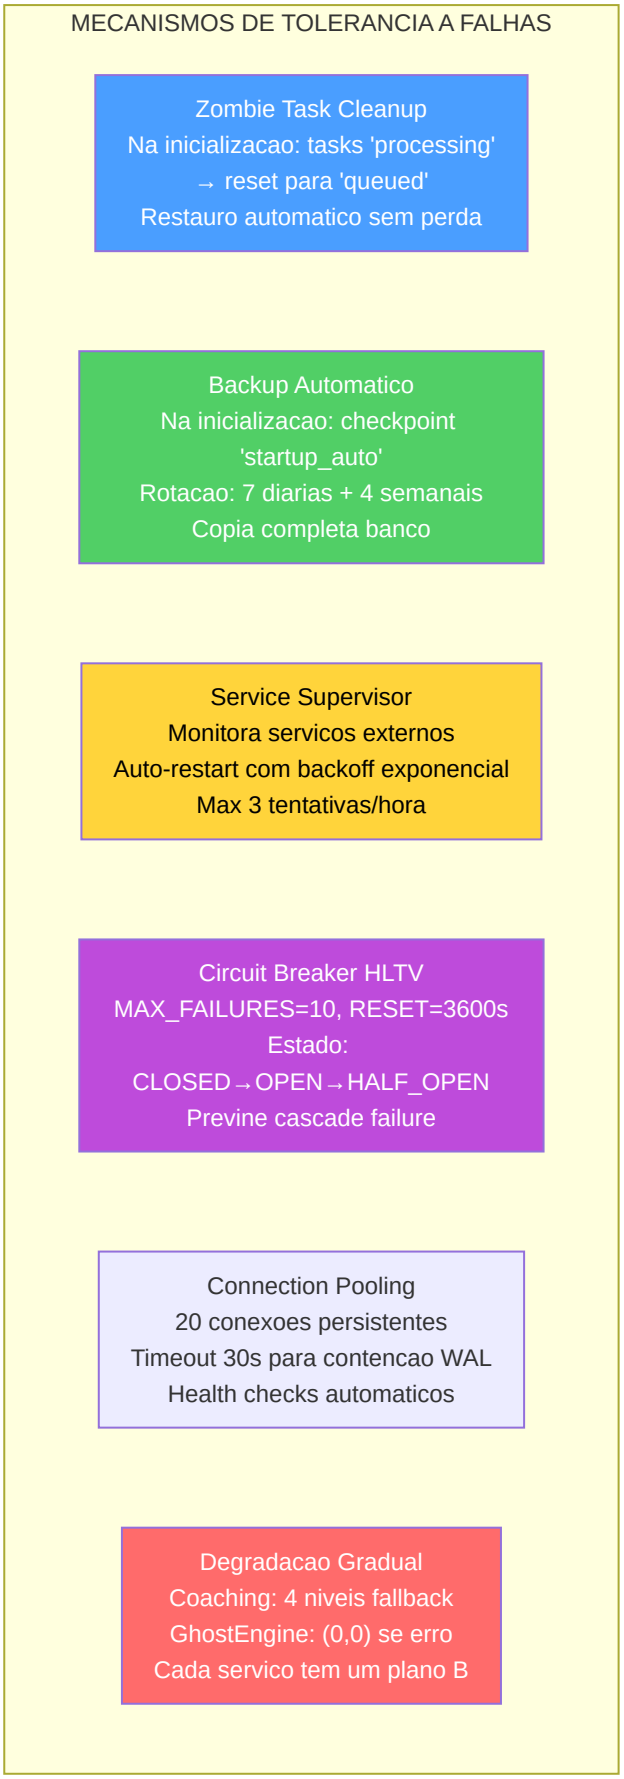
MECANISMOS DE TOLERANCIA A FALHAS
Zombie Task Cleanup
Na inicializacao: tasks 'processing'
→ reset para 'queued'
Restauro automatico sem perda
Backup Automatico
Na inicializacao: checkpoint
'startup_auto'
Rotacao: 7 diarias + 4 semanais
Copia completa banco
Service Supervisor
Monitora servicos externos
Auto-restart com backoff exponencial
Max 3 tentativas/hora
Circuit Breaker HLTV
MAX_FAILURES=10, RESET=3600s
Estado:
CLOSED→OPEN→HALF_OPEN
Previne cascade failure
Connection Pooling
20 conexoes persistentes
Timeout 30s para contencao WAL
Health checks automaticos
Degradacao Gradual
Coaching: 4 niveis fallback
GhostEngine: (0,0) se erro
Cada servico tem um plano B

Matriz de falha e recuperacao:

Cenario de falha	Mecanismo de recuperacao	Perda de dados
Crash da aplicacao durante parsing	Zombie Task Cleanup no reinicio	Nenhuma — task recomecada
Corrupcao banco	Restore de backup automatico mais recente	Maximo 24 horas de dados
Servico HLTV nao alcancavel	Circuit Breaker `_CircuitBreaker` (MAX_FAILURES=10, RESET_WINDOW_S=3600): apos 10 falhas consecutivas o circuito se abre e bloqueia as requisicoes por 1 hora, depois passa para HALF_OPEN para um teste. Previne cascade failure em APIs externas.	Nenhuma — dados pro atrasados
Modelo ML nao carregavel	Fallback para pesos aleatorios (GhostEngine) ou coaching base	Nenhuma — qualidade degradada
RAM insuficiente durante training	Early stopping automatico, checkpoint salvo	Nenhuma — ultimo checkpoint valido
Disco cheio	Database Governor detecta e notifica via ServiceNotification	Prevencao — nenhum dado escrito
Demo corrompida/truncada	IntegrityChecker rejeita antes do parsing	Nenhuma — demo ignorada com warning
Ollama nao disponivel	LLM fallback para RAG puro, depois coaching base	Nenhuma — qualidade narrativa degradada
API Steam/FACEIT timeout	Retry com backoff exponencial (max 3 tentativas)	Nenhuma — perfil nao atualizado
Browser Playwright crash	BrowserManager: recria instancia, retry operacao	Nenhuma — scraping HLTV atrasado
Conflito WAL (lock contention)	Timeout 30s com retry automatico	Nenhuma — operacao atrasada
Checkpoint ML corrompido	Fallback para checkpoint anterior (versionamento)	Parcial — perde ultimo training
Vetor query norma-zero (M-07)	`VectorIndex.search()` retorna `None` com warning — pipeline RAG continua sem crash	Nenhuma — resultado RAG vazio

Cenario de falha	Mecanismo de recuperacao	Perda de dados
Arquivo settings.json corrompido (M-08)	`load_user_settings()` valida estrutura, fallback para default se nao-dict	Nenhuma — configuracoes padrao
Logger nao inicializado (C-09)	Bootstrap antecipado usa `print()` antes da init do logger	Nenhuma — mensagens em stdout
DB handle leak em integrity check (H-02)	`_verify_integrity()` usa `try/finally` + `PRAGMA quick_check`	Nenhuma — conexao sempre fechada
Erros batch mascarados em RAP training (H-03)	Removido `except (KeyError, TypeError): continue` — `train_step()` requer dict com key `'loss'`	Nenhuma — erros agora visiveis

Degradacao gradual — A Cadeia de Fallback:

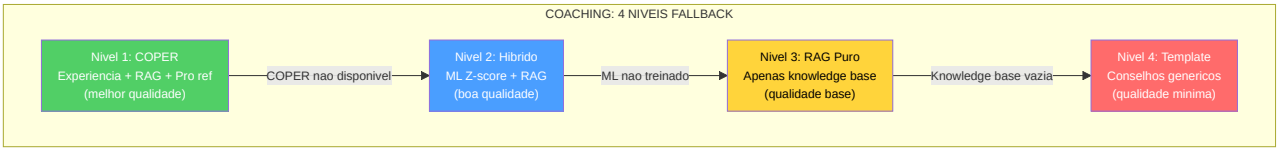

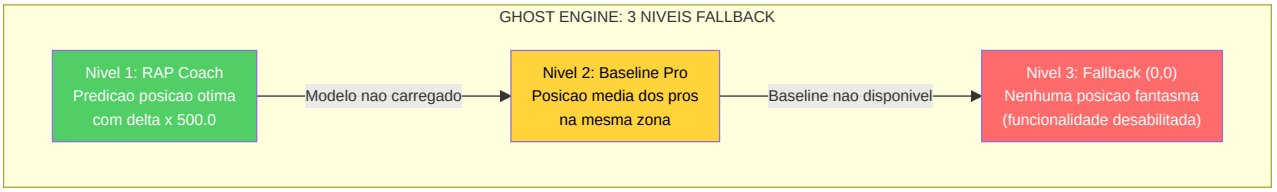

> **Analogia da Degradacao:** A degradacao gradual e como um **sistema de iluminacao de 4 niveis em caso de blackout**. Nivel 1: corrente principal (COPER completo — a melhor experiencia). Nivel 2: gerador de backup (ML+RAG hibrido — bom mas nao perfeito). Nivel 3: baterias de emergencia (RAG puro — as luzes estao acesas mas fracas). Nivel 4: lanternas de mao (templates genericos — voce mal enxerga, mas nao fica no escuro). O sistema **nunca crasha** — sempre degrada de forma controlada e transparente.

12.16 Jornada Completa do Usuario — 4 Fluxos Principais

Esta secao descreve os **4 fluxos principais** que um usuario percorre durante o uso do Macena CS2 Analyzer.

Fluxo 1: Upload e Analise de uma Demo

> **Analogia:** Este fluxo e como **levar uma amostra de sangue ao laboratorio**: voce entrega no balcao de aceitacao (upload), o tecnico a prepara (parsing), o quimico a analisa (feature extraction), o medico le os resultados (coaching service) e voce recebe o laudo (insights na UI). Tudo acontece de forma automatica uma vez entregue a amostra.

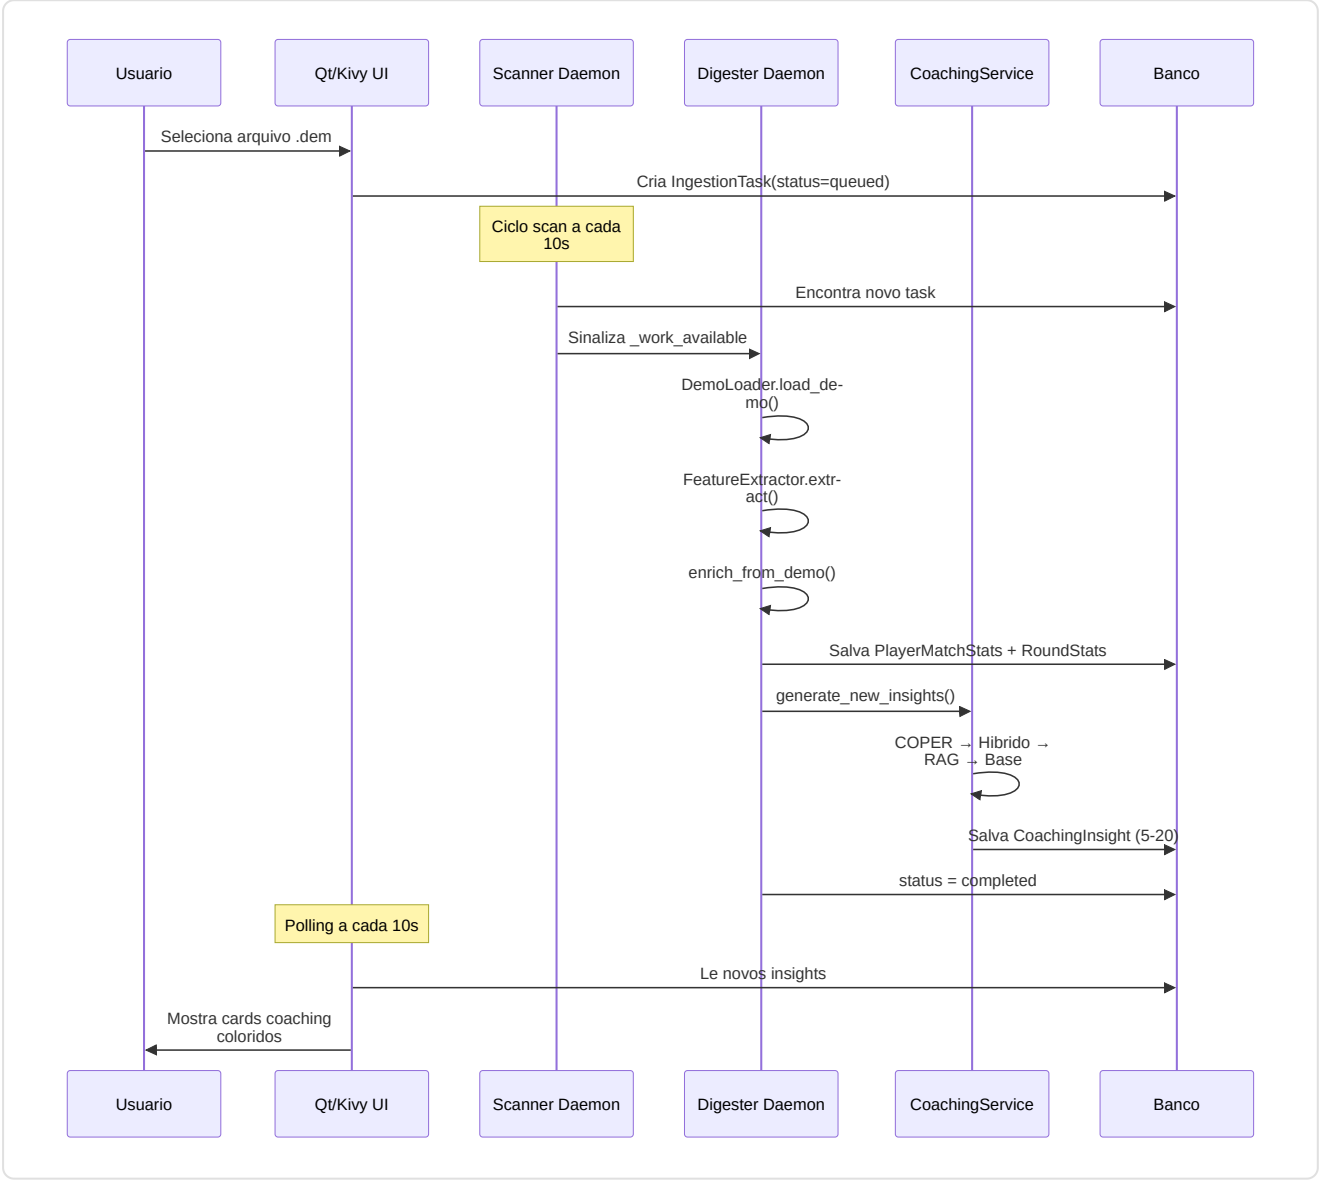

Detalhe: Pipeline CoachingService interna

Quando `generate_new_insights()` e invocado, o CoachingService executa internamente:

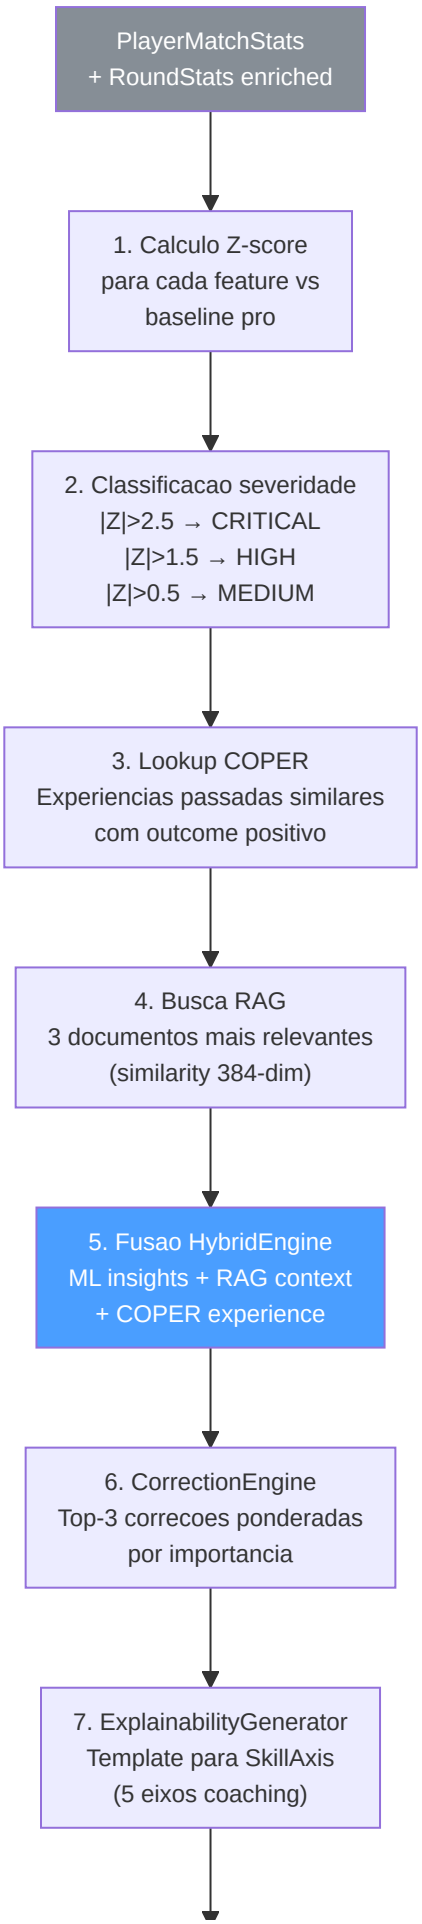
PlayerMatchStats
+ RoundStats enriched
1. Calculo Z-score
para cada feature vs
baseline pro
2. Classificacao severidade
|Z|>2.5 → CRITICAL
|Z|>1.5 → HIGH
|Z|>0.5 → MEDIUM
3. Lookup COPER
Experiencias passadas similares
com outcome positivo
4. Busca RAG
3 documentos mais relevantes
(similarity 384-dim)
5. Fusao HybridEngine
ML insights + RAG context
+ COPER experience
6. CorrectionEngine
Top-3 correcoes ponderadas
por importancia
7. ExplainabilityGenerator
Template para SkillAxis
(5 eixos coaching)

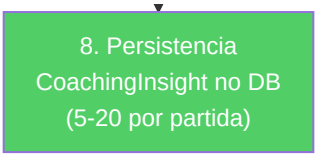

LessonGenerator — geracao de licoes estruturadas de demo:

Parametro	Valor	Significado
`ADR_STRONG`	75	ADR >= 75 → "Bom dano medio"
`HS_STRONG`	0.40	HS% >= 40% → "Boa precisao na cabeca"
`KAST_STRONG`	0.70	KAST >= 70% → "Boa contribuicao ao round"
Formato output	Secao 1 (Overview) + Secao 2 (Pontos fortes) + Secao 3 (Areas de melhoria) + Secao 4 (Pro tip)	Estrutura licao padrao

O LessonGenerator opera em modo duplo: se Ollama esta disponivel, gera licoes em linguagem natural via `LLMService.generate_lesson()`. Se nao esta disponivel, usa templates estruturados com os dados numericos inseridos em frases preformadas.

Fluxo 2: Visualizacao Tatica

> **Analogia:** Este fluxo e como **assistir a uma partida gravada na moviola** com um comentarista AI. Voce carrega o video (demo), o sistema o decodifica, e entao voce pode navegar para frente e para tras, desacelerar, acelerar, e ver onde o comentarista acha que voce deveria ter se posicionado.

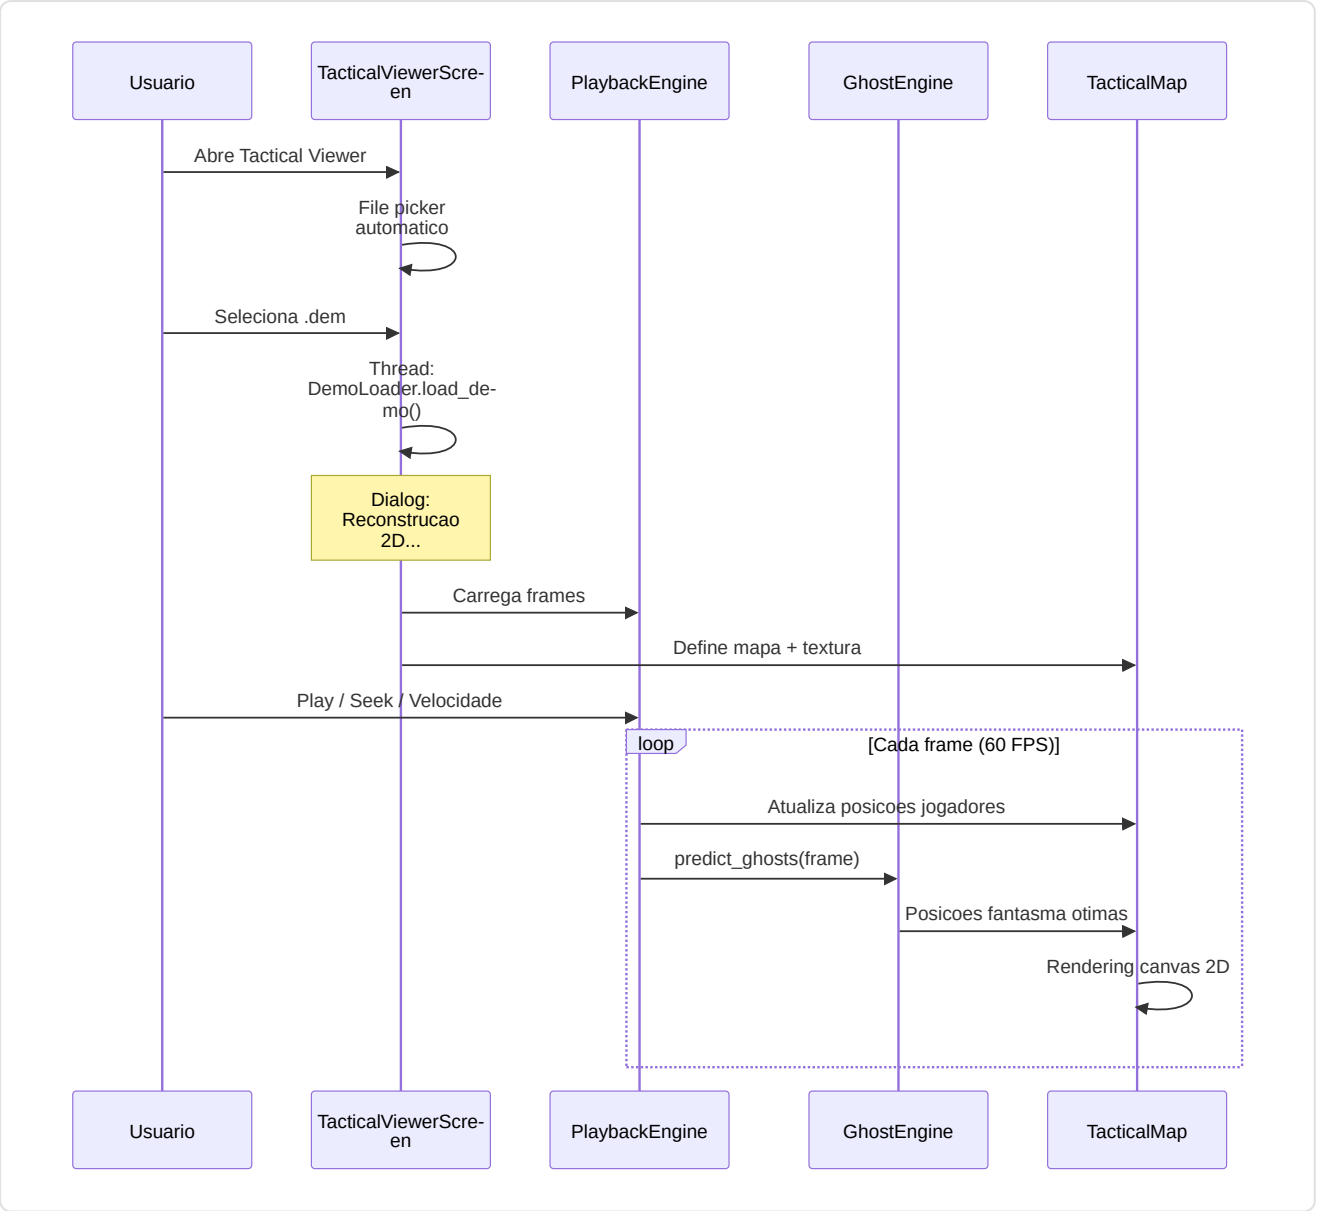

Fluxo 3: Retreinamento ML Automatico

> **Analogia:** Este fluxo e completamente **automatico**, como o piloto automatico de um aviao. O usuario nao precisa fazer nada: o sistema monitora constantemente a quantidade de dados disponiveis e, quando ha novos suficientes, retreina automaticamente o modelo para mante-lo atualizado com o meta atual.

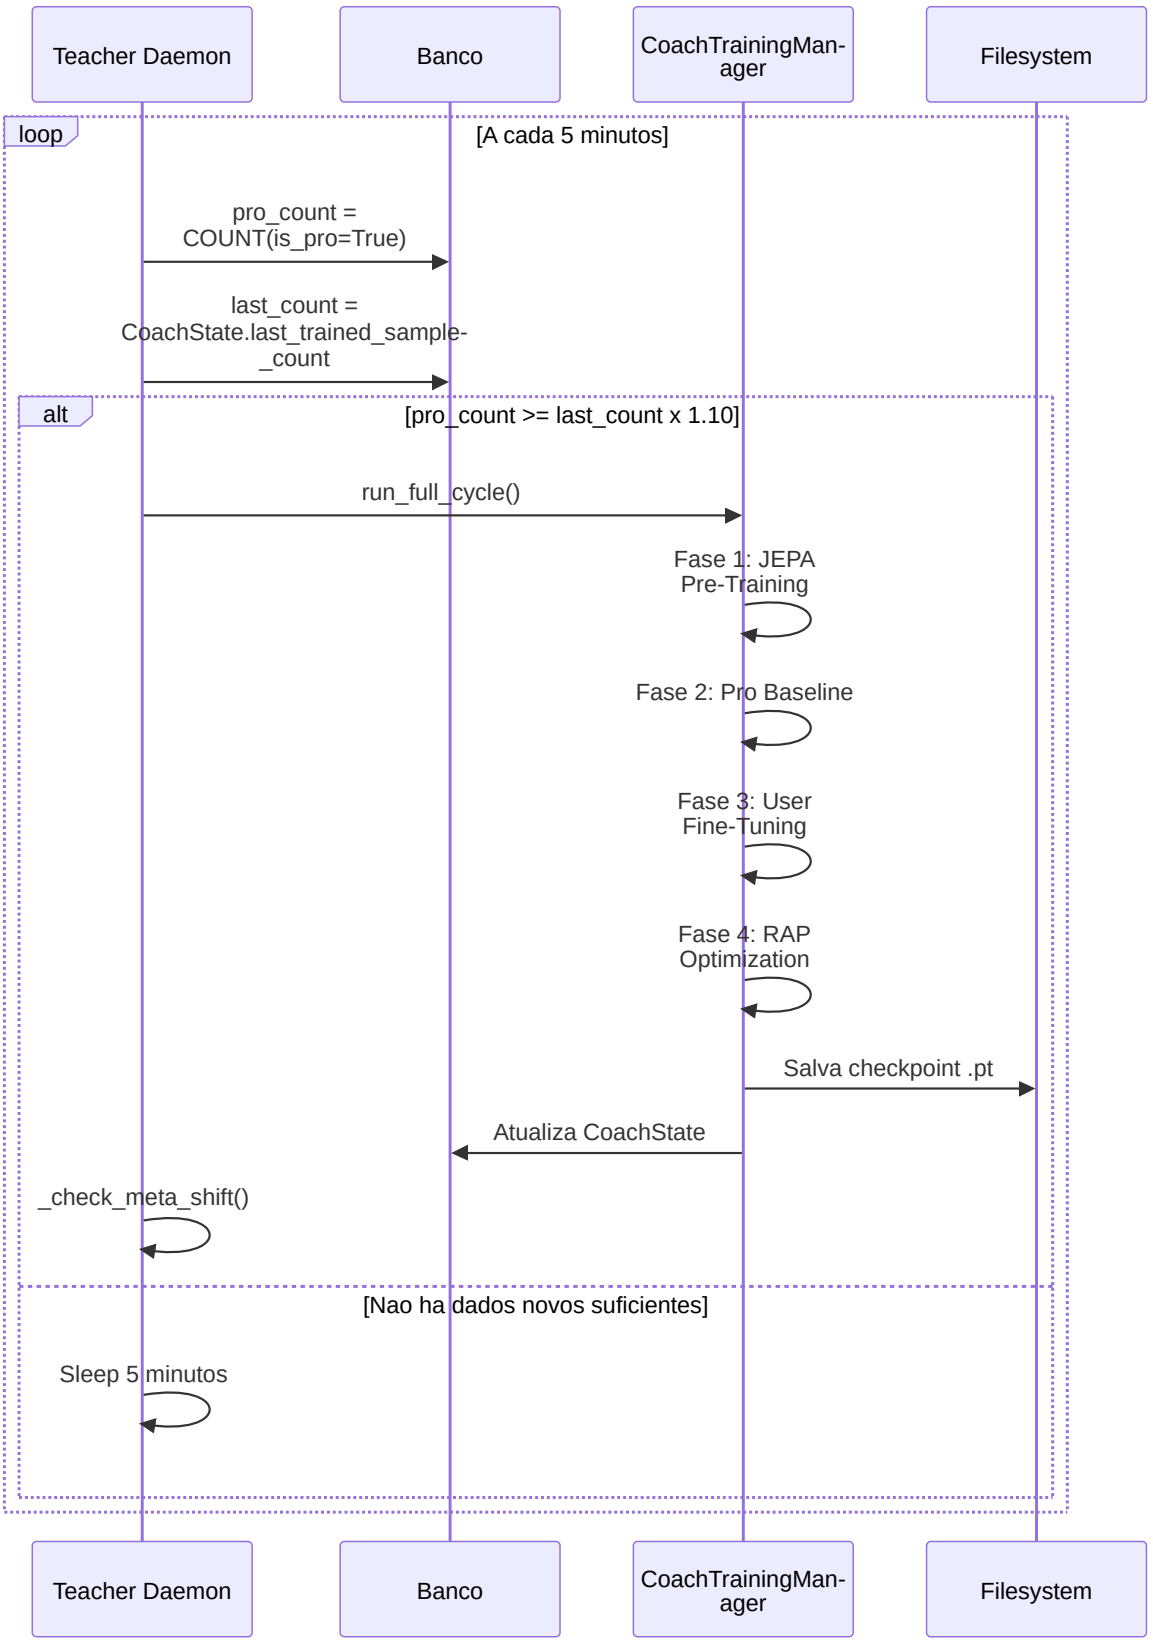
Teacher Daemon
Banco
CoachTrainingManager
Filesystem
loop
[A cada 5 minutos]
pro_count = COUNT(is_pro=True)
last_count = CoachState.last_trained_sample_count
alt
[pro_count >= last_count x 1.10]
run_full_cycle()
Fase 1: JEPA Pre-Training
Fase 2: Pro Baseline
Fase 3: User Fine-Tuning
Fase 4: RAP Optimization
Salva checkpoint .pt
Atualiza CoachState
_check_meta_shift()
[Nao ha dados novos suficientes]
Sleep 5 minutos
Teacher Daemon
Banco
CoachTrainingManager
Filesystem

Fluxo 4: Chat AI com o Coach

> **Analogia:** O chat e como ter uma **conversa privada com seu treinador**. Voce pode fazer perguntas especificas ("O que devo melhorar em Dust2?"), e ele consulta sua base de conhecimento, suas estatisticas e as referencias pro para dar uma resposta personalizada. Se Ollama esta instalado localmente, a resposta soa natural e motivadora. Se nao esta disponivel, o sistema usa mesmo assim a base de conhecimento RAG para fornecer respostas uteis.

CoachingDialogueEngine — Pipeline Multi-Turno:

O dialogo AI segue uma pipeline de 5 fases para cada mensagem do usuario:

Fase	Componente	Descricao
1	**Intent Classification**	Classifica a pergunta: coaching, stats query, comparison, general
2	**Context Retrieval**	Recupera as ultimas N partidas, insights recentes, perfil jogador
3	**RAG Augmentation**	Busca na knowledge base os 3 documentos mais relevantes (similarity search 384-dim)
4	**COPER Augmentation**	Se disponivel, adiciona experiencias de coaching passadas com outcome positivo
5	**Response Generation**	Gera resposta via Ollama (se disponivel) ou template RAG estruturado

Parametro	Valor	Proposito
`MAX_CONTEXT_TURNS`	6	Numero maximo de turnos mantidos no contexto
`MAX_RESPONSE_WORDS`	100	Limite de palavras para resposta LLM
`SIMILARITY_THRESHOLD`	0.5	Limite minimo para resultados RAG
Tone	"coaching, encouraging"	Prompt system para tom positivo

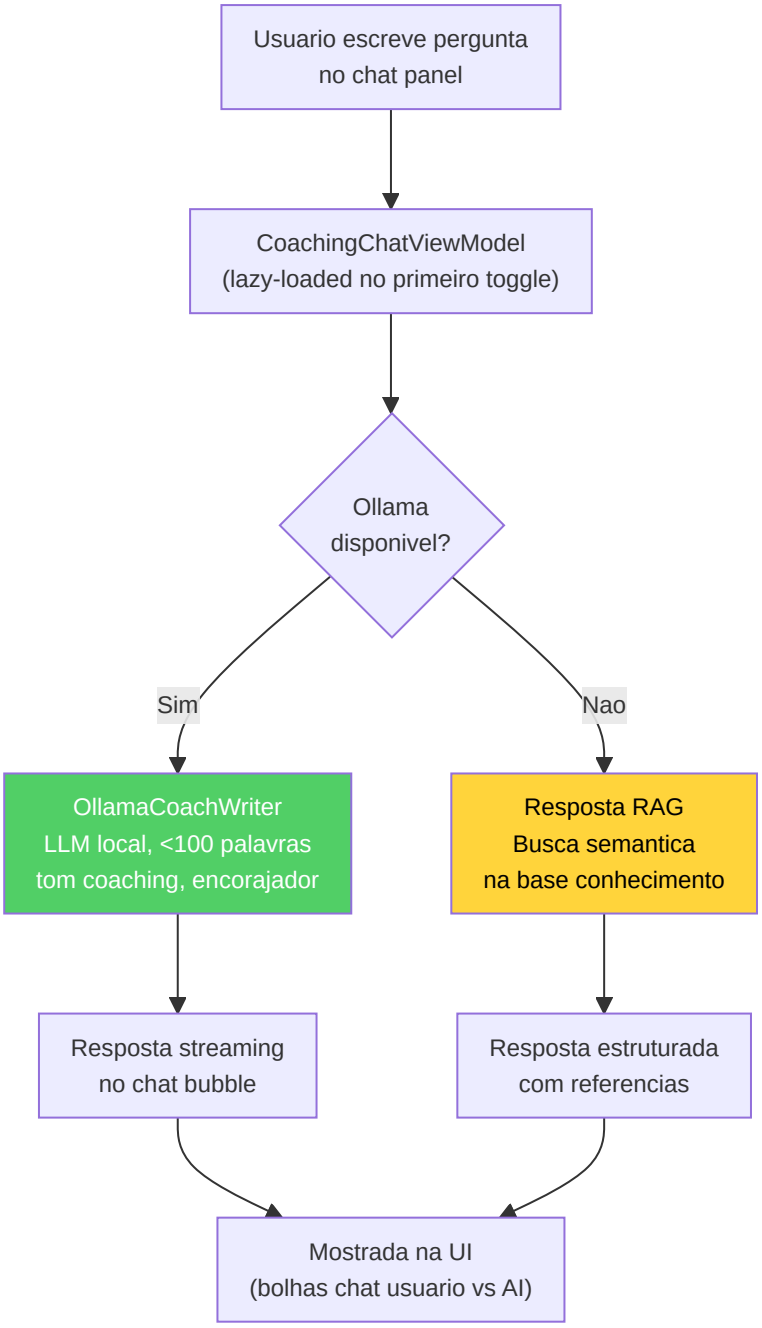

Fluxo 5: Diagnostico e Manutencao

> **Analogia:** Este fluxo e a **revisao periodica do carro**. O operador (desenvolvedor ou usuario experiente) leva o sistema a oficina (console ou tools) e executa uma serie de verificacoes. Nao e necessario faze-lo todos os dias, mas e recomendado apos atualizacoes, apos periodos de inatividade, ou quando algo parece estar errado.

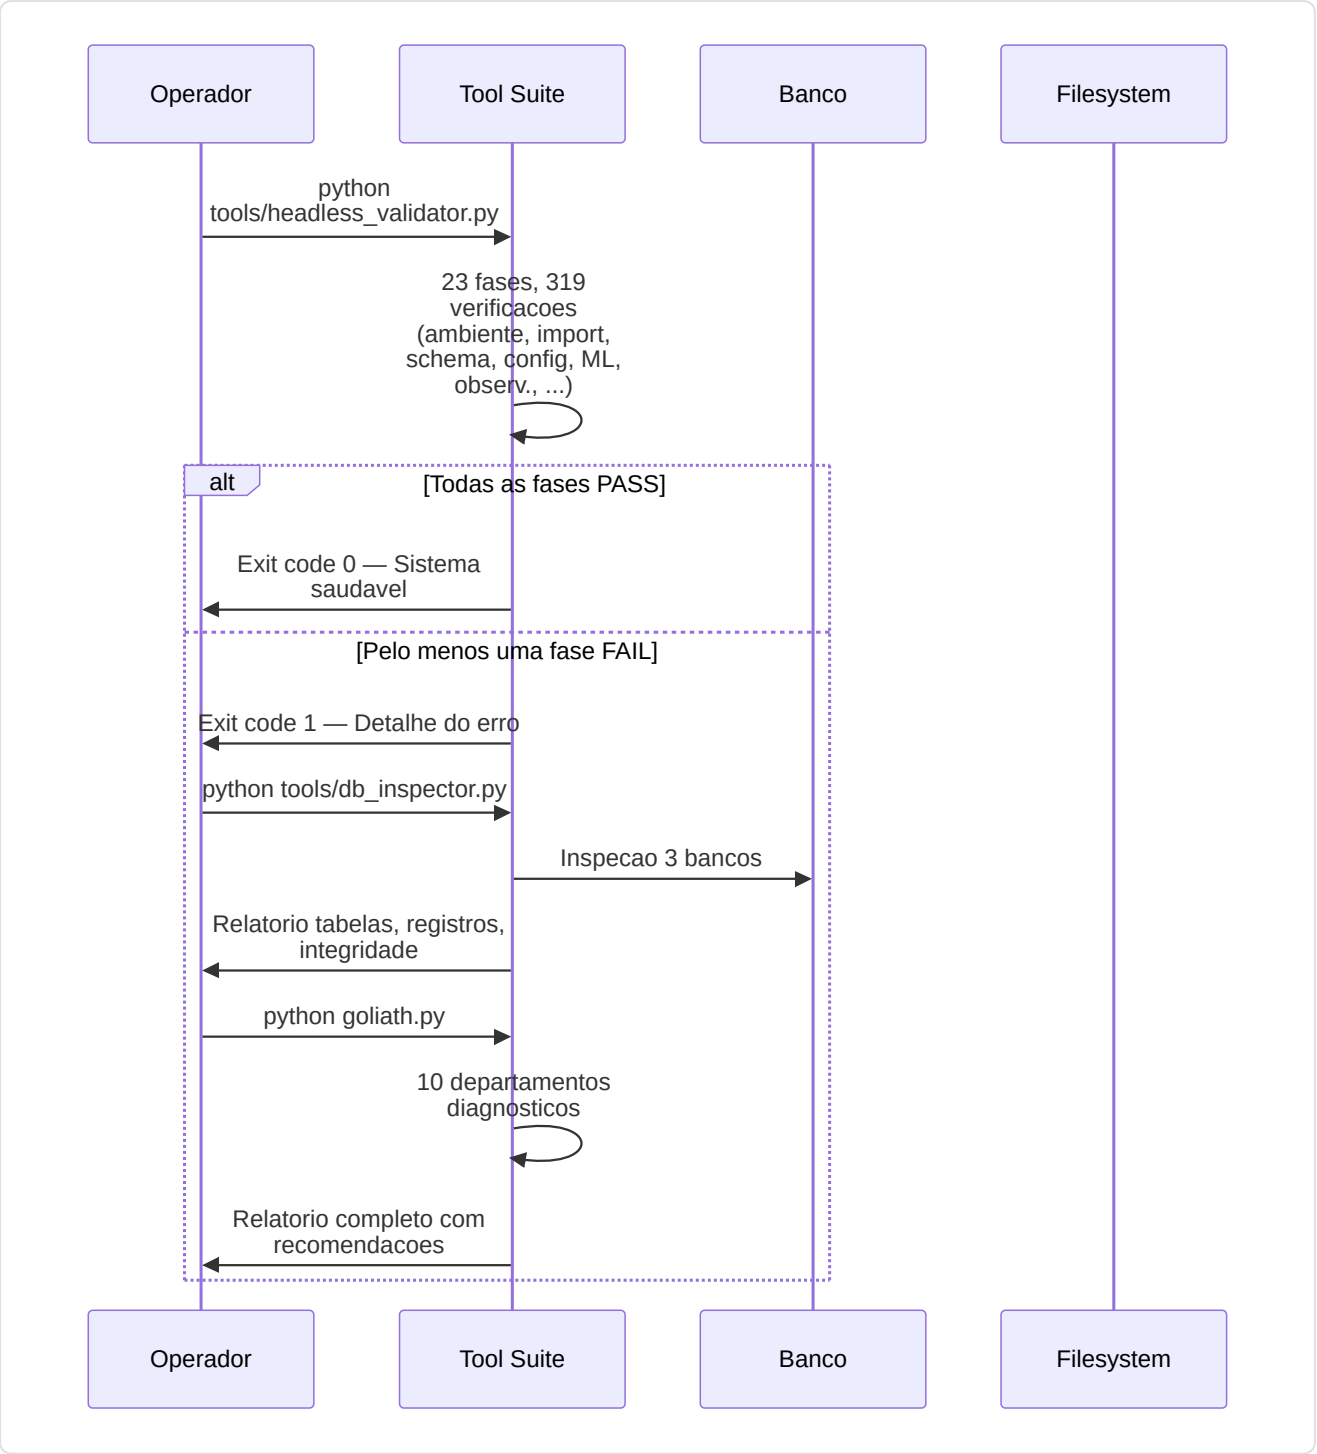

Matriz ferramentas por cenario:

Cenario	Ferramenta recomendada	Tempo
Quick check pos-deploy	`headless_validator.py`	~10s
Banco suspeito	`db_inspector.py`	~30s
Demo nao parsed	`demo_inspector.py`	~5s
Training diverge	`Ultimate_ML_Coach_Debugger.py`	~2min
Check-up completo	`Goliath_Hospital.py`	~3min
Audit ML profundo	`brain_verify.py`	~5min

12.17 Suite de Ferramentas — Validacao e Diagnostico (`tools/`)

Diretorio: `tools/` (root) + `Programma_CS2_RENAN/tools/` **Arquivos principais:** `headless_validator.py`, `db_inspector.py`, `demo_inspector.py`, `brain_verify.py` *(planejado, ainda nao implementado)*, `Goliath_Hospital.py`, `Ultimate_ML_Coach_Debugger.py`, `_infra.py`

A suite de ferramentas e uma **colecao de 41 scripts** distribuidos em duas diretorias (`tools/` root com 29 scripts e `Programma_CS2_RENAN/tools/` com 12 scripts) que formam uma piramide de validacao multi-nivel. Cada ferramenta tem um proposito preciso e pode ser executada independentemente, mas juntas formam um sistema de garantia de qualidade que cobre cada aspecto do projeto.

> **Analogia:** A suite de ferramentas e como o **departamento de controle de qualidade de uma fabrica automobilistica**. Cada veiculo (build do projeto) atravessa uma serie de estacoes de inspecao, cada uma especializada em um aspecto: o **Headless Validator** e a estacao de colaudo rapido que verifica que o motor liga e as rodas giram (regression gate em 23 fases, 319 verificacoes). O **DB Inspector** e o mecanico que desmonta e controla o motor peca por peca (inspecao banco). O **Demo Inspector** e o tecnico que verifica a carroceria (integridade arquivo demo). O **Brain Verify** e o neurologista que testa cada funcao cognitiva (118 regras de qualidade da inteligencia). O **Goliath Hospital** e o hospital completo com 10 departamentos especializados. Nenhum veiculo sai da fabrica sem ter passado por todos os controles.

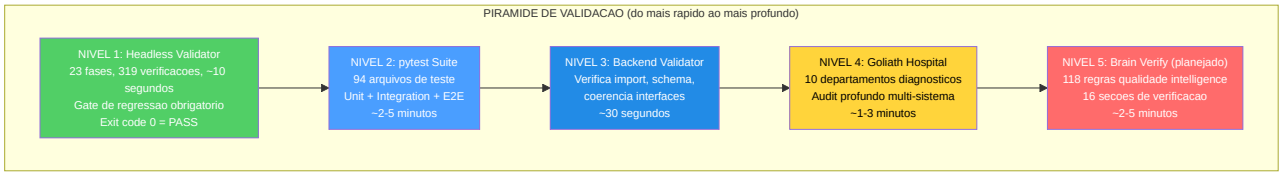

Headless Validator (`tools/headless_validator.py`) — o gate de regressao obrigatorio (Dev Rule 9). Executado apos **cada** task de desenvolvimento com 23 fases e 319 verificacoes:

Fase	Verificacao	Detalhe
1	**Ambiente**	Python >= 3.10, dependencias criticas presentes (torch, kivy, sqlmodel, demoparser2)
2	**Import Core**	`config.py`, `spatial_data.py`, `lifecycle.py` — os modulos fundamentais se carregam sem erros
3	**Import Backend**	`nn/`, `processing/`, `storage/`, `services/`, `coaching/` — todos os subsistemas backend importaveis
4	**Schema DB**	As 21 tabelas SQLModel se criam corretamente, as relacoes sao validas
5	**Configuracao**	`METADATA_DIM`, paths, constantes — valores coerentes e alcancaveis
6	**ML Smoke**	Instanciacao modelos (JEPA, RAP, MoE) com pesos aleatorios — verificam dimensoes e forward pass
7	**Observabilidade**	`get_logger()` funcional, `StateManager` inicializavel, log path escrivel

> **Analogia:** O Headless Validator e o **termometro** do projeto. Nao faz um diagnostico aprofundado, mas se a temperatura esta alta (exit code != 0), voce sabe imediatamente que algo nao vai bem. E a primeira verificacao a ser feita, rapida e nao invasiva. Se passa, voce pode prosseguir com confianca. Se falha, pare e investigue antes de seguir adiante.

Infraestrutura Compartilhada (`tools/_infra.py`):

Componente	Papel
`BaseValidator`	Classe base para todos os validadores — output console unificado, contagem pass/fail/warning
`path_stabilize()`	Normalizacao `sys.path` para evitar imports relativos inconsistentes
`Console` (Rich)	Output colorido com tabelas, progress bar, emoji de estado
`Severity` enum	4 niveis: `INFO`, `WARNING`, `ERROR`, `CRITICAL`

DB Inspector (`tools/db_inspector.py`) — inspecao profunda do banco:

- Abre `database.db` e `hltv_metadata.db` separadamente
- Para cada tabela: conta registros, verifica schema, controla integridade indices
- Mostra metricas de espaco (tamanho arquivo, paginas WAL, fragmentacao)
- Detecta anomalias: tabelas vazias inesperadas, registros orfaos, timestamps fora do range
- Output: tabela Rich colorida com estado para cada tabela

Demo Inspector (`tools/demo_inspector.py`) — inspecao arquivo demo:

- Verifica magic bytes (`PBDEMS2\0` para CS2, `HL2DEMO\0` para legacy)
- Controla tamanho arquivo (1KB min, 5GB max)
- Extrai metadata header sem parsing completo
- Detecta corrupcao parcial (truncamento, header danificado)

- Output: relatorio sobre validade da demo com detalhes erro se invalida

Brain Verify (`tools/brain_verify.py` + `brain_verification/`, 16 secoes) — *(planejado, ainda nao implementado)*:

O sistema de verificacao da inteligencia e projetado com **16 secoes tematicas** que cobrirao **118 regras** de qualidade:

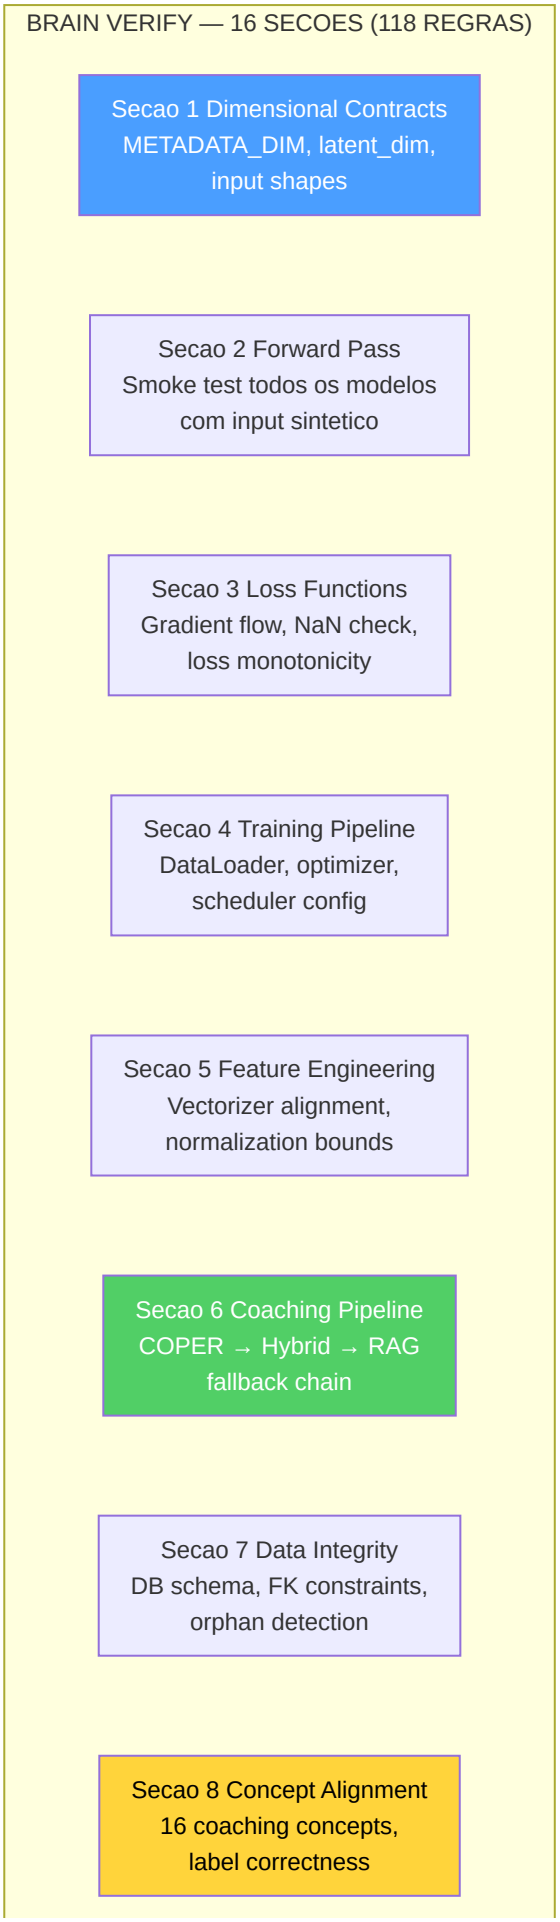
BRAIN VERIFY — 16 SECOES (118 REGRAS)
Secao 1 Dimensional Contracts
METADATA_DIM, latent_dim,
input shapes
Secao 2 Forward Pass
Smoke test todos os modelos
com input sintetico
Secao 3 Loss Functions
Gradient flow, NaN check,
loss monotonicity
Secao 4 Training Pipeline
DataLoader, optimizer,
scheduler config
Secao 5 Feature Engineering
Vectorizer alignment,
normalization bounds
Secao 6 Coaching Pipeline
COPER → Hybrid → RAG
fallback chain
Secao 7 Data Integrity
DB schema, FK constraints,
orphan detection
Secao 8 Concept Alignment
16 coaching concepts,
label correctness

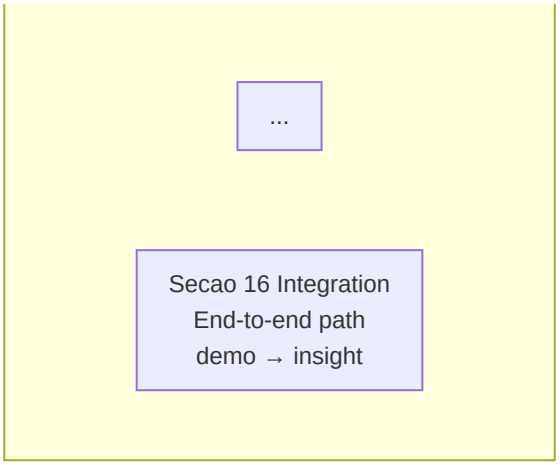

Goliath Hospital (`tools/Goliath_Hospital.py`) — diagnostico multi-departamento:

O "Goliath Hospital" e o **sistema de diagnostico mais completo** do projeto, organizado como um hospital com 10 departamentos especializados:

Departamento	Nome	Verificacoes
1	**Pronto Socorro (ER)**	Import criticos, crashes imediatos, path resolution
2	**Radiologia**	Estrutura arquivo/diretorio, arquivos ausentes, permission
3	**Patologia**	Schema DB, integridade dados, registros anomalos
4	**Cardiologia**	Session Engine, daemon heartbeat, IPC
5	**Neurologia**	ML models, forward pass, gradient flow
6	**Oncologia**	Dead code, import nao utilizados, dependencias circulares
7	**Pediatria**	Onboarding, fluxos primeiro usuario, wizard
8	**Terapia Intensiva (ICU)**	Concorrencia, race condition, WAL contention
9	**Farmacia**	Dependencias, versoes, compatibilidade
10	**Clinica dos Instrumentos**	Validacao dos outros instrumentos (meta-teste)

> **Analogia:** Goliath Hospital e como um **check-up medico completo**. Nao te faz apenas o termometro (Headless Validator) — te faz raios-X, analise de sangue, eletrocardiograma, ressonancia magnetica, e chama 10 especialistas diferentes para examinar cada aspecto da sua saude. Se um departamento encontra um problema, o sinaliza com a severidade apropriada. O resultado final e um **laudo completo** com recomendacoes priorizadas.

Ultimate ML Coach Debugger (`tools/Ultimate_ML_Coach_Debugger.py`) — falsificacao das crencas neurais:

Esta ferramenta executa um audit em **3 fases** na pipeline ML:

1. **Verificacao Estrutural** — Dimensoes tensor, arquitetura modelos, parametros learnable

2. **Verificacao Comportamental** — Forward pass com dados reais, gradient flow, loss convergence
3. **Falsificacao Crencas** — Testa se o modelo "acredita" em coisas erradas: predicoes overconfident, bias sistematicos, patterns degenerados

Outros instrumentos:

Instrumento	Arquivo	Proposito
`backend_validator.py`	`tools/`	Verifica coerencia import e interfaces backend
`build_tools.py`	`tools/`	Automacao build PyInstaller
`user_tools.py`	`tools/`	Utilidades para o usuario final (reset, export)
`dev_health.py`	`tools/`	Quick check saude desenvolvimento
`context_gatherer.py`	`tools/`	Coleta contexto para debug report
`dead_code_detector.py`	`tools/`	Identifica codigo morto nao referenciado
`sync_integrity_manifest.py`	`tools/`	Atualiza `integrity_manifest.json` com hash SHA-256
`project_snapshot.py`	`tools/`	Snapshot completo do estado do projeto
`ui_diagnostic.py`	`tools/`	Diagnostico especifico UI (Qt/Kivy)
`build_pipeline.py`	Root `tools/`	Pipeline de build completa
`Feature_Audit.py`	Root	Audit do feature vector 25-dim
`Sanitize_Project.py`	Root	Limpeza arquivos temporarios, cache, artifacts
`audit_binaries.py`	Root	Verifica integridade executaveis e .pt

12.18 Arquitetura da Test Suite (`tests/`)

Diretorio: `Programma_CS2_RENAN/tests/` **Arquivos totais:** 94 arquivos de teste + `conftest.py` + 10 scripts forensics + 15 scripts de verificacao

A test suite e organizada segundo o **principio da piramide dos testes**: muitos unit tests (rapidos, isolados), menos integration tests (mais lentos, com dependencias reais), e poucos end-to-end tests (completos mas custosos).

> **Analogia:** A test suite e como o **sistema de exames de uma escola**. Os **unit tests** sao os quizzes diarios: rapidos, focados em um unico topico, faceis de corrigir. Os **integration tests** sao os exames de meio de trimestre: verificam que varios topicos funcionem juntos. Os **e2e tests** sao os exames finais: simulam a experiencia inteira do aluno desde a matricula ate o diploma. Os **forensics** sao as investigacoes especiais: quando algo da errado, escavam a fundo para encontrar a causa raiz.

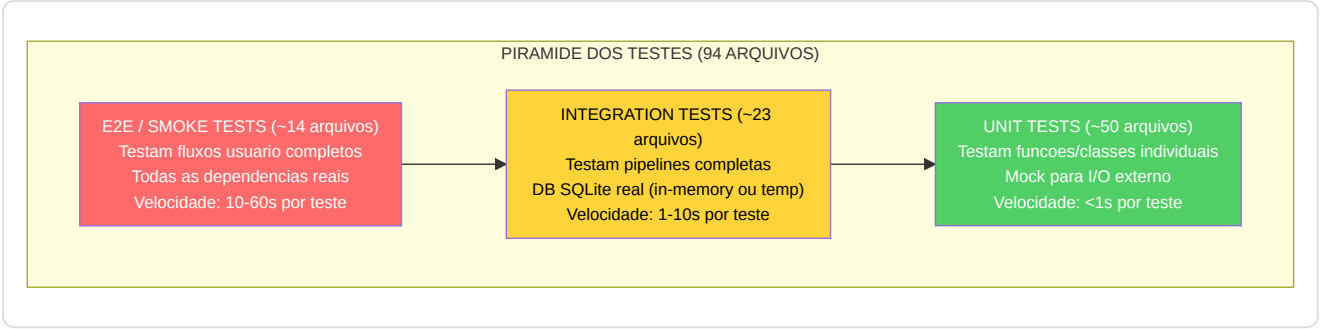

Conftest (`tests/conftest.py`) — fixtures compartilhadas:

Fixture	Scope	Descricao
`test_db`	`function`	Banco SQLite in-memory com todas as tabelas criadas, auto-cleanup
`sample_match_stats`	`function`	`PlayerMatchStats` com dados realisticos derivados de partidas reais
`mock_demo_data`	`function`	`DemoData` mock com frames e eventos para testes de parsing
`tmp_models_dir`	`function`	Diretorio temporario para checkpoints `.pt`
`coaching_service`	`function`	`CoachingService` configurado com DB de teste

Automated Suite (`tests/automated_suite/`):

Categoria	Arquivo	Cobertura
Smoke	`test_smoke_*.py`	Imports criticos, instanciacao modelos, DB connection
Unit	`test_unit_*.py`	Funcoes puras, calculos, transformacoes
Functional	`test_functional_*.py`	Pipelines completas, fluxos de trabalho
E2E	`test_e2e_*.py`	Demo upload → parsing → coaching → insight
Regression	`test_regression_*.py`	Bug fixes especificos (G-01 label leakage, G-07 Bayesian, etc.)

Testes por subsistema:

Subsistema	Arquivos de teste	O que testam
NN Core	`test_jepa_model.py`, `test_rap_model.py`, `test_advanced_nn.py`	Forward pass, dimensoes tensor, gradient flow
Coaching	`test_coaching_service.py`, `test_hybrid_engine.py`, `test_correction_engine.py`	Pipeline coaching, priorizacao insights, fallback chain
Processing	`test_vectorizer.py`, `test_heatmap.py`, `test_feature_eng.py`	Feature extraction, normalizacao, METADATA_DIM=25
Storage	`test_database.py`, `test_models.py`, `test_backup.py`	CRUD, schema, backup/restore, WAL mode
Data Sources	`test_demo_parser.py`, `test_hltv_scraper.py`, `test_steam_api.py`	Parsing, scraping, API timeout/retry
Analysis	`test_game_theory.py`, `test_belief.py`, `test_role_engine.py`	Motores analise, calibracao, heuristica
Knowledge	`test_rag.py`, `test_experience_bank.py`, `test_knowledge_graph.py`	Retrieval, COPER eficacia, KG query
Ingestion	`test_ingest_pipeline.py`, `test_registry.py`	Pipeline completa, deduplicacao

Forensics (`tests/forensics/`, 10 scripts):

Os scripts forensics sao instrumentos diagnosticos para investigacoes post-mortem:

Script	Proposito
`diagnose_training_failure.py`	Analisa logs de training para identificar divergencia, NaN, gradient explosion
`inspect_model_weights.py`	Distribuicao pesos, layer statistics, dead neurons
`replay_ingestion.py`	Re-executa ingestao de uma demo especifica com logging verboso
`trace_coaching_path.py`	Rastreia o caminho de um insight da demo ate a UI
`db_consistency_check.py`	Verifica coerencia entre os 3 bancos

> **Analogia Forensics:** Os scripts forensics sao como a **caixa preta de um aviao**. Apos um incidente (bug, crash, resultado inesperado), voce os usa para reconstruir exatamente o que aconteceu, passo a passo. Nao sao executados por rotina — apenas quando e necessario investigar um problema especifico.

Verification Scripts (15 arquivos na root `tests/`):

Scripts de verificacao one-shot para validar aspectos especificos do sistema:

Script	Verifica
`verify_feature_pipeline.py`	METADATA_DIM=25 respeitado em todos os paths
`verify_training_cycle.py`	4 fases training completam sem erro
`verify_db_schema.py`	21 tabelas presentes com schema correto
`verify_coaching_pipeline.py`	Demo → insight path end-to-end
`verify_imports.py`	Todos os modulos importaveis sem erros circulares
`verify_rag_index.py`	Knowledge base indexada com dimensoes corretas (384-dim)
`verify_pro_baseline.py`	Baselines pro carregadas e validas
`verify_hltv_sync.py`	HLTV sync service configurado corretamente

Estrategia de teste por criticidade:

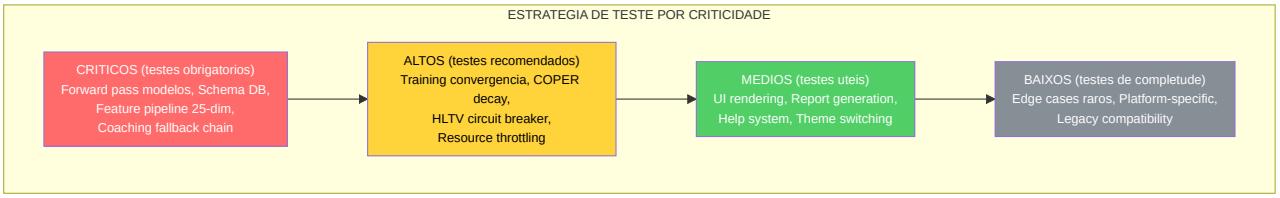

Gaps de cobertura identificados:

Os seguintes modulos tem alta complexidade (>500 LOC) mas cobertura de teste limitada:

Modulo	LOC	Cobertura teste	Risco
`training_orchestrator.py`	733	Baixa	ALTO — orquestracao multi-fase
`session_engine.py`	538	Media	MEDIO — testavel somente com subprocess
`coaching_service.py`	585	Media	MEDIO — 4 niveis fallback
`experience_bank.py`	751	Baixa	ALTO — logica COPER complexa
`tensor_factory.py`	686	Baixa	ALTO — DataLoader/Dataset
`coach_manager.py`	878	Baixa	ALTO — estado global training

12.19 As 12 Fases de Remediacao Sistematica

O projeto atravessou um processo de **remediacao em 12 fases** que resolveu no total **370+ problemas** identificados durante audits de qualidade progressivos. Cada fase se concentrou em uma categoria especifica de problemas, da correcao de bugs criticos a reestruturacao arquitetural.

> **Analogia:** As 12 fases de remediacao sao como a **restauracao progressiva de um edificio historico**. A Fase 1 consertou as **fundacoes** (bugs criticos que impediam o funcionamento). As fases intermediarias reforcaram os **muros portantes** (arquitetura, seguranca, dados). As fases finais completaram os **acabamentos** (logging, edge cases, documentacao). Cada fase produziu um relatorio detalhado na diretoria `reports/`.

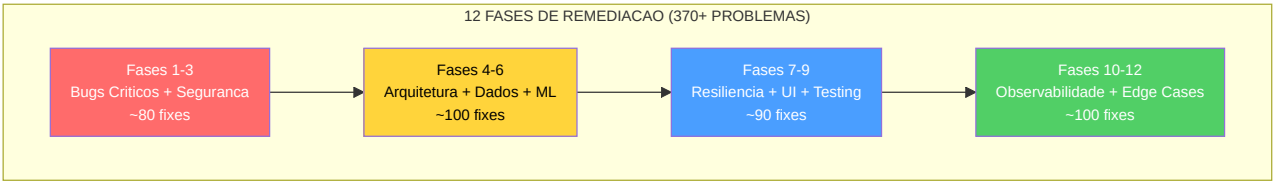

Detalhe por fase:

Fase	Foco	Problemas resolvidos	Exemplo chave
1	Import e estrutura base	~20	Circular imports, path resolution, missing `__init__.py`
2	Seguranca e secrets	~25	API keys hard-coded → env vars/keyring, input validation
3	Data pipeline e features	~30	G-01 label leakage, G-02 normalizacao bounds, feature alignment
4	Banco e schema	~30	WAL mode enforcement, missing indices, schema migration safety
5	Dead code e cleanup	~25	G-06 eliminacao `nn/advanced/`, imports nao usados, arquivos duplicados
6	Analysis engines	~30	Graceful degradation para todos os 10 motores, edge case handling
7	ML pipeline	~35	G-07 Bayesian calibration, gradient clipping, checkpoint versioning
8	Coaching e COPER	~30	G-08 experience decay, RAG index validation, fallback chain
9	UI e UX	~25	F8-XX feedback visual, state consistency, error prevention
10	Resiliencia e concorrencia	~40	F5-35 threading.Event, timeout enforcement, circuit breaker
11	Observabilidade e logging	~35	F5-33 structured logging, correlation IDs, Sentry integration
12	Deep debug e wiring	~45	18 issues: wiring verification, integration testing, edge case audit

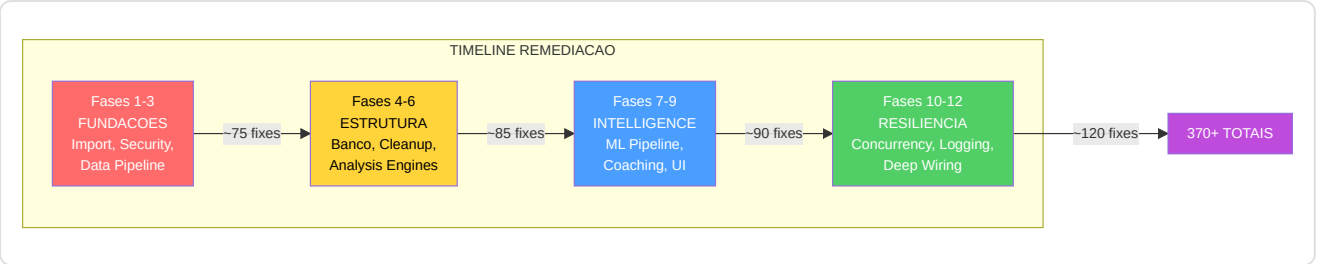

Diretorio `reports/`:

Cada fase de remediacao produziu um relatorio detalhado salvo na diretoria `reports/`. Cada relatorio inclui:

- Lista numerada dos problemas encontrados com codigo (G-XX ou F-XX)
- Descricao do problema com arquivo e linhas afetadas
- Solucao implementada com diff conceitual
- Verificacao: confirma que o fix nao introduziu regressoes

Correcoes chave por codigo (G-XX):

Codigo	Fase	Descricao	Impacto
G-01	3	Label leakage em `ConceptLabeler.label_tick()` — features futuras vazadas nas labels de training	CRITICO — invalidava o treinamento VL-JEPA
G-02	4	Danger zone em `vectorizer.py` — normalizacao sem bounds check	ALTO — NaN propagation em training
G-06	5	Dead code em `backend/nn/advanced/` — 3 arquivos nao referenciados	MEDIO — confusao e imports acidentais
G-07	7	Bayesian death estimator nao calibrado — modelo estatico sem auto-calibration	ALTO — predicoes imprecisas
G-08	8	COPER experience bank sem decay — experiencias obsoletas nunca removidas	MEDIO — coaching baseado em dados envelhecidos

Correcoes por feature (F-XX):

Codigo	Area	Descricao
F3-29	Processing	ResNet resize inconsistente — dimensoes imagem nao normalizadas
F5-19	Services	Matplotlib rendering sem error handling — crash em stats vazias
F5-21	Storage	`session.commit()` explicito dentro de context manager — commit duplo
F5-22	Security	API keys hard-coded em source — migrate para env vars + keyring
F5-33	Observability	`print()` debugging — migrado para structured logging
F5-35	Control	`time.sleep()` loop para stop — migrado para `threading.Event`
F6-XX	Analysis	Motores analise sem graceful degradation — crash em inputs incompletos
F7-XX	Knowledge	RAG sem index validation — embedding dimensoes incoerentes
F8-XX	UI	Widgets Kivy sem feedback visual — acoes silenciosas confundem o usuario

---

12.20 Pre-commit Hooks e Quality Gates

Arquivo: `.pre-commit-config.yaml`

O projeto utiliza um sistema de **pre-commit hooks** que se ativam automaticamente antes de cada commit, impedindo que codigo nao conforme chegue ao repositorio.

> **Analogia:** Os pre-commit hooks sao como os **detectores de metal na entrada de um aeroporto**. Antes que qualquer bagagem (codigo) embarque no aviao (repositorio), deve passar por uma serie de verificacoes automaticas. Se uma verificacao falha, a bagagem e rejeitada e o passageiro (desenvolvedor) deve resolver o problema antes de tentar novamente.

4 Hooks Locais (custom do projeto):

Hook	Script	Timeout	Descricao
`headless-validator`	`tools/headless_validator.py`	20s	23 fases, 319 verificacoes regression gate — o mais importante
`dead-code-detector`	`tools/dead_code_detector.py`	15s	Identifica imports e funcoes nao referenciados
`integrity-manifest-check`	`tools/sync_integrity_manifest.py`	10s	Verifica coerencia hash SHA-256 do manifesto
`dev-health-quick`	`tools/dev_health.py`	10s	Quick check saude projeto

Hooks Padrao (7 de `pre-commit/pre-commit-hooks` + 2 Python):

Hook	Fonte	Descricao
`trailing-whitespace`	`pre-commit/pre-commit-hooks`	Remocao espacos em branco finais
`end-of-file-fixer`	`pre-commit/pre-commit-hooks`	Newline final obrigatorio
`check-yaml`	`pre-commit/pre-commit-hooks`	Validacao sintaxe YAML
`check-json`	`pre-commit/pre-commit-hooks`	Validacao sintaxe JSON
`check-added-large-files`	`pre-commit/pre-commit-hooks`	Bloqueia arquivos >1MB (previne `.pt` acidentais)
`check-merge-conflict`	`pre-commit/pre-commit-hooks`	Detecta marcadores de merge conflict nao resolvidos
`detect-private-key`	`pre-commit/pre-commit-hooks`	Bloqueia commit de chaves privadas
`black`	`psf/black`	Formatacao automatica Python (line length 100, target py3.12)
`isort`	`pycqa/isort`	Ordenacao automatica imports (profile black, line length 100)

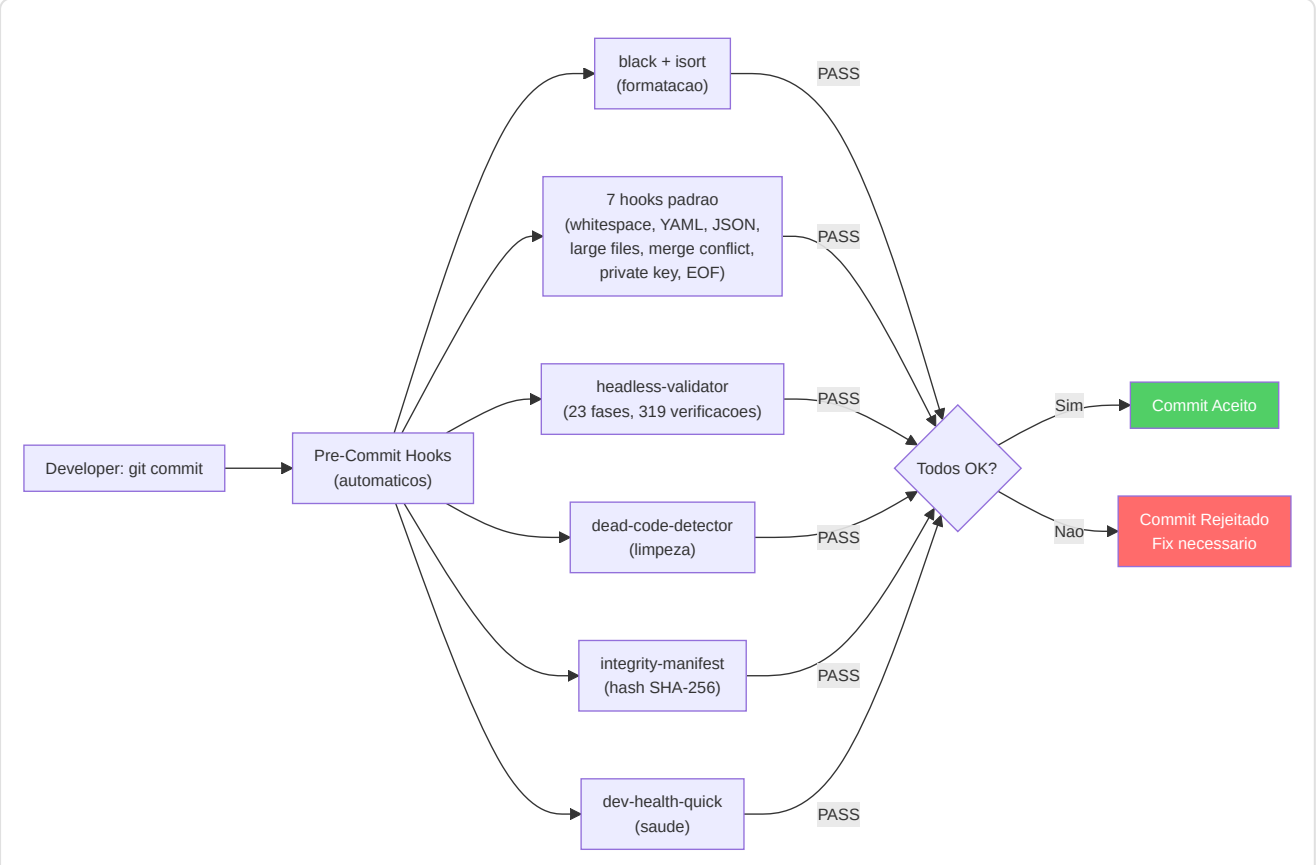

12.21 Build, Packaging e Deployment

Arquivos chave: `packaging/windows_installer.iss`, `setup_new_pc.bat`, `export_env.bat`

O projeto inclui um sistema de build e packaging para a distribuicao da aplicacao desktop em Windows.

> **Analogia:** O sistema de build e como uma **linha de montagem automobilistica**. O processo de build pega todos os componentes (fontes Python, modelos ML, assets UI) e os monta em um unico pacote executavel. `windows_installer.iss` (Inno Setup) e a **carroceria**: envolve o pacote em um installer profissional com wizard de instalacao, icones e atalho no desktop. Os 3 arquivos requirements sao as **listas de materiais**: especificam exatamente quais pecas sao necessarias para cada tipo de montagem.

3 Arquivos Requirements:

Arquivo	Proposito	Dependencias
`requirements.txt`	**Base** — dependencias principais para execucao	28 pacotes (torch, kivy, sqlmodel, demoparser2, playwright, httpx, etc.)
`requirements-ci.txt`	**CI/CD** — adiciona ferramentas de teste e analise	pytest, coverage, mypy, black, isort, pre-commit
`requirements-lock.txt`	**Lock** — versoes exatas para builds reproduciveis	Pin exato de cada dependencia e sub-dependencia

Packaging Windows (`packaging/windows_installer.iss`):

- Installer Inno Setup com wizard grafico
- Icone personalizado CS2 Analyzer
- Atalho no desktop e no menu Start
- Tamanho estimado: ~500MB (inclui PyTorch e modelos)
- Target: Windows 10/11 64-bit

Scripts de Setup:

Script	Proposito
`setup_new_pc.bat`	Configuracao de ambiente do zero: Python, pip, venv, dependencias
`export_env.bat`	Exportacao de variaveis de ambiente necessarias
`run_full_training_cycle.py`	Orquestracao ciclo completo de treinamento ML

12.22 Sistema de Migracoes Alembic

Diretorio: `alembic/` (root) + `Programma_CS2_RENAN/backend/storage/migrations/`

O projeto utiliza **dois setups Alembic separados** para gerenciar as migracoes do schema do banco de forma organizada.

> **Analogia:** Os dois setups Alembic sao como dois **cadernos de trabalho** para um arquiteto. O caderno principal (`alembic/` root) contem o **plano de construcao completo**: 13 revisoes que documentam cada modificacao estrutural desde o inicio do projeto. O caderno secundario (`backend/storage/migrations/`) contem as **anotacoes de obra**: 2 revisoes mais especificas para modificacoes na storage layer. Cada revisao e numerada, datada e reversivel — como as versoes de um documento legal.

Alembic Root (`alembic/` , 13 versoes):

Contem as migracoes principais do schema, desde a criacao inicial das tabelas ate as modificacoes mais recentes. Cada migracao:

- Tem um hash unico como identificador
- Contem `upgrade()` (aplica modificacao) e `downgrade()` (desfaz modificacao)
- E idempotente — pode ser reaplicada sem erros
- E testada em schema production-like antes do deploy

Backend Migrations (`backend/storage/migrations/` , 2 versoes):

Migracoes especificas para a storage layer, separadas por modularidade. Gerenciam modificacoes em tabelas que sao responsabilidade exclusiva do modulo `backend/storage/` .

Execucao automatica: As migracoes sao executadas automaticamente durante a fase 3 da sequencia de inicializacao (`main.py`), garantindo que o schema esteja sempre atualizado antes de qualquer operacao DB.

12.23 Orquestrador de Ingestao Principal (`run_ingestion.py`)

Arquivo: `Programma_CS2_RENAN/run_ingestion.py`

O `run_ingestion.py` e o **coracao orquestrador** da pipeline de ingestao inteira. E o arquivo maior dedicado a ingestao e coordena todas as fases da descoberta das demos a persistencia dos resultados no banco.

> **Analogia:** Se a pipeline de ingestao (secao 12.6) e o caminho de uma carta atraves do correio, `run_ingestion.py` e o **diretor do correio** em pessoa. Nao tria ele mesmo as cartas — delega aos carteiros (DemoLoader), aos arquivistas (FeatureExtractor) e aos medicos (CoachingService) — mas coordena o fluxo geral, decide as prioridades, gerencia os erros e mantem o registro de tudo.

12+ funcoes principais:

Funcao	Papel
`discover_demos()`	Escaneia diretorias configuradas, filtra arquivos `.dem` validos
`validate_demo_file()`	Controla magic bytes, tamanho, integridade pre-parsing
`process_single_demo()`	Pipeline completa para uma demo: parse → extract → enrich → persist
`batch_process()`	Processa varias demos em sequencia com progress tracking
`enrich_round_stats()`	Pos-processamento: calcula trade kills, blind kills, flash assists
`compute_hltv_rating()`	Calcula HLTV 2.0 rating para cada jogador
`assign_dataset_split()`	Atribui 70% train / 15% val / 15% test com split temporal
`generate_coaching_insights()`	Invoca CoachingService para gerar 5-20 insights
`update_ingestion_task()`	Atualiza estado task no DB (queued → processing → completed/failed)
`cleanup_failed_tasks()`	Limpa tasks falhados, reseta para queued se recuperavel
`report_progress()`	Logging estruturado do progresso geral
`handle_duplicate_detection()`	Verifica via Registry se a demo ja foi processada

ResourceManager (`ingestion/resource_manager.py`):

O ResourceManager gerencia os **recursos de hardware** durante a ingestao para evitar a sobrecarga do sistema:

Parametro	Valor Default	Proposito
CPU threshold	80%	Pausa ingestao se CPU supera esse limite
RAM threshold	85%	Pausa ingestao se RAM supera esse limite
Disk check	Sim	Verifica espaco disco suficiente antes do processing
Throttle delay	2s	Delay entre tasks consecutivos para resfriamento

> **Analogia:** O ResourceManager e como o **termostato de um forno industrial**. Se a temperatura (CPU/RAM) sobe demais, desacelera automaticamente a producao (ingestao) para evitar superaquecimento. Quando a temperatura desce, retoma em regime pleno. Nao pede permissao ao operador — age autonomamente para proteger o sistema.

12.24 HLTV Sync Service e Background Daemon

Arquivo: `Programma_CS2_RENAN/hltv_sync_service.py` **Arquivos relacionados:** `backend/data_sources/hltv/` , `backend/services/telemetry_client.py`

O HLTV Sync Service e um **daemon em background** que sincroniza automaticamente os dados dos jogadores profissionais de HLTV.org. Opera como um servico monitorado pelo `ServiceSupervisor` da Console.

> **Analogia:** O HLTV Sync Service e como um **correspondente esportivo** que vive perto do estadio (HLTV.org). A cada hora verifica os resultados das partidas, baixa as estatisticas dos jogadores e as envia a redacao (o banco). Se o estadio fecha (HLTV down), o correspondente entra em "modo dormente" por 6 horas antes de tentar novamente. Se e expulso do estadio muitas vezes (rate limit), o Circuit Breaker o para por uma hora para evitar o ban permanente.

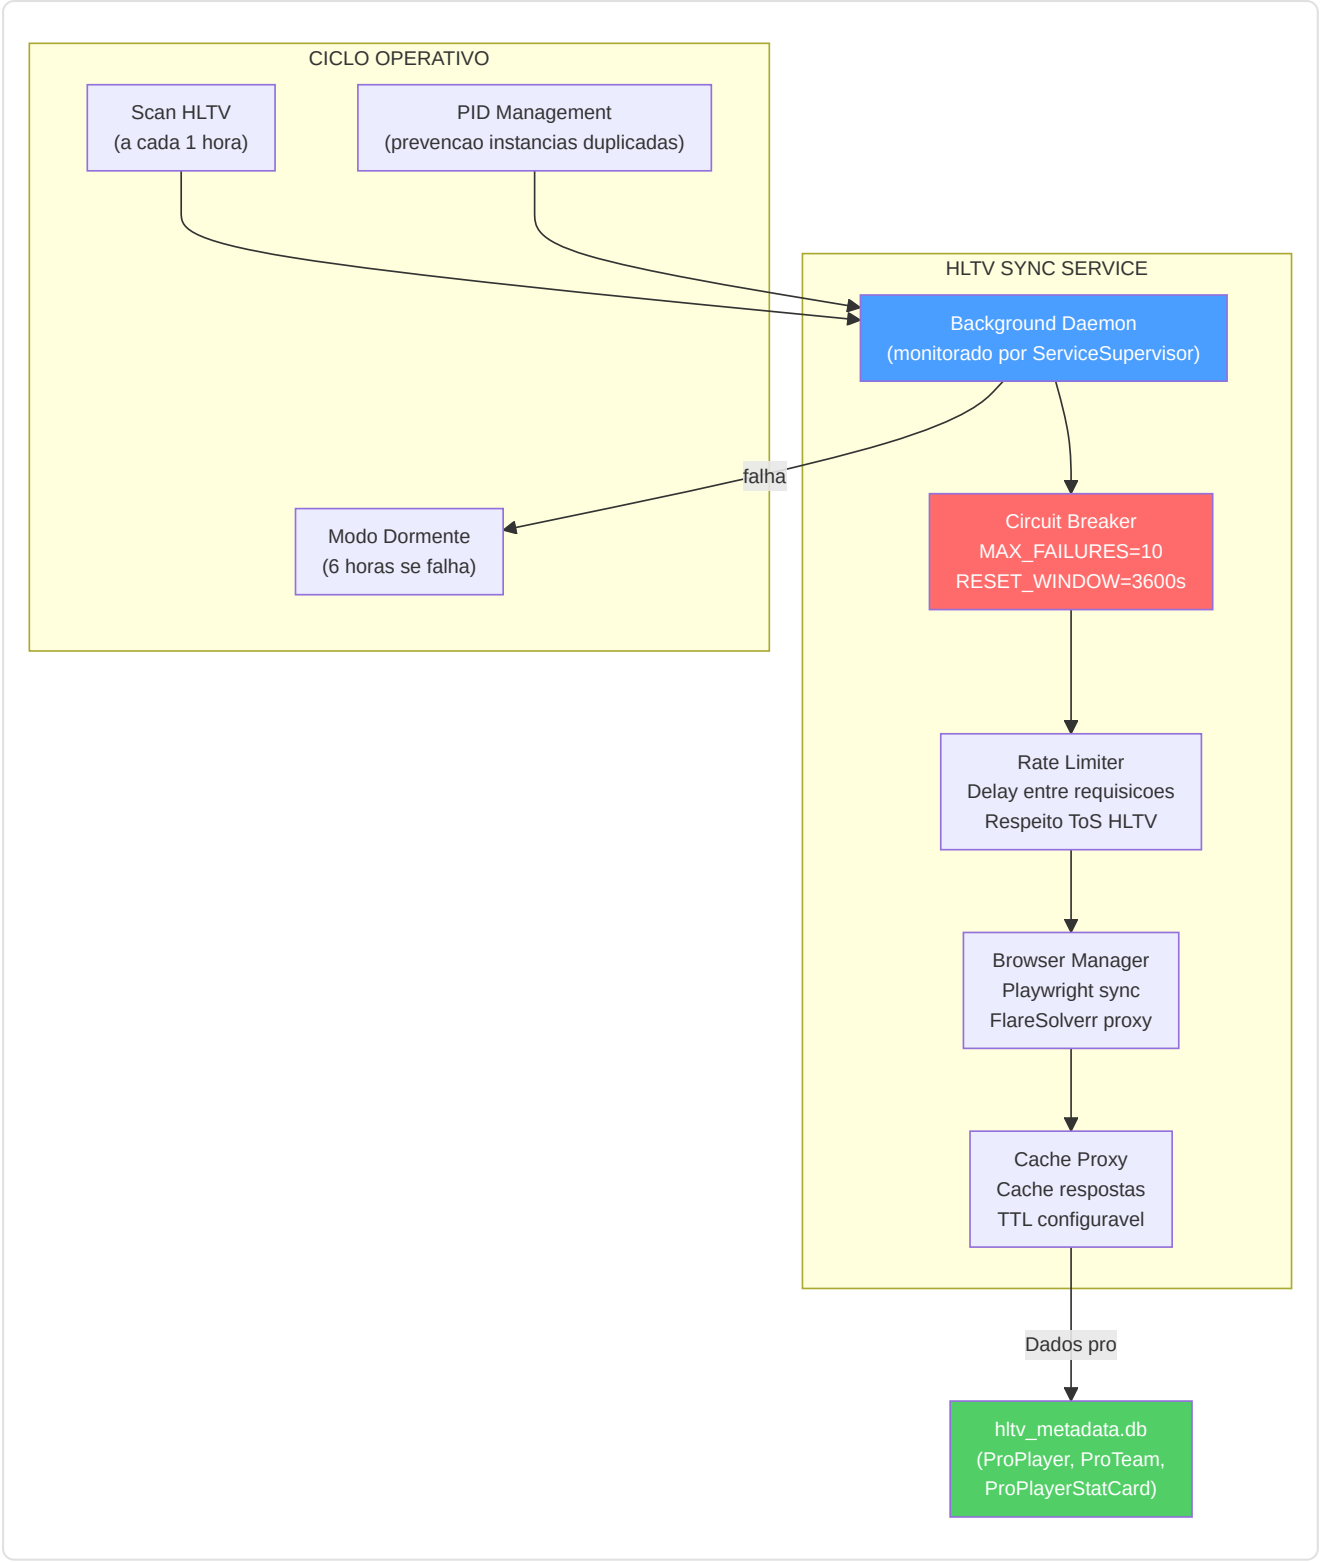
CICLO OPERATIVO
Scan HLTV
(a cada 1 hora)
PID Management
(prevencao instancias duplicadas)
HLTV SYNC SERVICE
Background Daemon
(monitorado por ServiceSupervisor)
falha
Modo Dormente
(6 horas se falha)
Circuit Breaker
MAX_FAILURES=10
RESET_WINDOW=3600s
Rate Limiter
Delay entre requisicoes
Respeito ToS HLTV
Browser Manager
Playwright sync
FlareSolverr proxy
Cache Proxy
Cache respostas
TTL configuravel
Dados pro
hltv_metadata.db
(ProPlayer, ProTeam,
ProPlayerStatCard)

Componente	Arquivo	Papel
CircuitBreaker	`circuit_breaker.py`	Protege de cascade failure: CLOSED→OPEN (apos 10 fails)→HALF_OPEN (test)→CLOSED
BrowserManager	`browser_manager.py`	Gestao browser Playwright headless com FlareSolverr para Cloudflare bypass
CacheProxy	`cache_proxy.py`	Cache local das respostas HLTV para reduzir requisicoes
RateLimiter	`rate_limiter.py`	Delay configuravel entre requisicoes para respeitar os ToS

Arquitetura HLTV Interna — Collectors e Selectors:

A arvore `ingestion/hltv/` tambem contem modulos especializados para a coleta de dados:

Modulo	Tipo	Descricao
`player_collector.py`	Collector	Coleta perfis de jogadores pro de paginas HLTV
`team_collector.py`	Collector	Coleta roster e estatisticas times
`match_collector.py`	Collector	Coleta resultados partidas e links demo
`stat_selector.py`	Selector	Extrai estatisticas especificas das paginas HTML parseadas
`demo_selector.py`	Selector	Identifica e baixa links demo das paginas match

Ciclo operativo detalhado:

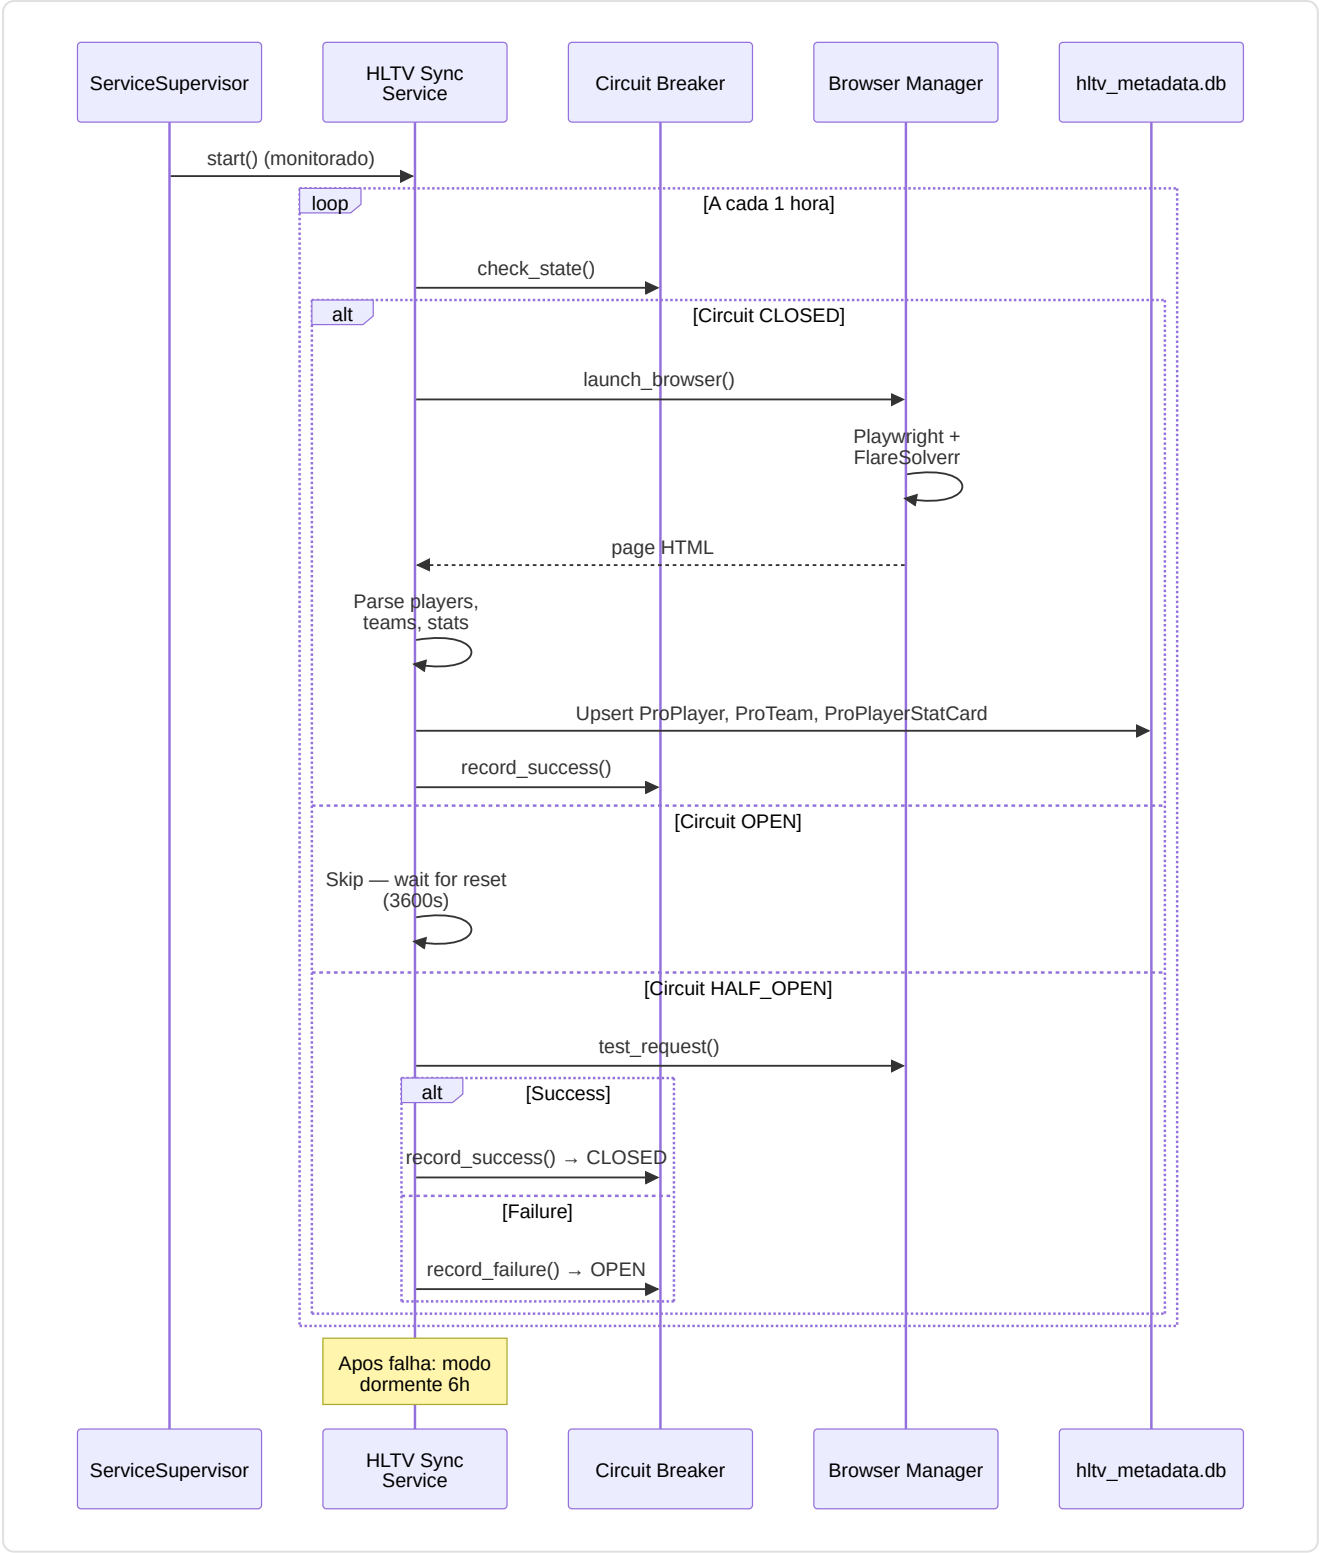
ServiceSupervisor
HLTV Sync Service
Circuit Breaker
Browser Manager
hltv_metadata.db
start() (monitorado)
loop
[A cada 1 hora]
check_state()
alt
[Circuit CLOSED]
launch_browser()
Playwright + FlareSolverr
page HTML
Parse players, teams, stats
Upsert ProPlayer, ProTeam, ProPlayerStatCard
record_success()
[Circuit OPEN]
Skip — wait for reset (3600s)
[Circuit HALF_OPEN]
test_request()
alt
[Success]
record_success() → CLOSED
[Failure]
record_failure() → OPEN
Apos falha: modo dormente 6h
ServiceSupervisor
HLTV Sync Service
Circuit Breaker
Browser Manager
hltv_metadata.db

> **Analogia do Circuit Breaker HLTV:** O Circuit Breaker e como um **fusivel eletrico inteligente**. Quando o circuito esta CLOSED (normal), a corrente flui livremente (as requisicoes HLTV funcionam). Se ha curtos-circuitos demais (10 falhas consecutivas), o fusivel queima → OPEN (todas as requisicoes bloqueadas por 1 hora). Apos o periodo de cooldown, o fusivel passa para HALF_OPEN: deixa passar uma unica requisicao de teste. Se o teste tem sucesso, o fusivel se fecha novamente (CLOSED). Se falha, reabre (OPEN) por mais uma hora. Esse mecanismo previne o "martelamento" de um server down, o que levaria a ban de IP ou blacklisting.

12.25 RASP Guard — Integridade Runtime do Codigo

Arquivo: `Programma_CS2_RENAN/observability/rasp.py` **Arquivo de dados:** `data/integrity_manifest.json`

O RASP (Runtime Application Self-Protection) Guard e a **primeira verificacao** executada na inicializacao da aplicacao (Fase 1 da sequencia de boot). Verifica que nenhum arquivo fonte tenha sido modificado em relacao ao manifesto de integridade.

> **Analogia:** O RASP Guard e como um **sistema anti-furto com sensores em cada porta e janela**. Ao acionar o alarme (inicializacao da app), o sistema controla que cada porta (arquivo Python) esteja na mesma posicao em que foi deixada (hash SHA-256). Se alguem forcou uma janela (modificou um arquivo), o alarme toca imediatamente e o edificio vai para lockdown (`IntegrityError` → terminacao). Isso protege contra manipulacoes acidentais (atualizacoes corrompidas) e intencionais (ataques supply chain).

Componentes do RASP Guard:

Componente	Descricao
`RASPGuard`	Classe principal — carrega o manifesto, verifica hash, levanta excecao
`integrity_manifest.json`	Arquivo JSON com hash SHA-256 de cada arquivo fonte critico
`IntegrityError`	Excecao custom — terminacao imediata com log detalhado
`sync_integrity_manifest.py`	Ferramenta para atualizar o manifesto apos modificacoes legitimas

Fluxo de verificacao:

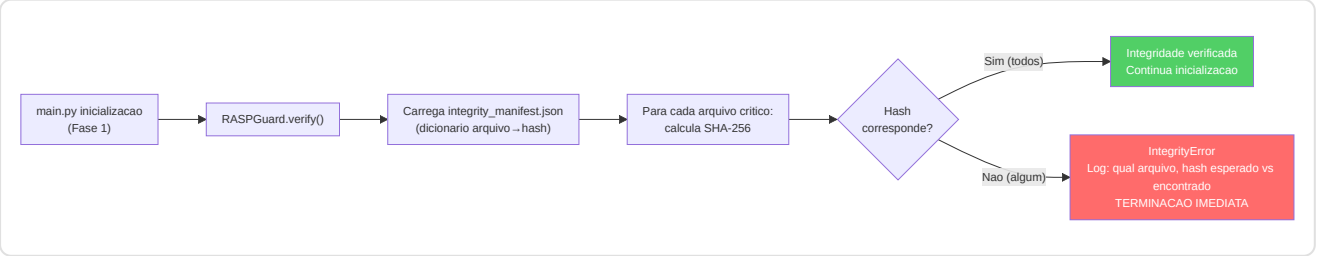

12.26 MatchVisualizer — Rendering Avancado

Arquivo: `Programma_CS2_RENAN/reporting/visualizer.py`

O `MatchVisualizer` estende o sistema de reporting (secao 12.13) com **6 metodos de rendering** especializados para a geracao de graficos e visualizacoes.

> **Analogia:** O MatchVisualizer e como um **ilustrador profissional** que transforma dados numericos aridos em ilustracoes compreensiveis a primeira vista. Cada metodo e uma tecnica diferente: o radar chart e um **retrato em aranha** das habilidades, a heatmap diferencial e um **mapa do calor** que mostra onde voce esta demais e onde pouco, os momentos criticos sao **baloes de quadrinho** que destacam as cenas-chave da partida.

6 Metodos de rendering:

Metodo	Output	Descricao
`render_skill_radar()`	Radar chart PNG	Pentagono de 5 eixos (Mecanica, Posicionamento, Utility, Timing, Decisao) com overlay pro
`render_trend_chart()`	Line chart PNG	Tendencia historica de metricas-chave (KPR, ADR, KAST) em N partidas
`render_heatmap()`	Heatmap PNG	Ocupacao gaussiana 2D no mapa tatico
`render_differential_heatmap()`	Heatmap diff PNG	Subtracao user-pro: vermelho=demais, azul=pouco, verde=otimo
`render_critical_moments()`	Annotated timeline PNG	Timeline com marcadores coloridos para momentos-chave (kills, deaths, plantagens)
`render_comparison_table()`	Table PNG/HTML	Tabela comparacao user vs pro com delta percentual para cada metrica

Heatmap diferencial — algoritmo:

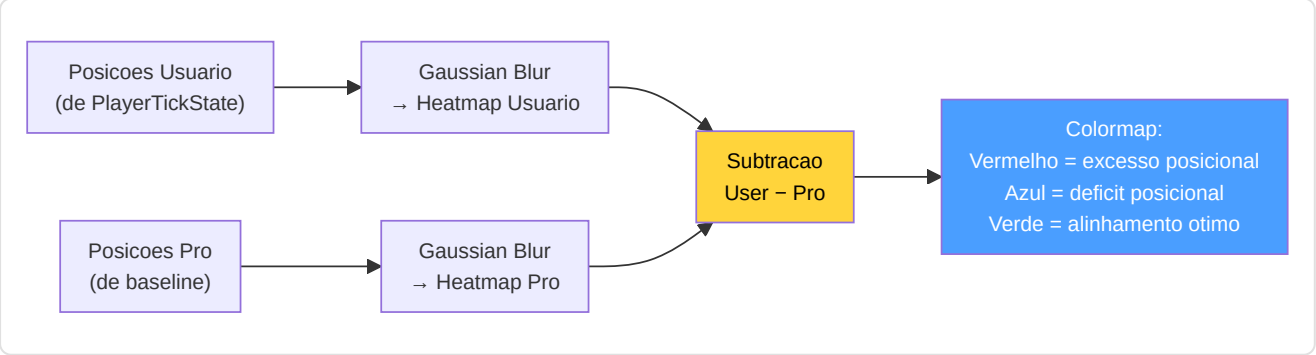

12.27 Arquivos de Dados e Configuracao Runtime

O projeto inclui varios arquivos de dados que sao lidos ou escritos durante a execucao. Esses arquivos nao sao codigo Python mas sao essenciais para o funcionamento do sistema.

`data/map_config.json` — Configuracao dos mapas CS2:

Contem os parametros de transformacao de coordenadas para cada mapa suportado (Dust2, Mirage, Inferno, Nuke, Vertigo, Overpass, Ancient, Anubis):

```
{
  "de_dust2": {
    "pos_x": -2476, "pos_y": 3239, "scale": 4.4,
    "z_cutoff": null, "level": "single"
  },
  "de_nuke": {
    "pos_x": -3453, "pos_y": 2887, "scale": 7.0,
    "z_cutoff": -495, "level": "multi"
  }
}
```

> **Analogia:** `map_config.json` e como um **atlas com as projecoes cartograficas**. Cada mapa tem sua projecao unica: ponto de origem, escala e, para os mapas multi-nivel, a altitude que separa os andares. Sem esse arquivo, o Tactical Viewer nao saberia onde posicionar os jogadores no mapa 2D.

`data/integrity_manifest.json` — Manifesto de integridade RASP:

Dicionario `{caminho_arquivo: hash_sha256}` para todos os arquivos Python criticos. Gerado/atualizado por `tools/sync_integrity_manifest.py`. Verificado na inicializacao por `RASPGuard` (secao 12.25).

`data/training_progress.json` — Progresso de treinamento:

Persiste o estado do training entre reinicios: epoca atual, melhor loss, learning rate, ultima demo processada. Consultado pelo Teacher daemon para retomar o training do ponto exato em que parou.

`user_settings.json` — Configuracoes do usuario:

Arquivo de configuracao nivel 2 (cf. secao 12.3). Salvo na diretoria do projeto, contem preferencias personalizaveis: paths demo, tema UI, idioma, flags funcionalidade.

12.28 Entry Point Root-Level

Alem de `main.py`, o projeto inclui varios **scripts executaveis** em nivel root que servem como pontos de entrada alternativos para operacoes especificas:

Script	Linhas	Proposito	Invocacao
`console.py`	~61KB	Console interativo TUI completo com Rich — registro de comandos, modo CLI e interativo, gestao completa do sistema	`python console.py`
`run_ingestion.py`	1.057	Orquestrador ingestao standalone (cf. 12.23) — processamento batch demo	`python run_ingestion.py [path]`
`goliath.py`	~200	Launcher para Goliath Hospital diagnostics (cf. 12.17)	`python goliath.py`
`schema.py`	~100	Geracao e visualizacao do schema DB atual	`python schema.py`
`run_full_training_cycle.py`	~150	Treinamento completo de 4 fases (JEPA→Pro→User→RAP) standalone	`python run_full_training_cycle.py`
`hflayers.py`	~50	Utilidade para Hopfield layers (NCPs integration)	Import only

Console interativo (`console.py` , ~61KB):

O console e o **ponto de entrada mais potente** para operadores experientes. Oferece uma TUI (Terminal User Interface) baseada em Rich com:

- **Registro de comandos**: Sistema registrado de comandos com autocompletamento
- **Modo CLI**: Execucao single-shot de comandos (`console.py status` , `console.py train`)
- **Modo Interativo**: Shell REPL com prompt personalizado e historico de comandos
- **Paineis Rich**: Dashboard com tabelas coloridas, progress bar, tree view do estado

> **Analogia:** O console e como o **terminal de um administrador de sistema Linux**. Enquanto a interface grafica (Kivy) e o desktop user-friendly para o usuario final, o console e o terminal SSH para o operador experiente que quer controlar tudo manualmente: iniciar/parar servicos, inspecionar o banco, lancar treinamento, executar diagnosticos.

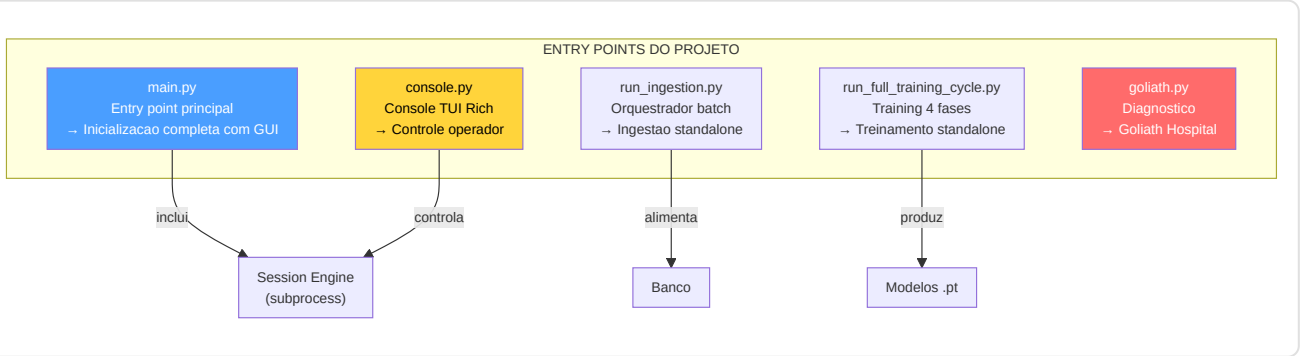

Resumo Arquitetural

Macena CS2 Analyzer e uma aplicacao **estratificada e modular** organizada em 5 niveis arquiteturais com 3 processos separados.

> **Analogia:** A arquitetura e como um **bolo de 5 camadas**, onde cada camada tem um papel preciso e se comunica apenas com as camadas imediatamente adjacentes. A camada superior (Apresentacao) e a cobertura: o que o usuario ve e toca. A camada seguinte (Aplicacao) e o recheio: combina ingredientes de varias fontes. A camada central (Dominio) e o pao-de-lo: a substancia real do sistema. A camada inferior (Persistencia) e o prato: sustenta tudo e nunca muda de forma. A camada base (Infraestrutura) e a mesa: o fundamento silencioso sobre o qual tudo se apoia.

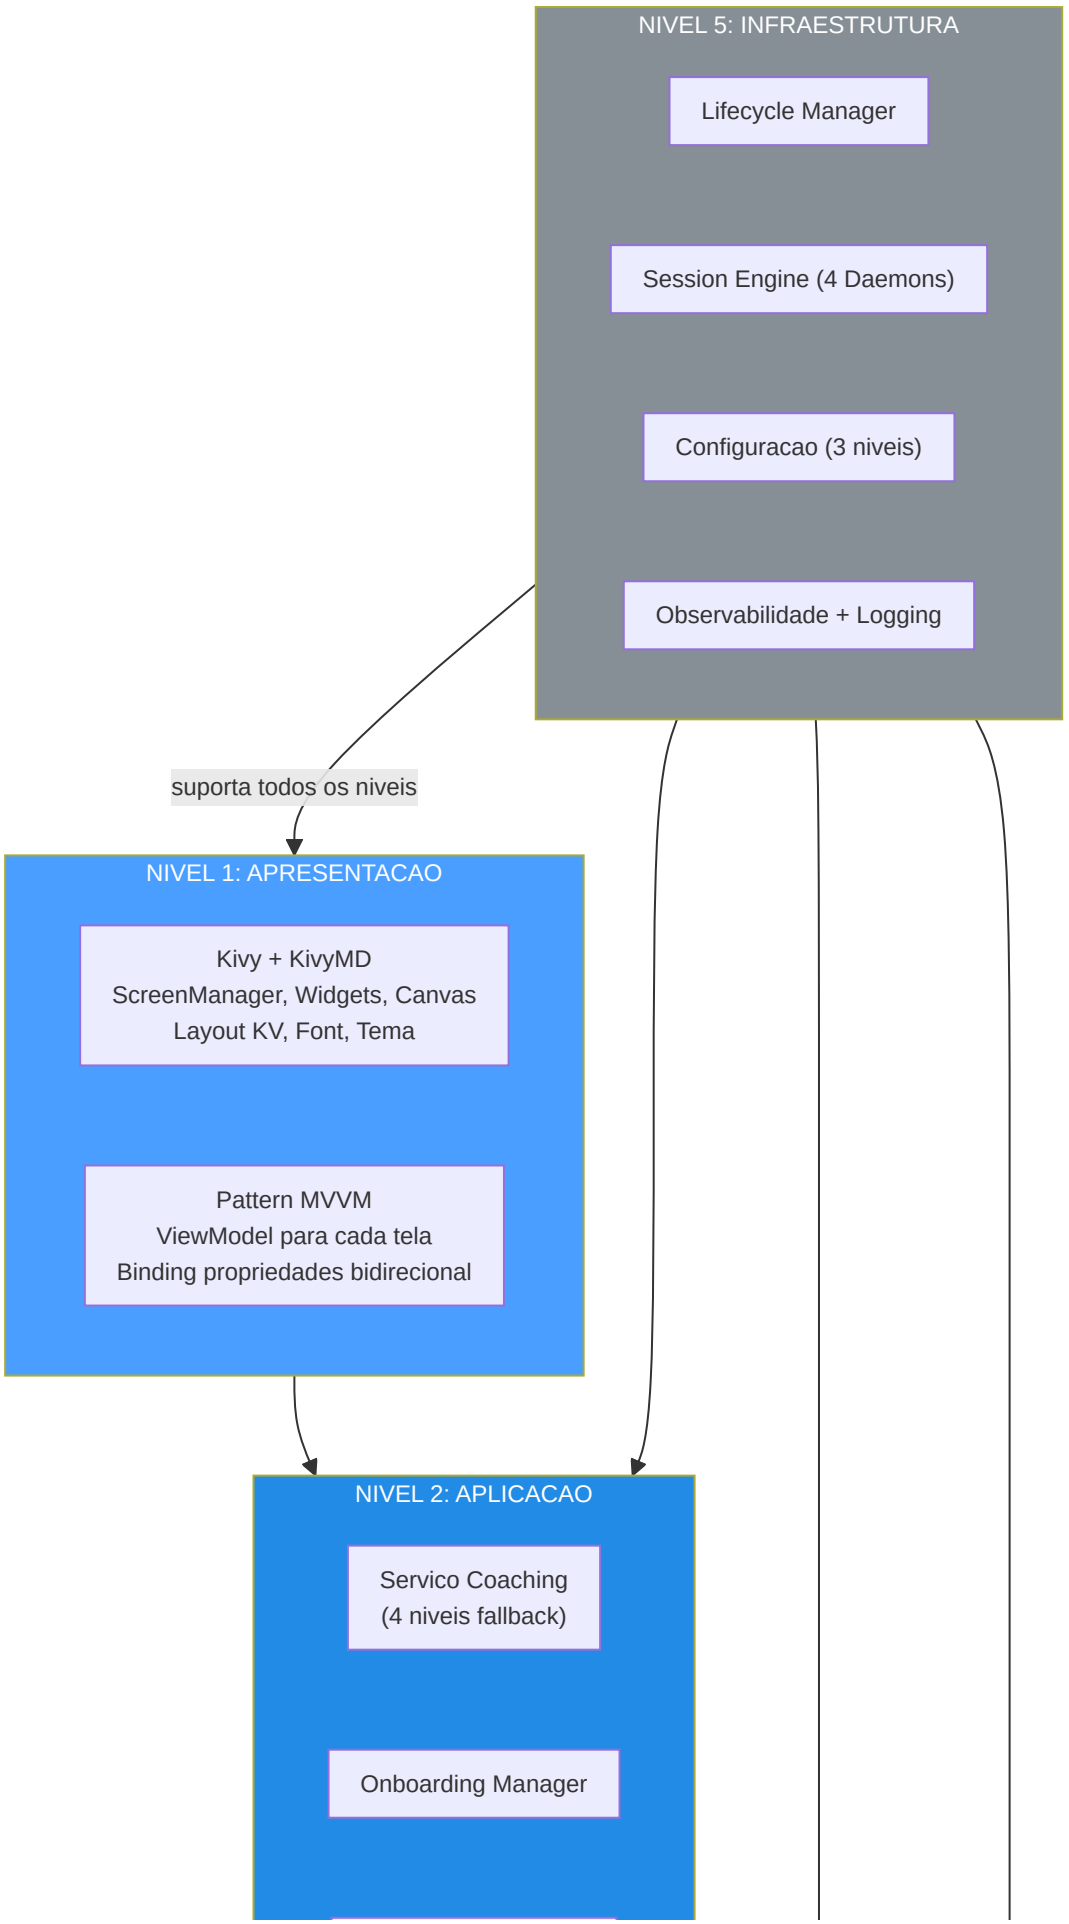
NIVEL 5: INFRAESTRUTURA
Lifecycle Manager
Session Engine (4 Daemons)
Configuracao (3 niveis)
Observabilidade + Logging
suporta todos os niveis
NIVEL 1: APRESENTACAO
Kivy + KivyMD
ScreenManager, Widgets, Canvas
Layout KV, Font, Tema
Pattern MVVM
ViewModel para cada tela
Binding propriedades bidirecional
NIVEL 2: APLICACAO
Servico Coaching
(4 niveis fallback)
Onboarding Manager

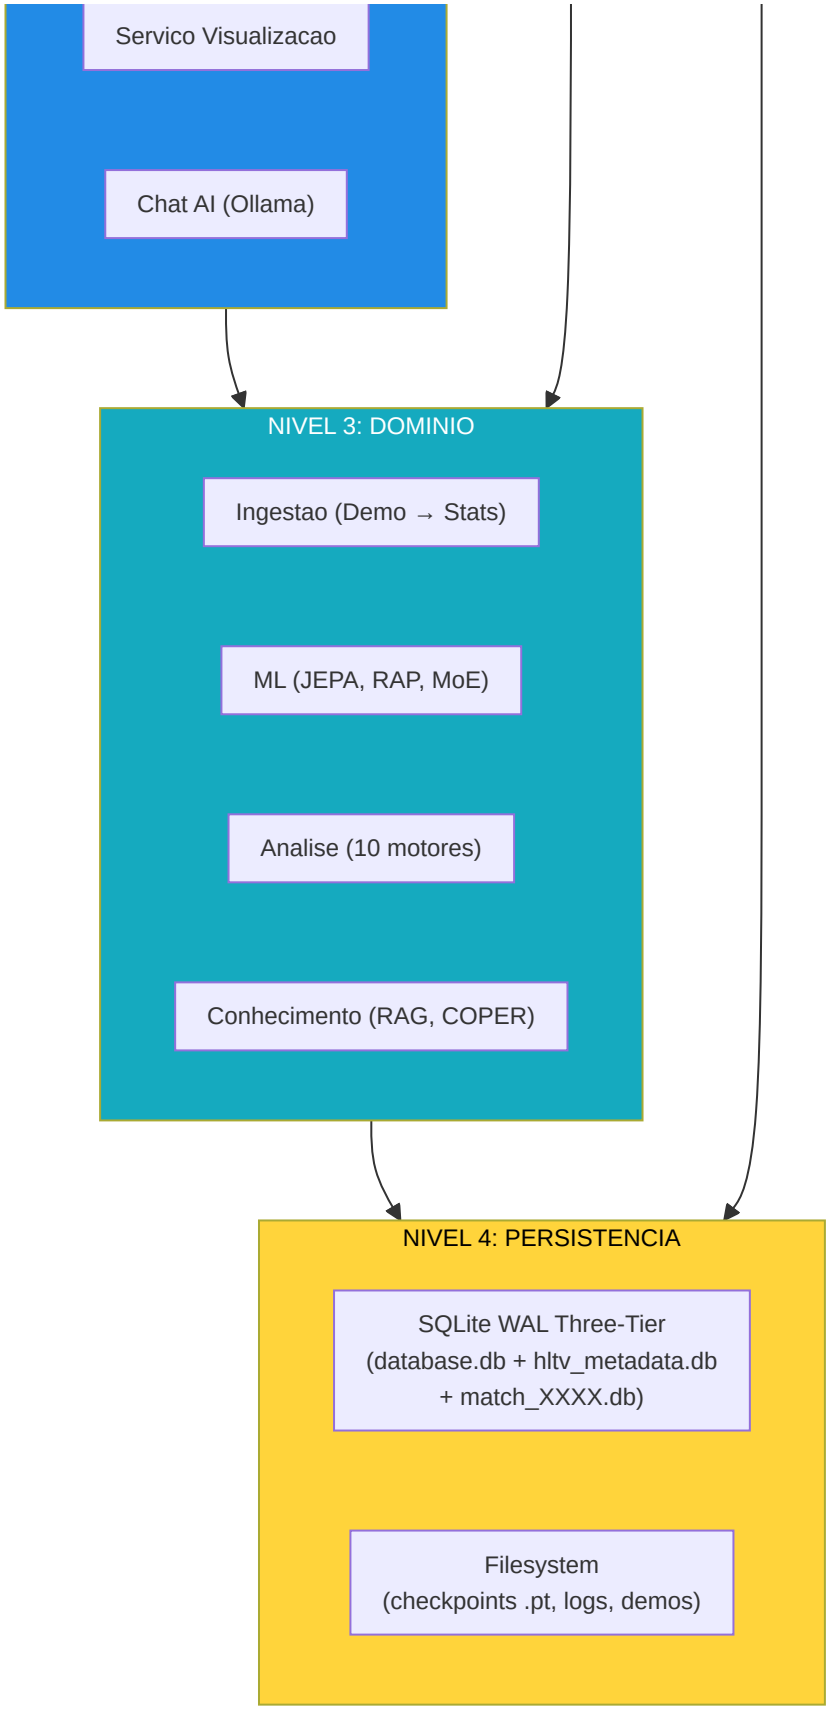

Stack tecnologico completo (28 dependencias):

Categoria	Biblioteca	Versao	Papel no projeto
ML Core	PyTorch	2.x	Redes neurais (JEPA, RAP, MoE, NeuralRoleHead, WinProb)
ML Ext	ncps	latest	Liquid Time-Constant Networks (LTC) para memoria RAP
ML Ext	hflayers	latest	Hopfield layers para atencao associativa
UI	Kivy	2.x	Framework UI cross-platform
UI	KivyMD	1.x	Material Design widgets
DB	SQLModel	latest	ORM (Pydantic + SQLAlchemy)
DB	SQLAlchemy	2.x	Engine banco subjacente
DB	Alembic	1.x	Migracoes schema
HTTP	requests	2.x	API Steam/FACEIT (sincrono)
HTTP	httpx	latest	Telemetria (assincrono)
Scraping	playwright	latest	Browser headless para HLTV
Parsing	demoparser2	latest	Parser demo CS2 (Rust-based, rapido)
Data	pandas	2.x	Manipulacao dados tabelares
Data	numpy	1.x	Calculos numericos
Viz	matplotlib	3.x	Graficos e visualizacoes
NLP	sentence-transformers	latest	Embedding 384-dim para RAG
TUI	rich	latest	Console colorida, tabelas, progress bar
Logging	logging (stdlib)	—	Logging estruturado
Security	keyring	latest	Gestao segura de API keys
Monitoring	sentry-sdk	latest	Error tracking remoto (opcional)
Testing	pytest	latest	Framework test
Formatting	black	latest	Formatacao codigo
Import	isort	latest	Ordenacao imports
QA	pre-commit	latest	Hooks pre-commit
Crypto	hashlib (stdlib)	—	SHA-256 para RASP manifesto
Concurrency	threading (stdlib)	—	Daemon thread, MLControlContext
IPC	subprocess (stdlib)	—	Session Engine como subprocess
Config	json (stdlib)	—	user_settings.json, map_config.json

> **Analogia do Stack:** O stack tecnologico e como a **caixa de ferramentas de um artesao experiente**. PyTorch e o **torno CNC** — o instrumento de precisao mais caro e potente. Kivy e a **bancada de trabalho** — a superficie na qual tudo e montado. SQLModel e o **arquivario organizado** — onde todos os projetos sao guardados. Playwright e o **drone de reconhecimento** — vai coletar dados no campo (HLTV). Rich e a **tinta de acabamento** — torna tudo mais bonito e legivel. Cada ferramenta tem um papel preciso, e nenhuma e redundante.

Os 3 processos da aplicacao:

Processo	Tipo	Responsabilidades	Comunicacao
Main	Kivy GUI	Interface usuario, rendering, interacao	Polling DB a cada 10-15s
Daemon	Subprocess (Session Engine)	Scanner, Digester, Teacher, Pulse	stdin pipe (IPC) + DB compartilhado
Servicos Opcionais	Processos externos	HLTV sync, Ollama LLM local	HTTP/API + supervisao Console

Fluxos de dados principais:

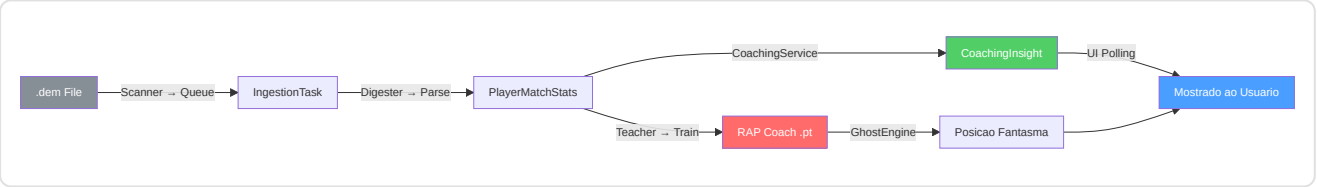

Nota sobre a Remediacao — Codigo Eliminado (G-06)

Durante o processo de remediacao em 12 fases (370+ problemas resolvidos no total — cf. secao 12.19), a diretoria `backend/nn/advanced/` foi **completamente eliminada** pois continha codigo morto nao referenciado:

- `superposition_net.py` — Uma rede de superposicao experimental nunca integrada ao fluxo de treinamento ou inferencia. A funcionalidade de superposicao ativa e implementada em `layers/superposition.py` (usada pela camada Estrategia RAP).
- `brain_bridge.py` — Uma ponte entre modelos experimental nunca chamada por nenhum modulo.
- `feature_engineering.py` — Feature engineering duplicada; a versao canonica reside em `backend/processing/feature_engineering/`.

> **Motivacao (G-06):** Manter codigo morto cria riscos de confusao (qual `superposition` e o verdadeiro?), aumenta a superficie de manutencao e pode introduzir imports acidentais. A eliminacao foi verificada via analise estatica das dependencias: nenhum arquivo do projeto importava de `backend/nn/advanced/`.

Utilidades Compartilhadas — `round_utils.py`

Arquivo: `Programma_CS2_RENAN/backend/knowledge/round_utils.py`

A funcao `infer_round_phase(equipment_value)` e uma **utilidade compartilhada** usada tanto pelo servico de coaching quanto pelo sistema de conhecimento para classificar a fase economica de um round. Reside em `backend/knowledge/` e e importada de modulos em `services/` e `processing/`.

Valor equipamento	Fase retornada
< $1.500	`"pistol"`
$1.500 – $2.999	`"eco"`
$3.000 – $3.999	`"force"`
>= $4.000	`"full_buy"`

> **Analogia:** `round_utils.py` e como um **dicionario compartilhado** consultado por varios departamentos. Em vez de cada escritorio definir suas proprias regras para classificar "eco" vs "force buy", todos consultam o mesmo dicionario, garantindo coerencia entre coaching, analise e knowledge base.

Pontos Fortes da Arquitetura

1. **Contrato de funcionalidade unificado a 25 dimensoes** — `METADATA_DIM = 25` impoe a paridade de treinamento/inferencia ao nivel de sistema.
2. **Gating de maturidade em 3 niveis** — Previne a implementacao prematura do modelo com dados insuficientes.
3. **Fallback de coaching em 4 niveis** — COPER → Hibrido → RAG → Base garante sempre a entrega de insights.
4. **Diversidade multi-modelo** — JEPA, VL-JEPA, LSTM+MoE, RAP e NeuralRoleHead contribuem com biases indutivos complementares.
5. **Subdivisao temporal** — Previne a perda de dados garantindo a ordenacao cronologica.
6. **Ciclo de feedback COPER** — Monitoramento da eficacia baseado em EMA com decaimento da experiencia obsoleta.
7. **Suite de analise de Fase 6** — 10 motores de analise (papel, probabilidade de vitoria, arvore de jogo, conviccao, engano, momentum, entropia, pontos cegos, utility e economia, distancia de

engajamento).

8. **Persistencia do limite** — Os limites de papel sobrevivem aos reinicios atraves da tabela DB `RoleThresholdRecord`.
9. **Heuristica configuravel** — `HeuristicConfig` externaliza os limites de normalizacao em JSON.
10. **Polishing LLM** — Integracao opcional com Ollama para narrativas de coaching em linguagem natural.
11. **Training Observatory** — Introspeccao em 4 niveis (Callback, TensorBoard, Maturity State Machine, Embedding Projector) com impacto zero quando desabilitada e callbacks isoladas dos erros.
12. **Neural Role Consensus** — Dupla classificacao heuristica + NeuralRoleHead MLP com protecao cold-start, que garante uma atribuicao de papeis confiavel mesmo com dados parciais.
13. **Per-Round Statistical Isolation** — O modelo `RoundStats` impede a contaminacao entre rounds, permitindo um coaching granular a nivel de round e avaliacoes HLTV 2.0 por round.
14. **Arquitetura Quad-Daemon** — Separacao completa entre GUI e trabalho pesado, com shutdown coordenado e zombie task cleanup automatico.
15. **Degradacao gradual pervasiva** — Cada componente tem um plano de fallback: o sistema nunca crasha, sempre degrada de forma controlada.
16. **Arquitetura Three-Tier Storage** — Separacao de `database.db` (core + conhecimento, 18 tabelas), `hltv_metadata.db` (dados pro, 3 tabelas) e `match_data/{id}.db` (telemetria por-match) para eliminar a contencao WAL e prevenir o crescimento descontrolado do monolite.
17. **Calibracao Bayesiana Live (G-07)** — O estimador de death se auto-calibra com `extract_death_events_from_db()` → `auto_calibrate()`, transformando-se de modelo estatico em sistema adaptativo.
18. **Controle Live Treinamento (MLControlContext)** — Pause/resume/stop/throttle em tempo real do training via `threading.Event`, com excecao custom `TrainingStopRequested` no lugar de `StopIteration`.
19. **Circuit Breaker Resiliente** — `_CircuitBreaker` para APIs externas (HLTV) com MAX_FAILURES=10, RESET_WINDOW_S=3600, previne cascade failure com pattern CLOSED→OPEN→HALF_OPEN.
20. **Piramide de Validacao em 5 Niveis** — Headless Validator → pytest → Backend Validator → Goliath Hospital → Brain Verify: cada nivel progressivamente mais profundo, do quick smoke test (10s) ao audit completo de 118 regras.
21. **RASP Guard** — Runtime Application Self-Protection com manifesto SHA-256: verifica integridade do codigo fonte na inicializacao, previne manipulacoes acidentais e intencionais.
22. **Pre-commit Gate de 13 Hooks** — 4 hooks custom + 7 padroes + 2 Python impedem que codigo nao conforme chegue ao repositorio. Formatacao, validacao, dead code, integridade, merge conflict e private key verificados automaticamente.
23. **ResourceManager Hardware-Aware** — Throttling automatico CPU/RAM durante ingestao: o sistema desacelera autonomamente se os recursos de hardware estao sob pressao, sem intervencao humana.

24. **Test Forensics** — 10 scripts de investigacao post-mortem para diagnosticar training failure, weight anomalies, coaching path traces e DB consistency — a "caixa preta" do sistema.

PONTOS FORTES ARQUITETURAIS - OS 24 PILARES

1. Contrato unificado 25-dim - Todos falam a mesma lingua

2. Gate maturidade 3 niveis - Nenhum release prematuro

3. Fallback coaching 4 niveis - Nunca de maos vazias

4. Diversidade multi-modelo - 5 cerebros > 1 cerebro

5. Divisao temporal - Nenhum truque viagens no tempo

6. Loop feedback COPER - Aprende com seus proprios conselhos

7. Analise Fase 6 (10 mot.) - 10 detetives especializados

8. Persistencia limites - Sobrevive aos reinicios

9. Heuristicas configuraveis - Override via JSON

10. Refinamento LLM (Ollama) - Conselhos soam naturais

11. Observatorio Treinamento - Boletim para o cerebro

12. Consenso Neural Papeis - Dois professores comparam notas

13. Isolamento Per-Round - Avalia cada questao, nao apenas o teste

14. Arquitetura Quad-Daemon - GUI responsiva, trabalho pesado em background

15. Degradacao Gradual - O sistema nunca crasha

16. Three-Tier Storage - Nenhuma contencao entre escrita e leitura

17. Calibracao Bayesiana Live - Auto-calibra com os dados

18. Controle Live Training - Pausa/Stop sem perda

19. Circuit Breaker - Resiliencia APIs

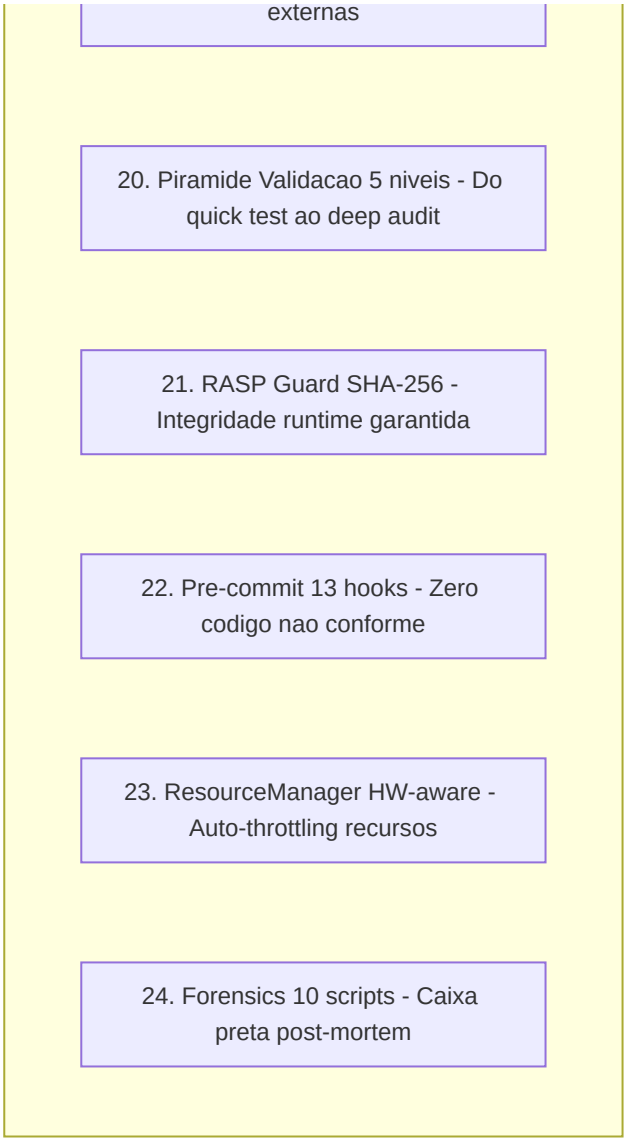

Fim do documento — Guia completo do Macena CS2 Analyzer

Total arquivos `.py` no projeto: **~406** (em `Programma_CS2_RENAN/`, ~~480 project-wide) Total linhas de codigo Python verificadas: **~~ 102.000+** Subsistemas AI cobertos: **8** (NN Core, VL-JEPA, RAP Coach, Servicos de Coaching, Motores de Coaching, Conhecimento, Analise, Processamento + Observatorio Treinamento) Subsistemas programa cobertos: **18** (Inicializacao, Lifecycle, Configuracao, Session Engine, UI Desktop, Ingestao, Storage, Observabilidade, Console de Controle, RASP Guard, HLTV Sync, Orquestrador Ingestao, ResourceManager, Tools Suite, Test Suite, Pre-commit, Build/Packaging, Migracoes Alembic) Modelos documentados: **6** (AdvancedCoachNN/TeacherRefinementNN, JEPA, VL-JEPA, RAPCoachModel, NeuralRoleHead, WinProbabilityNN) Motores de analise documentados: **10** (Papel, WinProb, GameTree, Crenca, Engano, Momentum, Entropia, Pontos Cegos, Utility e Economia, Distancia de Engajamento) Motores de coaching documentados: **7** (HybridEngine, CorrectionEngine, ExplainabilityGenerator, NNRefinement, ProBridge, TokenResolver, LongitudinalEngine) Servicos adicionais documentados: **7** (CoachingDialogue, LessonGenerator, LLMService, VisualizationService, ProfileService, AnalysisService, TelemetryClient) Tabelas do banco documentadas: **21** (distribuidas em arquitetura three-tier storage: `database.db`, `hltv_metadata.db`, `match_data/{id}.db`) Telas UI

documentadas: **14** (Wizard, Home, Coach, Tactical Viewer, Settings, Help, Match History, Match Detail, Performance, User Profile, Profile, Pro Comparison, Steam Config, FACEIT Config) — Qt/PySide6 (primario) + Kivy/KivyMD (legacy) Daemons documentados: **4** (Scanner, Digester, Teacher, Pulse) Ferramentas de validacao documentadas: **41** (Headless Validator, Brain Verify, Goliath Hospital, DB Inspector, Demo Inspector, ML Coach Debugger, Backend Validator, Dead Code Detector, Dev Health, Feature Audit, etc.) Arquivos de teste documentados: **94** (+ conftest.py, 10 forensics, 15 verification scripts) Fases headless validator: **23** (319 verificacoes automatizadas) Pre-commit hooks documentados: **13** (4 locais custom + 7 padrao + 2 Python) Pilares arquiteturais: **24** (incluidos Three-Tier Storage, Calibracao Bayesiana Live, Controle Live Training, Circuit Breaker, Piramide Validacao, RASP Guard, Pre-commit Gate, ResourceManager HW-aware, Forensics) Problemas resolvidos via remediacao: **368** (em 12 fases sistematicas) Fases de remediacao documentadas: **12** (com codigos G-XX e F-XX)

Mapa das Interconexoes entre as 3 Partes

As tres partes da documentacao formam um sistema interconectado. Este mapa mostra as principais dependencias entre as secoes:

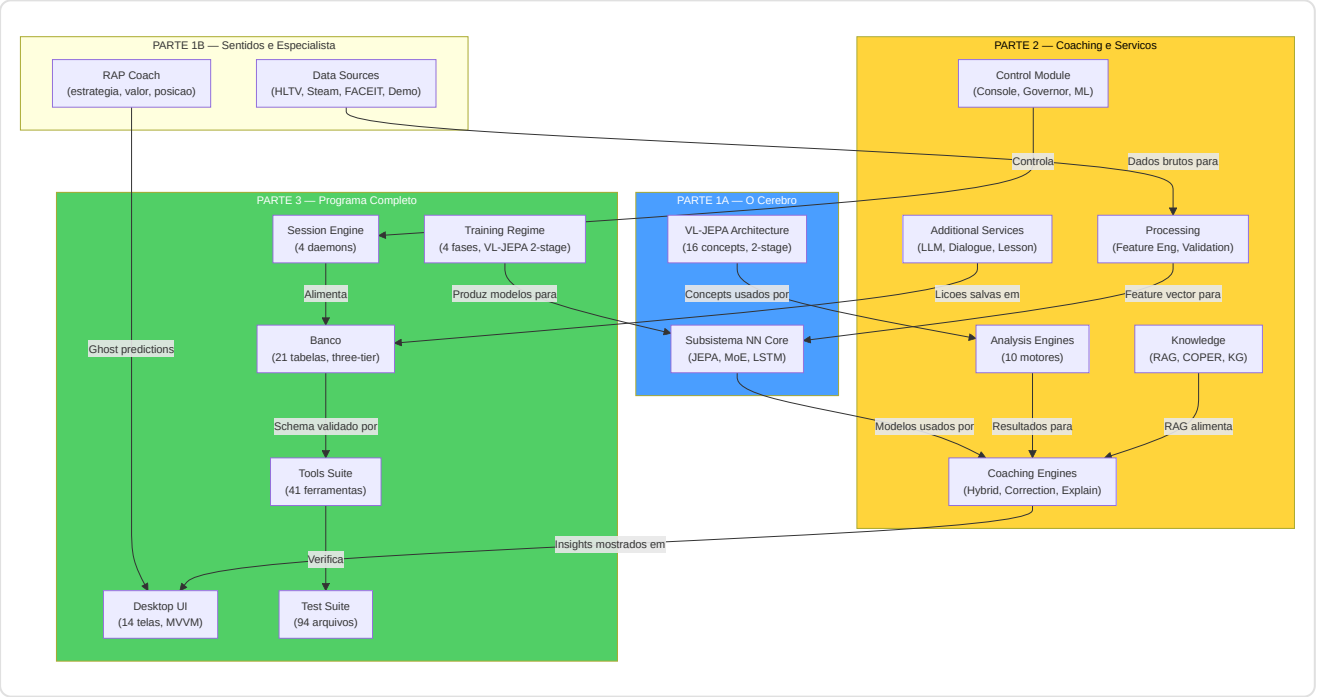

Referencias cruzadas chave:

De (Parte)	Para (Parte)	Ligacao
Parte 1 Secao VL-JEPA	Parte 3 Secao 10 (Training)	O protocolo two-stage descrito na Parte 1 e implementado pelo training regime na Parte 3
Parte 1 Secao Data Sources	Parte 3 Secao 12.6 (Ingestion)	As fontes de dados alimentam a pipeline de ingestao
Parte 2 Secao Coaching Engines	Parte 3 Secao 12.16 Fluxo 1	Os motores de coaching geram os insights mostrados na UI
Parte 2 Secao Control Module	Parte 3 Secao 12.4 (Session Engine)	O modulo de controle gerencia os 4 daemons
Parte 2 Secao Processing	Parte 1 Secao NN Core	O vectorizer produz o METADATA_DIM=25 consumido pelos modelos
Parte 3 Secao 9 (Banco)	Parte 2 Secao Knowledge	As tabelas RAG/COPER sao usadas pelo sistema de conhecimento
Parte 3 Secao 11 (Loss)	Parte 1 Secao VL-JEPA	As loss functions documentadas implementam o treinamento VL-JEPA
Parte 3 Secao 12.17 (Tools)	Parte 3 Secao 12.18 (Tests)	A piramide de validacao inclui tanto tools quanto test suite

Glossario Tecnico

Termo	Definicao
ADR	Average Damage per Round — dano medio causado por round
BCE	Binary Cross-Entropy — loss para classificacao binaria
COPER	Coaching through Past Experiences and References — coaching baseado em experiencias passadas
EMA	Exponential Moving Average — media movel exponencial usada para target encoder JEPA
HLTV 2.0	Sistema de rating do HLTV.org baseado em KPR, survival, impact, damage
InfoNCE	Noise Contrastive Estimation — loss contrastiva para alinhar representacoes
JEPA	Joint-Embedding Predictive Architecture — arquitetura que preve embeddings target de contexto
KAST	Kill/Assist/Survive/Trade — percentual de rounds com contribuicao positiva
KG	Knowledge Graph — grafo de conhecimento com entidades e relacoes
KPR	Kills Per Round — kills medios por round
LTC	Liquid Time-Constant — redes neurais com constantes temporais aprendidas
METADATA_DIM	Dimensao do feature vector unificado (25 no projeto)
MoE	Mixture of Experts — rede com especialistas especializados e gating
MVVM	Model-View-ViewModel — pattern arquitetural para separacao UI/logica
RAG	Retrieval-Augmented Generation — geracao enriquecida por retrieval
RAP	Reasoning Action Planning — modelo para coaching estrategico
RASP	Runtime Application Self-Protection — protecao runtime da aplicacao
TUI	Terminal User Interface — interface de usuario no terminal
VICReg	Variance-Invariance-Covariance Regularization — regularizacao para diversidade de embedding
VL-JEPA	Vision-Language JEPA — extensao com conceitos linguisticos
WAL	Write-Ahead Logging — modo SQLite para leituras/escritas concorrentes
Z-score	Numero de desvios-padrao da media — mede o quanto um valor esta longe da norma

---

Autor: Renan Augusto Macena